



**T.C.
BURSA TEKNİK ÜNİVERSİTESİ
LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ**

**FEDERE ÖĞRENME KULLANILARAK NESNELERİN İNTERNETİ (IoT)
VERİLERİ ANALİZİ**

YÜKSEK LİSANS TEZİ

Süleyman Burak ALTINIŞIK

Bilgisayar Mühendisliği Anabilim Dalı

Bilgisayar Mühendisliği Tezli Yüksek Lisans Programı

HAZİRAN 2025

**T.C.
BURSA TEKNİK ÜNİVERSİTESİ
LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ**

**FEDERE ÖĞRENME KULLANILARAK NESNELERİN İNTERNETİ (IoT)
VERİLERİ ANALİZİ**

YÜKSEK LİSANS TEZİ

Süleyman Burak ALTINIŞIK

(22435004017)

ORCID: 0009-0005-0987-1798

**Bilgisayar Mühendisliği Anabilim Dalı
Bilgisayar Mühendisliği Tezli Yüksek Lisans Programı**

Danışman: Prof. Dr. Turgay Tugay BİLGİN

ORCID: 0000-0002-9245-5728

HAZİRAN 2025

BTÜ, Lisansüstü Eğitim Enstitüsü'nün 22435004017 numaralı Yüksek Lisans Öğrencisi Süleyman Burak ALTINIŞIK, ilgili yönetmeliklerin belirlediği gerekli tüm şartları yerine getirdikten sonra hazırladığı “FEDERE ÖĞRENME KULLANILARAK NESNELERİN İNTERNETİ (IoT) VERİLERİ ANALİZİ” başlıklı tezini aşağıda imzaları olan jüri önünde başarı ile sunmuştur.

Tez Danışmanı : **Prof. Dr. Turgay Tugay BİLGİN**
Bursa Teknik Üniversitesi

Jüri Üyeleri : **Doç. Dr. Üyesi Ergün GÜMÜŞ**
Bursa Teknik Üniversitesi

Prof. Dr. Ahmet Emir DİRİK
Bursa Uludağ Üniversitesi

Teslim Tarihi :
Savunma Tarihi : 02/07/2025



20.04.2016 tarihli Resmi Gazete’de yayımlanan Lisansüstü Eğitim ve Öğretim Yönetmeliğinin 9/2 ve 22/2 maddeleri gereğince; Bu Lisansüstü teze, Bursa Teknik Üniversitesi’nin abonesi olduğu intihal yazılım programı kullanılarak Lisansüstü Eğitim Enstitüsü’nün belirlemiş olduğu ölçütlere uygun rapor alınmıştır.

İNTİHAL BEYANI

Bu tezde görsel, işitsel ve yazılı biçimde sunulan tüm bilgi ve sonuçların akademik ve etik kurallara uyularak tarafımdan elde edildiğini, tez içinde yer alan ancak bu çalışmaya özgü olmayan tüm sonuç ve bilgileri tezde kaynak göstererek belgelediğimi, aksinin ortaya çıkması durumunda her türlü yasal sonucu kabul ettiğimi beyan ederim.

Öğrencinin Adı Soyadı: Süleyman Burak
ALTINIŞIK

İmzası:



Eşime ve çocuklarıma,

ÖNSÖZ

Bu tez çalışması sürecinde hiçbir desteğini esirgemeyen ve bilim insanı olma yolundaki ilk adımlarımı atarken kıymetli bilgi ve tecrübesiyle yolumu aydınlatan danışman hocam Sayın Prof. Dr. Turgay Tugay BİLGİN 'e teşekkürü borç bilirim. Bana her koşulda destek olan, sabrıyla ve sevgisiyle yanımda duran sevgili eşime; varlıklarıyla bana güç veren canım anneme, babama ve kardeşlerime en içten teşekkürlerimi sunuyorum. Bu süreçte bilgi birikimimi derinleştirmemde katkısı olan ve bana yol gösteren değerli iş arkadaşlarıma da ayrıca minnettarım. Her birinin desteği, bu çalışmanın tamamlanmasında çok kıymetli bir yere sahiptir.

Bu tez çalışmasını, hayatımın anlamı olan aileme ve özellikle sevgili oğlum Eymen'e armağan ediyorum. Varlığın, bu satırların ardında yatan en büyük ilham kaynağıdır.

Temmuz 2025

Süleyman Burak
ALTINIŞIK
(Veri Analisti ve
Raporlama Uzmanı)

İÇİNDEKİLER

Sayfa

ÖNSÖZ.....	vii
İÇİNDEKİLER.....	viii
KISALTMALAR.....	x
SEMBOLLER.....	xii
ÇİZELGE LİSTESİ.....	xiii
ŞEKİL LİSTESİ.....	xiv
ÖZET.....	xvi
SUMMARY.....	xviii
1. GİRİŞ	20
1.1 Problem Tanımı ve Motivasyon.....	21
1.2 Tezin Amacı ve Hedefleri.....	22
1.3 Tezin Kapsamı ve Kısıtları	24
1.4 Tezin Özgün Katkıları	25
1.5 Tezin Organizasyonu.....	27
2. LİTERATÜR TARAMASI.....	29
2.1 Federe Öğrenme'nin Gelişimi ve Teorik Temelleri	29
2.2 Federe Öğrenme Mimarileri	32
2.2.1 Yatay federe öğrenme	33
2.2.2 Dikey federe öğrenme	35
2.2.3 Hibrit federe öğrenme	37
2.3 Endüstriyel Sistemlerde Federe Öğrenme Uygulamaları	39
2.3.1 Kestirimci bakım uygulamaları	42
2.3.2 Kalite kontrol sistemleri	45
2.3.3 Mevcut zorluklar ve çözüm önerileri	48
2.4 Veri Güvenliği ve Gizlilik	50
2.4.1 Diferansiyel mahremiyet	51
3. KAVRAMSAL ÇERÇEVE	54
3.1 Federe Öğrenme'nin Matematiksel Temelleri	55
3.1.1 Dağıtık optimizasyon	57
3.1.2 Model agregasyon stratejileri	60
3.2 Endüstriyel Veri Analizi	63
3.2.1 OPC protokolü ve veri yapıları.....	64
3.2.2 Zaman serisi analizi	66
3.2.3 Anomali tespiti	70
4. METODOLOJİ.....	73
4.1 Araştırma Tasarımı.....	76
4.1.1 Sistem mimarisi	79
4.1.2 Veri toplama ve ön işleme.....	82
4.1.3 Model seçimi ve validasyon stratejisi	85
4.2 Federe Öğrenme Implementasyonu.....	89

4.2.1 Haberleşme protokolleri.....	90
4.2.2 Model güncelleme mekanizması	91
4.3 Veri Güvenliği Önlemleri	95
4.3.1 Şifreleme mekanizmaları.....	100
4.3.2 Gizlilik koruma protokolleri.....	103
4.4 Performans Metrikleri ve Değerlendirme Kriterleri.....	107
5. UYGULAMA VE DENEYSEL SONUÇLAR.....	113
5.1 Deney Ortamı ve Veri Seti Özellikleri	113
5.2 Model Eğitimi ve Optimizasyon	119
5.2.1 Hiperparametre ayarlamaları	122
5.3 Performans Değerlendirmesi.....	128
5.3.1 Model doğruluğu ve güvenilirlik	133
5.3.2 Hesaplama verimliliği	138
5.3.3 İletişim maliyeti.....	141
5.4 Karşılaştırmalı Analizler.....	144
6. TARTIŞMA.....	150
6.1 Bulguların Değerlendirilmesi.....	151
6.2 Kısıtlar ve Zorluklar	152
6.3 Gelecek Çalışma Önerileri.....	153
7. SONUÇ	156
7.1 Araştırma Bulgularının Özeti.....	156
7.2 Teorik ve Pratik Katkıları	157
7.3 Endüstriyel Uygulamalar için Öneriler.....	158
KAYNAKLAR.....	162
ÖZGEÇMİŞ	171

KISALTMALAR

Adam	: Optimizasyon Algoritması – Adaptive Moment Estimation
AES	: Gelişmiş Şifreleme Standardı - Advanced Encryption Standart
AI	: Yapay Zeka - Artifical Intelligence
CBC	: Şifreleme Blok Zinciri – Cipher Block Chaining
CCM	: CBC Sayaç Modu - CBC Counter Mode
CNN	: Katmanlı Sinir Ağı - Convolutional Neural Network
CPU	: Merkezi İşlem Birimi - Central Process Unit
CSV	: Virgülle Ayrılmış Değerler - Comma Seperated Values
GDPR	: Genel Veri Koruma Tüzüğü - General Data Protection Regulation
DP	: Farklılaştırılmış Gizlilik - Differential Privacy
DTLS	: Datagram Taşıma Katmanı Güvenliği - Datagram Transport Layer Security
ERP	: Kurumsal Kaynak Planlaması - Enterprise Resource Planning
FCNN	: Tam Bağlantılı Sinir Ağı - Fully Connected Neural Network
FedAvg	: Federe Ortalama Alma Algoritması - Federated Averaging
FedOpt	: Federe Optimizasyon - Federated Optimisation
FedProx	: Heterojen Ağlarda Federe Optimizasyon - Federated Optimization in Heterogeneous Networks
FL	: Federe Öğrenme - Federated Learning
FN	: Yanlış Negatif - False Negative
FP	: Yanlış Pozitif - False Positive
FPGA	: Alanda Programlanabilir Kapı Dizileri - Field Programmable Gate Array
GCM	: Galois/Sayaç Şifreleme Modu – Galois/Counter Mode
GPU	: Grafik İşlem Birimi - Graphics Processing Unit
gRPC	: Uzaktan Prosedür Çağrılar - Remote Procedure Calls
GRU	: Gated Recurrent Unit – Kapılı Tekrarlayan Birim
HFL	: Yatay Federe Öğrenme - Horizontal Federated Learning
HIPAA	: Sağlık Sigortası Taşınabilirliği ve Sorumluluk Yasası - Health Insurance Portability and Accountability Act
HMI	: İnsan Makine Arayüzü - Human Machine Interface
HTTP	: Hiper Metin Aktarım Protokolü - Hyper Text Transfer Protocol
IIoT	: Endüstriyel Nesnelerin İnterneti - Industrial Internet of Things
IoT	: Nesnelerin İnterneti - Internet of Things
JSON	: JavaScript Nesne Gösterimi - JavaScript Object Notation
KB	: Kilobayt - Kilobyte
LSTM	: Uzun Kısa Süreli Bellek - Long Short-Term Memort
M2M	: Makineden makineye - Machine to Machine

MAE	: Ortalama Mutlak Hata - Mean Absolute Error
MAPE	: Ortalama Mutlak Yüzde Hatası - Mean Absolute Percentage Error
MES	: Üretim Yürütme Sistemi - Manufacturing Execution System
MSSQL	: Microsoft Server Yapılandırılmış Sorgu Dili - Microsoft Server Structured Query Language
OAEP	: Optimum Asimetrik Şifreleme Dolgusu - Optimal Asymmetric Encryption Padding
OLE	: Nesne Bağlama ve Gömme - Object Linking and Embedding
OPC	: Süreç Kontrolü için Nesne Bağlantısı - OLE for Process Control
OPC UA	: OPC Birleşik Mimarisi - OPC Unified Architecture
RAM	: Rastgele Erişimli Bellek – Random Access Memory
ReLU	: Doğrultulmuş Doğrusal Birim - Rectified Linear Unit
RMSE	: Kök Ortalama Kare Hata - Root Mean Squared Error
RNN	: Tekrarlayan Sinir Ağı - Recurrent Neural Network
RSA	: Şifreleme Algoritması - Rivest-Shamir-Adleman
SA	: Güvenli Birleştirme – Secure Aggregation
SGD	: Stokastik Gradyan İnişi - Stochastic Gradient Descent
Sn	: Saniye - Second
TFL	: Hibrit Federe Öğrenme - Transfer Federated Learning
TLS	: Taşıma Katmanı Güvenliği - Transfer Layer Security
TN	: Gerçek Negatif - True Negative
TP	: Gerçek Pozitif - True Positive
VFL	: Dikey Federe Öğrenme - Vertical Federated Learning
VRAM	: Video Rastgele Erişimli Bellek – Video Random Access Memory
XGBoost	: Aşırı Derecede Güçlendirilmiş Gradyan Artırımı - Extreme Gradient Boosting

SEMBOLLER

w	: Ağırlık
t	: Eğitim turu
k	: İstemci indexi
K	: Toplam istemci sayısı
p	: Ağırlıklandırma katsayısı
n	: Toplam veri örneği sayısı
F	: Kayıp fonksiyonu
∇	: Gradyan operatörü
ϵ	: Pozitif sabit
N	: Gaussian dağılımı simgesi
B	: Sabit yada katsayı
σ	: Sigma
μ	: Ortalama
δ	: Delta

ÇİZELGE LİSTESİ

Sayfa

Çizelge 3.1: FL agregasyon yöntemleri karşılaştırması.	62
Çizelge 3.2: Endüstriyel veri analizinde karşılaşılan zorluklar ve çözüm önerileri. ..	64
Çizelge 3.3: OPC UA'nın temel bileşenleri ve açıklamaları.	66
Çizelge 3.4: Zaman serisi yöntemleri, uygulama alanları ve avantajları.	70
Çizelge 3.5: Anomali tespit yöntemleri karşılaştırması.	71
Çizelge 4.1: OPC tabanlı veri toplama özellikleri.	74
Çizelge 4.2: Kullanılan python kütüphaneleri ve fonksiyonları.	80
Çizelge 4.3: Veri ön işleme aşamaları ve kullanılan teknikler.	84
Çizelge 4.4: Hiperparametre ayarları ve açıklamaları.	88
Çizelge 4.5: FCNN, CNN ve LSTM modelleri iletişim maliyetleri analizi	88
Çizelge 4.6: FL round akışı.	90
Çizelge 4.7: FL iletişim katmanları ve görevleri.	91
Çizelge 4.8: FL model güncelleme yöntemleri ve avantajları.	94
Çizelge 4.9: Kullanılan güvenlik protokolleri ve rolleri.	99
Çizelge 4.10: AES ve TLS özelliklerinin karşılaştırılması.	103
Çizelge 4.11: Gizlilik koruma yöntemlerinin avantaj ve sınırlılıkları.	107
Çizelge 4.12: Asenkron ve senkron mimarilerin performans analizi	109
Çizelge 4.13: Performans metrikleri ve FL sistemine katkıları.	110
Çizelge 4.14: Performans göstergeleri özeti.	111
Çizelge 5.1: Donanım ve yazılım konfigürasyon özeti.	114
Çizelge 5.2: Örnek veri seti yapısı.	115
Çizelge 5.3: FCNN ve diğer modellerin karşılaştırılması	117
Çizelge 5.4: FCNN katman özellikleri.	119
Çizelge 5.5: Hiperparametre özeti ve sistem üzerindeki etkileri.	128
Çizelge 5.6: Karmaşıklık Matrisi.	129
Çizelge 5.7: Farklı koşullarda yürütülen deney sonuçlarının performans metrikleri.	130
Çizelge 5.8: İkili sınıflandır: TP, TN, FP, FN açıklamaları.	132
Çizelge 5.9: Model güvenilirliğini artıran yaklaşımlar.	137
Çizelge 5.10: İstemci sayısına göre performans değerlendirmesi.	139
Çizelge 5.11: İletişim maliyetini etkileyen faktörler.	143
Çizelge 5.12: İki farklı senaryoda iletişim maliyeti analizi	144
Çizelge 5.13: Farklı FL mimarilerinin doğruluk, F1 score, stabilite ve iletişim maliyeti karşılaştırılması.	145
Çizelge 5.14: FedAvg nin diğer algoritmalar ile karşılaştırılması	146
Çizelge 5.15: FL yöntemlerinin doğruluk, F1 skor ve iletişim maliyeti karşılaştırması.	146
Çizelge 5.16: Epsilon değerine göre performans metrikleri ve gürültü seviyesinde ki değişimler.	147
Çizelge 5.17: İki farklı toplu işlem boyutu ayarı sonucunda yapılan deney sonuçları.	148
Çizelge 5.18: Üç farklı agregasyon sıklığı değeri altında ki deney sonuçları.	148
Çizelge 6.1: FL sisteminin tur süresi analizi.	152
Çizelge 6.2: FL sisteminin daha etkin kullanılabilmesi için öneri.	155
Çizelge 7.1: FL' nin endüstri üzerindeki rolü.	159

ŞEKİL LİSTESİ

Sayfa

Şekil 2.1: Yatay federe öğrenme örneği.	33
Şekil 2.2: Dikey federe öğrenme örneği.	35
Şekil 2.3: Hibrit federe öğrenme örneği.	37
Şekil 2.4: OPC ve FL entegrasyonu akış diyagramı.	41
Şekil 2.5: Federe Öğrenme ve geleneksel model karşılaştırması.	42
Şekil 2.6: FL ile entegre edilmiş kestirimci bakım süreci.	44
Şekil 2.7: FL ile Kestirimci Bakım Kazanımları.	45
Şekil 2.8: FL ile kalite kontrol süreci akış diyagramı.	47
Şekil 2.9: FL ile Kalite Kontrol Performans Göstergeleri.	47
Şekil 2.10: FL'de zorluklar ve çözüm yolları akış diyagramı.	49
Şekil 2.11: Teknik çözümlerin FL üzerindeki etkisi.	49
Şekil 2.12: FL ile güvenli ve gizli veri işleme akışı.	51
Şekil 2.13: FL güvenlik yöntemlerinin karşılaştırması.	51
Şekil 2.14: Diferansiyel mahremiyet ile FL süreci.	53
Şekil 2.15: Diferansiyel Mahremiyetin Etkileri.	53
Şekil 3.1: Global ve Yerel Kayıp Fonksiyonları Eğrileri.	57
Şekil 3.2: Zaman serisi verisinin bileşenleri.	68
Şekil 3.3: Zaman serisi tahmin yöntemlerinin MAPE karşılaştırması.	69
Şekil 4.1: FL sistem mimarisi.	74
Şekil 4.2: Diferansiyel gizlilikle ağırlık paylaşımı.	75
Şekil 4.3: FL senaryosunda erken durdurma geri çağırma kullanımı.	75
Şekil 4.4: Model performans metrikleri.	76
Şekil 4.5: OPC – FL veri akış diyagramı.	78
Şekil 4.6: Diferansiyel gizlilik ile gürültü ekleme.	79
Şekil 4.7: FL Performans Optimizasyonu – İletişim ve Doğruluk.	79
Şekil 4.8: Sistem mimarisi iş akış şeması.	80
Şekil 4.9: İstemci tarafından diferansiyel gizlilikle ağırlık gönderimi.	81
Şekil 4.10: Sunucu tarafından FedAvg algoritması çalışması.	81
Şekil 4.11: Sistem mimarisinin blok diyagramı.	82
Şekil 4.12: OPC tabanlı veri toplama akışı.	84
Şekil 4.13: FL sistem mimarisi (TLS ve güvenli iletişim).	90
Şekil 4.14: FL istemci-sunucu haberleşme mimarisi.	91
Şekil 4.15: FedAvg model güncelleme süreci.	94
Şekil 4.16: FedAvg yaklaşımında yerel modelin hedef değişkenlerinin belirlenmesi.	95
Şekil 4.17: Güvenlik katmanları.	96
Şekil 4.18: İstemci tarafında güvenli eğitim.	97
Şekil 4.19: Sunucu tarafında güvenli toplama.	97
Şekil 4.20: FL güvenlik mimarisi (katmanlı koruma yapısı).	99
Şekil 4.21: Diferansiyel gizlilik + AES ile güvenli ağırlık gönderimi.	99
Şekil 4.22: Güvenli Toplama Fonksiyonu (Sunucu Tarafı).	100
Şekil 4.23: Model parametrelerinin AES ile şifrelenerek gönderime hazırlanması.	101
Şekil 4.24: TLS protokolü ile şifreli veri aktarımı.	101
Şekil 4.25: Şifreleme katmanları ve veri akışı.	102
Şekil 4.26: Diferansiyel gizlilik süreci.	104
Şekil 4.27: Laplace mekanizması ile diferansiyel gizlilik uygulaması.	104

Şekil 4.28: SA akış diyagramı.....	105
Şekil 4.29: RSA ve OAEP ile asimetrik şifreleme kullanımı.	105
Şekil 4.30: Epsilon değerine göre gizlilik/doğruluk eğrisi.	106
Şekil 4.31: Diferansiyel gizlilik süreci.	106
Şekil 4.32: SA yapısı.	106
Şekil 4.33: İletişim maliyetini azaltan yapı.	108
Şekil 4.34: İstemci sayısına göre doğruluk ve gecikme.	109
Şekil 4.35: İstemci sayısına göre doğruluk ve iletişim süresi.	112
Şekil 5.1: Zaman serisinde $\pm 5\%$ sapma gösterimi.	115
Şekil 5.2: Yapay sinir ağı modelinin oluşturulması.	119
Şekil 5.3: Kullanılan FCNN model mimarisi.	119
Şekil 5.4: Model eğitimi, değerlendirme ve ağırlık gönderimi süreci.	120
Şekil 5.5: Gürültü ekleme fonksiyonu.	120
Şekil 5.6: Sunucu tarafında FedAvg ağırlık toplama ve yayma işlemi.	121
Şekil 5.7: Gürültü eklenmiş ağırlıkların sunucuya gönderimi.	122
Şekil 5.8: Model eğitimi ve FL süreci.	122
Şekil 5.9: Erken durdurma kullanımı.	124
Şekil 5.10: Sunucuya gönderilmeden önce fonksiyon parametreleri.	125
Şekil 5.11: Epsilon değerine göre model doğruluğu.	127
Şekil 5.12: Agregasyon sıklığı etkileri.	127
Şekil 5.13: Tahminleme sonuçları sonrasında confusion matrix çıktısını veren kod.	130
Şekil 5.14: Doğruluk değerinin model parametrelerine göre değişimi.	131
Şekil 5.15: Deney koşullarına göre F1 skoru ($\pm$ standart sapma).	132
Şekil 5.16: Sınıflandırma metrikleri hesaplama fonksiyonu.	133
Şekil 5.17: Performans metriklerini hesaplayarak kaydeden kod.	134
Şekil 5.18: Doğruluk değeri model parametrelerine göre kutu grafiği gösterimi. ...	135
Şekil 5.19: F1 Skor model parametrelerine göre değişimi.	135
Şekil 5.20: Model Değerlendirme Metrikleri.	136
Şekil 5.21: Model iletişim maliyeti hesabı.	137
Şekil 5.22: Diferansiyel gizlilik: Laplace gürültü ekleme.	138
Şekil 5.23: İstemci sayısına doğruluk ve iletişim maliyeti.	140
Şekil 5.24: İstemci sayısına göre eğitim süresi ve toplam iletişim maliyeti.	140
Şekil 5.25: Senkron ve asenkron güncelleme yapıları.	141
Şekil 5.26: İletişim maliyeti hesaplayan fonksiyon.	141
Şekil 5.27: Agregasyon sıklığı'na göre iletişim maliyeti.	142
Şekil 5.28: Farklı FL mimarilerinin F1 score karşılaştırması.	145
Şekil 5.29: FedAvg ve FedProx karşılaştırması ($\pm$ Std).	149

FEDERE ÖĞRENME KULLANILARAK NESNELERİN İNTERNETİ (IoT) VERİLERİ ANALİZİ

ÖZET

Endüstri 4.0 ve dijital dönüşüm süreçlerinin etkisiyle birlikte, üretim sektöründe veri temelli karar alma mekanizmalarına olan ihtiyaç önemli ölçüde artmıştır. Özellikle üretim hatlarında meydana gelen arızaların önceden tahmin edilmesi, kalite sapmalarının zamanında tespit edilerek müdahale edilmesi ve süreç verimliliğinin artırılması, modern endüstriyel sistemlerin en temel hedefleri arasında yer almaktadır. Bu bağlamda, büyük veri analitiği ve yapay zekâ tabanlı karar destek sistemleri, üretim süreçlerinin daha öngörülebilir ve esnek hale gelmesine önemli katkılar sunmaktadır. Ancak bu teknolojik kazanımlar, aynı zamanda veri güvenliği, gizlilik ve yasal düzenlemelere uyum gibi çeşitli kısıtlamaları da beraberinde getirmektedir. Geleneksel makine öğrenimi yaklaşımları, büyük veri kümelerinin merkezi sunucularda toplanarak işlenmesini gerektirirken, bu yöntemler özellikle hassas verilerin işlendiği üretim ortamlarında güvenlik risklerini artırmakta, iletişim maliyetlerini yükseltmekte ve hesaplama yükünü yoğunlaştırmaktadır. Bu sorunlara çözüm olarak ortaya çıkan FL (Federe Öğrenme), merkezi veri aktarımına ihtiyaç duymadan, verilerin yerel cihazlar üzerinde işlenmesini sağlayan dağıtık bir öğrenme yaklaşımı sunmaktadır. Bu tez çalışmasında, üretim hatlarında OPC (Süreç Kontrolü için Nesne Bağlantısı) protokolü kullanılarak toplanan sensör verilerinin FL mimarisi ile analiz edilmesi hedeflenmiştir. Önerilen sistemde, istemcilerden elde edilen sıcaklık, basınç ve hız gibi üretim parametrelerine ait veriler, merkezi sunucuya iletilmeden istemci tarafında işlenmiş; her istemcide eğitilen yerel modellerin parametreleri merkezi bir sunucuda birleştirilerek küresel model oluşturulmuştur. Bu süreçte veri gizliliğini artırmak amacıyla diferansiyel gizlilik ve güvenli model toplama protokolleri sisteme entegre edilmiştir. Ayrıca iletişim maliyetlerini azaltmak adına gradyan sıkıştırma ve seyrek güncelleme gibi optimizasyon teknikleri kullanılmıştır. Modelin başarımı; doğruluk, hassasiyet, hatırlama ve F1 skoru gibi klasik sınıflandırma metriklerinin yanı sıra, sistem gecikmesi, ağ trafiği, hesaplama verimliliği ve veri heterojenliğine karşı genelleştirme kabiliyeti gibi kriterler üzerinden de değerlendirilmiştir. Uygulama sonuçları, FL mimarisinin küçük ve büyük ölçekli istemci senaryolarında dahi tutarlı ve güvenilir performans gösterdiğini ortaya koymuştur. Asenkron haberleşme yapısı sayesinde düşük donanımlı istemcilerde bile başarılı model eğitimi gerçekleştirilmiştir. Ayrıca, sistemin veri ön işleme bileşeninde; eksik veri tamamlama, zaman damgası senkronizasyonu, anomali tespiti gibi gelişmiş teknikler kullanılmış ve bu sayede sensör verilerinin modellemeye uygun hale getirilmesi sağlanmıştır. Geliştirilen yapı, üretim süreçlerinin çeşitliliğine uyum sağlayabilecek esnek bir mimari sunmakta, aynı zamanda gerçek zamanlı ve güvenli analiz altyapısı oluşturmaktadır. Dolayısıyla, bu tez çalışması FL mimarisinin üretim sektörüne entegrasyonunu ele alarak, veri gizliliğini ihlal etmeden, dağıtık yapay zekâ çözümlerinin nasıl uygulanabileceğini detaylı bir şekilde ortaya koymuştur. Geliştirilen sistem, merkezi veri toplamaya gerek duymadan, çok lokasyonlu üretim

ortamlarında çalışabilecek, ölçeklenebilir, güvenli ve yüksek performanslı bir analiz platformu sunmaktadır. Bu yönüyle FL, yalnızca akademik düzeyde değil, sanayi uygulamaları açısından da geleceğin dijital dönüşüm bileşenlerinden biri olmaya adaydır. İlerleyen çalışmalarda sistemin daha büyük veri kümeleriyle ve gerçek saha koşulları altında test edilmesi, uygulama kapsamını daha da genişletecektir.

Anahtar kelimeler: Federe öğrenme, Veri gizliliği, OPC protokolü, Kestirimci bakım, Kalite kontrol, Diferansiyel gizlilik



ANALYSIS OF INTERNET OF THINGS (IoT) DATA USING FEDERATED LEARNING

SUMMARY

With the impact of Industry 4.0 and digital transformation processes, the need for data-driven decision-making mechanisms in the manufacturing sector has significantly increased. Anticipating equipment failures on production lines, detecting quality deviations in a timely manner, and enhancing process efficiency have become fundamental objectives of modern industrial systems. In this context, big data analytics and AI (artificial intelligence)-based decision support systems contribute substantially to making production processes more predictable and adaptive. However, these technological advancements also bring forth challenges such as data security, privacy concerns, and compliance with regulatory frameworks. Traditional machine learning approaches typically require the aggregation of large datasets on centralized servers, which poses considerable security risks, increases communication overhead, and imposes heavy computational burdens—especially in environments dealing with sensitive data. As a solution to these limitations, FL (Federated Learning) has emerged as a decentralized learning paradigm that allows model training on local devices without transferring raw data to a central location. This thesis investigates the application of FL in analyzing sensor data collected through the OPC (OLE (Object Linking and Embedding) for Process Control) protocol on production lines. In the proposed system, parameters such as temperature, pressure, and speed are processed locally at the client side without being transmitted to a central server. Instead, only the parameters of locally trained models are aggregated on a central server to construct a global model. To enhance data privacy, the architecture integrates differential privacy techniques and secure model aggregation protocols. Furthermore, optimization techniques such as gradient compression and sparse updates are implemented to reduce communication costs. The model's performance is evaluated using conventional classification metrics such as accuracy, precision, recall, and F1-score, as well as system-level metrics including latency, network traffic, computational efficiency, and generalizability under data heterogeneity. Experimental results demonstrate that the proposed FL framework delivers consistent and reliable performance across both small- and large-scale client scenarios. Moreover, the asynchronous communication structure enables successful model training even on low-resource client devices. In addition, the system's data preprocessing module employs advanced techniques including missing data imputation, timestamp synchronization, and anomaly detection to ensure that sensor data is properly prepared for modeling. The developed architecture offers a flexible structure adaptable to various production processes and provides a secure, real-time analytics infrastructure. In conclusion, this thesis presents a comprehensive implementation of Federated Learning in the manufacturing domain, illustrating how distributed AI solutions can be applied without violating data privacy. The proposed system enables scalable, secure, and high-performance analytics in

multi-location industrial environments without relying on centralized data collection. These findings highlight the potential of FL not only as an academic concept but also as a critical component of future digital transformation initiatives in the industry. Future studies will aim to extend the system's applicability through testing with larger datasets and real-world industrial conditions.

Keywords: Federated learning, Data privacy, OPC protocol, Predictive maintenance, Quality control, Differential privacy



1. GİRİŞ

Sanayi ve üretim sistemleri, veriye dayalı analizler ve yapay zeka teknolojilerinin gelişmesiyle birlikte büyük bir dönüşüm geçirmektedir. Endüstri 4.0 ve Endüstri 5.0 vizyonları doğrultusunda akıllı üretim sistemleri, operasyonel verimliliği artırmak, maliyetleri düşürmek ve karar alma süreçlerini daha hızlı hale getirmek için makine öğrenimi ve büyük veri analitiğinden faydalanmaktadır. Üretim hatlarında meydana gelebilecek arızaların önceden tespit edilmesi ve kalite süreçlerinin optimize edilmesi, işletmeler için rekabet avantajı sağlayan kritik unsurlar arasında yer almaktadır. Kestirimci bakım ve kestirimci kalite yönetimi, bu dönüşüm sürecinin temel taşlarından biri olarak ortaya çıkmakta ve fabrikaların sürekli ve kesintisiz çalışmasını sağlamak için en yaygın kullanılan veri odaklı yaklaşımlar arasında bulunmaktadır. Geleneksel kestirimci bakım sistemleri, üretim makinelerinden ve sensörlerden elde edilen verilerin merkezi bir sunucuya aktarılması ve burada analiz edilerek gerekli bakım faaliyetlerinin planlanması esasına dayanmaktadır. Ancak, bu merkezi yapı bazı önemli sınırlamalara sahiptir. Öncelikle, büyük ölçekli üretim tesislerinde toplanan verilerin yüksek hacmi, veri işleme sürecini hem zaman alıcı hem de maliyetli hale getirmektedir. Bunun yanı sıra, tüm verilerin merkezi bir sistemde toplanması güvenlik risklerini artırmakta ve üretim verilerinin yetkisiz kişiler tarafından ele geçirilme ihtimalini doğurmaktadır. Ayrıca, farklı üretim hatlarından gelen heterojen veri kümelerinin merkezi bir yapıda anlamlandırılması ve analiz edilmesi, model doğruluğunu olumsuz yönde etkileyebilir. Merkezi öğrenme modelleri, genellikle her sistemde genelleştirilmiş çözümler sunmakta ve bu durum, her üretim hattına özel çözümler gerektiren özelleşmiş kestirimci bakım sistemlerinin etkisini sınırlamaktadır. Bu noktada, FL yöntemi, merkezi veri işleme ihtiyacını ortadan kaldırarak kestirimci bakım ve kalite yönetimi uygulamalarında yeni bir yaklaşım sunmaktadır. FL, makine öğrenimi modellerinin eğitimi sırasında verileri merkezi bir sunucuya taşımak yerine, yerel makinelerde işlemesine olanak tanımaktadır. Böylece, işletmeler hem veri gizliliğini sağlayabilir hem de modelin üretim sistemlerine özgü daha doğru tahminler yapmasını mümkün kılabilir. FL ayrıca, büyük veri kümelerinin merkezi bir sistemde

depolanmasını gerektirmediği için, veri iletim maliyetlerini ve işlem sürelerini azaltmaktadır. Bunun yanı sıra, üretim hatlarının farklı noktalarında bulunan sensörler ve makineler üzerinden öğrenmeyi mümkün kılarak, dağıtık bir yapay zeka sisteminin kurulmasına olanak tanımaktadır. Bu tez çalışmasında, FL'nin kestirimci bakım ve kalite yönetimi süreçlerine entegrasyonu ele alınmaktadır. Çalışmanın temel amacı, geleneksel merkezi makine öğrenimi yöntemleri ile FL tabanlı çözümleri karşılaştırmak ve FL'in üretim süreçlerine sunduğu avantajları ortaya koymaktır. Çalışmada, FL'in veri gizliliği ve işlem verimliliği üzerindeki etkileri detaylı bir şekilde incelenerek, üretim sistemlerinde bu yeni teknolojinin uygulanabilirliği değerlendirilecektir. FL tabanlı yaklaşımlar, üretim süreçlerinde kesintisiz çalışma sürelerini artırma, bakım maliyetlerini düşürme ve kalite yönetimini iyileştirme gibi önemli faydalar sunmaktadır. Bu bağlamda, FL'in geleneksel yöntemlere kıyasla nasıl daha ölçeklenebilir, güvenli ve verimli çözümler sunduğu bu tezde kapsamlı bir şekilde ele alınacaktır. Çalışmada ayrıca, FL modellerinin eğitim sürecinde farklı üretim ortamlarında karşılaşılabilecek potansiyel zorluklar da ele alınarak, bu sistemlerin gerçek dünya uygulamalarındaki etkinliği değerlendirilecektir. FL'in endüstriyel üretim süreçlerine nasıl entegre edilebileceği, geleneksel merkezi yaklaşımlarla karşılaştırıldığında hangi durumlarda daha avantajlı olduğu ve bu yeni yöntemin gelecekte üretim sektörüne nasıl yön verebileceği bu tez kapsamında ele alınan temel sorular arasında yer almaktadır.

1.1 Problem Tanımı ve Motivasyon

Sanayinin gelişmesiyle birlikte üretim süreçleri, daha verimli, güvenli ve sürdürülebilir hale gelmek amacıyla dijital dönüşüm ve veri analitiği odaklı yaklaşımlar benimsenmektedir. Günümüzde fabrikalar, üretim hatlarındaki olası arızaları önceden tespit ederek plansız duruşları azaltmayı, bakım maliyetlerini düşürmeyi ve üretim sürekliliğini sağlamayı hedeflemektedir. Aynı şekilde, kalite kontrol süreçlerinde üretim aşamasında meydana gelebilecek sapmaların önceden tahmin edilerek düzeltilmesi, hem maliyetlerin minimize edilmesine hem de müşteri memnuniyetinin artırılmasına katkı sağlamaktadır. Kestirimci bakım ve kestirimci kalite yönetimi olarak adlandırılan bu yaklaşımlar, üretim hatlarından sensörler ve makineler aracılığıyla toplanan büyük verilerin analiz edilmesi ile mümkün olmaktadır. Geleneksel kestirimci bakım sistemleri, toplanan verilerin merkezi bir

sunucuda işlenerek anlamlandırılması esasına dayanır. Bu yöntemde, tüm üretim verileri merkezi bir noktaya iletilerek makine öğrenimi modelleri aracılığıyla analiz edilir ve arızalar ya da kalite sapmaları tahmin edilmeye çalışılır. Ancak bu yaklaşımın bazı önemli sınırlamaları ve zorlukları bulunmaktadır. Öncelikle, üretim hattından gelen veri hacminin çok büyük olması, bu verilerin merkezi sunuculara aktarımında bant genişliği, işlem süresi ve depolama maliyetleri açısından büyük bir yük oluşturmaktadır. Merkezi veri işleme modeli, büyük ölçekli üretim tesislerinde hesaplama gereksinimlerini artırmakta, yüksek maliyetler ve operasyonel karmaşıklık yaratmaktadır. Bir diğer kritik sorun ise veri gizliliği ve güvenliği ile ilgilidir. Üretim süreçlerinde kullanılan veriler genellikle firma için stratejik öneme sahip hassas bilgilerden oluşmaktadır. Üretim hattındaki makinelerin çalışma koşulları, üretim parametreleri ve kalite süreçlerine dair veriler, rakiplere karşı rekabet avantajı sağlayan kritik bilgiler arasında yer almaktadır. Tüm bu verilerin merkezi bir sunucuda toplanması, yetkisiz erişim, veri ihlalleri ve siber saldırılar açısından büyük riskler oluşturabilir. Özellikle büyük üretim tesislerinde farklı bölgelerden ve çeşitli sistemlerden gelen heterojen verilerin tek bir noktada işlenmesi, güvenlik açıklarına neden olabileceği gibi verilerin yanlış yorumlanmasına da sebep olabilir. FL'in, veri gizliliği, işlem maliyetleri ve model doğruluğu açısından sunduğu avantajlar incelenecek ve endüstriyel üretim süreçlerine entegre edilme potansiyeli detaylı olarak ele alınacaktır. Çalışmada ayrıca, FL tabanlı yaklaşımların mevcut kestirimci bakım ve kalite yönetimi sistemlerine nasıl adapte edilebileceği, hangi durumlarda daha avantajlı olduğu ve sanayi uygulamalarında nasıl ölçeklendirilebileceği analiz edilecektir.

1.2 Tezin Amacı ve Hedefleri

Sanayinin dijitalleşmesi ve üretim süreçlerinin giderek daha karmaşık hale gelmesi, kestirimci bakım ve kalite yönetimi gibi veri odaklı yaklaşımların giderek daha fazla önem kazanmasına yol açmıştır. Bu çalışma kapsamında, FL'in üretim süreçlerinde nasıl uygulanabileceği detaylı olarak ele alınacak ve geleneksel yöntemlerle karşılaştırmalı bir analiz gerçekleştirilecektir. Tez çalışmasının temel hedefleri şu şekilde özetlenebilir:

FL modellerinin kestirimci bakım süreçlerinde uygulanabilirliğini incelemek: Üretim hatlarında bulunan makineler, operasyonel süreçlerinde farklı türde arızalara ve performans dalgalanmalarına maruz kalmaktadır. Geleneksel kestirimci bakım sistemleri, makine öğrenimi ile arıza tahmini yaparak önleyici bakım stratejileri geliştirmektedir. Ancak bu sistemler, verinin merkezi bir sunucuda işlenmesini gerektirdiğinden hem güvenlik riskleri doğurmakta hem de büyük veri setlerinin işlenmesi sürecinde zaman ve maliyet açısından dezavantajlar oluşturmaktadır. FL tabanlı kestirimci bakım sistemlerinde, her makine kendi üzerinde analiz yaparak yerel model güncellemeleri ile sistemin genel öğrenme sürecine katkı sağlamaktadır. Bu tezde, FL'in kestirimci bakım süreçlerine entegrasyonu araştırılacak ve geleneksel merkezi yöntemlerle performans karşılaştırması yapılacaktır.

FL modellerinin kestirimci kalite yönetimi süreçlerinde performansını değerlendirmek:

Üretim süreçlerinde kalite dalgalanmaları, nihai ürünün güvenilirliği ve müşteri memnuniyeti açısından büyük bir öneme sahiptir. Üretim hatlarında kullanılan merkezi kalite kontrol sistemleri, sensör verilerini analiz ederek kalite sorunlarını erken aşamada tespit etmeye çalışmaktadır. Ancak, büyük üretim tesislerinde farklı hatlardan gelen verilerin merkezi bir sistemde analiz edilmesi, kalite tahmin modellerinin doğruluğunu olumsuz yönde etkileyebilir. FL tabanlı kestirimci kalite yönetimi sistemleri, her üretim hattında yerel olarak çalışan dağıtık modellerle kalite analizlerini gerçekleştirebilmekte ve genel modelin daha doğru tahminler yapmasına katkı sunmaktadır. Bu tez kapsamında, FL'in kalite yönetimi süreçlerine adaptasyonu ele alınarak, merkezi sistemlerle performans kıyaslaması yapılacaktır.

Veri gizliliğini koruyarak dağıtık öğrenme modellerinin avantajlarını göstermek: Endüstriyel tesislerde üretilen veriler, işletmelerin rekabet avantajını doğrudan etkileyen kritik bilgileri içermektedir. FL modeli, veriyi yerel makinelerde işleyerek yalnızca model güncellemelerini paylaşmaktadır. Bu sayede veri gizliliğini ve güvenliğini artırmaktadır. Tez çalışmasında, FL'in veri paylaşımına gerek duymadan model eğitimi gerçekleştirme kapasitesi detaylı bir şekilde test edilecek ve veri güvenliği üzerindeki etkileri analiz edilecektir.

Endüstri 4.0 ve 5.0 kapsamında FL'in kullanım potansiyelini ortaya koymak: Sanayi, Endüstri 4.0 ile dijital dönüşümünü hızlandırırken, Endüstri 5.0 ile insan-

makine iş birliğini daha da ileriye taşımayı hedeflemektedir. Akıllı üretim sistemlerinde FL' nin entegrasyonu, üretim süreçlerini daha otonom hale getirme ve sistemler arası iletişimi güçlendirme açısından büyük bir potansiyele sahiptir. FL, merkezi modelleme ihtiyacını ortadan kaldırarak, üretim süreçlerinde daha ölçeklenebilir ve sürdürülebilir çözümler sunmaktadır. FL'in Endüstri 4.0 ve 5.0 ekosistemlerindeki potansiyel kullanım alanları değerlendirilecek ve gelecekte sanayiye nasıl yön verebileceği analiz edilecektir.

Tezin genel amacı, FL' nin kestirimci bakım ve kalite yönetimi uygulamalarındaki etkinliğini değerlendirerek, geleneksel merkezi makine öğrenimi yaklaşımlarına kıyasla daha güvenli, hızlı ve düşük maliyetli bir alternatif olup olmadığını ortaya koymaktır. Çalışma kapsamında FL tabanlı çözümlerin üretim süreçlerine entegre edilmesiyle elde edilebilecek avantajlar, potansiyel sınırlamalar ve uygulanabilirlik analizleri detaylı bir şekilde ele alınacaktır.

1.3 Tezin Kapsamı ve Kısıtları

Bu tez çalışması, FL yönteminin avantajları doğrultusunda, bu yöntemin endüstriyel üretim süreçlerine entegrasyonu kapsamında, kestirimci bakım ve kalite yönetimi alanında nasıl kullanılabileceğini incelemektedir. FL'in temel tanımı, işleyişi ve geleneksel yöntemlerle karşılaştırmalı avantajları Giriş bölümünde ayrıntılı olarak açıklanmıştır. Bu nedenle bu bölümde doğrudan çalışmanın kapsamı, sınırları ve uygulanabilirlik detaylarına odaklanılmaktadır. OPC (Süreç Kontrolü için Nesne Bağlantısı) protokolü aracılığıyla toplanan üretim verilerinin FL modelleriyle nasıl işlenebileceği araştırılacaktır. OPC verileri, fabrikalarda üretim süreçlerinin izlenmesi, makine performanslarının değerlendirilmesi ve operasyonel verimliliğin artırılması için kullanılan önemli bir veri kaynağıdır. FL tabanlı kestirimci bakım ve kalite yönetimi sistemleri oluşturularak, merkezi modeller ile performans karşılaştırmaları yapılacaktır. FL'in üretim süreçlerinde hata tespiti, kalite analizleri ve bakım yönetimi gibi kritik alanlarda nasıl avantajlar sağladığı detaylı bir şekilde değerlendirilecektir. Bu çalışmanın kapsamı, aşağıdaki temel başlıklar etrafında şekillenmektedir:

- FL tabanlı kestirimci bakım sistemlerinin uygulanabilirliği
- FL destekli kestirimci kalite yönetimi
- FL ile merkezi makine öğrenimi sistemlerinin karşılaştırmalı analizi

- FL modellerinin sanayiye entegrasyonu

Ele alınan FL yönteminin endüstriyel ölçekte uygulanabilirliği bazı kısıtlamalara tabidir. Bu kısıtlamalar aşağıdaki başlıklar altında incelenmektedir: FL modellerinin eğitimi için kullanılan veriler, belirli bir üretim tesisine veya sektöre özgü olabilir. Çalışma kapsamında kullanılan OPC verileri, belli bir üretim hattında toplanan spesifik makine verilerini içermektedir. Ancak farklı sektörlerde veya üretim süreçlerinde benzer başarı seviyelerine ulaşıp ulaşılamayacağı test edilmelidir. FL yönteminin uygulanabilirliği, hesaplama gücü, donanım kapasitesi ve ağ altyapısı gibi teknik faktörlere bağlıdır. FL modelleri, merkezi makine öğrenimi modellerine kıyasla daha fazla yerel işlem gücü gerektirmektedir, çünkü her istemci (fabrika makinesi veya üretim hattı) kendi verilerini yerel olarak işleyip model güncellemeleri göndermektedir. Büyük ölçekli üretim tesislerinde, FL'in getirdiği ek işlem yükünün nasıl yönetileceği önemli bir araştırma konusu olacaktır. Donanım sınırlamaları, modelin karmaşıklığına bağlı olarak farklı sonuçlar doğurabilir. FL modellerinin merkezi sunucu ile istemciler (yerel makineler) arasında sürekli iletişim kurması gerekmektedir. Yerel makinelerde işlenen model güncellemelerinin merkezi sunucuya gönderilmesi süreci, ağ trafiğini artırabilir ve iletişim maliyetlerini yükseltebilir. FL yönteminin, büyük ölçekli üretim tesislerinde gerçek zamanlı olarak ne kadar verimli çalıştığı bu tez kapsamında ele alınacak önemli konular arasındadır. FL modellerinin mevcut üretim hatlarına entegrasyonu, işletmelerin sahip olduğu mevcut altyapıya bağlı olarak değişkenlik gösterebilir. Fabrikalardaki mevcut veri toplama sistemleri, yazılım ve donanım altyapısı FL'e uyumlu olmayabilir veya entegrasyon süreci ek maliyetler ve teknik zorluklar içerebilir. Ayrıca, üretim hatlarında FL modelinin uygulanması sırasında oluşabilecek güvenlik ve uyumluluk sorunları da dikkate alınmalıdır. FL'in sanayiye entegrasyon sürecinde hangi zorlukların ve fırsatların bulunduğunu analiz ederek, gelecekteki çalışmalar için önemli bir yol haritası sunmayı amaçlamaktadır.

1.4 Tezin Özgün Katkıları

Günümüz endüstriyel üretim sistemleri, veriye dayalı karar alma mekanizmalarının güçlenmesiyle hızlı bir dönüşüm geçirmektedir. Özellikle kestirimci bakım ve kalite yönetimi gibi alanlarda yapay zekâ ve büyük veri analitiği, operasyonel verimliliği

artırmak ve maliyetleri azaltmak amacıyla yoğun bir biçimde kullanılmaktadır. Ancak geleneksel merkezi makine öğrenimi modelleri; veri gizliliği ihlalleri, yüksek iletişim maliyetleri ve sınırlı ölçeklenebilirlik gibi ciddi sorunlarla karşı karşıyadır. Bu bağlamda, FL mimarisi, üretim süreçlerinde yapay zekâ uygulamalarını daha güvenli, verimli ve ölçeklenebilir hale getirmek üzere öne çıkan bir çözüm olarak değerlendirilmektedir. Bu tez çalışması, FL mimarisinin endüstriyel üretim süreçlerine entegrasyonuna odaklanarak literatüre somut katkılar sunmaktadır. Literatürde genellikle kavramsal düzeyde ele alınan FL, bu çalışmada gerçek üretim verileri üzerinden uygulamaya aktarılmıştır. Özellikle üretim hatlarında yaygın olarak kullanılan OPC protokolü ile toplanan sıcaklık, basınç ve hız gibi sensör verilerinin FL mimarisiyle işlenebilirliği detaylı biçimde incelenmiştir. Böylece FL'in sahadan elde edilen operasyonel verilerle nasıl bütünleştirilebileceği deneysel olarak ortaya konmuş, geleneksel merkezi modellerle performans karşılaştırmaları gerçekleştirilmiştir. Tez kapsamında geliştirilen sistem, verilerin yerel cihazlarda işlenmesini sağlayarak hem gizlilik risklerini minimize etmiş hem de veri paylaşımına olan ihtiyacı ortadan kaldırmıştır. Bununla birlikte, iletişim maliyetlerini düşürmeye yönelik olarak gradyan sıkıştırma ve seyrek güncelleme gibi optimizasyon teknikleri uygulanmış, sistemin farklı ölçeklerdeki istemci senaryolarında gösterdiği performans ölçülmüştür. Modelin başarımı yalnızca doğruluk, hassasiyet, hatırlama ve F1 skoru gibi klasik sınıflandırma metrikleriyle değil; aynı zamanda sistem gecikmesi, ağ trafiği, hesaplama verimliliği ve veri heterojenliği gibi pratik uygulamalarda kritik öneme sahip metriklerle de değerlendirilmiştir. Çalışmanın bir diğer özgün yönü, veri ön işleme sürecinde gelişmiş tekniklerin kullanılmasıdır. Eksik verilerin tamamlanması, zaman damgası senkronizasyonu ve anomali tespiti gibi işlemler sayesinde sensör verileri modelleme sürecine daha uygun hale getirilmiştir. Ayrıca, FL mimarisi ile diferansiyel gizlilik ilkeleri bir araya getirilerek, model eğitimi sırasında bireysel verilerin korunması sağlanmıştır. Bu yapı, üretim ortamlarında hem güvenlik hem de performans açısından merkezi sistemlere kıyasla üstünlük sağlamıştır. Bu tezde elde edilen bulgular, FL'in Endüstri 4.0 ve 5.0 vizyonlarına uygun şekilde sanayide nasıl etkin biçimde kullanılabileceğini göstermekte; özellikle akıllı fabrikalar ve dağıtık üretim ağları gibi sistemlerde FL'in sağlayabileceği avantajlara dikkat çekmektedir. Ayrıca, geleneksel merkezi öğrenme yaklaşımlarıyla karşılaştırmalı analizler yapılarak, FL'in hangi koşullarda daha uygun bir alternatif sunduğu açık biçimde ortaya konmuştur. Dolayısıyla, bu tez çalışması yalnızca FL'in

uygulanabilirliğini göstermekle kalmamış, aynı zamanda üretim ortamlarında karşılaşılan temel problemlere çözüm getiren, deneysel olarak test edilmiş ve sistematik biçimde analiz edilmiş bir mimari sunmuştur. Bu yönüyle çalışma, literatürde ki teorik yaklaşımları uygulamaya dönüştürmekte ve sanayi ile akademi arasında köprü kuran yenilikçi bir katkı niteliği taşımaktadır.

1.5 Tezin Organizasyonu

Bu tez çalışması, toplam yedi ana bölümden oluşmakta olup, her bir bölüm üretim süreçlerine yönelik FL uygulamalarının kapsamlı bir şekilde ele alınmasını hedeflemektedir.

Giriş bölümünün de çalışmanın problemi, motivasyonu, amacı, kapsamı ve özgün katkıları detaylı olarak sunulmuştur. FL tabanlı kestirimci bakım ve kalite yönetimi sistemlerine dair temel bilgiler verilmiş, ayrıca bu sistemlerin üretim ortamlarındaki önemi ve uygulama potansiyeli ele alınmıştır. Tezin dayandığı varsayımlar ve sınırlılıklar da burada tanımlanmıştır.

Literatür Taraması bölümünde, FL, kestirimci bakım ve kalite yönetimi alanlarında literatürde yer alan güncel çalışmalar sistematik şekilde analiz edilmiştir. FL'in endüstride nasıl uygulandığına dair yapılan önceki araştırmalar değerlendirilmiş, bu çalışmaların güçlü ve zayıf yönleri ortaya konularak, bu tezin literatüre sunduğu özgün katkılar vurgulanmıştır.

Kavramsal Çerçeve bölümünde, çalışmada kullanılan veri setleri, FL model mimarisi ve deneysel tasarım süreci ayrıntılı olarak açıklanmıştır. FL'in kestirimci bakım ve kalite yönetimi uygulamalarındaki uygulanabilirliği değerlendirilmiş; merkezi öğrenme modelleri ile karşılaştırmalı bir yaklaşım benimsenmiştir.

Metodoloji bölümünde, Tez kapsamında gerçekleştirilen deneysel çalışmalar, kullanılan yöntemler ve eğitim süreci bu bölümde paylaşılmıştır. Federe ve merkezi öğrenme modelleri arasındaki performans farklılıkları; doğruluk, F1 skoru, iletişim maliyeti ve eğitim süresi gibi ölçütler üzerinden analiz edilmiştir.

Uygulama ve Deneysel Sonuçlar bölümünde, Modelin üretim ortamlarına entegrasyonu kapsamında elde edilen bulgular sunulmuş, FL'in sanayi ortamında

karşılaştığı avantajlar ve zorluklar değerlendirilmiştir. Ayrıca küçük ve büyük ölçekli istemci senaryolarındaki başarımları da bu bölümde örneklerle desteklenmiştir.

Tartışma bölümünde, Elde edilen deneysel sonuçların ışığında FL mimarisinin güçlü ve zayıf yönleri, farklı metrikler (veri gizliliği, öğrenme başarısı, iletişim verimliliği vb.) çerçevesinde tartışılmıştır. Diferansiyel gizlilik uygulamasının model performansına etkisi analiz edilmiş ve merkezi öğrenme yaklaşımları ile karşılaştırmalar yapılmıştır. Ayrıca sistemin ölçeklenebilirliği ve gerçek saha uygulamaları için adaptasyon düzeyi incelenmiştir.

Sonuç bölümünde, Tezin genel bir özeti sunularak, FL'in üretim verileri üzerinde uygulandığında hem veri güvenliğini sağladığı hem de başarılı kestirimci analizler gerçekleştirebildiği ortaya konmuştur. Literatürdeki mevcut boşlukları dolduran bu çalışma, FL'in sanayideki uygulanabilirliğine dair somut bulgular sunmuştur. Gelecek çalışmalarda FL algoritmalarının çeşitlendirilmesi, istemci-sunucu yapılandırmalarının zenginleştirilmesi, haberleşme protokollerinin optimize edilmesi ve model kişiselleştirme tekniklerinin entegre edilmesi önerilmektedir.

2. LİTERATÜR TARAMASI

Literatür taraması, çalışmanın dayandığı teorik ve uygulamalı temelleri ortaya koymak için kritik bir aşamadır. Bu bölümde, FL, kestirimci bakım, kestirimci kalite ve OPC protokolü konularında kapsamlı bir analiz yapılmış ve bu alanlardaki literatür, çalışmanın hedefleri ile ilişkilendirilerek detaylı bir şekilde ele alınmıştır.

2.1 Federe Öğrenme'nin Gelişimi ve Teorik Temelleri

FL, günümüzde özellikle gizlilik odaklı veri analitiği gerektiren sektörlerde etkili bir çözüm olarak öne çıkmaktadır. Bu bölümde FL'in teorik temelleri, literatürdeki gelişimi, algoritmik yapısı ve uygulama alanlarındaki çeşitliliği detaylı biçimde ele alınmaktadır. FL'in temelleri, McMahan ve arkadaşlarının geliştirdiği FedAvg (Federe Ortalama Alma Algoritması) algoritması ile atılmıştır (McMahan ve diğ., 2017). Bu algoritma, istemcilerin yerel verileri üzerinde model eğitip, yalnızca ağırlık güncellemelerini merkezi sunucuya iletmeleri prensibiyle çalışır. Merkezî sunucu, bu güncellemeleri ortalayarak global modeli oluşturur ve güncellenmiş parametreleri istemcilere dağıtır. Böylece veri aktarımı minimize edilirken, iletişim verimliliği artırılmış olur. Ayrıca, FedAvg algoritmasının sistem heterojenliğine toleranslı yapısı, farklı donanım ve veri profiline sahip cihazlarda da etkili sonuçlar elde edilmesini mümkün kılar (McMahan ve diğ., 2017). FL' nin sunduğu en önemli avantajlardan biri, verilerin cihazda işlenmesi sayesinde yasal düzenlemelere uyum ve kullanıcı güveninin artmasıdır (McMahan ve diğ., 2017). Özellikle Avrupa Birliği'nin GDPR (Genel Veri Koruma Tüzüğü) gibi katı veri koruma düzenlemeleri bağlamında, FL veri sahipliğini koruyan sürdürülebilir bir çözüm sunar. FL yönetimi, verinin cihazda işlenmesini sağlayarak erişim kontrolünü veri sahibine bırakır ve merkezi model eğitimi gerçekleştirilmesini mümkün kılar (McMahan ve diğ., 2017). FL, medikal alanında sağlık uygulamaları, doğal dil işleme, finans ve e-ticaret gibi birçok alanda uygulanmaktadır (Akşit ve diğ., 2023). Üretim sektöründe, çeşitli tesislerden gelen operasyonel veriler FL ile yerel olarak analiz edilmekte, bu sayede hem kestirimci bakım uygulamaları geliştirilmekte hem de kalite kontrol süreçleri optimize edilmektedir. Yang ve ekibi, FL'in heterojen veri yapılarında doğruluk kaybını

azaltacak adaptif yöntemler geliştirerek, farklı kaynaklardan gelen verilerin etkili şekilde bütünleştirilmesini sağlamıştır (Yang ve diğ, 2019). Kairouz ve çalışma arkadaşları, FL'in teorik altyapısını ve uygulama potansiyelini kapsamlı bir şekilde inceleyerek; veri gizliliği, model doğruluğu ve iletişim verimliliği arasındaki hassas dengeyi ortaya koymuştur (Kairouz ve diğ, 2021). Bu inceleme, özellikle dağıtık veri yapılarının getirdiği zorluklar ve optimizasyon gerekliliklerine dikkat çekmektedir. Polat, FL sistemlerinin saldırılara karşı dayanıklılığını artırmak amacıyla geliştirilen BARFED yaklaşımını sunmuş ve bu yapının özellikle veri dağılımı ve kötü niyetli istemciler gibi unsurlar karşısında güvenli ve esnek bir çözüm sunduğunu göstermiştir (Polat ve diğ, 2021). Gökberk Elmas tarafından yürütülen çalışmada, FL'in merkezi olmayan yapısı sayesinde, tıbbi görüntü verilerinin gizliliğini koruyan farklı kurumlar arasında ortak model eğitimi yapılabileceği gösterilmiştir (Elmas ve diğ, 2023). Bu bağlamda, özellikle üretim tesislerinde uygulanan geleneksel anonimleştirme tekniklerinin veri doğruluğunu düşürebileceği vurgulanırken, FL'in bu ihtiyacı ortadan kaldırarak doğrudan yerel cihazlar üzerinden kolektif öğrenme süreçleri gerçekleştirebildiği gösterilmiştir. Bu durum, hem sistem verimliliğini hem de güvenlik düzeyini önemli ölçüde artırmaktadır. Zhao ve ekibi, FL'in heterojen ağ yapılarında nasıl optimize edilebileceğini araştırmış; üretim süreçlerindeki veri çeşitliliği ve donanım farklılıklarının FL performansına etkisini analiz etmiştir (Zhao ve diğ, 2019). Bu analizler, özellikle çeşitli sensör altyapılarına sahip üretim hatlarından gelen farklı veri türlerinin FL sistemleriyle nasıl entegre edilebileceğine ışık tutmuştur. Ahn ve çalışma arkadaşları, üretim süreçlerinde kullanılan pompaların sensör verilerinden elde edilen zaman serisi verilerini kullanarak, 1DCNN-BiLSTM modeli ile FL'yi birleştirilen bir yaklaşım sunmuş ve bu sayede dağılım değişikliklerini dikkate alarak anomali tespiti ve kestirimci bakım gerçekleştirmiştir (Neto ve diğ, 2023). Bu çalışmada, geleneksel sistemlerde tüm verilerin merkezi sunucuya aktararak analiz edilmesinin yerine, FL ile yerel analizlerin mümkün kılınması sayesinde hem veri aktarım maliyetlerinin azaldığı hem de gerçek zamanlı karar destek sistemlerinin geliştirilebildiği vurgulanmıştır. Kairouz ve arkadaşları, FL'in istatistiksel öğrenme teorisi, dağıtık optimizasyon teknikleri ve iletişim protokolleri üzerine kurulu teknik altyapısını kapsamlı şekilde incelemiş; aynı zamanda bu alandaki güncel zorlukları ve çözüm stratejilerini analiz etmişlerdir (Kairouz ve diğ, 2021). Bu sistemin başarısı, farklı istemciler arasında model parametrelerinin doğru biçimde senkronize edilmesine ve iletişim maliyetlerinin minimize edilmesine


bağlıdır. Konečný ve arkadaşları, FL' in sürdürülebilirliğini arttırmak amacıyla iletişim protokollerinin optimizasyonunda sıkıştırma algoritmaları ve model ağırlıklarının azaltılması gibi yöntemleri önermiştir (Konečný ve diğ, 2016). Truex ve arkadaşları, FL sistemlerinde güvenliği arttırmak amacıyla diferansiyel gizlilik ve homomorfik şifreleme gibi gizlilik koruma tekniklerinin birlikte kullanılabileceğini göstermiştir (Truex ve diğ, 2019). Diferansiyel gizlilik, model güncellemelerine rastgele gürültü ekleyerek bireysel veri noktalarının çıkarılmasını engellerken; homomorfik şifreleme, verilerin şifrelenmiş biçimde işlenmesine olanak tanır. Bu yöntemler, kullanıcı verilerinin merkezileştirilmeden işlenmesini sağladığı için sürücülük verilerinin analizinde olduğu gibi gizliliğin önemli olduğu uygulamalarda FL 'in tercih edilmesini sağlamaktır (Li, 2020a). FL'in en güçlü yönlerinden biri, sistem heterojenliğine ve veri dengesizliklerine karşı sağladığı esnekliktir. Farklı cihazların işlem gücü, bağlantı hızı ve veri yapısının çeşitliliği, geleneksel makine öğrenimi yöntemlerinde ciddi sorunlara yol açarken; FL, bu farklılıkları tolere edebilen bir yapı sunar (Çağlayan, 2023). Bu bağlamda, FedAvg gibi temel algoritmalar sayesinde, her bir istemcinin yerel güncellemeleri ortalama alınarak merkezi modele yansıtılmakta ve senkronizasyon sağlanmaktadır (McMahan ve diğ, 2017). Böylece, hem modelin genel doğruluğu korunmakta hem de farklı cihazlardan gelen katkılar adil biçimde temsil edilmektedir. Son yıllarda, FL sistemlerinin farklı uygulama alanlarında kullanımına yönelik çalışmalar hız kazanmıştır. Özellikle medikal görüntü analizi, otonom araç sistemleri, akıllı şehirler ve siber güvenlik gibi yüksek güvenlik ve gizlilik gerektiren alanlarda FL, etkin ve güvenli bir çözüm olarak öne çıkmaktadır (Kocadurdu, 2023). Bu uygulamalarda, kurumlar arası veri paylaşımına gerek kalmadan ortak modeller geliştirilmesi mümkün hale gelmekte; bu da hem yasal düzenlemelere uyumu kolaylaştırmakta hem de iş birliğine dayalı inovasyonu teşvik etmektedir. Literatürde bu alanlara özgü birçok Federe Öğrenme yaklaşımı geliştirilmiştir (Eriş ve diğ, 2021). Örneğin, sağlık alanında hastaneler arasında hasta verilerinin paylaşılmadan, FL aracılığıyla merkezi olmayan bir modelin eğitilmesi; hem hasta mahremiyetini korumakta hem de teşhis doğruluğunu artırmaktadır. Aynı şekilde, otonom sürüş teknolojilerinde FL, araçların çevresel verileri işleyerek sürüş modellerini geliştirmesine olanak tanımaktadır. FL aynı zamanda güvenlik açısından da dikkat çekici çözümler sunar. Diferansiyel gizlilik ve homomorfik şifreleme tekniklerinin entegrasyonu ile FL sistemleri, veri gizliliğini korurken kötü niyetli saldırılara karşı güvenlik düzeyini artırabilmektedir (Wen ve diğ,

2023). Bu durum, finans, sađlık ve üretim gibi yüksek riskli veri ortamlarında FL’i öne çıkaran en önemli özelliklerden biridir. Bununla birlikte, sistem heterojenliđi, istemciler arası eşzamanlılık sorunları ve veri dengesizliđi gibi zorluklar da halen önemli araştırma konularıdır (Mehta ve Shao, 2023). Bu zorluklara karşı geliştirilen yeni nesil federated optimization yöntemleri, adaptif model güncellemeleri ve kişiselleştirme yaklaşımları, FL’in performansını artırmayı hedeflemektedir. Böylece hem istemcilerin bireysel özellikleri korunabilmekte hem de daha kapsayıcı bir global model elde edilebilmektedir (Abbas ve diğ, 2023). FL, yalnızca teknik bir paradigma deđişikliđi deđil; aynı zamanda etik, hukuki ve operasyonel bir dönüşümü de beraberinde getirmektedir. GDPR ve HIPAA (Sađlık Sigortası Taşınabilirliđi ve Sorumluluk Yasası) gibi düzenlemeler çerçevesinde veri sahipliđinin korunması, birey mahremiyetine saygı duyulması ve aynı anda yüksek doğruluđa sahip makine öğrenimi modelleri geliştirilmesi, FL’in önümüzdeki yıllarda daha da yaygınlaşmasını sağlayacaktır (Truong ve diğ, 2021). Akademik literatürde yapılan çalışmalar da FL’ in sürdürülebilir, güvenli ve ölçeklenebilir yapısıyla birçok sektörde devrim niteliğinde bir yaklaşım sunduđunu göstermektedir (Kairouz ve diğ, 2021).

2.2 Federe Öğrenme Mimarileri

FL mimarileri, verilerin fiziksel dağılımı ve organizasyonu göz önünde bulundurularak üç ana başlık altında incelenmektedir: Yatay FL (Horizontal FL), Dikey FL (Vertical FL) ve Hibrit FL (Transfer FL). Bu mimariler, uygulama alanları ve kullanım senaryoları açısından farklılık göstermektedir (Chen ve diğ, 2023).

2.2.1 Yatay federe öğrenme




Şekil 2.1: Yatay federe öğrenme örneği.

Yang ve arkadaşları, benzer veri özelliklerine sahip ancak farklı kullanıcı gruplarına ait verilerin ortak modelle işlenmesini mümkün kılan HFL (Yatay FL) yaklaşımını tanımlamıştır (Yang ve diğ., 2019). Bu yaklaşım, özellikle büyük ölçekli veri kümeleri üzerinde çalışan organizasyonlar için büyük avantajlar sağlamaktadır. Merkezi bir veri havuzu oluşturma zorunluluğunu ortadan kaldırarak, farklı coğrafi konumlardaki veri kaynaklarının güvenli bir şekilde işlenmesine imkan tanımaktadır. Örneğin, farklı şehirlerdeki bankaların müşterileri üzerine yapılan bir analiz, yatay FL kapsamında değerlendirilebilir. Bu senaryoda, her banka kendi müşterilerine ait verileri yerel olarak işler ve merkezi bir modele katkı sağlarken, bireysel müşteri bilgileri hiçbir zaman paylaşılmaz. Bu yöntem, finans sektöründe dolandırıcılığın önlenmesi, kredi risk analizleri ve müşteri davranışlarının modellenmesi gibi kritik uygulamalar için güvenli bir çözüm sunmaktadır. Yang ve arkadaşları, benzer veri yapısına sahip büyük veri setlerinin yatay FL ile etkin şekilde işlenebileceğini göstermiştir (Yang ve diğ., 2019). Farklı organizasyonların veya kurumların kendi veri kaynaklarını ortak bir model geliştirmek için kullanmalarına olanak tanıyan yatay FL, veri çeşitliliğini artırırken bireysel gizliliği de korumaktadır. Özellikle büyük veri platformları, sağlık araştırmaları ve tüketici analizleri gibi geniş çaplı çalışmalar için yatay FL'in ölçeklenebilirliği önemli bir avantajdır. Hard ve arkadaşları, Yatay FL' nin en yaygın kullanım alanlarından birinin mobil cihazlardan kullanıcı davranışlarının öğrenilmesi olduğunu göstermiştir (Hard ve diğ., 2018). Mobil uygulamalar, kullanıcı etkileşimlerinden elde edilen verileri FL aracılığıyla analiz ederek, kişiselleştirilmiş hizmetler sunma konusunda büyük ilerlemeler kaydetmiştir. Örneğin, akıllı klavye

uygulamaları, bireysel yazım alışkanlıklarını öğrenerek kullanıcı deneyimini geliştirirken, bu verilerin gizliliğini FL sayesinde koruyabilmektedir. Aynı şekilde, çevrimiçi alışveriş platformları ve dijital pazarlama sistemleri, kullanıcı verilerini merkezi bir sunucuya taşımadan analiz ederek, öneri motorlarını daha etkili hale getirebilmektedir. FedAvg algoritmasıyla optimize edilen Yatay FL, iletişim maliyetlerini düşürürken global model doğruluğunu da önemli ölçüde artırmaktadır (McMahan ve diğ., 2017). FedAvg algoritması, yerel cihazlarda eğitilen model güncellemelerini merkezi bir sunucuda birleştirerek, hem hesaplama hem de iletişim yükünü dengeli bir şekilde yönetmektedir. Bu, özellikle geniş ölçekli dağıtık sistemlerde model eğitim sürecinin daha verimli hale gelmesini sağlar. Yatay FL'in bu avantajı, mobil cihazlar ve IoT (Nesnelerin İnterneti) ağları gibi bant genişliği ve işlem kapasitesi kısıtlı ortamlarda büyük önem taşımaktadır. Bu mimaride, cihazlar tarafından yerel olarak eğitilen modellerin merkezi bir sunucuya gönderilmesi ve burada birleştirilmesi temel prensiptir (AY, 2023). Şekil 2.1 de gösterildiği gibi, her bir cihaz yalnızca kendi verileri üzerinden model güncellemeleri üretir ve merkezde toplanan bilgiler, küresel modelin iyileştirilmesine katkı sağlar. Bu yöntem, özellikle veri hassasiyetinin yüksek olduğu uygulamalarda güvenli bir modelleme süreci sunmaktadır. Yang ve arkadaşları, kişisel cihazlardan sağlık verilerinin işlenmesi ve IoT cihazlarından enerji tüketim verilerinin analizinin Yatay FL mimarisi ile başarılı şekilde uygulanabildiğini göstermiştir (Yang ve diğ., 2019). Sağlık sektöründe, farklı hastanelerin FL kullanarak ortak bir teşhis modeli geliştirmesi, tıbbi araştırmalarda önemli bir ilerleme kaydetmesine yardımcı olabilir. Benzer şekilde, enerji sektöründe IoT cihazlarının FL ile entegre edilmesi, akıllı şebeke sistemlerinde enerji yönetiminin daha verimli hale getirilmesine olanak tanımaktadır. Bu tür uygulamalar, veri gizliliğini ihlal etmeden geniş ölçekte veri analizi yapmayı mümkün kılarak, yatay FL'in modern veri bilimi uygulamalarında kritik bir yer edinmesini sağlamaktadır.

2.2.2 Dikey federe öğrenme




Şekil 2.2: Dikey federe öğrenme örneği.

Yang ve arkadaşları, farklı özellik kümelerine sahip ancak aynı kullanıcı gruplarını içeren veri setlerinin Dikey FL (VFL) ile işlenebileceğini ortaya koymuştur (Yang ve diğ., 2019). Bu yöntem, bireylerin veya kuruluşların farklı alanlardaki verilerini güvenli bir şekilde birleştirerek, ortak bir model eğitme olanağı sağlamaktadır. Geleneksel veri analiz yöntemlerinde, farklı kurumlar arasında veri paylaşımı, gizlilik endişeleri ve yasal kısıtlamalar nedeniyle oldukça sınırlıdır. Ancak, dikey FL sayesinde, veriler fiziksel olarak paylaşılmadan analiz edilebilir ve daha kapsamlı tahmin modelleri oluşturulabilir. Yang ve arkadaşları, bir bankanın finansal verileri ile bir sigorta şirketinin sağlık verileri gibi, aynı kullanıcıya ait ancak farklı özelliklere sahip verilerin VFL ile bir araya getirilebileceğini vurgulamıştır (Yang ve diğ., 2019). Bankalar genellikle bireylerin harcama alışkanlıkları, kredi geçmişi ve yatırım eğilimlerine odaklanırken, sigorta şirketleri sağlık kayıtları, hastalık geçmişi ve polise bilgileri gibi finans dışı verilere sahiptir. Geleneksel veri işleme yöntemlerinde, bu tür çapraz sektör analizleri yapmak hem yasal düzenlemeler hem de teknik engeller nedeniyle oldukça zordur. Ancak dikey FL sayesinde, her kurum kendi verilerini saklarken, ortak bir model geliştirmek için yalnızca anonimleştirilmiş model güncellemeleri paylaşır. Yang ve arkadaşları, farklı sektörler arasında veri gizliliğini koruyarak makine öğrenimi modelleri geliştirme imkanı sunan FL mimarisinin bu tür iş birlikleri için uygun olduğunu ifade etmiştir (Yang ve diğ., 2019). Şekil 2.2 de gösterildiği üzere benzer örneklere sahip ancak farklı özelliklere sahip veriler üzerinde kullanılır. Finans ve sağlık sektörleri dışında, e-ticaret ve reklamcılık gibi alanlarda da dikey FL büyük bir potansiyele sahiptir. Örneğin, bir perakende şirketi, müşteri harcamalarına ilişkin verilerini bir telekomünikasyon firmasının kullanıcı davranış

verileriyle birleřtirerek, daha kiřiselleřtirilmiř pazarlama stratejileri geliřtirebilir. Bu tr bir veri birleřimi, geleneksel yntemlerle yapılmak istendiğinde ciddi gvenlik riskleri doęururken, dikey FL bu sreci gvenli hale getirmektedir. Dikey FL, veri gvenlięini saęlarken farklı kurumlar arasında bilgi paylařımını teřvik etmektedir (Saleh, 2022). Geleneksel merkezi veri analitięi yntemlerinde, byk lekli veri kmelerinin tek bir merkezde toplanması gereklidir, bu da veri ihlali risklerini artırmaktadır. Ancak, dikey FL’de her kuruluř, kendi veri setini yerel olarak saklarken, yalnızca model ęrenimi iin gerekli olan bilgileri paylařmaktadır. Bu durum, zellikle GDPR gibi sıkı veri dzenlemelerinin bulunduęu blgelerde, yasal gerekliliklere uygun bir veri iřleme yntemi olarak ne ıkmaktadır. Dikey FL, ortak bir model eęitmek iin yalnızca ilgili veri zelliklerini paylařmayı amalayarak, gereksiz veri aktarımını ve gvenlik risklerini minimize etmektedir. rneęin, bir saęlık sigorta řirketi, hastalarının hastalık gemiřiyle ilgili bilgilere sahipken, bir finans kuruluřu yalnızca bireylerin sigorta prim deme gemiřini bilmektedir. Dikey FL sayesinde, bu iki kurum doęrudan veri paylařmadan, belirli bir kullanıcının saęlık durumu ve finansal durumu hakkında ngrlerde bulunabilen bir model oluřturabilir. Bu yntem, hem bilgi btnlęn korumakta hem de yasal dzenlemelere tam uyum saęlamaktadır. zellikle, kredi deęerlendirme sistemlerinde, bireylerin saęlık gemiřleri finansal gvenilirlik aısından nemli bir gsterge olabilir. Ancak, geleneksel yntemlerle bu tr bir veri entegrasyonu yapmak yasal ve etik sorunlara yol aabilir. Dikey FL sayesinde, bireysel gizlilięi koruyarak saęlık ve finans verileri arasındaki iliřki analiz edilebilir ve daha kapsamlı risk deęerlendirme sistemleri geliřtirilebilir. Dikey FL, veri gizlilięini koruyarak farklı sektrlerde iř birlięi yapılmasını saęlayan yeniliki bir ęrenme yntemi olarak ne ıkmaktadır. Kurumlar arası veri paylařımını gvenli hale getiren bu yntem, veri gvenlięi, reglasyonlara uyumluluk ve model performansı aısından byk avantajlar sunmaktadır. Gelecekte, farklı sektrlerde dikey FL uygulamalarının artmasıyla birlikte, apraz sektr veri analitięi daha yaygın hale gelecek ve bireysel gizlilik koruma mekanizmaları daha da glenecektir.

2.2.3 Hibrit federe öğrenme



Şekil 2.3: Hibrit federe öğrenme örneği.

AbdulRahman ve arkadaşları, Dikey FL' nin aynı kullanıcıya ait ancak farklı özelliklere sahip verilerin, farklı kurumlar arasında gizliliği koruyarak birleştirilmesini sağladığını belirtmiştir (AbdulRahman ve diğ., 2020). Bu yöntem, farklı veri yapılarının ve veri sahiplerinin bulunduğu sistemlerde, merkezi olmayan öğrenme süreçlerinin daha esnek hale getirilmesini sağlamaktadır. Şekil 2.3 de gösterildiği üzere kullanılan veri setlerinin hem özellikleri hemde örnekleri birbirlerinden farklıdır. Geleneksel yatay ve dikey FL yaklaşımları belirli veri düzenlerine odaklanırken, hibrit FL, hem benzer veri yapılarının farklı kaynaklardan işlenmesine hem de farklı veri türlerinin ortak bir modelde birleştirilmesine olanak tanımaktadır. Kairouz ve arkadaşları, FL' nin farklı coğrafi bölgelerdeki veri kaynaklarını güvenli biçimde işleyerek çok uluslu şirketlerin heterojen verilerini birleştirmede etkili olduğunu göstermiştir (Kairouz ve diğ., 2021). Böylece, farklı veri türlerini işleyerek geniş kapsamlı modellerin geliştirilmesine imkan tanır. Örneğin, global bir sağlık hizmeti sağlayıcısının farklı ülkelerdeki hasta verilerini merkezi bir modelde birleştirmesi, hibrit FL kapsamında değerlendirilebilir. Sağlık sektöründe, her ülkenin kendi veri toplama ve saklama politikaları bulunmaktadır. Hibrit FL sayesinde, bu veriler yerel olarak işlenirken, genel bir tahmin modeli eğitilerek küresel çapta daha tutarlı sağlık çözümleri geliştirmek mümkün olmaktadır. Benzer şekilde, bir e-ticaret platformu, hem müşteri harcama alışkanlıkları (yatay FL) hem de istemci demografik bilgileri (dikey FL) üzerinde çalışarak kişiselleştirilmiş pazarlama stratejileri oluşturabilir. Bu, daha kapsamlı veri entegrasyonu sağlayarak işletmelerin müşteri davranışlarını daha

iyi anlamasına yardımcı olur. Hibrit FL mimarisinin en büyük avantajlarından birinin, farklı veri kaynaklarından gelen bilgileri birleştirerek daha genel ve güçlü modeller üretme kapasitesi olduğunu belirtmiştir (AbdulRahman ve diğ, 2020). Geleneksel merkezi öğrenme yaklaşımlarında, farklı kaynaklardan gelen verilerin bir araya getirilmesi, veri gizliliği ihlalleri ve uyumsuz veri yapıları gibi zorluklar nedeniyle sınırlıdır. Ancak, hibrit FL, çeşitli veri türlerini birleştirme yeteneği sayesinde, modellerin genelleme gücünü artırarak farklı kullanıcı grupları için daha doğru tahminler yapılmasını sağlar. Bu özellik, özellikle üretim, finans ve sağlık gibi sektörlerde, farklı veri kaynaklarının bütünleşik olarak değerlendirilmesi açısından büyük bir avantaj sunmaktadır. FL mimarisinin veri heterojenliği, yüksek iletişim maliyeti ve sistem eşzamanlılığı gibi zorluklarla karşı karşıya olduğunu vurgulamıştır (Kairouz ve diğ, 2021). Yatay FL’de, aynı veri türleri farklı cihazlarda bulunduğundan iletişim süreci nispeten daha basitken, hibrit FL’de hem yatay hem de dikey veri paylaşımı yapılması gerektiğinden, model güncellemeleri daha fazla işlem gücü ve bant genişliği gerektirebilir. Ayrıca, farklı veri türleriyle çalışmak, veri yapılarının uyumluluğunu sağlamak için ek optimizasyon yöntemleri gerektirmektedir. Bu nedenle, hibrit FL’in performansını artırmak için verimli model güncelleme stratejilerinin ve iletişim protokollerinin geliştirilmesi gerekmektedir. FL sistemlerinde iletişim güvenliği ve veri gizliliğini arttırmak için homomorfik şifreleme ile güvenli çok taraflı hesaplama tekniklerinin birlikte uygulanabileceğini göstermiştir (Truex ve diğ, 2019). Homomorfik şifreleme, verilerin şifreli haldeyken bile analiz edilmesine olanak tanıyarak veri gizliliğini korumakta, güvenli çok taraflı hesaplama ise, birden fazla tarafın verilerini doğrudan paylaşmadan ortak hesaplamalar yapmasına imkan tanımaktadır. Bu teknikler, özellikle sağlık ve finans sektörlerinde kullanılan hibrit FL modellerinin güvenliğini artırarak veri sahiplerinin iş birliği yapmasını kolaylaştırmaktadır. FL mimarilerinin farklı veri dağılımı senaryolarına esnek biçimde uyarlanarak modern veri analitiği uygulamalarına katkı sunduğunu belirtmiştir (Li, 2020a). Geleneksel merkezi makine öğrenimi yöntemlerine kıyasla, FL’in sunduğu merkezi olmayan yaklaşım, veri sahiplerine daha fazla kontrol imkanı sunarken, büyük ölçekli veri kümelerinin güvenli bir şekilde işlenmesine olanak tanımaktadır. Yatay, dikey ve hibrit FL mimarilerinin farklı veri dağılımı senaryolarında uygulanarak FL’in geniş kullanım alanlarına olanak sağladığını göstermiştir (AbdulRahman ve diğ, 2020). Bu üç farklı mimari, farklı sektörlerin ve veri tiplerinin gereksinimlerine uyarlanarak, FL’in adaptasyonunu ve yaygınlaşmasını


hızlandırmaktadır. FL mimarilerine yönelik yapılan çalışmaların hem teorik hem de uygulamalı düzeyde önemli ilerlemeler sağladığını ortaya koymuştur (Kairouz ve diğ, 2021). Akademik araştırmalar, FL'in optimizasyonu, iletişim maliyetlerinin azaltılması ve güvenlik önlemlerinin artırılması konularında sürekli gelişim göstermektedir. Endüstride ise, büyük teknoloji firmaları ve veri odaklı şirketler, FL'i kendi iş süreçlerine entegre ederek, veri gizliliğini koruyarak model geliştirme sürecini daha verimli hale getirmektedir. Gelecekte, FL'in daha ölçeklenebilir ve verimli hale getirilmesiyle, makine öğrenimi modellerinin merkezi olmayan yapılarla daha geniş çapta uygulanması beklenmektedir.

2.3 Endüstriyel Sistemlerde Federe Öğrenme Uygulamaları

OPC protokolü, üretim sektöründe veri toplama ve cihazlar arası iletişim için yaygın olarak kullanılan bir endüstri standardıdır (Mahmoud ve diğ, 2015). Modern endüstriyel otomasyon sistemlerinde, sensörler ve diğer veri kaynaklarından gelen bilgiler farklı formatlarda olabilir ve bu verilerin merkezi bir yapıda işlenmesi gerekmektedir. OPC, bu noktada devreye girerek, heterojen veri akışlarını standart bir protokol çerçevesinde birleştirerek üretim süreçlerinin daha verimli ve kesintisiz yönetilmesini sağlamaktadır. Aynı zamanda, OPC'nin sağladığı güvenilir veri iletimi, üretim hatlarında gerçek zamanlı karar alma süreçlerine katkıda bulunmaktadır. Endüstride kullanılan farklı sensörlerin ve makinelerin veri toplama yöntemleri değişiklik gösterebilir. OPC'nin bu heterojenliği yönetebilme kabiliyeti, farklı üretim tesislerinde ortak bir veri yönetim standardı oluşturulmasına imkan tanımaktadır. Özellikle büyük ölçekli üretim hatlarında, OPC protokolü ile toplanan verilerin merkezi analiz sistemlerine entegre edilmesi, kestirimci bakım ve üretim optimizasyonu açısından kritik öneme sahiptir. OPC protokolü ile FL' nin entegrasyonunun, üretim sektöründe hem veri güvenliğini artırdığını hem de süreç optimizasyonuna katkı sağladığını göstermiştir (Altınışık ve Bilgin, 2024). FL ile entegre edilmiş bir OPC altyapısı, üretim tesislerinin veri gizliliğini koruyarak, merkezi bir veritabanına ihtiyaç duymadan ortak bir model eğitmesine olanak tanımaktadır. Bu sayede, farklı fabrikalar arasında iş birliği yapılabilirken, her tesisin verileri yerel olarak kalmaya devam eder. Bu yaklaşım, hem veri güvenliğini sağlamakta hem de veri paylaşımından doğan yasal ve etik sorunları minimize etmektedir. OPC'nin üretim ortamlarında veri toplama süreçlerindeki rolünü ve bu


verilerin FL sistemlerinde kullanılmasının sunduğu gizlilik ve verimlilik avantajlarını ele almıştır (Altınışik ve Bilgin, 2024). OPC'nin sunduğu veri toplama mekanizması, FL ile birleştirildiğinde, üretim sistemlerinde daha ölçeklenebilir ve güvenilir bir veri işleme süreci oluşturulmaktadır. Özellikle, FL'in dağıtık yapısının OPC üzerinden gelen verilerle beslenmesi, model güncellemelerinin daha doğru ve kapsamlı olmasını sağlamaktadır. Bu, üretim süreçlerinde anormalliklerin tespit edilmesi, üretim hatalarının azaltılması ve süreç optimizasyonunun iyileştirilmesi açısından önemli bir avantaj sunmaktadır. OPC'nin sensörlerden gelen verilerin heterojen yapısını yönetme kapasitesini incelemiş ve bu protokolün üretim hatları arasındaki uyumu nasıl sağladığını göstermiştir (Kim ve diğ, 2010). Günümüz üretim tesislerinde, birbirinden farklı makineler ve otomasyon sistemleri kullanılmaktadır. Bu farklı sistemlerin birbirleriyle uyumlu çalışabilmesi, veri iletiminin tutarlı bir şekilde sağlanmasına bağlıdır. OPC'nin sağladığı standartlaşma, üretim hatlarındaki cihazların birbiriyle uyumlu bir şekilde çalışmasını kolaylaştırmakta ve üretim verimliliğini artırmaktadır. Üretim sektöründe kestirimci bakım, makinelerin arızalanmadan önce bakım ihtiyacının belirlenmesine olanak tanıyan kritik bir süreçtir. OPC protokolü, makinelerden gerçek zamanlı veriler toplayarak, olası arızaların önceden tahmin edilmesine ve bakım süreçlerinin optimize edilmesine yardımcı olmaktadır. FL ile birleştirildiğinde, farklı üretim hatlarından gelen bakım verileri merkezi olmayan bir model ile analiz edilerek daha genel geçer tahmin modelleri oluşturulabilir. Bu sayede, yalnızca tek bir tesise bağlı kalmadan, daha geniş çapta bir kestirimci bakım yaklaşımı uygulanabilir. Literatürde yapılan çalışmalar, FL, kestirimci bakım, kestirimci kalite ve OPC protokolünün üretim sektöründeki önemini açıkça ortaya koymaktadır (Altınışik ve Bilgin, 2024). Bu üç alanın entegrasyonu, üretim süreçlerini daha esnek, verimli ve güvenli hale getirmekte; aynı zamanda, veri paylaşımı konusundaki kısıtlamaları aşarak sektör genelinde inovatif çözümler sunmaktadır. OPC, üretim verilerinin toplanması ve işlenmesi için kritik bir altyapı sunarken, FL ile entegre edildiğinde, bu verilerin güvenli bir şekilde analiz edilmesi mümkün hale gelmektedir. Bu tez, literatürdeki mevcut çalışmalardan yararlanarak, bu teknolojilerin entegrasyonu ile üretim süreçlerinde nasıl somut faydalar sağlanabileceğini göstermeyi amaçlamaktadır. Bu kapsamda, OPC tabanlı veri toplama süreçlerinin FL ile nasıl birleştirilebileceği, üretim verilerinin nasıl güvenli bir şekilde analiz edilebileceği ve bu yöntemlerin endüstriyel sistemlerde nasıl uygulanabileceği detaylandırılacaktır. Önerilen entegrasyon modeli, üretim süreçlerinde daha yüksek

verimlilik, düşük maliyet ve iyileştirilmiş bakım süreçleri sunmayı hedeflemektedir. Literatürdeki çalışmalar, OPC ve FL kombinasyonunun, üretim sektöründe büyük veri analitiği ve süreç optimizasyonu açısından nasıl kritik bir rol oynadığını ortaya koymaktadır. FL, endüstriyel sistemlerdeki büyük veri analitiği ihtiyaçlarını karşılamak için giderek daha fazla uygulanmaktadır (Altınışık ve Bilgin, 2024). FL'in merkezi olmayan yapısı, üretim tesislerinin verilerini güvenli bir şekilde analiz etmesine olanak tanırken, kestirimci bakım, kalite kontrol sistemleri ve süreç optimizasyonu gibi alanlarda da önemli avantajlar sunmaktadır. Bu uygulamalar arasında kestirimci bakım, kalite kontrol sistemleri ve mevcut zorluklar için geliştirilen çözüm önerileri yer almaktadır (Altınışık ve Bilgin, 2024). Kestirimci bakım sistemleri, makine arızalarını önceden tahmin ederek bakım süreçlerini optimize etmekte ve üretim hattında kesintileri en aza indirmektedir. Kalite kontrol sistemleri, ürün kalitesini artırmak için anormallikleri tespit edebilmekte ve hatalı üretimin önüne geçmektedir. OPC ve FL'in birleşimi, bu sistemlerin daha güvenilir, ölçeklenebilir ve verimli çalışmasını sağlayarak, üretim sektöründe daha akıllı ve veri odaklı karar alma süreçlerinin önünü açmaktadır.



Şekil 2.4: OPC ve FL entegrasyonu akış diyagramı.

Şekil 2.4, bu entegrasyon sürecinin temel akışını görsel olarak sunmaktadır.



Şekil 2.5: Federe Öğrenme ve geleneksel model karşılaştırması.

Şekil 2.5'de, FL ile geleneksel merkezi modellerin doğruluk, eğitim süresi ve iletişim maliyeti açısından karşılaştırması sunulmuştur.


Yapılan literatür incelemesi kapsamında değerlendirilen 117 çalışmadan yalnızca 27'sinin üretim sektörü ile doğrudan ilişkili olduğu tespit edilmiştir. Bu durum, FL alanındaki çalışmaların yaklaşık %23'ünün üretim odaklı olduğunu göstermekte ve alandaki belirgin boşluğa işaret etmektedir. Bu tez çalışması, FL uygulamalarının üretim sektörü bağlamında ele alınması ve gerçek zamanlı üretim verileriyle modellenmesi açısından literatürdeki bu açığı kapatmaya yönelik özgün bir katkı sunmaktadır.

2.3.1 Kestirimci bakım uygulamaları

Kestirimci bakım, endüstriyel ekipmanların arızalanmadan önce bakım gereksinimlerini tahmin etmeyi amaçlayan bir yaklaşımdır (Chen ve diğ, 2023). Geleneksel reaktif bakım stratejilerinin aksine, kestirimci bakım, sensörler ve diğer veri kaynaklarından elde edilen bilgileri analiz ederek ekipmanların ne zaman bakım gerektireceğini belirler. Bu sayede, bakım süreçleri optimize edilerek plansız duruş süreleri en aza indirilir ve operasyonel verimlilik artırılır. FL, bu bağlamda, sensör verilerinin analiz edilmesi ve merkezi bir model oluşturulması için önemli bir araç olarak kullanılmaktadır (Abbas ve diğ, 2023). FL'in dağıtık yapısı sayesinde, farklı lokasyonlardaki üretim tesisleri, ekipmanlardan gelen verileri paylaşmadan ortak bir model eğitebilir. FL mimarisinin farklı üretim tesislerinden gelen verilerin gizliliğini koruyarak birleştirilmesini ve merkezi bir model oluşturulmasını mümkün kıldığını göstermiştir (Nguyen, 2021a). Özellikle küresel çapta faaliyet gösteren şirketler için bu yaklaşım, çeşitli tesislerden gelen heterojen verilerin güvenli bir şekilde


işlenmesine olanak tanımaktadır. Havacılık sektöründe uçak motorlarından gelen çok lokasyonlu verilerin FL ile analiz edilerek arızaların önceden tespit edilebileceğini vurgulamıştır (Khan ve diğ, 2021). Bu sayede, bakım süreçleri daha öngörülebilir hale gelirken, uçak güvenliği ve operasyonel süreklilik de artırılmaktadır. Kestirimci bakımın ekipmanların çalışma koşullarını sürekli izleyerek, potansiyel arızaları önceden tahmin etmeyi amaçlayan proaktif bir strateji olduğunu belirtmektedir (Zonta ve diğ, 2020). Ekipman sağlığının sürekli izlenmesi ve geçmiş verilerin analiziyle gelecekteki arızaların tahmin edilmesinin, geleneksel yöntemlere kıyasla bakım maliyetlerini düşürerek üretim sürekliliğini sağladığını ortaya koymuştur (Jardine ve diğ, 2006). Ceyhan ve Kasapbaşı'nın çalışması, üretim sistemlerinde kestirimci bakım modellerinin geliştirilmesine odaklanmış ve özellikle makine öğrenimi yöntemleriyle bu modellerin nasıl optimize edilebileceğini göstermiştir (Ceyhan ve Kasapbaşı, 2022). FL 'in kestirimci bakım süreçlerinde veri gizliliğini koruyarak güvenli model geliştirmede önemli bir rol üstlendiğini belirtmiştir (Nguyen, 2021a). Verilerin merkezi bir sunucuya aktarılmadan işlenmesi, endüstriyel süreçlerde veri gizliliğini korurken, aynı zamanda model performansını artırmaktadır. Dijital ikizlerin kestirimci bakım süreçlerinde kullanımını detaylandırmış ve bu süreçlerin sensör verileriyle nasıl beslendiğini kapsamlı biçimde incelemiştir (Kritzinger ve diğ, 2018). Dijital ikizler, fiziksel sistemlerin sanal modellerini oluşturarak ekipmanların gerçek zamanlı simülasyonlarını yapmaya olanak tanır. FL'in bu tür süreçlere entegre edilmesi, yalnızca veri güvenliğini artırmakla kalmayıp, aynı zamanda model doğruluğunu da artırdığı gösterilmiştir (Cetin, 2020). Dijital ikizler ve FL'in birleşimi, üretim süreçlerinin daha akıllı ve veri odaklı hale gelmesini sağlayarak kestirimci bakım uygulamalarının başarısını artırmaktadır. Kestirimci bakımın modern üretim sistemlerinde operasyonel verimliliği artırma, beklenmedik arızaları önleme ve bakım maliyetlerini düşürmede kilit bir strateji olduğunu vurgulamıştır (Lee ve diğ, 2015). Kestirimci bakım modellerinin heterojen veri setleri ile nasıl geliştirilebileceğini ve bu sayede bakım kararlarının daha isabetli hale getirilebileceğini göstermiştir (Zonta ve diğ, 2020). Bu çalışmada, FL'in veri güvenliği avantajları sayesinde, ekipmanların sağlığı hakkında daha fazla bilgi edinilmiş ve bu bilgilerle bakım süreçleri daha verimli hale getirilmiştir. Farklı üretim tesislerinden gelen verilerin birleştirilerek daha kapsamlı bir modelin oluşturulması, kestirimci bakım süreçlerinin daha doğru tahminler yapmasını sağlamaktadır. Kestirimci bakımın başarısının büyük ölçüde doğru veri toplama, etkin durum izleme ve analiz süreçlerine bağlı olduğunu

vurgulamaktadır (Jardine ve diğ, 2006). İlk olarak Microsoft tarafından geliştirilen bu protokol, zaman içinde evrilerek OPC UA (OPC Birleşik Mimarisi) adıyla platform bağımsız bir yapıya dönüşmüştür. OPC UA protokolünün sensörlerden gelen verileri standart bir veri modeli ile toplayarak, kestirimci bakım uygulamaları için gerekli veri altyapısını sağladığını belirtmiştir (Sakurada ve Leitão, 2020). Özellikle büyük ölçekli üretim tesislerinde, farklı sistemlerden gelen verilerin uyumlu bir şekilde yönetilmesi, kestirimci bakım modellerinin doğruluğunu doğrudan etkilemektedir. OPC UA'nın farklı kaynaklardan gelen verileri standart bir yapıda toplayarak kestirimci bakım uygulamalarında model doğruluğunu artıran temel bir araç olduğunu göstermiştir (Sakurada ve Leitão, 2020). OPC'nin sağladığı veri standardizasyonu, kestirimci bakım uygulamalarında sensörlerden gelen bilgilerin daha etkin kullanılmasını sağlamakta ve bakım süreçlerinin daha öngörülebilir hale gelmesine katkıda bulunmaktadır. Şekil 2.6, bu sürecin mimarisini görsel olarak göstermektedir.



Şekil 2.6: FL ile entegre edilmiş kestirimci bakım süreci.

Gelecekte, kestirimci bakım sistemlerinde FL ve OPC gibi teknolojilerin entegrasyonu, üretim süreçlerinde daha yüksek verimlilik ve sürdürülebilirlik sağlamaya devam edecektir.



Şekil 2.7: FL ile Kestirimci Bakım Kazanımları.


Şekil 2.7' de FL 'in kazandırdığı performans artışları grafiksel olarak sunulmaktadır.

2.3.2 Kalite kontrol sistemleri

Kalite kontrol süreçleri, üretim hatasızlığını sağlamak ve ürün kalitesini artırmak için kritik öneme sahiptir. Üretim süreçlerinde ortaya çıkabilecek kalite sorunlarının erken tespit edilmesi, yalnızca maliyetleri düşürmekle kalmaz, aynı zamanda müşteri memnuniyetini artırarak markaların rekabet avantajını güçlendirir. Günümüzde, kalite kontrol süreçlerinin daha verimli hale getirilmesi için makine öğrenimi ve büyük veri analitiği gibi teknolojilerden yararlanılmaktadır. Özellikle FL, üretim hatlarında yer alan farklı sensörlerden gelen verilerin analiz edilmesi için etkili bir araç olarak öne çıkmaktadır. Örneğin, otomotiv sektöründe, araç montaj süreçlerindeki kalite sorunlarını tespit etmek için FL kullanılabilir. Montaj hatlarında kullanılan sensörler, bileşenlerin hizalanması, tork seviyeleri ve montaj hassasiyeti gibi kritik parametreleri ölçerek kalite kontrol süreçlerine katkıda bulunur. FL tabanlı modeller, bu verileri analiz ederek, üretim sırasında olası kalite problemlerini tespit edebilir ve montaj süreçlerinin iyileştirilmesini sağlayabilir. FL'nin merkezi olmayan veriler üzerinde öğrenme yaparak üretim ve kalite kontrol süreçlerinde karar doğruluğunu ve süreç verimliliğini artırdığını göstermiştir (Nguyen, 2021b). Farklı üretim tesislerinden gelen verilerin FL kullanılarak merkezi veri paylaşımına gerek kalmadan analiz edilebileceğini ve bu sayede ürün kalitesinin standartlara uygunluğunun değerlendirilebileceğini göstermiştir (Lu ve diğ., 2020). Örneğin, gıda işleme tesislerinde sıcaklık, nem ve üretim sürecine ait diğer parametreler, FL ile analiz edilerek ürünlerin raf ömrü ve kalite standartlarına uygunluğu değerlendirilebilir. Kestirimci analiz ve üretim süreçlerine yönelik veri odaklı iyileştirmelerin, ürün geri çağırma oranlarını azaltmanın yanı sıra müşteri memnuniyetini de önemli ölçüde


artırabileceğini göstermiştir (Lee ve diğ, 2013). Gıda güvenliği açısından, FL'in merkezi olmayan yapısı, farklı üretim tesislerindeki kalite kontrol verilerinin güvenli bir şekilde analiz edilmesini mümkün kılarak, tüm üretim zincirinin daha güvenilir hale gelmesini sağlar. Geleneksel kalite kontrol yöntemlerinin reaktif bir yapıya sahip olduğunu, buna karşılık kestirimci kalite yaklaşımının üretim sırasında kaliteyi proaktif biçimde iyileştirmeyi hedeflediğini vurgulamıştır (Zhou ve diğ, 2015). Bu yöntem, geleneksel kalite kontrol yöntemlerinden farklı olarak, kalite problemlerini önceden tahmin eder ve üretim süreçlerindeki kusurları minimize eder. Kestirimci kalite süreçlerinde sensör verilerinin analizine odaklanmış ve bu verilerin yapay zeka algoritmalarıyla değerlendirilmesinin kalite problemlerini önlemede etkili olduğunu göstermiştir (Schulze ve diğ, 2019). Elektronik üretiminde kullanılan lehimleme makineleri, sıcaklık ve malzeme bileşimi gibi parametreleri sürekli olarak izleyerek, hatalı bileşenlerin üretim sürecinde ayıklanmasını sağlayabilir. Dijital ikiz teknolojilerinin ve kestirimci algoritmaların üretim süreçlerine entegre edilerek kalite kontrol uygulamalarının nasıl geliştirilebileceğini göstermiştir (Tao ve diğ, 2018). Dijital ikizler, fiziksel üretim sistemlerinin sanal simülasyonlarını oluşturarak, üretim süreçlerini analiz etme ve kaliteyi artırma konusunda güçlü bir araç sunmaktadır. Bu çalışmada, OPC protokolünün kalite verilerini toplamada ve FL'in bu verilerle modeller eğitmede sunduğu avantajlar vurgulanmıştır. Kestirimci kalitenin üretim süreçlerinde kaliteyi iyileştirmek, kusurlu ürün oranını azaltmak ve müşteri memnuniyetini artırmak için veri analitiği ve yapay zeka temelli yöntemleri kullanan yenilikçi bir yaklaşım olduğunu belirtmektedir (Schulze ve diğ, 2019). Örneğin, tekstil sektöründe, üretim hattında kumaş dokuma işlemi sırasında iplik gerilimi ve renk tonları gibi kritik kalite parametreleri izlenerek, hatalı kumaş üretiminin önüne geçilebilir. Kestirimci üretim yaklaşımlarının yalnızca üretim maliyetlerini düşürmekle kalmayıp, aynı zamanda ürün iadelerini ve müşteri şikayetlerini önemli ölçüde azalttığını ortaya koymuştur (Lee ve diğ, 2013). Üretim sistemlerinde sensör verilerinin nasıl analiz edilerek kestirimci kalite süreçlerinde kullanılabileceğini kapsamlı şekilde açıklamıştır (Schulze ve diğ, 2019). Bu çalışmada, üretim sırasında sıcaklık, basınç ve hız gibi OPC den alınabilen parametrelerin analizi ile kalite sorunlarının önlenebileceği vurgulanmıştır. Ayrıca, süreç parametrelerinin sürekli izlenmesi ve analiz edilmesi, kusurlu ürün oranının azaltılmasına katkı sağlamaktadır (George ve Pergert, 2023). Yang ve diğerlerinin çalışmasında, yapay zeka ve veri analitiği kullanılarak kalite kontrol süreçlerinin nasıl iyileştirilebileceği ele alınmıştır

(Zhang ve diğ, 2019). Bu çalışmada, FL'in kalite kontrol süreçlerinde veri gizliliği ve güvenliği sağlayarak daha geniş bir uygulama alanı sunduğu belirtilmiştir. Özellikle farklı üretim tesislerinden gelen kalite verilerinin paylaşılmadan analiz edilmesi, FL'in sunduğu en büyük avantajlardan biridir. Ayrıca, FL'nin üretim hatlarından elde edilen verileri merkezi bir ortamda toplamadan işleyerek, kalite kontrol süreçlerini hızlandırdığı ve daha güvenilir hale getirdiği vurgulanmıştır (Hegiste ve diğ, 2023). FL ve kestirimci kalite yaklaşımının entegrasyonu, üretim süreçlerinde kalite yönetimini bir üst seviyeye taşıyarak, verimliliği artırmakta ve maliyetleri düşürmektedir.



Şekil 2.8: FL ile kalite kontrol süreci akış diyagramı.

Üretim hatlarından gerçek zamanlı veri toplanması, FL ile analiz edilmesi ve kestirimci kalite uygulamalarının hayata geçirilmesi, endüstride sürdürülebilir ve daha etkin kalite yönetimi sağlamaktadır. Şekil 2.8'de, kalite kontrol süreçlerine FL entegrasyonu görsel olarak sunulmuştur.



Şekil 2.9: FL ile Kalite Kontrol Performans Göstergeleri.

Şekil 2.9, bu avantajların performans üzerindeki etkisini göstermektedir.

2.3.3 Mevcut zorluklar ve çözüm önerileri


Endüstriyel uygulamalarda FL'in benimsenmesi, veri heterojenliği, iletişim maliyetleri ve güvenlik gibi çeşitli zorluklarla karşılaşmaktadır (Islam ve diğ, 2023). Endüstriyel sistemlerde kullanılan sensörler, makineler ve üretim hatları farklı veri yapıları ve formatlarıyla çalıştığından, veri heterojenliği, FL modellerinin tutarlı bir şekilde eğitilmesini zorlaştırmaktadır (Li, 2022a). Üretim süreçlerinde kullanılan farklı cihazlardan toplanan verilerin değişkenlik göstermesi, model genelleştirilebilirliği açısından önemli bir problem oluşturmaktadır. Örneğin, bir üretim tesisinde kullanılan sıcaklık sensörleri ile bir diğer fabrikadaki basınç sensörleri farklı veri dağılımlarına sahip olabilir. Bu tür farklılıklar, merkezi olmayan bir öğrenme modeli olan FL'in etkinliğini doğrudan etkileyebilir. Bu sorunun üstesinden gelmek için adaptif optimizasyon algoritmaları geliştirilmiştir (Reddi ve diğ, 2020). Adaptif optimizasyon, FL modellerinin farklı veri kaynaklarına uyum sağlamasını kolaylaştıran bir yaklaşımdır. Böylece, farklı cihazlardan gelen verilerin etkili bir şekilde işlenmesi sağlanarak model doğruluğu artırılmaktadır. İletişim maliyetleri, FL uygulamalarında önemli bir zorluk olarak karşımıza çıkmaktadır (Konečný ve diğ, 2016). FL süreçlerinde model güncellemelerinin uç cihazlar ile merkezi sunucu arasında paylaşılması gerekmektedir. Özellikle büyük ölçekli endüstriyel sistemlerde, veri aktarımı sırasında oluşan gecikmeler ve yüksek bant genişliği gereksinimleri, FL'nin uygulanabilirliğini sınırlayabilir (Asad ve diğ, 2023). Bu sorun, özellikle bant genişliği kısıtlı olan fabrikalarda ve IoT cihazlarıyla çalışan sistemlerde önemli bir engel oluşturur. Model güncellemelerinin sıkıştırılması, FL'in iletişim maliyetlerini azaltmak için yaygın olarak kullanılan bir tekniktir. Ayrıca, yerel güncellemelerin belirli sayıda eğitim turundan sonra senkronize edilmesi (örneğin, FedAvg algoritması), gereksiz iletişim maliyetlerini azaltarak sistem verimliliğini artırmaktadır. Güvenlik ve mahremiyet, endüstriyel sistemlerde FL uygulamaları için kritik öneme sahiptir (Fu ve diğ, 2020). FL'in merkezi olmayan yapısı, avantajlı olsa da, model güncellemelerinin paylaşılması potansiyel gizlilik ihlalleri yaratabilir. Örneğin, bir üretim tesisinde kullanılan model parametreleri, hassas üretim süreçleri hakkında bilgi sızdırabilir. Bu nedenle, FL'in endüstriyel uygulamalarda başarılı bir şekilde kullanılabilmesi için güvenlik önlemlerinin güçlendirilmesi gerekmektedir. Veri şifreleme ve diferansiyel gizlilik teknikleri, endüstriyel verilerin korunmasını sağlamak için yaygın olarak kullanılmaktadır (Asad ve diğ, 2023). Özellikle

homomorfik şifreleme yöntemleri, FL'in veri gizliliğini korurken model performansını artırmasını mümkün kılmaktadır. Bu tür güvenlik önlemleri, FL'in sağlık, finans ve üretim gibi hassas verilerin işlendiği sektörlerde daha yaygın bir şekilde benimsenmesini kolaylaştırmaktadır. Kestirimci bakım, kalite kontrol ve diğer endüstriyel uygulama alanlarında etkili sonuçlar elde edilmesini sağlarken, mevcut zorlukların çözülmesi için geliştirilen yeni yöntemler, FL' nin daha geniş bir ölçekte benimsenmesine olanak tanımaktadır (Abdelli ve diğ, 2022).



Şekil 2.10: FL'de zorluklar ve çözüm yolları akış diyagramı.

Kalite kontrol süreçlerinde, farklı üretim tesislerinden gelen veriler FL kullanılarak analiz edilebilir ve böylece kalite standartlarına uyumluluk sağlanabilir. Günümüzde, yeni nesil optimizasyon algoritmaları, model sıkıştırma teknikleri ve gelişmiş güvenlik çözümleri, FL'in daha geniş çapta endüstriyel sistemlerde uygulanmasını mümkün kılmaktadır. Şekil 2.10, veri heterojenliği, iletişim ve güvenlik gibi temel FL zorluklarına yönelik çözüm yollarını özetlemektedir.




Şekil 2.11: Teknik çözümlerin FL üzerindeki etkisi.

Şekil 2.11'de, bu tekniklerin model performansı üzerindeki etkileri gösterilmektedir.


2.4 Veri Güvenliđi ve Gizlilik

FL, özellikle kiřisel ve endüstriyel verilerin korunmasının kritik olduđu alanlarda büyük avantaj sağlamaktadır. Sağlık, finans ve üretim sektörleri gibi yüksek güvenlik gereksinimleri olan alanlarda, verilerin merkezi bir yerde toplanması yasal ve etik zorluklara yol açabilir. FL, Avrupa Birliđi'nin GDPR gibi veri koruma düzenlemelerine uyumluluk açısından da avantaj sağlamaktadır. Hastaneler, finans kuruluşları ve üretim tesisleri, FL sayesinde verilerini paylaşmadan ortak modeller oluşturabilir ve böylece veri gizliliđini riske atmadan gelişmiş makine öğrenimi uygulamalarından faydalanabilir. Dağıtık öğrenme mimarisi, hem bireysel kullanıcılar hem de büyük ölçekli kurumsal sistemler için daha güvenli bir veri işleme süreci sunar. Örneđin, sağlık sektöründe FL, farklı hastanelerde bulunan hasta kayıtlarının merkezi bir veritabanına aktarılmadan analiz edilmesine imkan tanır. Bu, yalnızca hasta mahremiyetini korumakla kalmaz, aynı zamanda veri sızıntıları ve güvenlik ihlalleri gibi olası riskleri de en aza indirir. Geleneksel merkezi sistemlerde, veri transferi sırasında yaşanan yetkisiz erişimler, veri ihlalleri ve siber saldırılar önemli riskler oluşturabilir. FL ise merkezi olmayan yapısı sayesinde, modelin eğitimi için yalnızca model ağırlıklarının paylaşılmasını sağlayarak bu riskleri büyük ölçüde ortadan kaldırır. Yapılan araştırmalar, FL'in diferansiyel gizlilik, homomorfik şifreleme ve güvenli çok taraflı hesaplama gibi gelişmiş güvenlik teknikleriyle birleştirilerek veri koruma düzeyinin daha da artırılabilceđini göstermektedir. Özellikle hassas kiřisel verilerin işlendiđi sağlık, finans ve üretim sektörlerinde, FL'in sunduđu veri güvenliđi çözümlerine yönelik büyük bir ilgi bulunmaktadır. Özellikle sağlık, finans ve üretim gibi hassas verilerin bulunduđu sektörlerde, FL'in uygulanabilirliđi üzerine yapılan çalışmalar dikkat çekmektedir (Nevrataki ve diğ, 2023). Örneđin, radyoloji görüntüleme verileri, FL ile analiz edilerek merkezi bir veri havuzuna ihtiyaç duymadan daha doğru teşhis modelleri oluşturulabilir. Finans sektöründe, FL kullanılarak müşteri verilerinin korunması sağlanırken, dolandırıcılık tespiti gibi kritik görevler için ortak makine öğrenimi modelleri geliştirilebilir. Şekil 2.12, FL'in veri akış sürecinde güvenli ve gizli işleme yeteneđini görsel olarak göstermektedir.



Şekil 2.12: FL ile güvenli ve gizli veri işleme akışı.

Gelecekte, gelişmiş güvenlik protokolleri ile birleştirilen FL çözümleri, daha geniş çapta benimsenerek veri koruma standartlarını daha da ileriye taşıyacaktır.




Şekil 2.13: FL güvenlik yöntemlerinin karşılaştırması.

Şekil 2.13, bu tekniklerin güvenlik ve doğruluk açısından performans karşılaştırmasını sunmaktadır.

2.4.1 Diferansiyel mahremiyet


Diferansiyel mahremiyet, bireylerin gizliliğini korumak için kullanılan matematiksel bir yöntemdir ve FL uygulamalarında önemli bir yer tutar (Wei ve diğ, 2021). FL'in merkezi olmayan yapısı, verilerin doğrudan paylaşılmadan işlenmesine olanak tanırken, diferansiyel mahremiyet ise bu süreçte bireylerin bilgilerinin tamamen korunmasını sağlayan kritik bir güvenlik mekanizmasıdır. Bu yaklaşım, her bir kullanıcının verisinin, modele katkıda bulunurken anonim kalmasını sağlar (Gosselin ve diğ, 2022). Veri gizliliğini sağlamak adına kullanılan bu yöntem, modelin bireysel verileri doğrudan öğrenmesini engelleyerek, yalnızca genel desenleri yakalamasına izin verir. Böylece, farklı cihazlardan veya kurumlardan gelen verilerin güvenli bir

şekilde işlenmesi sağlanırken, bireylerin özel bilgileri korunmuş olur. Diferansiyel mahremiyetin temel ilkesi, bir veri setine bir bireyin verisi eklendiğinde veya çıkarıldığında, modelin çıktısının önemli ölçüde değişmemesini sağlamaktır (Dwork ve Roth, 2014). Bu özellik, FL modellerinin herhangi bir bireysel veri noktasına aşırı duyarlı hale gelmesini önleyerek veri gizliliğini garanti altına alır. FL bağlamında diferansiyel mahremiyet, özellikle model güncellemeleri sırasında uygulanmaktadır (Wei ve diğ., 2021). Modelin ağırlıkları veya gradyan değerleri, doğrudan paylaşılmadan önce rastgele gürültü eklenerek bireysel veri noktalarının tanımlanabilir olması engellenir. Bu süreç, FL modelinin güvenliğini artırarak veri sızıntısı riskini minimize eder. Gradyan paylaşımı sırasında gürültü eklenerek bireylerin verileri koruma altına alınır (Wei ve diğ., 2021). Bu teknik, modelin genel doğruluğunu korurken, aynı zamanda bireysel veri noktalarının çıkarılmasını imkansız hale getirir. Diferansiyel mahremiyet kapsamında kullanılan Laplace ve Gauss mekanizmaları, gizlilik bütçesini kontrol ederek verilerin istatistiksel olarak korunmasına yardımcı olur (Dwork ve Roth, 2014). Laplace mekanizması, modele eklenen rastgele gürültünün dağılımını kontrol ederken, Gauss mekanizması bireysel verilerin mahremiyetini koruyarak modelin güvenli bir şekilde eğitilmesini sağlar. Sağlık sektörü, diferansiyel mahremiyetin yaygın olarak uygulandığı alanlardan biridir (Dayan ve diğ., 2021). Hassas hasta verilerinin korunması, FL'in sağlık alanındaki en kritik avantajlarından biri olarak öne çıkmaktadır. Özellikle tıbbi görüntü analizi ve hasta teşhis modellerinde, diferansiyel mahremiyet, bireysel hasta bilgilerinin korunmasını sağlarken, FL modellerinin doğruluğunu artırmaktadır (Guan ve diğ., 2024). Diferansiyel mahremiyetin bir diğer avantajı, yasal düzenlemelerle uyumlu olmasıdır. Özellikle Avrupa Birliği'nin GDPR ve diğer uluslararası veri koruma yasaları, bireylerin gizliliğini korumayı zorunlu kılmaktadır (Guan ve diğ., 2024). Günümüz dijital dünyasında, bireylerin kişisel verilerini koruma gerekliliği giderek daha fazla önem kazanmaktadır. FL'in merkezi olmayan bir yapıya sahip olduğunu ve bu özelliği sayesinde verilerin cihazlardan dışarı çıkmadan analiz edilebildiğini göstermiştir (McMahan ve diğ., 2017). Merkezi sistemlere duyulan ihtiyacı ortadan kaldıran bu yaklaşım, hem büyük ölçekli veri analitiği sistemleri için güvenli bir çözüm sunmakta, hem de veri paylaşımı gereksinimlerini en aza indirerek gizlilik endişelerini ortadan kaldırmaktadır.



Şekil 2.14: Diferansiyel mahremiyet ile FL süreci.

FL' nin veri gizliliği ve güvenliği sağlama konusundaki uygulama alanlarını detaylandırmış ve bu yöntemin sağlık, finans ve üretim gibi sektörlerde nasıl kullanılabileceğini açıklamıştır (Kairouz ve diğ., 2021). Şekil 2.14 te diferansiyel mahremiyet ile FL süreci gösterilmiştir.



Şekil 2.15: Diferansiyel Mahremiyetin Etkileri.

Şekil 2.15 te ise diferansiyel mahremiyetin modelin doğruluğuna, mahremiyet skoruna ve veri sızıntı riskine karşı etkileri gösterilmiştir. Model doğruluğunda bir düşüş görülse de, mahremiyet skorundaki artış ve veri sızıntı riskinde ki düşüş diferansiyel mahremiyetin önemini göstermektedir.

3. KAVRAMSAL ÇERÇEVE

IoT teknolojilerinin yaygınlaşması, üretim süreçlerinde veri toplama ve yapay zekâ tabanlı kara destek sistemlerinin entegrasyonunu mümkün kılmaktadır (Chen ve diğ, 2023). Modern üretim sistemleri, otomasyon, yapay zeka ve büyük veri analitiği gibi teknolojilerle daha verimli hale getirilirken, bu süreçlerin temelinde güvenilir ve standart bir veri akışı sağlamak yatmaktadır. IoT tabanlı sistemlerde yoğun biçimde toplanan verilerin analizi, üretim gibi çeşitli dikey sektörlerde akıllı uygulamalara olanak tanır (Campolo ve diğ, 2023). Günümüz üretim tesisleri, farklı üretim hatlarından ve makinelerden gelen heterojen verilerin işlenmesini gerektirir. Endüstriyel sistemlerde üretilen verilerin üçüncü parti bulut altyapılarına aktarılması, veri güvenliği ve gizliliği açısından yeni riskler doğurmaktadır (Jalali ve Chen, 2023). OPC'nin sunduğu standartlaşma, özellikle büyük ölçekli üretim tesislerinde veri entegrasyonunu kolaylaştırarak, operasyonel verimliliği artırmaktadır. FL mimarileri, esneklik ve ölçeklenebilirlik avantajları sayesinde büyük ve dağınık cihaz gruplarında etkin biçimde uygulanabilmektedir (AY, 2023). Farklı işletim sistemleri ve donanımlarla uyumlu çalışabilmesi, OPC UA'nın üretim sistemlerindeki adaptasyonunu kolaylaştırmakta ve dijital dönüşüm sürecini hızlandırmaktadır. Özellikle sensör teknolojilerinin gelişmesi, M2M (Makineden makineye), HMI (İnsan Makine Arayüzü) haberleşmesi ve standartlarının olgunlaşması (OPC UA), nesnelerin interneti, yapay zeka ve büyük veri analitiği ile karmaşık sorunların üstesinden gelinebilmesi sağlanmıştır (Ceyhan ve Kasapbaşı, 2022). Örneğin, sıcaklık, basınç veya hız gibi parametrelerin anlık olarak izlenmesi, hem süreç optimizasyonu hem de kestirimci bakım uygulamalarında kritik bir rol oynar. Gerçek zamanlı veri toplama, üretim süreçlerinde anlık karar almayı mümkün kılar, böylece hataların önceden tespit edilerek operasyonel verimliliğin artırılması sağlanır. Kestirimci bakım, ekipmanların arızalanmadan önce bakımını yaparak plansız duruş sürelerini ve maliyetleri azaltır. Titreşim ve sıcaklık gibi verilerin analizi, potansiyel arızaların erken tespiti için kullanılır. Örneğin, rulmanların aşınma durumu, titreşim verileri ile belirlenebilir ve buna göre zamanında müdahale yapılır. Bu tür uygulamalar, bakım maliyetlerini düşürür, ekipman ömrünü uzatır ve üretim sürekliliğini artırır. Kestirimci kalite

uygulamaları da, üretim süreçlerindeki kalite sorunlarını önceden tahmin ederek ürün kalitesini iyileştirir.

3.1 Federe Öğrenme'nin Matematiksel Temelleri


FL' in matematiksel temelleri, global bir modelin eğitimi için dağıtık optimiasyon tekniklerine ve yerel modellerin parametrelerini birleştiren yöntemlere dayanır (Jalali ve Chen, 2023). FL, her istemcidenki verileri yerel tutarken paylaşımlı bir modelin işbirliğiyle eğitilmesini mümkün kılar (Li, 2020a). Bu süreç, özellikle büyük ölçekli sistemlerde veri gizliliğini korurken, model performansını da artırır. FL, birden fazla istemcide yerel olarak hesaplanan kayıpların toplamını oluşturan global bir kayıp fonksiyonunu minimize etmeyi hedefler (Kairouz ve diğ, 2021). FL'de global kayıp fonksiyonu, her istemcideki yerel kayıp fonksiyonlarının ağırlıklı ortalaması olarak tanımlanır (Kairouz ve diğ, 2021). Bu ağırlıklı ortalama, her istemci'nin veri büyüklüğüne göre belirlenir ve bu da daha büyük veri setlerine sahip istemci'lerin global model üzerinde daha fazla etkiye sahip olmasını sağlar. Her bir katılımcı, kendi yerel verileri üzerinde model eğitimi gerçekleştirir ve güncellenmiş model parametrelerini sunucuya gönderir (Akşit ve diğ, 2023). Merkezi sunucu, istemcilerden gelen model parametrelerini ağırlıklı ortalama yöntemiyle birleştirerek global modeli günceller (Kairouz ve diğ, 2021). Bu süreç, iteratif olarak tekrarlanarak daha iyi bir global modele ulaşılır (Kocadurdu, 2023). Bu iteratif yaklaşım, FL'in ölçeklenebilirliğini artırır ve büyük veri setlerinin analiz edilmesini mümkün kılar. Matematiksel olarak, her istemci kendi verisi üzerinde tanımlı kayıp fonksiyonunu minimize ederek yerel modelini eğitir (Kairouz ve diğ, 2021). Bu süreçte, SGD (Stokastik Gradyan İnişi) gibi optimizasyon algoritmaları kullanılır (Elmas ve diğ, 2023). Öğrenme sürecinde, her istemci modeli şu şekilde günceller:

$$w_k^{t+1} = w_k^t - \eta \nabla F_k(w_k^t) \quad (3.1)$$

Denklem 3.1 de, w_k^{t+1} , k -inci istemci'nin t -inci yinelemedeki model parametrelerini, η ise öğrenme oranını ifade eder. Bu güncelleme, istemci'nin kendi verisi üzerinde en iyi hale getirilmiş bir model oluşturmalarını sağlar. Daha sonra, merkezi sunucu, tüm istemci'lerden gelen parametreleri toplar ve ağırlıklı ortalama olarak global modeli günceller:

$$w^{t+1} = \sum_{k=1}^K p_k w_k^{t+1} \quad (3.2)$$

Denklem 3.2 de, p_k her istemci'nin veri kümesinin büyüklüğüne göre belirlenmiş ağırlık katsayısını ifade eder. FL sisteminin başarısı, istemcilerdeki verilerin homojenliğine bağlı olarak artmaktadır (Zhao ve diğ, 2018). Heterojen verilerin neden olduğu zorlukları aşmak için, yerel düzenleme terimleri, ağırlıklı ortalama yöntemleri ve özel optimizasyon teknikleri gibi stratejiler önerilmiştir (Li, 2020b). Bu stratejiler, farklı veri dağılımlarına sahip istemci'lerin eğitim süreçlerine katkısını optimize etmeyi ve modelin genelleme kapasitesini artırmayı hedefler. Özellikle üretim, sağlık ve finans sektörlerinde kullanılan FL modelleri için bu tür optimizasyon teknikleri büyük önem taşımaktadır. Veri gizliliği, FL sistemlerinin tasarımındaki en kritik unsurlardan biridir (Bonawitz ve diğ, 2019). FL, sadece model parametrelerini paylaşarak veri gizliliğini sağlamaya çalışsa da, yapılan çalışmalar bu parametrelerin kötüye kullanımının bireysel verilerin sızdırılmasına yol açabileceğini göstermektedir (Zhu ve diğ, 2019). Bu tür tehditleri önlemek için FL modellerinde güçlü gizlilik mekanizmaları kullanılmaktadır. FL süreçlerinde, bireysel veri gizliliğini sağlamak amacıyla diferansiyel gizlilik ve homomorfik şifreleme gibi yöntemler yaygın olarak kullanılmaktadır (Truex ve diğ, 2019). Diferansiyel gizlilik, modelin genel performansını büyük ölçüde etkilemeden bireysel verilerin korunmasını sağlar. Homomorfik şifreleme, model parametrelerinin şifreli biçimde işlenmesine olanak tanır; böylece veriler şifre çözme işlemi yapılmadan analiz edilebilir (Acar ve diğ, 2018). İstemci 1 ve istemci 2' ye ait yerel kayıplar, kendi verilerine özgü farklı optimum ağırlık değerlerine sahiptir. Buna karşılık, sunucu tarafında oluşturulan global model, tüm istemcilerin katkılarını dikkate alarak global kayıp fonksiyonunu minimize etmeye çalışır.



Şekil 3.1: Global ve Yerel Kayıp Fonksiyonları Eğrileri.

Ancak global minimum, her bir istemci için yerel optimumla tam olarak örtüşmeyebilir. Bu durum, FL sistemlerinde veri heterojenliği nedeniyle oluşan optimizasyon dengesizliklerini ifade eder. Şekil 3.1’de, FL süreçlerinde sunucunun rolünü ve istemciler arası model tutarlılığı açısından karşılaşılan temel zorlukları yansıtmaktadır.

3.1.1 Dağıtık optimizasyon

Dağıtık optimizasyon, FL paradigmasının temel bileşenlerinden biri olarak karşımıza çıkar (Chen ve diğ, 2023). Her istemcinin veri büyüklüğüne bağlı olarak belirlenen ağırlıklar, global modelin dengeli ve temsili bir şekilde öğrenmesini sağlar (McMahan ve diğ, 2017). Bu durum, daha büyük veri kümesine sahip olan istemci’lerin model üzerindeki etkisini artırırken, küçük veri kümelerine sahip istemci’lerin katkısını da göz ardı etmeden dengeleme mekanizmalarını devreye sokar. Örneğin, daha büyük bir veri kümesine sahip bir istemci’nin güncellemeleri, daha küçük veri kümesine sahip bir istemci’ye göre global model üzerinde daha fazla etkiye sahip olur. Bu tür ağırlıklı ortalama prensibi, sistemin genel performansını artırmakta ve veri dağılımından kaynaklanan dengesizliklerin etkilerini azaltmaktadır (McMahan ve diğ, 2017). Böylelikle, modelin yalnızca belirli veri kümelerine odaklanarak yanlı öğrenmesini önleyerek, tüm istemci’lerin katkı sağladığı adil bir öğrenme süreci yürütülmüş olur. SGD, büyük veri kümeleriyle çalışırken hesaplama maliyetlerini düşürmesi ve modelin daha hızlı öğrenmesini sağlaması nedeniyle yaygın olarak tercih edilmektedir. Bu süreç, istemcinin kendi verisi üzerinde tanımlı yerel kayıp fonksiyonunu minimize etmesini sağlar (McMahan ve diğ, 2017). Ancak, her istemci’nin bağımsız olarak optimizasyon gerçekleştirmesi, modelin genel performansı üzerinde farklı etkilere neden olabilir. Bu nedenle, global modele entegre edilen güncellemelerin

dengelenmesi ve farklı veri yapılarının optimizasyon sürecine etkisinin iyi yönetilmesi büyük önem taşımaktadır. Örneğin, bir istemci'nin yerel modeli, her iterasyonda aşağıdaki gibi güncellenir:

$$w_k^{t+1} = w_k^t - \eta \nabla F_k(w_k^t), \quad (3.3)$$

Denklem 3.3 de, w_k^t , k -inci istemci'nin model parametrelerini, η ise öğrenme oranını ifade eder. Gradyan hesaplaması sonucunda elde edilen bu güncellemeler, istemcinin kendi verisi üzerinde optimize edilmiş bir model oluşturmasını sağlar (McMahan ve diğ, 2017). Daha sonra bu güncellemeler merkezi sunucuya iletilir ve merkezi sunucu, bu yerel güncellemeleri birleştirerek global modeli günceller (Neto ve diğ, 2023). Global modelin güncellenmesi, istemci'lerden gelen parametrelerin ağırlıklı ortalamasının alınmasıyla gerçekleştirilir. Matematiksel olarak bu işlem denklem 3.4 te ki şekilde ifade edilir:

$$w^{t+1} = \sum_{k=1}^K p_k w_k^{t+1}. \quad (3.4)$$

FL süreci iteratif olarak devam eder ve her adımda global modelin performansı artar (Kairouz ve diğ, 2021). Her iterasyonda istemci'lerden gelen güncellemeler, merkezi sunucuda birleştirilerek modelin daha iyi genelleme yapması sağlanır. Dağıtık optimizasyon, FL' in hem ölçeklenebilirlik hem de gizlilik koruma hedeflerini gerçekleştirmede temel bir rol oynamaktadır (Kairouz ve diğ, 2021). FL sistemleri, veri dağılımı, işlem gücü ve ağ bağlantısı açısından heterojen ortamlarla çalıştığından, modelin tüm istemci'lere eşit şekilde adapte olması her zaman kolay değildir. Özellikle veri heterojenliği (non-IID), FL'in başarısını olumsuz etkileyen en kritik faktörlerden biridir (Zhao ve diğ, 2018). Farklı istemci'ler arasındaki veri dağılım farklılıkları, modelin belirli veri kümelerine aşırı uyum sağlamasına ve genelleme kapasitesinin düşmesine yol açabilir. Gerçek dünyadaki FL uygulamalarında, istemci'lerin veri dağılımları genellikle birbirinden farklıdır ve bu durum sistem performansını doğrudan etkileyebilir (Zhao ve diğ, 2018). Gerçek dünyada bazı istemciler yalnızca belirli sınıflara ait verilere sahipken, bazıları daha çeşitli veri setleri barındırabilir (Zhao ve diğ, 2018). Bu tür senaryolar, modelin genel performansını etkileyerek bazı istemci'ler için daha az etkili olmasına neden olabilir. İstemci'ler arası veri dağılımındaki farklılıklar, global modelin geliştirilebilirliğini azaltabilir ve bazı

istemcilerde modelin performansının düşmesine neden olabilir (Zhao ve diğ, 2018). Bu sorunları minimize etmek için farklı regularizasyon teknikleri uygulanabilir ve istemci'lerin model güncellemeleri, veri dağılımını dengeleyecek şekilde düzenlenebilir. Veri heterojenliğinin neden olduğu istemci sapmalarını gidermek için, istemci güncellemelerinin düzenlenmesi veya regularizasyon yöntemleri gibi stratejiler kullanılmaktadır (Li, 2020b). İletişim maliyetleri, dağıtık optimizasyonun bir diğer önemli zorluğudur. Her istemci döngü sonrasında parametre sonuçlarını sunucuya iletir. Bu, büyük ölçekli sistemlerde özellikle yüksek bant genişliği gerektiren bir süreçtir ve verinin sık sık güncellenmesini gerektirdiğinden iletişim yükünü artırabilir. Özellikle büyük modellerde, model parametrelerinin iletimi yüksek iletişim maliyetlerine neden olabilir (Kairouz ve diğ, 2021). Örneğin, derin öğrenme modellerinde milyonlarca parametre bulunabilir ve bu parametrelerin sürekli olarak iletilmesi ağ trafiğini artırabilir. FL'in büyük ölçekli uygulamalarda daha verimli çalışabilmesi için iletişim yükünü azaltmaya yönelik stratejiler geliştirilmiştir. Bu zorlukların üstesinden gelmek için iletişim verimliliğinin artırıcı gradyan sıkıştırma ve seyrek güncellemeler gibi stratejiler önerilmiştir (Konečný ve diğ, 2016). Bu teknikler, modelin yalnızca belirli kritik parametreleri güncellemesini sağlayarak gereksiz veri transferlerini en aza indirir. Bu tür stratejiler, yalnızca en anlamlı parametrelerin iletilmesini sağlayarak iletişim maliyetlerini önemli ölçüde azaltmaktadır (Konečný ve diğ, 2016). Örneğin, sadece belirli değişkenler veya büyük değişiklikler içeren parametre güncellemelerinin merkezi sunucuya gönderilmesi, ağ trafiğini önemli ölçüde azaltabilir ve FL süreçlerini daha verimli hale getirebilir. İstemciler arasındaki hesaplama kapasitesi farkları, dağıtık optimizasyonun zorluklarından biridir ve FL sistemlerinde adil güncellemeler tasarlamayı zorlaştırabilir (Li, 2020b). Örneğin, bazı istemci'ler yüksek işlem gücüne sahip GPU (Grafik İşlem Birimi)'lar kullanırken, diğerleri daha düşük kapasiteli donanımlarla çalışıyor olabilir. Hesaplama gücündeki farklılıklar nedeniyle bazı istemciler güncellemeleri zamanında tamamlayamayabilir; bu da global model güncelleme sürecinde gecikmelere yol açabilir (Chen ve diğ, 2023). FL'in etkin çalışabilmesi için, bu tür hesaplama farklılıklarını dengeleyecek yöntemlerin geliştirilmesi gereklidir. Asenkron optimizasyon teknikleri ve düşük güç tüketen güncelleme algoritmaları, istemciler arası gecikme ve kaynak sınırlamalarını azaltmak için etkili stratejiler sunar (Chen ve diğ, 2023). Böylece, yavaş çalışan veya düşük işlem gücüne sahip istemci'ler, sürecin genel performansını düşürmeden model eğitimine katkıda bulunabilir. Bu, özellikle büyük ve dağıtık sistemlerde model

eğitiminin kesintisiz devam etmesini sağlayarak sürecin daha verimli hale getirilmesine yardımcı olur. Dağıtık optimizasyona dair birçok zorluğa rağmen, FL; veri gizliliği, sistem merkezsizliği ve yerel verilerle öğrenme yeteneği gibi önemli avantajlar sunmaktadır (Kairouz ve diğ., 2021). Özellikle veri gizliliği açısından merkezi öğrenim yöntemlerine göre büyük bir üstünlüğe sahiptir. Modelin, farklı coğrafyalardaki veya farklı sektörlerdeki veri kümelerinden öğrenmesi, genel performansını artırarak daha geniş kullanım alanlarına hitap etmesini sağlar. Dağıtık optimizasyon, FL' nin temelini oluşturan bir matematiksel kavramdır. Yerel güncellemelerin merkezi birleştirme ile bir araya getirilmesi, FL'in ölçeklenebilir, verimli ve güvenli bir öğrenme yöntemi olmasını sağlar (Kairouz ve diğ., 2021). Veri heterojenliği, iletişim maliyetleri ve hesaplama kapasitelerindeki farklılıklar gibi zorluklar, dağıtık optimizasyon süreçlerinde ele alınması gereken önemli konular olsa da, bu zorlukları aşmak için geliştirilen yöntemler, FL'in endüstriyel ve akademik alandaki uygulamalarını genişletmektedir. FL alanında sürekli gelişen optimizasyon teknikleri, dağıtık öğrenme süreçlerini daha etkili hale getirmekte ve bu yöntemin farklı alanlarda yaygınlaşmasını sağlamaktadır (Kairouz ve diğ., 2021).

3.1.2 Model agregasyon stratejileri

Model agregasyon stratejileri, yerel güncellemelerin birleşimini sağlayarak FL sürecinde kritik bir rol oynamaktadır (McMahan ve diğ., 2017). FL nin amacı istemci lerde eğitilen modelin sunucuda birleştirilerek genel bir model oluşturmak olduğundan dolayı, bu birleştirme işleminin nasıl yapıldığı sistemin performansı üzerinde doğrudan etkilidir. Farklı istemci'lerin eğitim süreçleri sonucunda elde edilen parametreler, global modelin oluşturulmasında temel yapı taşlarını oluşturur ve bu süreçte kullanılan agregasyon yöntemleri, modelin doğruluk, genelleme yeteneği ve hesaplama verimliliği açısından büyük önem taşır. Bu nedenle, sunucunun güncellemeleri nasıl birleştirdiği, global modelin her istemci'ye eşit derecede adapte olup olamayacağını belirleyen kritik bir faktördür. Agregasyon sürecinin başarısı, federe öğrenme sistemlerinde hem model doğruluğunu hem de genel verimliliği belirleyen kritik bir faktördür (Kairouz ve diğ., 2021). Model güncellemeleri sırasında, istemci'lerin sahip olduğu veri büyüklüğü, veri çeşitliliği ve eğitim sürecindeki optimizasyon yöntemleri gibi faktörler göz önünde bulundurularak birleştirme işlemi gerçekleştirilmelidir. En yaygın kullanılan yöntem, FedAvg algoritmasıdır; bu yöntem, yerel güncellemeleri birleştirerek global modeli oluşturmak için kullanılır

(McMahan ve diğ, 2017). Bu yöntemde, her bir istemci'nin güncellemeleri sahip olduğu veri miktarına göre ağırlıklandırılarak birleştirilir. Bu, global modelin temsiliyetini artırmak için kullanılan yaygın bir stratejidir (McMahan ve diğ, 2017). Böylece, büyük veri kümeleri ile eğitilen istemci'ler, global modelin güncellenmesinde daha büyük bir etkiye sahip olurken, daha küçük veri kümelerine sahip istemci'lerin de katkısı dengelenmiş olur. Bu, modelin genel doğruluğunu artırırken, aynı zamanda belirli istemci'lerin verilerine aşırı bağımlı hale gelmesini önlemek için dengeleme stratejilerinin geliştirilmesini gerekli kılar. Özellikle heterojen veri dağılımlarına sahip FL sistemlerinde, FedAvg gibi ağırlıklı ortalama stratejileri modelin adil ve dengeli öğrenmesini sağlamak açısından kritik bir öneme sahiptir. Ağırlıklı ortalama matematiksel olarak şu şekilde ifade edilir:

$$w^{t+1} = \sum_{k=1}^K p_k w_k^{t+1}, \quad (3.5)$$

Denklem 3.5 te, w^{t+1} , global modelin $t + 1$ -inci iterasyondaki parametrelerini, w_k^{t+1} , k -inci istemci'nin $t + 1$ -inci iterasyondaki parametrelerini ve p_k , k -inci istemci'nin veri miktarına göre belirlenen ağırlığını ifade eder. FedAvg gibi yöntemler teorik olarak basit ve pratikte oldukça verimli olsa da, her senaryo için ideal olmayabilir (Kairouz ve diğ, 2021). Gerçek dünyadaki FL uygulamalarında, farklı istemci'ler genellikle birbirinden farklı veri dağılımlarına sahiptir. Bu durum istatistiksel heterojenlik olarak tanımlanır (Zhao ve diğ, 2018). Bu durum, modelin her istemci için eşit derecede iyi performans göstermesini zorlaştırabilir ve bazı istemci'lerin güncellemeleri, global model üzerinde diğerlerine kıyasla daha az etkiye sahip olabilir. Örneğin, bir istemci yalnızca belirli bir sınıfa ait veriler içerirken, başka bir istemci daha geniş bir veri çeşitliliğine sahip olabilir. Bu zorluğun üstesinden gelmek için geliştirilen stratejilerden biri, yerel güncellemeleri düzenleyici terimlerle dengelemeye çalışmaktır (Li, 2020b). Bu teknik, modelin her istemci'nin verisinden adil bir şekilde öğrenmesini sağlamak amacıyla güncellemeler üzerinde kontrol mekanizmaları uygulayarak model optimizasyonunu yönlendirmektedir. Böyle bir strateji, her istemci'nin katkısını daha dengeli hale getirebilir ve global modelin daha genelleştirilebilir bir performansa ulaşmasını sağlayabilir (Wen ve diğ, 2023). Örneğin, veri çeşitliliği daha düşük olan istemci'lerin model güncellemeleri düzenlenerek, global modelin diğer istemci'lerin verilerini öğrenme yeteneği

artırılabilir. Bu sayede, modelin belirli veri türlerine aşırı bağımlı hale gelmesi önlenir ve daha sağlam bir öğrenme süreci sağlanmış olur. Model agregasyon stratejilerinin bir diğer kritik unsuru veri güvenliğidir; çünkü paylaşılan parametrelerin gizliliğini korumak, sistem tasarımının temel bir bileşeni olarak ele alınmaktadır (Bonawitz ve diğ., 2019). İstemci'lerden gelen model güncellemeleri, bireysel veriler hakkında bilgi sızdırma potansiyeline sahiptir. Yapılan çalışmalar, gradyan bilgilerinden veri geri kazanımının mümkün olduğunu göstermektedir (Zhu ve diğ., 2019). Model güncellemelerinin analiz edilmesiyle, kötü niyetli saldırganlar bireysel istemci'lerin verileri hakkında tahminlerde bulunabilir ve bu da FL sistemlerinde güvenlik açıkları yaratabilir. Bu sorunu çözmek için, SA ve DP gibi gizlilik koruma stratejileri yaygın olarak kullanılmaktadır (Abadi ve diğ., 2016). Bu yöntem, istemci'lerin model güncellemelerini şifreleyerek, merkezi sunucunun yalnızca toplu model güncellemelerini almasını ve bireysel katkıları görememesini sağlar. Farklı uygulama senaryolarında FL'in etkinliği, model agregasyon stratejilerinin veri heterojenliği, iletişim kısıtları ve veri güvenliği gibi zorluklara yanıt verecek şekilde optimize edilmesine bağlıdır (Kairouz ve diğ., 2021). Bu optimizasyon süreci, modelin adil, ölçeklenebilir ve güvenli bir şekilde çalışmasını sağlamak için kritik öneme sahiptir. Agregasyon stratejileri, veri gizliliği açısından hassas olan alanlarda yaygın bir şekilde benimsenmesini sağlayan kritik bir bileşen olarak öne çıkar. Çizelge 3.1 de FL agregasyon yöntemlerinin karşılaştırılması gösterilmiştir.

Çizelge 3.1: FL agregasyon yöntemleri karşılaştırması.

Yöntem	Temel Özellik	Avantaj
FedAvg	Ağırlıkların ortalaması alınır	Basit ve yaygın
FedProx	Heterojenliğe karşı dayanıklılık için ceza terimi eklenir	Cihaz çeşitliliğine uyumlu
FedNova	Normalize edilmiş lokal güncellemeler uygulanır	Veri yoğunluk farklarını dengeler
FedOpt	Optimizasyon tabanlı yaklaşım, momentum destekli	Optimizasyon tabanlı yaklaşım, momentum destekli

Gelecekte, model agregasyon stratejilerinin daha da geliştirilmesiyle, FL'in daha geniş çapta benimsenmesi ve büyük ölçekli sistemlerde daha etkili bir şekilde kullanılması mümkün olacaktır.

3.2 Endüstriyel Veri Analizi

Endüstriyel veri analizi, modern üretim süreçlerinde verimliliği artırmak, maliyetleri düşürmek ve ürün kalitesini yükseltmek amacıyla büyük miktarda verinin toplanması, işlenmesi ve anlamlı bilgilere dönüştürülmesini içerir (Lee ve diğ, 2015). Bu süreç, özellikle Endüstri 4.0'ın getirdiği dijitalleşme ve otomasyon trendleriyle birlikte daha da önem kazanmıştır. Veri toplama ve analiz etme yeteneği, işletmelerin rekabet avantajı elde etmesinde kritik bir rol oynamaktadır. IoT cihazlarının yaygınlaşmasıyla birlikte, veri akışlarının gerçek zamanlı olarak yönetilebilmesi mümkün hale gelmiş ve bu durum, endüstriyel veri analizini işletmeler için stratejik bir gereklilik haline getirmiştir (Lee ve diğ, 2015). IoT cihazları, üretim süreçlerindeki veri toplama kapasitesini artırarak, daha hızlı ve daha doğru kararlar alınmasını sağlar. Endüstriyel veri analizi, üretim hatlarından sıcaklık, basınç, hız ve titreşim gibi fiziksel parametrelerin toplanmasıyla başlar (Lee ve diğ, 2015). Toplanan veriler, analiz amacıyla merkezi sistemlere veya bulut tabanlı platformlara aktarılır. Bu mimari, uzaktan yönetim ve büyük veri analitiği için olanak sağlar (Shi ve diğ, 2016). Bulut tabanlı çözümler, özellikle büyük veri kümelerinin işlenmesinde ve depolanmasında önemli bir rol oynar. Üretim süreçlerindeki anormalliklerin tespit edilmesi, üretim hatlarının daha verimli çalıştırılması ve ekipmanların arızadan önce bakımının yapılabilmesi bu analizlerin temel hedeflerindendir. Örneğin, bir üretim hattında sıcaklık değerlerinin sürekli izlenmesi, tolerans sınırlarının dışında kalan değerlerin tespit edilmesini ve böylece olası arızaların önlenmesini sağlar. Bu tür proaktif yaklaşımlar, üretim süreçlerinin kesintisiz bir şekilde devam etmesini sağlar. Endüstriyel veri analizi süreçlerinde, OPC gibi standart veri iletişim protokolleri; kontrol sistemleri, sensörler ve veri toplama altyapıları arasında güvenli ve standart veri alışverişini mümkün kılar (Mahmoud ve diğ, 2015). Endüstriyel veri analizinin en önemli uygulama alanlarından biri kestirimci bakım ve kestirimci kalitedir. Kestirimci kalite uygulamaları, müşteri memnuniyetini artırarak rekabet avantajı sağlamada kritik bir öneme sahiptir. Üretim süreçlerinde toplanan veriler hassas verilerdir ve üretime yönelik önemli detaylar içerir. Bu verilerin yetkisiz erişimlere karşı korunması büyük bir öneme sahiptir. Çizelge 3.2 de endüstriyel veri analizde karşılaşılan zorluklardan ve bu zorluklara karşı çözüm önerileri sunulmuştur. Dijitalleşme çağında endüstriyel veri analizine olan ihtiyaç giderek artmakta ve bu alan, üretim sektöründe rekabet avantajı sağlamak için vazgeçilmez bir araç haline gelmektedir.

Çizelge 3.2: Endüstriyel veri analizinde karşılaşılan zorluklar ve çözüm önerileri.

Zorluk	Çözüm
Veri Heterojenliği	Veri standardizasyonu ve ön işleme teknikleri
Gerçek Zamanlı İşleme Gereksinimi	Stream veri analitiği altyapısı kurulumu
Veri Güvenliği ve Mahremiyet	FL, şifreleme ve anonimleştirme yöntemleri
Model Genelleme Zorluğu	Transfer learning ve meta öğrenme

3.2.1 OPC protokolü ve veri yapıları

OPC, endüstriyel otomasyon sistemlerinde standartlaştırılmış veri toplama ve iletişimi mümkün kılmak amacıyla geliştirilmiştir (Campolo ve diğ, 2023). OPC UA yalnızca teknolojik uyumluluğu değil, aynı zamanda sistemler arası veri alışverişinde esnekliği de beraberinde getirmiştir. OPC' nin sadece Windows tabanlı sistemlerle sınırlı kalmayıp, açık kaynaklı ve diğer işletim sistemleriyle de uyumlu hale gelmesini sağlamıştır. Özellikle OPC UA adıyla modernize edilen versiyonu, endüstriyel veri toplama ve iletim süreçlerinde esneklik, güvenlik ve ölçeklenebilirlik sağlamaktadır (Ladegourdie ve Kua, 2022). Bu bağlamda OPC UA, endüstri 4.0'ın gereksinimlerine cevap veren gelişmiş bir veri iletişim çerçevesi sunmaktadır. Endüstriyel ortamlarda kullanılan sensörler, kontrol sistemleri ve diğer cihazlar genellikle farklı veri protokolleri üzerinde çalışır (Behnke ve Austad, 2023). Bu çeşitlilik, sistem mühendisleri ve operatörler açısından ciddi bir senkronizasyon sorunu yaratabileceğinden, ortak bir protokole duyulan ihtiyaç her geçen gün artmaktadır. OPC, endüstriyel otomasyon ve kontrol sistemlerinde farklı cihazlar ve sistemler arasında güvenli ve güvenilir veri alışverişini mümkün kılar (Hirsch ve diğ, 2023). Bu standartlaşma, veri yönetimi süreçlerini basitleştirirken, operatörlerin daha hızlı ve doğru kararlar almasını sağlar. Özellikle karar destek sistemleriyle entegre edildiğinde, OPC verilerinin değeri daha da artmaktadır. Gerçek zamanlı veri toplama, özellikle dinamik endüstriyel süreçlerde anlık müdahale ve optimizasyon imkanı sunar. Gerçek zamanlı izleme teknikleri, üretim süreçlerindeki sapmaları tespit ederek sistem hatalarının ve kalite problemlerinin önüne geçilmesini mümkün kılar (Elía ve Pagola, 2024). Erken uyarı sistemlerinin etkinliği, sistemin genel güvenilirliğini artıran temel bileşenlerden biridir. Bu erken uyarı sistemi, özellikle yüksek maliyetli arızaların önlenmesinde işletmelere büyük tasarruf sağlar. Örneğin, bir motorun hız ve sıcaklık değerleri sürekli olarak OPC protokolü üzerinden izlenebilir. Bu izleme işlemi, yalnızca verinin toplanması değil, aynı zamanda anlamlandırılmasını da içerdiğinden üretim sürecinde bilgiye dayalı karar almayı mümkün kılar. Bu bilgiler, motorun aşırı

ısının otomatik bir uyarı sistemini tetikleyebilir. Böylelikle, insan müdahalesi gerektirmeden otomatik tepkiler verilebilir. Bu tür otomasyonlar, insan hatalarını minimize eder ve sistem güvenilirliğini artırır. OPC UA'nın bilgi modeli, toplanan verilerin semantik olarak tanımlanmasını ve standart bir formatta sunulmasını sağlayarak birlikte çalışabilirliği destekler (Hirsch ve diğ, 2023). Bu yapı, veri işlemede tutarlılığı artırarak analiz süreçlerini daha hızlı ve güvenli hale getirir. Bu standart format, veri analizi ve raporlama süreçlerini büyük ölçüde kolaylaştırır. Her veri noktası, bir "tag" ile tanımlanır. Bu etiketleme, verinin kaynağını kolayca tanımlanabilir hale getirerek analizde şeffaflık sağlar. Bu tag, bir sensörün veya cihazın verisini benzersiz bir şekilde tanımlar ve kullanıcının bu veriye kolayca erişmesine olanak tanır. Örneğin, bir sıcaklık sensörü "Temp_Sensor_01" gibi bir tag ile işaretlenebilir. Bu şekilde bir etiketleme sistemi, özellikle yüksek hacimli veri akışının yönetilmesinde sistematik bir çözüm sunar. Bu tag ile ilişkilendirilen değer, sensörden gelen sıcaklık verisini ifade eder. Bu tür bir etiketleme sistemi, büyük ölçekli sistemlerde veri yönetimini son derece organize hale getirir. Buna ek olarak, her veri noktasına bir zaman damgası eklenir. Bu, geçmişe dönük analizler için zamansal bağlamda anlamlı sonuçlar elde edilmesini sağlar. Veri tazeliği, zaman serisi analizlerinde kritik bir faktördür ve zaman damgası bu tazeliği belirlemede temel bir rol oynar (Çakır, 2022). Zaman damgası, veri trendlerinin izlenmesi ve geçmiş verilere dayalı analizler yapılması için vazgeçilmezdir. OPC UA bilgi modeli, zaman damgası, mühendislik birimi ve veri kalitesi gibi nitelikleri içeren yapısıyla veri güvenilirliğini artırır (Hirsch ve diğ, 2023). Kalite metriği olarak isimlendirdiğimiz metrik, toplanan verinin doğruluğunu ve güvenilirliğini belirler. Bu metrik, özellikle kritik kararların alındığı durumlarda verinin güvenilirliğini garanti altına alır. Bu bilgi, operatörlerin hatalı verilere dayalı kararlar almasını engeller ve sistem güvenilirliğini artırır. Kalite metriği, veri odaklı karar alma süreçlerinde şeffaflık ve güven sağlar. Bu teknolojik yapı, üretim süreçlerinin daha güvenilir ve bütünsel bir şekilde yönetilmesine olanak tanır. Çizelge 3.3 te OPC UA'nın temel bileşenleri, açıklamaları ve önemlerinden bahsedilmiştir. OPC, endüstriyel veri yönetiminin geleceğini şekillendirmeye devam edecek gibi görünüyor.


Çizelge 3.3: OPC UA'nın temel bileşenleri ve açıklamaları.

Bileşen	Açıklama	Önemi
OPC UA Server	Veri sağlayan ve erişim izni olan istemci/sunucu	Veri kaynaklarının merkezidir
OPC UA İstemci	Veri çeken uygulama veya kontrol sistemi	Veriye erişimi yöneten temel bileşendir
Address Space	Veri nesnelerini hiyerarşik yapıda organize eder	Veri yapısının düzenli ve anlaşılır olmasını sağlar
Security Model	Şifreleme, kimlik doğrulama ve mesaj güvenliği içerir	Gizlilik ve bütünlük için gereklidir
Pub/Sub	Gerçek zamanlı veri dağıtımını sağlar	Veri yayılımını hızlandırır

3.2.2 Zaman serisi analizi

Zaman serisi analizi, akıllı üretim ortamlarında kestirimci bakım, arıza tespiti ve süreç optimizasyonu gibi uygulamalarda hayati bir rol oynar (Syed ve diğ., 2025). Bu analiz yöntemi, endüstriyel süreçlerde veriye dayalı karar alma süreçlerinin temelini oluşturur. Özellikle üretim sistemlerinin gerçek zamanlı kontrolünde karar vericilerin elindeki en önemli araçlardan biridir. Zaman serisi verileri, belirli bir süre boyunca düzenli aralıklarla ölçülen bir dizi gözlemi ifade eder. Bu veriler, süreçlerin dinamik yapısını anlamak ve geleceğe yönelik proaktif adımlar atmak için vazgeçilmezdir. Ayrıca, bu veri yapısı sayesinde süreçlerdeki istikrarsızlıklar veya anomaliler daha kolay fark edilebilir. Bu veriler, geçmişteki eğilimleri ve desenleri anlamak, gelecekteki olayları tahmin etmek ve üretim süreçlerini iyileştirmek için analiz edilir. Özellikle IIoT (Endüstriyel IoT) uygulamalarında, zaman serisi analizi büyük veri kümelerinin anlamlandırılmasında kilit bir rol oynar. Giderek yaygınlaşan akıllı fabrika uygulamalarında bu analizler, sistemlerin kendi kendine öğrenmesini ve tepki vermesini de mümkün kılar. Endüstriyel ortamlarda sensörler ve makinelerden elde edilen zaman serisi verileri, üretim süreçlerinin izlenmesi ve optimizasyonu açısından kritik öneme sahiptir (Yan ve diğ., 2024). Bu sayede karar destek sistemlerinin doğruluğu artmakta ve operatör müdahaleleri daha isabetli hale gelmektedir. Bu veriler, operasyonel verimliliği artırırken, maliyetleri düşürme potansiyeli de sunar. Zaman serisi analizinin temel amacı, verilerdeki eğilimleri, mevsimselliği ve rastgele dalgalanmaları belirlemektir. Bu bileşenlerin doğru bir şekilde analiz edilmesi, süreçlerin daha iyi anlaşılmasını ve kontrol edilmesini sağlar. Bu analizler, yalnızca geçmiş verilerle değil, ileriye dönük tahminler ve stratejik planlamalarla da desteklenmelidir. Sıcaklık, basınç veya enerji tüketimi gibi veriler, üretim


süreçlerindeki performansın sürekli izlenmesi için ideal bir kaynaktır. Ayrıca bu gözlemler, süreçlerin dinamik özelliklerinin modellenmesinde önemli bir temel sağlar. Endüstriyel ortamlarda elde edilen zaman serisi verilerindeki eğilimler, operasyonel anormalliklerin erken tespitine ve süreç verimliliğinin artırılmasına katkı sağlar (Yan ve diğ, 2024). Erken uyarı sistemleri, bu tür analizler sayesinde olası arızaları önceden tespit ederek plansız duruş sürelerini azaltır. Süreç sürekliliği ve arıza önleme açısından zaman serisi analizinin rolü her geçen gün daha da önem kazanmaktadır. Uzun vadeli kaynak planlaması ve çevresel etki değerlendirmeleri açısından bu bilgiler son derece değerlidir. Bu tür bir eğilim, uzun vadeli planlama ve kaynak yönetimi açısından önemli bilgiler sunar. Özellikle enerji verimliliği projelerinde, bu tür eğilimler büyük bir rol oynar. Mevsimsellik (seasonality), verinin düzenli aralıklarla tekrarlayan desenlerini ifade eder. Bu bileşen, özellikle talep dalgalanmalarının yoğun olduğu sektörlerde önemlidir. Bu desenler, kaynak tahsisi ve vardiya planlamasında daha isabetli kararlar alınmasına yardımcı olur. Rastgele dalgalanmalar (gürültü), verideki öngörülemez ve düzensiz değişimlerdir. Bu bileşen, genellikle sistemdeki ani değişiklikleri veya dış etkenleri yansıtır. Bu bileşenler, genellikle üretim sürecindeki ani değişiklikleri veya beklenmedik olayları temsil eder. Bu tür dalgalanmalar, özellikle kestirimci bakım uygulamalarında dikkate alınması gereken bir faktördür. Çünkü bu tür beklenmedik değişimler, ekipman ömrünü kısaltan faktörlerin habercisi olabilir. Şekil 3.2 de bir zaman serisinin temel bileşenleri gösterilmektedir. Grafik üzerinde trend, mevsimsellik ve rastgele gürültü ayrı ayrı görselleştirilmiştir. Zaman serisi analizinin başarısı, verinin trend, mevsimsellik ve rastgele bileşenlerine doğru şekilde ayrıştırılmasına bağlıdır (Brockwell ve Davis, 2022). Özellikle makine öğrenimi modelleri, bu bileşenlerin ayrıştırılmasında büyük bir rol oynar. Örneğin, rastgele dalgalanmaların doğru bir şekilde modellenmesi, kestirimci bakım algoritmalarının daha güvenilir tahminler yapmasını sağlar.



Şekil 3.2: Zaman serisi verisinin bileşenleri.

Endüstriyel uygulamalarda kullanılan zaman serisi analiz yöntemleri, verinin özelliklerine ve uygulama senaryosuna bağlı olarak değişir (Farahani ve diğ, 2023). Bu esneklik, zaman serisi analizinin farklı endüstriyel ihtiyaçlara uyarlanabilmesini sağlar. Analiz amaçlarına göre kullanılan modeller, veri ön işleme süreçleriyle desteklendiğinde çok daha yüksek doğruluk sunar. Yaygın olarak kullanılan yöntemler arasında otokorelasyon ve mevsimsel analiz yer alır. Bu yöntemler, verideki tekrarlayan desenlerin anlaşılması için temel bir araçtır. Verideki yinelenen desenleri ve zaman bağımlılığını belirlemek için otokorelasyon fonksiyonları kullanılır (Kumari ve diğ, 2021). ARIMA ve SARIMA modelleri, özellikle durağan olmayan ve mevsimsel bileşenler içeren zaman serilerinde, basit yapıları ve etkili performansları sayesinde yaygın olarak tercih edilmektedir (Athiyarath ve diğ, 2020). Bu modeller, özellikle karmaşık zaman serisi verilerinin analizinde etkilidir. Örneğin, ARIMA modelleri, üretim süreçlerinde enerji tüketimi veya makine arıza oranlarını tahmin etmek için kullanılabilir. Bu tahminler, işletmelerin kaynak yönetimi ve kapasite planlamasını daha etkin yapmasına olanak tanır. Makine öğrenimi yaklaşımlarının zaman serisi analizinde kullanımı giderek artmaktadır. Bu yaklaşımlar, özellikle büyük veri kümelerinin analizinde büyük bir potansiyel sunar. LSTM (Uzun Kısa Süreli Bellek) ağları, sıralı verilerdeki uzun vadeli bağımlılıkları öğrenebilme kabiliyetleri sayesinde zaman serisi tahmininde oldukça etkili yöntemler arasında yer almaktadır (Pacella ve Papadia, 2021). Bu yöntemler, geleneksel yöntemlerle modellenemeyen karmaşık ilişkileri ortaya çıkararak tahmin gücünü artırır. Kestirimci bakım uygulamalarında zaman serisi analizi, makinelerin çalışma durumlarını izlemek ve gelecekteki arızaları tahmin etmek için kullanılır. Zaman serisi analizi, kestirimci kalite süreçlerinde de önemli bir rol oynar (Zhang ve diğ, 2019). Üretim süreçlerinde kaliteyi etkileyen faktörler, genellikle zamanla değişen parametrelerdir. Bu

parametrelerin sürekli izlenmesi, kalite sorunlarının önlenmesinde büyük bir avantaj sağlar. Örneğin, bir otomotiv üretim hattında boyama işlemi sırasında sıcaklık ve nem oranı zamanla değişebilir. Bu tür parametrelerin kontrol altında tutulması, ürün kalitesini doğrudan etkiler. Bu parametrelerin düzenli olarak izlenmesi ve analiz edilmesi, kalite sorunlarının önlenmesine yardımcı olur. Bu tür analizler, kalite kontrol süreçlerinde büyük bir verimlilik sağlar. Şekil 3.3 , farklı zaman serisi tahmin yöntemlerinin MAPE (Ortalama Mutlak Yüzde Hatası) değerlerine göre karşılaştırmasını göstermektedir. Bu sonuçlar, LSTM modelinin diğer yöntemlere kıyasla daha isabetli tahminler ürettiğini ortaya koymaktadır. Bu gibi durumlarda, verinin doğru biçimde etiketlenmesi, zaman damgalarının senkronize olması ve sensör kaynaklı hataların filtrelenmesi gerekmektedir.



Şekil 3.3: Zaman serisi tahmin yöntemlerinin MAPE karşılaştırması.

Çizelge 3.4, farklı zaman serisi modelleme yöntemlerinin tipik uygulama alanlarını ve öne çıkan avantajlarını özetlemektedir. ARIMA ve SARIMA, sırasıyla durağanlık ve mevsimsellik özellikleri taşıyan ekonomik ve talep verilerinde öne çıkarken; LSTM, karmaşık örüntülere sahip IoT ve üretim verilerinde yüksek doğruluk sağlamaktadır. Exponential Smoothing ise sade yapısı sayesinde hızlı ve pratik çözümler sunmaktadır.

Çizelge 3.4: Zaman serisi yöntemleri, uygulama alanları ve avantajları.

Yöntem	Uygulama Alanı	Avantajı
ARIMA	Ekonomik ve finansal veriler	Durağan seriler için iyi performans
SARIMA	Mevsimsel talep tahminleri	Mevsimsellik barındıran verileri iyi işler
LSTM	Karmaşık veri örüntüleri (IoT, üretim)	Öğrenme kapasitesi yüksek, doğruluğu yüksek
Exponential Smoothing	Basit ve düz seyirli zaman serileri	Hızlı ve kolay uygulanabilir

3.2.3 Anomali tespiti

Endüstri 4.0 ve dijitalleşme ile birlikte üretim süreçlerinin yönetiminde veri odaklı teknolojilerin önemi artmıştır. Artık üretim yalnızca fiziksel çıktı üretmekten ibaret değil, aynı zamanda veriye dayalı kararlarla yönlendirilen bir süreç haline gelmiştir. Bu dönüşüm, üretim süreçlerinin daha akıllı, esnek ve verimli hale gelmesini sağlamaktadır. OPC protokolü, endüstriyel veri toplama ve analiz süreçlerinde standartlaşmayı sağlayan önemli bir araçtır. OPC UA, endüstriyel sistemlerin gelişen ihtiyaçlarına yanıt verecek şekilde protokolün güncellenmesini ve yaygınlaşmasını sağlamıştır. Bu evrim, OPC'nin sadece Windows tabanlı sistemlerle sınırlı kalmayıp, açık kaynaklı ve diğer işletim sistemleriyle de uyumlu hale gelmesini sağlamıştır. OPC UA, veri güvenliği, esneklik ve ölçeklenebilirlik özellikleri ile endüstriyel otomasyon alanında geniş bir uygulama alanına sahiptir. Bu özellikler, özellikle farklı departmanların eş zamanlı olarak veri alışverişi yapmasını mümkün kılar. Bu özellikler, OPC UA'yı modern endüstriyel uygulamaların vazgeçilmez bir parçası haline getirmiştir. Gerçek zamanlı veri toplama, üretim süreçlerindeki anormalliklerin erken tespit edilmesini sağlar ve bu sayede olası arızaların veya kalite sorunlarının önüne geçilebilir. Anomali tespiti açısından da bu sistemler, olaylar meydana gelmeden önce önlem alınmasını mümkün kılar. Kestirimci bakım arızaların önceden tespit edilmesine olanak tanır. Bu tür uygulamalar ile yüksek maliyetli arızalar önlenir ve tasarruf sağlanır. Bu verilerin zaman serisi şeklinde analiz edilmesi, anormalliklerin normal varyans dışındaki davranışlarla tanımlanmasını kolaylaştırır. Bu analizler, operasyonel verimliliği artırırken, bakım maliyetlerini de düşürür. Bu tür proaktif yaklaşımlar, sistem güvenilirliğini artırır ve operasyonel sürekliliği sağlar. FL, yerel veriler ve cihazlardaki işlem gücü kullanılarak merkezi olmayan bir eğitim süreci sağlar; bu sayede iletişim yükü azalır ve büyük ölçekli veri kümeleri üzerinde analiz

yapılabilir (Wen ve diğ, 2023). Bu tür uygulamalar, özellikle enerji verimliliği ve maliyet optimizasyonu açısından büyük bir avantaj sağlar. OPC ve FL’ nin bir arada kullanılması, üretim sektöründeki dijital dönüşümü daha ileri bir seviyeye taşımaktadır. Bu iki teknolojinin birlikte kullanılması, yalnızca veri işleme değil, aynı zamanda karar destek sistemlerinin güvenliğini de artırır. Bu sinerji, üretim süreçlerinde operasyonel verimliliği artırırken, veri gizliliği ve güvenliğini de üst düzeye çıkarır. OPC, üretim süreçlerinden güvenilir veri sağlarken, FL bu verilerin güvenli ve etkili bir şekilde analiz edilmesini mümkün kılar (Campolo ve diğ, 2023). Bu esneklik, işletmelerin dinamik ortamlara ve gelecekteki olası zorluklara karşı daha sağlam bir şekilde uyum sağlamasına olanak tanır (Mehta ve Shao, 2023). Bu tür bir yaklaşım, işletmelerin rekabet avantajını korumasına yardımcı olur. Endüstri 4.0’ın gereksinimlerine yanıt verebilmek için dijitalleşme sürecinde veri odaklı teknolojilere yapılan yatırımların artırılması kritik öneme sahiptir. Bu yatırımlar, işletmelerin dijital dönüşüm süreçlerini başarılı bir şekilde yönetmelerini sağlar. OPC ve FL gibi yenilikçi yaklaşımlar, özellikle kestirimci bakım ve kalite uygulamalarında büyük bir potansiyel sunar. Özellikle kestirimci bakım ve kalite uygulamalarında bu teknolojilerin entegre bir şekilde kullanılması, işletmelerin rekabet avantajı elde etmelerinde ve dijital dönüşüm süreçlerini başarılı bir şekilde yönetmelerinde belirleyici bir rol oynar.

Çizelge 3.5: Anomali tespit yöntemleri karşılaştırması.

Yöntem	Avantaj	Kısıt
Z-skör	Basit ve hızlı	Sadece normal dağılım varsayımıyla çalışır
Isolation Forest	Yüksek boyutlu verilerde etkili	Tüm anomali türlerini yakalayamayabilir
Otokodlayıcı	Veri sıkıştırma ile temsil gücü yüksek	Aşırı öğrenme riski, eğitim gerektirir
LSTM	Zaman serilerine özel güçlü öğrenme kapasitesi	Veri miktarı ve eğitim süresi gereksinimi yüksek

Çizelge 3.5, farklı anomali tespit yöntemlerinin avantajlarını ve sınırlılıklarını karşılaştırmalı olarak sunmaktadır. Z-skör yöntemi basitliği ve hızıyla öne çıkarken, sadece normal dağılım varsayımı altında etkilidir. Isolation Forest, yüksek boyutlu verilerde başarı gösterse de her tür anomaliyi tespit edemeyebilir. Otokodlayıcı, veriyi sıkıştırarak temsil etme gücü yüksek bir yöntem olup aşırı öğrenme riski taşır ve eğitim


gerektirir. LSTM ise zaman serisi verileri için güçlü öğrenme yeteneđi sunsa da yüksek veri miktarı ve uzun eđitim süresi gerektirir.



4. METODOLOJİ

Bu bölümde çalışmanın yöntemi, sistem mimarisi, veri toplama ve ön işleme adımları, model seçimi ve validasyon stratejisi, FL implementasyonu, veri güvenliği önlemleri ile performans metrikleri ve değerlendirme kriterleri ayrıntılı olarak açıklanmaktadır. Her bir adım, uygulama sürecinde karşılaşılan zorluklara çözüm getirmek amacıyla yapılandırılmıştır. Bu yapı, çalışmanın temelini oluşturan dağıtık öğrenme paradigmasının gerçekleştirilmesini desteklemek üzerine tasarlanmıştır. Böylece sistem, hem teorik olarak tutarlı hem de pratikte uygulanabilir bir yapıya kavuşturulmuştur. Bu bölümde ağırlıklı olarak uygulama senaryosu, veri işleme adımları, güvenlik protokolleri ve performans değerlendirme yaklaşımı ele alınmaktadır. İstemciler, verilerini kullanarak yerel eğitim gerçekleştirir; yalnızca eğitilmiş model parametrelerini merkezi sunucuya iletirler ve sunucu bu parametreleri birleştirerek küresel modeli günceller (Nasim ve diğ., 2025). Böylece verinin fiziksel olarak paylaşılmasına gerek kalmadan, model iş birliği sağlanmıştır. Bu tasarım, hem veri gizliliğini artırmakta hem de merkezi sunucunun hesaplama yükünü azaltmaktadır. Buna bağlı olarak, TLS (Taşıma Katmanı Güvenliği) ve DTLS (Datagram Taşıma Katmanı Güvenliği) gibi çeşitli hesaplama açısından hafif protokoller önerilmiş ve uygulanmıştır (Jalali ve Chen, 2023). Böylece hem performans hem de güvenlik gereklilikleri aynı anda karşılanmıştır. Bu yapı, çeşitli istemcilerin ağ üzerinden sunucuyla güvenli şekilde iletişim kurmasına olanak tanımıştır (Boiano ve diğ., 2024). Bu tür bir iletişim protokolü, özellikle endüstriyel ortamlarda veri güvenliğini sağlamak için kritik öneme sahiptir. Veri toplama ve ön işleme aşamasında, OPC protokolü kullanılarak sensörlerden çeşitli özelliklerde gerçek zamanlı olarak toplanmıştır. Bu verilerin güvenilir ve anlık olarak toplanması, modelin doğruluğu için kritik bir gerekliliktir. Bu veriler, zaman damgası ve kalite metriği gibi ek bilgilerle birlikte kaydedilerek analiz için hazırlanmıştır (Boiano ve diğ., 2024). Bu meta veriler, zaman serisi analizleri ve güvenilirlik testlerinde aktif şekilde kullanılmıştır. Eksik verilerin tamamlanması ve anomali tespiti süreçlerini entegre eden yaklaşımlar, veri temizleme sürecinin etkinliğini artırmaktadır (Xiao ve Fan, 2024). Böylece modelin eğitimi için yalnızca güvenilir ve bütünlüklü veri

kullanılmıştır. Bu adımlar, modelin eğitim sürecinde daha güvenilir ve tutarlı sonuçlar elde edilmesini sağlamaktadır. FL sistemimiz için HTTP (Hiper Metin Aktarım Protokolü) ve gRPC (Uzaktan Prosedür Çağrılar) haberleşme protokollerini kullanarak bir karşılaştırma sunuyoruz. Bu karşılaştırma, gRPC çerçevesinin HTTP protokolünden daha hızlı ve daha iyi ölçeklenebilirliğe sahip olduğunu göstermektedir. Bunun temel nedeni, bu iki farklı haberleşme protokolünün mimarilerinin ve mesajları sıkıştırma yöntemlerinin farklı olmasıdır (Lu, 2020). Gecikmelerin ve veri kayıplarının minimize edilmesi için ağ testi simülasyonları yapılmıştır. FedAvg algoritması, her bir istemcinin sahip olduğu veri miktarına orantılı olarak ağırlıklı ortalama alınması prensibine dayanmaktadır (Li, 2020a). Böylece daha büyük veri kümeleriyle eğitilen istemcilerin modele katkısı daha yüksek olmuştur. Haberleşme süresince model parametrelerinin optimize edilmesi ve iletişim maliyetlerinin azaltılması amacıyla gradyan sıkıştırma yöntemleri uygulanmıştır (Hu ve diğ, 2024).



Şekil 4.1: FL sistem mimarisi.


Bu yöntemler, büyük veri setleriyle çalışan FL sistemlerinde zamandan ve bant genişliğinden tasarruf edilmesini sağlamıştır. Bu tür optimizasyonlar, özellikle büyük ölçekli endüstriyel uygulamalarda önemli bir zaman ve kaynak tasarrufu sağlamaktadır. Şekil 4.1 de, istemci-sunucu temelli FL yapısının genel mimarisi sunulmaktadır.

Çizelge 4.1: OPC tabanlı veri toplama özellikleri.

Sensör	Ölçülen Özellik	Birim	Frekans
OPC1	Sıcaklık	°C	1 sn
OPC2	Basınç	bar	1 sn
OPC3	Çekme Kuvveti	N	1 sn

Çizelge 4.1, OPC protokolü üzerinden toplanan sensör verilerinin temel özelliklerini göstermektedir. Sıcaklık, basınç ve çekme kuvveti gibi fiziksel büyüklükler farklı

sensörler aracılığıyla ölçülmekte ve her biri saniyelik frekansla kaydedilmektedir. Bu yapı, gerçek zamanlı üretim verisinin izlenmesi ve analizine olanak tanımaktadır.



Şekil 4.2: Diferansiyel gizlilikle ağırlık paylaşımı.

Şekil 4.2 , diferansiyel gizlilik uygulanan bir FL senaryosunda ağırlık paylaşım sürecini görselleştirmektedir. Orijinal model ağırlığına belirli bir ölçüde rastgele gürültü eklenerek gizli ağırlık (paylaşılan versiyon) elde edilmiştir. Bu yöntem, istemciden sunucuya gönderilen model parametrelerinin doğrudan ifşasını önleyerek veri gizliliğini koruma amacı taşır. Grafik, gizlilik ile doğruluk arasında kurulan dengeyi basit biçimde ortaya koymaktadır. Model ağırlıkları, istemci tarafında belirli bir epsilon parametresine göre rastgele gürültü ile korunur ve bu şekilde merkezi sunucuya iletilir.

Algorithm 1 Erken Durdurma ile Model Eğitimi

```

1: ErkenDurdurma'yı Başlat:
2:   izlenecek_metrik ← doğrulama başarımı
3:   sabır ← 10 dönem
4:   en_ iyi_ ağırlıkları_ geri_ yükle ← Doğru


5: procedure MODELEGIT(X_egitim, y_egitim)
6:   toplam_donem ← 100
7:   yigin_boyutu ← 512
8:   dogrulama_ayirma ← 0.2
9:   Modeli, ErkenDurdurma geri çağırma fonksiyonu ile eğit
10: end procedure

```

Şekil 4.3: FL senaryosunda erken durdurma geri çağırma kullanımı.

Şekil 4.3, Model eğitiminde kullanılan Erken Durdurma mekanizması, doğrulama doğruluğunda (val_accuracy) bir iyileşme görülmediğinde eğitimi erken sonlandırarak aşırı öğrenmenin (overfitting) önüne geçmektedir. Belirlenen bekleme süresi (patience) değeri sayesinde model, belirli bir süre boyunca gelişme göstermediğinde en iyi ağırlıklarla durdurulmaktadır. Bu yaklaşım, eğitim süresini optimize ederken

modelin genellenebilirliğini artırmayı hedeflemektedir. FL ortamında bu tür erken durdurma stratejileri, istemci tarafındaki kaynak tüketimini de azaltmaktadır.



Şekil 4.4: Model performans metrikleri.


Şekil 4.4 , geliştirilen modelin performansını değerlendirmek amacıyla hesaplanan dört temel metriği göstermektedir: Doğruluk (accuracy), F1 Skor, Kesinlik (precision) ve Duyarlılık (Recall). Grafik, modelin doğruluk açısından %91 civarında güçlü bir performans sergilediğini ortaya koyarken; F1 skor, kesinlik ve duyarlılık değerlerinin de yüksek ve dengeli olduğunu göstermektedir. Bu sonuçlar, modelin hem genel başarı düzeyinin hem de pozitif sınıfları tanıma yetisinin güçlü olduğunu göstermektedir.

4.1 Araştırma Tasarımı

FL uygulamalarında araştırma tasarımı, sistem mimarisinin etkili bir şekilde geliştirilmesini, veri güvenliğinin sağlanmasını ve performans optimizasyonunun gerçekleştirilmesini hedeflemektedir (Shanmugam ve diğ, 2023). Bu yaklaşım, dağıtık öğrenme sistemlerinin gerçek dünya senaryolarında uygulanabilirliğini artırmak açısından büyük önem taşır. Bu bağlamda, çalışmamızın araştırma tasarımı, OPC protokolü aracılığıyla endüstriyel verilerin toplanması ve bu verilerin FL modeliyle entegrasyonuna dayanmaktadır. Böylece, hem endüstriyel sistemlerdeki veri üretimi hem de makine öğrenimi temelli analiz süreçleri arasında güçlü bir köprü kurulmuştur. FL mimarisi, veri sahipliğini ve taşınabilirliğini destekleyen yenilikçi bir yapı sunarak, verilerin gizliliğini sağlarken aynı zamanda öğrenme sürecinin etkin bir şekilde yürütülmesini mümkün kılmaktadır (Mpofu ve diğ, 2023). Bu tür bir tasarım, özellikle veri gizliliği ve güvenliği konularında endüstriyel uygulamalar için büyük bir avantaj sağlamaktadır. FL mimarisinin sunduğu yerel öğrenme prensibi, veri paylaşımı gerektirmediği için hassas üretim ortamlarında ideal bir çözüm sunmaktadır. Araştırma tasarımıımızın temel amacı, merkezi veri toplama ihtiyacını ortadan kaldıran

dağıtık bir öğrenme mimarisi geliştirmektir. Böylelikle veri bütünlüğü bozulmadan analiz süreçlerine katkı sağlanmakta ve yasal düzenlemelere uyum kolaylaşmaktadır. Bu kapsamda, OPC UA protokolü, endüstriyel veri toplama süreçleri için temel bir bileşen olarak kullanılmıştır (Hirsch ve diğ., 2023). Araştırmamızda OPC den aldığımız veriler, FL modeliyle işlenerek hem veri güvenliği hem de süreç optimizasyonu hedeflenmiştir. Bu çift yönlü fayda, hem üretim verimliliğini hem de sistem güvenliğini aynı anda desteklemektedir. Bu yaklaşım, özellikle endüstriyel verilerin güvenli bir şekilde işlenmesi ve analiz edilmesi için önemli bir adımdır. Araştırma tasarımında ilk adım, OPC protokolü aracılığıyla toplanan verilerin ön işlenmesidir. Bu süreç, ham verinin analiz edilebilir forma dönüştürülmesi açısından kritik bir basamaktır. Endüstriyel veriler genellikle heterojen bir yapıya sahip olduğundan, bu verilerin analiz edilebilir bir forma dönüştürülmesi önemlidir. Veri ön işleme aşamasında eksik veri tespiti ve tamamlama, anormal veri noktalarının tespiti, zaman damgası senkronizasyonu ve çok boyutlu veri entegrasyonu gerçekleştirilmiştir. Eksik veri tespiti ve tamamlama, analiz sırasında oluşabilecek sapmaları önleyerek model doğruluğunu doğrudan etkiler. FL uygulamalarında, farklı cihazlardan gelen verilerin aynı zaman dilimine göre düzenlenmesini sağlamak amacıyla zaman damgası senkronizasyonu uygulanmaktadır (Zhu ve Niu, 2025). Böylece modelin girdi verileri tutarlı hale getirilmiş olur. Bu adımlar, modelin doğruluğunu artırmak ve veri kalitesini optimize etmek için gereklidir. Bir sonraki aşama, FL modelinin tasarlanması ve uygulanmasıdır. Modelin çıktısı, kalite problemi (1/0) ve bakım gerekliliği (1/0) olacak şekilde ikili sınıflandırmadır. Bu aşama, dağıtık sistemin merkezinde yeralan algoritmik yapıyı belirlemektedir. Araştırmamızda, bu süreçte kullanılan temel algoritma FedAvg olmuştur. Merkezi bir veri havuzu oluşturulmadığı için veriler istemci cihazlarda yerel olarak tutulur ve yalnızca model parametreleri paylaşılır (Hu ve diğ., 2024). Ancak, bu süreçte parametrelerin güvenli bir şekilde iletilmesi gereklidir (Kairouz ve diğ., 2021). Bu amaçla diferansiyel gizlilik ve homomorfik şifreleme gibi ileri seviye güvenlik teknikleri uygulanmıştır (Xu ve diğ., 2024). Homomorfik şifreleme, model parametrelerinin şifreli bir şekilde iletilmesine olanak tanır ve bu şifreli parametrelerin sunucu tarafından işlenebilmesini sağlar (Zhu ve Niu, 2025). Bu güvenlik önlemleri, endüstriyel veri analizi süreçlerinde veri gizliliğini korumak için kritik bir rol oynamaktadır. Araştırma tasarımının önemli bir bileşeni de istemciler ve merkezi sunucu arasındaki iletişimidir. Bu yapı, dağıtık sistemlerin performansını doğrudan etkileyen bir faktördür. İletişim sürecinde,

istemcilerden gelen model parametrelerinin boyutunu azaltmak için optimizasyon stratejileri geliştirilmiştir (Altınışık ve Bilgin, 2024). Gradyan sıkıştırma teknikleri ile parametreler gönderilmiştir, bu şekilde iletişim maliyetleri düşürülerek sistemin ölçeklenebilirliği arttırılmıştır. Ayrıca, istemci cihazlar arasındaki asenkron iletişim yöntemi, farklı cihazların farklı zamanlarda güncelleme göndermesine olanak tanıyarak sistemin esnekliğini artırmıştır (Zang ve diğ, 2024). Bu yöntem, özellikle farklı işlem kapasitelerine sahip cihazlar için önemlidir. Bu tür optimizasyonlar, özellikle büyük ölçekli endüstriyel uygulamalarda önemli bir zaman ve kaynak tasarrufu sağlamaktadır. FL modelinin doğruluğunu artırmak ve genelleştirilebilirliğini sağlamak için validasyon stratejileri geliştirilmiştir. Model, her iterasyonda istemcilerden gelen verilerle test edilerek performansı değerlendirilmiştir (Ghaleb ve diğ, 2025). Test sürecinde kullanılan metrikler, modelin genel doğruluğunu, kayıp fonksiyonundaki değişiklikleri ve veri heterojenliğine karşı direncini değerlendirmek için optimize edilmiştir (Zeng ve diğ, 2024). Modelin veri heterojenliğinden etkilenmesini minimize etmek için düzenleme stratejileri ve ağırlıklandırılmış birleştirme yöntemleri uygulanmıştır. Bu sayede modelin farklı senaryolarda tutarlı sonuçlar vermesi sağlanmıştır. Bu tür kapsamlı bir değerlendirme, modelin gerçek dünya uygulamalarında ne kadar etkili olabileceğini anlamak için büyük önem taşır. Araştırma tasarımı, sadece teknik bir çerçeve ile sınırlı kalmamış, aynı zamanda endüstriyel uygulamalarda kullanılabilirliği hedeflemiştir. Bu bakış açısı, akademik çıktının saha uygulamalarıyla örtüşmesini sağlamıştır. Bu tür çalışmalar, endüstriyel süreçlerin daha verimli, güvenli ve sürdürülebilir hale gelmesine önemli bir katkı sağlamaktadır. Şekil 4.5 de, OPC protokolü üzerinden toplanan verilerin ön işlenerek yerel modellerde eğitildiği ve sonuçların FedAvg ile birleştirildiği süreç gösterilmektedir.



Şekil 4.5: OPC – FL veri akış diyagramı.

Şekil 4.6, Diferansiyel gizlilik sağlamak amacıyla model ağırlıklarına Laplace dağılımı kullanılarak gürültü eklenmektedir. `add_noise_to_weights` fonksiyonu, her bir ağırlık matrisine epsilon parametresiyle kontrol edilen miktarda rastgele gürültü uygular. Bu yöntem, modelin kullanıcı verilerinden doğrudan izler taşımamasını

engelleyerek gizlilik koruması sağlar. FL senaryolarında, istemciden sunucuya gönderilen ağırlıkların güvenliğini artırmak için yaygın olarak kullanılmaktadır.

Algorithm 2 Model Ağırlıklarına Gürültü Ekleme


```

procedure AGIRLIKLARAGURULTUEKLE(agirliklar, epsilon)
2:   gurultulu_agirliklar adlı boş bir liste başlat
   for her bir ağırlık a içinde agirliklar do
4:     Laplace dağılımından, ölçek parametresi  $1/\epsilon$  olacak şekilde gürültü
       üret
        $gurultu \leftarrow \text{Laplace}(0, 1/\epsilon, \text{seki} = a.\text{seki})$ 
6:     Gürültüyü ağırlığa ekle:  $a \leftarrow a + gurultu$ 
       Gürültülü a'yı gurultulu_agirliklar listesine ekle
8:   end for
   return gurultulu_agirliklar
10: end procedure

```

Şekil 4.6: Diferansiyel gizlilik ile gürültü ekleme.

Şekil 4.7 te görüldüğü üzere, Gradyan sıkıştırma uygulandığında iletişim süresinde azalma sağlanmakta, ancak model doğruluğu çok az bir farkla korunmaktadır.



Şekil 4.7: FL Performans Optimizasyonu – İletişim ve Doğruluk.

4.1.1 Sistem mimarisi


FL tabanlı sistem mimarimiz, merkezi bir sunucu ve birden fazla istemci cihazından oluşan dağıtık bir yapıya sahiptir. Mimari, istemcilerdeki yerel öğrenme ile merkezi model birleştirmesini dengeleyerek hem güvenlik hem de performans açısından dengeli bir çözüm üretir. Merkezi sunucu, istemcilerden gelen model güncellemelerini toplayarak bu güncellemeleri birleştirir ve global bir model oluşturur (Boiano ve diğ, 2024). İstemci cihazlar ise yerel verilerini kullanarak model eğitimi yapar ve yalnızca model parametrelerini sunucuya iletir (Boiano ve diğ, 2024). Bu veri paylaşımından arındırılmış yaklaşım, verilerin merkezi bir yerde toplanmasını gerektirmediği için veri gizliliği ve güvenliği açısından büyük avantaj sağlar (Boiano ve diğ, 2024). Geliştirilen sistem mimarisinin uygulamasında aşağıdaki platform ve kütüphaneler

kullanılmıştır: Python 3.9, TensorFlow Federated 0.20.0, TensorFlow 2.12.0, PyTorch + PySyft, scikit-learn 1.2.2, pandas 1.5.3, NumPy 1.24.2 ve Flask 2.2.3. Bu kütüphanelerin görev dağılımı Çizelge 4.2'de verilmiştir.

Çizelge 4.2: Kullanılan python kütüphaneleri ve fonksiyonları.

Kütüphane	Rolü
TensorFlow	Derin öğrenme ve FL modeli
TensorFlow Federated	FL altyapısı
Flask	Sunucu-istemci iletişimi
PySyft	Gizlilik-preserving alternatif eğitim
NumPy / pandas	Veri işleme ve analiz
scikit-learn	Model değerlendirme ve validasyon

İstemci cihazlar, FL sistem mimarisinin temel bileşenlerinden biri olup yerel veri ile model eğitimi gerçekleştirmektedir (Kairouz ve diğ, 2021). Her istemci, kendi yerel veri setinde tanımlı kayıp fonksiyonunu minimize ederek model parametrelerini günceller (Reddi ve diğ, 2020). FL sistemleri, istemcilerin farklı hesaplama kapasitelerine sahip olabileceği göz önünde bulundurularak ölçeklenebilir şekilde tasarlanmaktadır (Kairouz ve diğ, 2021). Sistem mimarisine ilişkin iş akış şeması Şekil 4.8' de sunulmuştur. FL sistemlerinde haberleşme katmanı, istemciler ile merkezi sunucu arasında model güncellemelerinin iletimini yönetir (Bonawitz ve diğ, 2019).



Şekil 4.8: Sistem mimarisi iş akış şeması.

İstemcilerden gelen model güncellemeleri, gizliliği sağlamak amacıyla şifrelenerek merkezi sunucuya iletilmektedir (Truex ve diğ, 2019). Şekil 4.9 da, istemci tarafında eğitilen modelin ağırlıklarını diferansiyel gizlilik ilkelerine uygun biçimde sunucuya göndermektedir.

Algorithm 3 Ağırlıklara Gürültü Ekle ve Sunucuya Gönder

```
1: procedure AGIRLIKLARAGURULTUEKLE(agirliklar, epsilon)
2:   gurultulu_agirliklar adlı boş bir liste başlat
3:   for her bir ağırlık a içinde agirliklar do
4:     Laplace dağılımından, ölçek  $1/\epsilon$  olacak şekilde gürültü üret
5:     gurultulu_a  $\leftarrow a + \text{gurultu}$ 
6:     gurultulu_a'yı gurultulu_agirliklar listesine ekle
7:   end for
8:   return gurultulu_agirliklar
9: end procedure

10: procedure AGIRLIKLARISUNUCUYAGONDER(model, sunucu_adresi, epsilon)
11:   Model ağırlıklarını al: agirliklar  $\leftarrow \text{model.get\_weights}()$ 
12:   gurultulu_agirliklar  $\leftarrow \text{AGIRLIKLARAGURULTUEKLE}(\text{agirliklar}, \text{epsilon})$ 
13:   gurultulu_agirliklar'ı JSON için liste formatına çevir
14:   veri  $\leftarrow$  "weights" anahtarına sahip ve değeri gurultulu_agirliklar olan bir JSON nesnesi oluştur
15:   Sunucuya POST isteği gönder ve veri'yi ilet
16:   if sunucudan dönen yanıt kodu 200 ise then
17:     "Ağırlıklar başarıyla sunucuya gönderildi." mesajını yazdır
18:   end if
19: end procedure
```

Şekil 4.9: İstemci tarafından diferansiyel gizlilikle ağırlık gönderimi.


Şekil 4.10' da, sunucu tarafında, bu parametreler FedAvg algoritmasıyla birleştirilerek yeni global model oluşturulur.

Algorithm 4 Sunucuda Ağırlıkları Al ve Birleştir

```
1: procedure AGIRLIKLARIAL
2:   POST isteğiyle gelen JSON verisini al
3:   Gelen ağırlıkları NumPy dizilerine dönüştür
4:   Bu ağırlıkları küresel agirlik_listesi'ne ekle
5:   tur_sayaci değerini 1 artır
6:   if tur_sayaci mod birlesme_sikligi eşitse 0 then
7:     Tüm alınan ağırlıklar arasında her katman için ortalama hesapla
8:     agirlik_listesi'ni temizle
9:     tur_sayaci'ni sıfırla
10:    Ortalama ağırlıkları içeren JSON nesnesini geri döndür
11:   else
12:     Başarı durumunu belirten JSON nesnesini geri döndür
13:   end if
14: end procedure
```

Şekil 4.10: Sunucu tarafından FedAvg algoritması çalışması.

Homomorfik şifreleme, diferansiyel gizlilik ve gradyan sıkıştırma gibi güvenlik ve performans artırıcı teknikler, sistemin hem güvenilir hem de etkili bir şekilde çalışmasını sağlamıştır. Şekil 4.11 de önerilen FL tabanlı sistemin genel işleyiş akışı gösterilmiştir. Bu yapı veri toplama, yerel model eğitimi, parametre transferi ve merkezi agregasyon süreçlerini içermektedir.



Şekil 4.11: Sistem mimarisinin blok diyagramı.


Çizelge 4.2, FL uygulamasında kullanılan Python kütüphanelerini ve bu kütüphanelerin sistem içerisindeki rollerini özetlemektedir. TensorFlow ve TensorFlow Federated, model oluşturma ve dağıtık eğitim altyapısını sağlarken; Flask, istemci ve sunucu arasındaki iletişimi yönetmektedir. PySyft, gizliliği koruyan alternatif eğitim mekanizmaları sunarken, NumPy ve pandas veri işleme süreçlerinde; scikit-learn ise model değerlendirme ve doğrulama işlemlerinde kullanılmaktadır.

4.1.2 Veri toplama ve ön işleme

Veri toplama sürecimiz, endüstriyel cihazlardan alınan sensör verilerinin standart bir formatta toplanmasını ve işlenmesini sağlayan OPC UA protokolüne dayanmaktadır (Hirsch ve diğ, 2023). OPC protokolü günümüzde OPC UA olarak evrimleşerek bağımsız bir yapıya kavuşmuştur. Örneğin, sıcaklık sensöründen alınan veri, “Sıcaklık_01” etiketiyle işaretlenirken, hız sensöründen alınan veri “Hız_02” etiketiyle tanımlanır. Bu yapı, veri kategorileri arasında ayırım yapmayı kolaylaştırarak ileri düzey analizlerin temelini oluşturmaktadır. Veri toplama sürecinin ardından, veriler işleme hattına aktarılmış ve normalizasyon ile filtreleme gibi ön işleme adımları uygulanmıştır (Li, 2022b). Ön işleme, verinin analiz için anlamlı hale getirilmesinde hayati rol oynayan bir adımdır. Veri ön işleme, ham verilerin daha anlamlı bir formata dönüştürülmesi ve analiz için uygun hale getirilmesini amaçlayan bir dizi adımdan oluşur. Eğitim verisi, aşırı değerlerin çıkarılmasını, eksik değerlerin enterpolasyonunu, hareketli ortalama uygulanmasını ve normalizasyonu gerektirir (Li ve diğ, 2023). Bu

işlemler, sadece veri setinin teknik kalitesini değil, aynı zamanda modelleme sürecinin doğruluğunu da doğrudan etkiler. Önerilen çerçeve, eksik verilerin tamamlanması, anomalilerin tespiti, arıza kaynaklarının belirlenmesi ve sensör verilerinin doğrulanması yoluyla hatalı sensörlerin güvenilirliğini artırmayı amaçlamaktadır (Ba-Alawi ve diğ, 2022). Bu sayede veri setinin bütünsel analizine olanak tanınmış olur. Eksik veriler, lineer interpolasyon veya zaman serisi modelleme gibi teknikler kullanılarak doldurulmuştur. Örneğin, bir sıcaklık sensöründen gelen verilerdeki eksik noktalar, önceki ve sonraki veri değerleri arasındaki ortalama ile tamamlanmıştır. Bu yaklaşım, zaman serisi analizinde yapay dalgalanmaların önlenmesi açısından fayda sağlamaktadır. Bu tür teknikler, veri bütünlüğünü korumak ve analiz sürecinde daha güvenilir sonuçlar elde etmek için önemlidir. Veri ön işleme, makine öğrenimi modellerinin başarısı üzerinde önemli bir etkiye sahip olan hayati bir adımdır (Vavra ve Hromada, 2019). Özellikle yüksek frekansta çalışan sensörlerde bu tür anomaliler, sistem performansını etkileyebilecek düzeyde olabilir. Sensörlerin yerleştirildiği zorlu ortamlar, iletilen verilerin kalitesinde önemli bir rol oynamaktadır (Teh ve diğ, 2020). Bu veriler analiz sürecinden çıkarılmazsa modelin öğrenme kapasitesini olumsuz yönde etkileyebilir. Eksik veri değerlerinin doldurulmasında ortalama ve medyan gibi istatistiksel teknikler kullanılarak anomalilerin doğru tespit edilmesi hedeflenmiştir (Vavra ve Hromada, 2019). Örneğin, sıcaklık verilerinde belirli bir eşik değerin üzerindeki ölçümler, anomali olarak işaretlenmiş ve analizden çıkarılmıştır. Farklı sensörlerden gelen verilerin zaman damgalarının senkronize edilmesi, çoklu sensör füzyon sistemlerinde sağlam durum kestirimi sağlamak için kritik öneme sahiptir (Kim ve diğ, 2025). Örneğin, hız ve sıcaklık verilerinin aynı anda ölçülmediği bir durumda, bu iki veri setinin eş zamanlı analiz edilmesi mümkün olmayabilir. Zaman damgası senkronizasyonu, bu sorunu çözerek tüm verilerin ortak bir zaman ölçeğinde birleştirilmesine olanak tanır (Kim ve diğ, 2025). Bu işlemde, veriler zaman serisi formatına dönüştürülmüş ve eksik zaman damgaları ileriye dönük doldurma (forward filling) yöntemiyle tamamlanmıştır. Böylece, tüm veri seti analiz için hazır hale getirilmiştir. Bu tür bir senkronizasyon, özellikle zaman serisi analizlerinde doğru sonuçlar elde etmek için kritik öneme sahiptir. Veri ön işleme ve normalleştirme, merkezi olmayan federe öğrenme sistemlerinde önemli adımlardır (Beltrán ve diğ, 2023). Normalizasyon, verilerin bir standarda oturtulmasını ve farklı ölçeklerdeki değişkenlerin analiz sırasında eşit ağırlıkta değerlendirilmesini sağlar (Singh ve Singh, 2020). Örneğin, sıcaklık verilerinin Celsius cinsinden, hız verilerinin ise metre/saniye

cinsinden ölçüldüğü bir durumda, bu iki değişkenin aynı analiz modelinde işlenebilmesi için bir standarda oturtulması gereklidir. Veriler, genellikle min-max normalizasyon veya z-skoru standardizasyon teknikleri kullanılarak normalize edilmiştir. Bu işlemler, modelin öğrenme sürecinde daha iyi sonuçlar elde etmesini ve algoritmanın farklı değişkenler arasındaki ilişkileri daha doğru bir şekilde öğrenmesini sağlar. Bu tür bir normalizasyon, özellikle makine öğrenimi modellerinin performansını artırmak için kritik öneme sahiptir. Veri ön işleme sürecinin son aşamasında, tüm veriler çok boyutlu bir formata dönüştürülmüştür. Bu dönüşüm, modelin daha karmaşık ilişkileri öğrenmesini mümkün kılar. Çok boyutlu veri formatı, farklı sensörlerden gelen bilgilerin bir arada analiz edilmesini sağlar. Örneğin, bir üretim hattındaki sıcaklık, basınç ve hız verileri bir matriste birleştirilerek model eğitimi için kullanılabilir hale getirilmiştir. Bu süreç, veriler arasındaki ilişkilerin daha iyi anlaşılmasını ve modelin daha doğru tahminler yapmasını sağlar. Ayrıca, çok boyutlu veri formatı, zaman serisi analizleri ve kestirimci modeller için de uygun bir yapı sunar (Brownlee, 2017). Bu tür bir format, özellikle endüstriyel veri analitiği uygulamalarında büyük bir avantaj sağlamaktadır. Veri toplama ve ön işleme sürecinde, veri güvenliği ve gizliliği konularına da dikkat edilmiştir. OPC protokolü üzerinden toplanan veriler, şifreleme yöntemleriyle korunmuş ve yetkisiz erişimlere karşı güvence altına alınmıştır. Veri ön işleme sırasında kullanılan algoritmalar, hem verilerin bütünlüğünü sağlamak hem de güvenli bir şekilde işlenmesini temin etmek amacıyla dikkatlice seçilmiştir.



Şekil 4.12: OPC tabanlı veri toplama akışı.

Şekil 4.12 de ki diyagram, endüstriyel sensörlerden gelen verilerin OPC protokolü ile etiketlenmesi, merkezi sisteme aktarılması ve FL için ön işlenmesini göstermektedir.

Çizelge 4.3: Veri ön işleme aşamaları ve kullanılan teknikler.

Aşama	Teknik/Algoritma
Eksik Veri Tamamlama	Lineer interpolasyon, forward fill
Anomali Tespiti	Z-skor, istatistiksel eşikler
Zaman Damgası Senkronizasyonu	Timestamp hizalama
Normalizasyon	Min-Max, Z-skor
Çok Boyutlu Dönüşüm	Matrisleşmiş sensor vektörleri

Çizelge 4.3, model eğitimi öncesinde uygulanan veri ön işleme aşamalarını ve bu süreçlerde kullanılan teknikleri özetlemektedir. Eksik veriler, lineer interpolasyon ve ileri doldurma (forward fill) yöntemleriyle tamamlanırken; anomali tespiti için Z-skoru ve istatistiksel eşik tabanlı yöntemler uygulanmıştır. Zaman damgalarının senkronizasyonu, farklı kaynaklardan gelen verilerin hizalanması amacıyla gerçekleştirilmiştir. Verilerin ölçeklendirilmesi Min-Max ve Z-skor normalizasyon teknikleriyle sağlanmış; son olarak, sensör verileri çok boyutlu yapıya dönüştürülerek matris formuna getirilmiştir. Bu işlemler, modelin daha sağlıklı ve doğru öğrenmesini desteklemektedir.

4.1.3 Model seçimi ve validasyon stratejisi

FL sistemlerinde model seçimi, istemcilerle paylaşılacak başlangıç modelinin belirlenmesi aşamasını oluşturmakta ve tüm sistemin eğitim sürecinin temelini oluşturmaktadır (Jalali ve Chen, 2023). Doğru model seçimi, yalnızca doğruluk oranlarını değil aynı zamanda sistemin genel güvenilirliğini ve genelleştirilebilirliğini de doğrudan etkiler. Çalışmamızda, endüstriyel süreçlerden toplanan zaman serisi verilerinin analizine odaklanıldığı için özellikle bu tür verilere uygun modeller tercih edilmiştir. Bu bağlamda, RNN (Tekrarlayan Sinir Ağı) ve LSTM gibi modeller, zaman bağımlılıklarını öğrenme kapasiteleri nedeniyle öncelikli seçenekler olarak değerlendirilmiştir. Bu modellerin yapısı, geçmiş zaman dilimlerinden gelen bilgileri hafızada tutarak gelecekteki çıktıları tahmin etme konusunda avantaj sağlamaktadır. Model seçim sürecimiz, veri setinin dinamik yapısı, doğruluk gereklilikleri ve FL mimarisi ile uyumluluk gibi parametrelere dayanarak gerçekleştirilmiştir. Bu yaklaşım, veri tipi ile model yapısı arasında doğrudan bir bağ kurarak yapay öğrenme sürecinin daha etkili işlemlerini sağlamıştır. Bu tür bir model seçimi, özellikle endüstriyel verilerin karmaşık yapısını anlamak ve analiz etmek için büyük bir avantaj sağlamaktadır. Zaman serisi verileri, ardışık gerçek değerlerden oluşan sıralı yapılar şeklinde tanımlanır (Farahani ve diğ, 2023). Bu nedenle, LSTM'ler ve diğer kapalı RNN'ler, birçok ardışık modelleme görevinde fiili standart olarak yaygın şekilde benimsenmiştir (Landi ve diğ, 2021). Bu özellik, özellikle üretim süreçlerindeki gecikmeli etkilerin öğrenilmesinde kritik rol oynamaktadır. Özellikle üretim hatlarından toplanan sıcaklık, basınç ve hız gibi parametrelerin birbirini takip eden zaman dilimlerinde nasıl bir etkileşim gösterdiğini anlamak, üretim süreçlerinin iyileştirilmesi açısından kritik bir öneme sahiptir. LSTM'ler, uzun vadeli bağımlılıkları

öğrenirken ortaya çıkan patlayan ve kaybolan gradyanları azaltmak için kapı mekanizmalarını kullanır (Landi ve diğ, 2021). Bu nedenle, LSTM'ler ve diğer kapılı RNN'ler, birçok ardışık modelleme görevinde fiili standart olarak yaygın şekilde benimsenmiştir (Landi ve diğ, 2021). Bu model, özellikle endüstriyel süreçlerdeki zaman serisi verilerinin analizinde büyük bir potansiyele sahiptir. Gerek doğruluk gerekse zaman içerisinde öğrenilen bağımlılıkların sürdürülebilirliği açısından LSTM yapısı öne çıkmaktadır. Çoğu makine öğrenimi algoritması, değerleri özenle seçilmesi gereken ve performansı büyük ölçüde etkileyebilen bir dizi hiperparametre ile yapılandırılmaktadır (Bischl ve diğ, 2023). Hiperparametre ayarları, modelin hem öğrenme sürecini hem de nihai başarımını büyük ölçüde etkileyen faktörlerdendir. Çalışmamızda, ızgara arama yönetimi (grid search) yöntemi kullanılarak öğrenme oranı, katman sayısı, LSTM hücre sayısı ve toplu işlem boyutu (batch size) gibi hiperparametreler optimize edilmiştir. Bu süreçte farklı kombinasyonlar test edilmiş ve en iyi performansı sağlayan yapılandırma seçilmiştir. Örneğin, öğrenme oranı 0.001 olarak belirlenmiş ve her bir LSTM katmanında 64 hücre kullanılarak modelin genel performansı optimize edilmiştir. Toplu işlem boyutu olarak ise 32 tercih edilmiştir; bu değer, hem donanım kaynaklarını verimli kullanmayı sağlamış hem de modelin stabilitesini artırmıştır. Bu tür bir optimizasyon, modelin eğitim sürecinde daha hızlı ve etkili bir şekilde öğrenmesini sağlamaktadır. FL modelinin performansını değerlendirmek için doğruluk, F1 skoru, kesinlik ve geri çağırma gibi yaygın performans metrikleri incelenmiştir (Altınışık ve Bilgin, 2024). Bu değerlendirme, modelin yalnızca eğitim verisi üzerinde değil, aynı zamanda daha önce görmediği örneklerde de nasıl davrandığını ölçmeyi amaçlamaktadır. Validasyon sürecinde, K-fold cross-validasyon yöntemi tercih edilmiştir (Bey ve diğ, 2020). Bu yöntem, veri setinin farklı alt kümelerine bölünerek modelin her bir alt küme üzerinde test edilmesini sağlar. Çalışmamızda, veri setinin zaman serisi doğası göz önüne alınarak 5-fold cross-validasyon kullanılmıştır. Bu yöntem, modelin tüm veri seti üzerinde dengeli bir şekilde test edilmesine olanak sağlamış ve modelin farklı veri örnekleri üzerindeki performansı hakkında daha net bir fikir sunmuştur. Bu tür bir validasyon stratejisi, modelin genelleştirme yeteneğini artırmak için kritik öneme sahiptir. Erken durdurma (early stopping) mekanizması, derin sinir ağlarında yaygın olarak kullanılan bir düzenleme tekniğidir ve performansı genellikle genel düzeleme yöntemlerinden daha iyidir (Jiao ve diğ, 2024). Eğitim sırasında, doğrulama kaybı bir süre boyunca iyileşme göstermediğinde eğitim süreci otomatik olarak durdurulmuştur. Bu yaklaşım, modelin

aşırı uyum yapmasını engelleyerek genelleştirme kapasitesini artırmıştır. Özellikle endüstriyel uygulamalarda, modelin genelleştirme kapasitesi büyük önem taşımaktadır; çünkü model, sadece mevcut veri setinde değil, gelecekte karşılaşacağı yeni veri örneklerinde de başarılı bir şekilde çalışmalıdır. Bu tür bir mekanizma, modelin daha güvenilir ve tutarlı sonuçlar üretmesini sağlamaktadır. Modelin performansı, doğruluk, MAE (ortalama mutlak hata) ve RMSE (kök ortalama kare hata) gibi yaygın metrikler kullanılarak değerlendirilmiştir. FL ile geliştirilen modelin performansı doğruluk, F1 puanı, kayıp ve kesinlik gibi metrikler kullanılarak değerlendirildi (Altınışik ve Bilgin, 2024). Bunun yanı sıra, zaman serisi analizlerinde yaygın olarak kullanılan otokorelasyon fonksiyonları ve görselleştirme teknikleri, modelin veriye uyum kapasitesini değerlendirmek için kullanılmıştır. Elde edilen sonuçlar, LSTM modelinin zaman serisi verilerindeki bağımlılıkları başarılı bir şekilde öğrendiğini ve hem kısa vadeli hem de uzun vadeli tahminlerde yüksek doğruluk sağladığını göstermiştir. Bu tür bir performans, özellikle endüstriyel süreçlerdeki tahminlerin doğruluğunu artırmak için büyük bir avantaj sağlamaktadır. Modelin genel başarısını artırmak için, diferansiyel gizlilik ve güvenli agregasyon gibi FL'e özgü veri gizliliği yöntemleri entegrasyon sürecine dahil edilmiştir. Bu yöntemler, modelin hem güvenlik standartlarını karşılamasını hem de dağıtık bir yapı içinde etkin bir şekilde çalışmasını sağlamıştır. Örneğin, diferansiyel gizlilik tekniği, model parametre güncellemelerine rastgele bir gürültü ekleyerek bireysel verilerin korunmasını sağlamıştır. Son olarak, merkezi sunucu, güvenli toplama protokolüne göre son kullanıcılardan alınan eğitilmiş yerel modelleri bir araya getirerek yeni küresel modeli oluşturur (Byun ve diğ, 2024). Bu tür güvenlik önlemleri, özellikle endüstriyel veri analizi süreçlerinde veri gizliliğini korumak için kritik bir rol oynamaktadır. Model seçimi ve validasyon stratejileri, FL sistemimizin başarısında kritik bir rol oynamıştır. Bu bütüncül yaklaşım, hem teknik yeterlilik hem de operasyonel uygulanabilirlik açısından sistemi güçlü kılmaktadır. Zaman serisi verilerinin analizine uygun olarak tasarlanan FCNN modeli, hiperparametre optimizasyonu ve validasyon süreçleriyle desteklenmiş ve endüstriyel veri setimiz üzerinde üstün bir performans sergilemiştir. Model seçimi süreci, yalnızca doğruluk metriğiyle sınırlı kalmamakta; aynı zamanda modelin açıklanabilirliği, genelleme kapasitesi ve dağıtık mimarilerle olan uyumu gibi çok boyutlu kriterleri de kapsamaktadır. FL bağlamında bu süreç, klasik yaklaşımlardan daha karmaşık hale gelmekte, çünkü model eğitimi merkezi olmayan bir yapıda gerçekleştirilmektedir.

Çizelge 4.4: Hiperparametre ayarları ve açıklamaları.

Parametre	Değer	Açıklama
Öğrenme Oranı	0.001	Eğitim stabilitesi ve hız dengesi
Hücre Sayısı	64	Zaman serisi örüntülerini yakalama
Katman Sayısı	2	Derin öğrenme kapasitesini artırır
Toplu işlem boyutu	32	Hafıza kullanımı ve güncelleme sıklığı

Çizelge 4.4, modelin eğitimi sırasında kullanılan temel hiperparametreleri ve bu parametrelerin rollerini açıklamaktadır. Öğrenme oranı 0.001 olarak belirlenmiş olup, eğitim sürecinde hem kararlılığı hem de öğrenme hızını dengelemektedir. Hücre sayısı 64 olarak seçilerek zaman serisi içindeki karmaşık örüntülerin yakalanması hedeflenmiştir. İki katmanlı yapı, modelin derinliğini ve temsil gücünü artırırken; toplu işlem boyutu değeri olarak 32 tercih edilerek bellek yönetimi ile güncelleme sıklığı arasında bir denge sağlanmıştır. Bu ayarlar, modelin genel performansını optimize etmek amacıyla belirlenmiştir. Kullanılan modelin sadece teknik doğruluğu değil, aynı zamanda veri gizliliği, iletişim verimliliği ve operasyonel sürdürülebilirliği de gözetilen bir yapıda olması FL sistemlerinin başarısı açısından kritik önem taşımaktadır.

Çizelge 4.5: FCNN, CNN ve LSTM modelleri iletişim maliyetleri analizi

Model	Parametre	Veri paketi (payload - KB)	Gecikme (sn)	Eğitim süresi	Hesaplama
FCNN	~24.000	180-220	0.4-0.6	Kısa	Düşük
CNN	~300.000	2.7	1.5-2.2	Orta	Orta
LSTM	~600.000	5.1	2.5-3.8	Uzun	Yüksek

Model yapılarının iletişim maliyeti, eğitim süresi ve hesaplama gereksinimi bakımından karşılaştırmalı olarak değerlendirildiği Çizelge 4.5 te gösterildiği gibi, CNN ve LSTM gibi derin öğrenme modellerinin FL ortamındaki verimliliği sorgulanmıştır. CNN modeli yaklaşık 300.000 parametre ile ortalama 2.7 MB'lık bir veri paketi büyüklüğüne sahiptir ve gecikme süresi 1.5-2.2 saniye aralığında değişmektedir. Buna karşılık, LSTM modelinde parametre sayısı yaklaşık 600.000'e ulaşmakta ve bu durum veri paketi boyutunu 5.1 MB seviyesine kadar çıkarmaktadır; aynı zamanda gecikme süresi 2.5-3.8 saniye aralığında ölçülmüş olup hesaplama yükü de oldukça yüksektir. Bu bağlamda, FCNN mimarisi 3 gizli katman ve 1 çıkış katmanından oluşan yaklaşık 24.000 parametrelili yapısı, JSON sıkıştırılmalı 180-220 KB veri paketi boyutu ve TLS dahil toplam 400-600 ms gecikme süresiyle, iletişim açısından oldukça avantajlı bir alternatif sunmaktadır. Özellikle düşük iletişim


maliyeti, hızlı eğitim süresi ve uygulama kolaylığı sayesinde FCNN, FL sistemleri için hem pratik hem de etkili bir çözüm olarak öne çıkmaktadır.

4.2 Federe Öğrenme Implementasyonu

Bu çalışmada geliştirilen FL yapısı, endüstriyel uygulamalarda veri gizliliğini koruyarak merkezi olmayan model eğitimi yapılabileceğini göstermiştir. FL, OPC protokolü üzerinden toplanan üretim verileri ile entegre edilerek istemci-sunucu mimarisi temelinde uygulanmıştır. Bu yapı, istemciler ve sunucu arasında güvenli haberleşme protokolleri (TLS 1.3, RSA, AES-256) aracılığıyla veri güvenliğini garanti altına almıştır. Özellikle model parametrelerinin aktarımı sırasında şifreleme uygulanmış, istemci-sunucu etkileşimi sırasında veri bütünlüğü ve gizliliği sağlanmıştır. AES (Advanced Encryption Standard) gibi simetrik şifreleme algoritmaları, yüksek performanslı veri işleme süreçlerinde etkin bir şekilde kullanılabilirken, RSA (Şifreleme Algoritması) gibi asimetrik şifreleme algoritmaları, özellikle veri paylaşımı ve kullanıcı doğrulama süreçlerinde güvenliği artırmaktadır (Sinap, 2025). İstemciler verilerini asla merkezi sunucuya aktarmadan yerel eğitim işlemleri yürütür. Her bir istemci, yerel verileri üzerinde önceden belirlenen sayıda model eğitim adımı uygulanmaktadır (Altınışık ve Bilgin, 2024). Bu güncellemeleri TLS ve RSA ile şifreleyerek sunucuya iletir. Bu, iletim halindeki verileri dinleme ve kurcalamaya karşı korur (He ve diğ, 2024). Sunucu tarafında, istemcilerden gelen güncellemeler ağırlıklı bir yöntem kullanılarak birleştirilmiş ve genel model parametreleri güncellenmiştir (Altınışık ve Bilgin, 2024). Ağırlıklı toplama, istemcilerin modele olan etkisini dengelerken, güncellemelerin doğruluk ve verimliliğini artırmıştır (Altınışık ve Bilgin, 2024). Bu döngü, model belirli bir performans seviyesine ulaşana kadar sürdürülür.

Sistemin temel avantajları şunlardır:

- Endüstriyel veri sızıntısına karşı koruma
- Ölçeklenebilir ve dağıtık yapı
- Veri heterojenliğine karşı ağırlıklandırma stratejileri
- Güvenli ve uyarlanabilir FL altyapısı



Şekil 4.13: FL sistem mimarisi (TLS ve güvenli iletişim).

Bu mimari yapı, Şekil 4.13 ve Çizelge 4.6’da süreç adımlarıyla birlikte görsel olarak sunulmuştur.

Çizelge 4.6: FL round akışı.

Adım	Açıklama
1. Global Model Dağıtımı	Sunucu, istemcilere en güncel model parametrelerini gönderir.
2. Yerel Eğitim	İstemciler kendi verileriyle belirli tur süresince eğitim yapar.
3. Parametre Şifreleme	Güncellenmiş parametreler TLS ve RSA ile şifrelenir.
4. Model Güncellemesi	Sunucu, FedAvg ile parametreleri birleştirerek global modeli günceller.


4.2.1 Haberleşme protokolleri

FL mimarisi, merkezi sunucu ve yerel istemcilerden oluşan istemci-sunucu yapısı üzerine kuruludur; bu yapı, model güncellemelerinin koordine edilmesi ve veri gizliliğinin korunması için temel bir rol üstlenmektedir (Altınışık ve Bilgin, 2024). Bu yapı, FL’in dağıtık öğrenme sürecini yönetmek için merkezi bir kontrol noktası sağlar. Aynı zamanda sistemin genel senkronizasyonu nu sağlayarak, farklı istemciler arasında tutarlı bir model güncelleme süreci yürütülmesine olanak tanır. İstemciler, TensorFlow tabanlı modelleri yerel verileriyle eğitmiş, model güncellemelerini ise diferansiyel gizlilik mekanizmalarıyla şifreleyerek güvenli biçimde sunucuya iletmıştır. Bu yapı, bireysel verilerin kimliğinin korunmasını sağlayarak FL sistemlerinin güvenliğini ve uygulanabilirliğini artırmıştır. Matematiksel olarak, bu süreç şu şekilde ifade edilir:

$$w^{(t+1)} = \sum_{k=1}^K p_k \cdot w_k^{(t+1)} \quad (4.1)$$

Denklem 4.1 de, w^{t+1} global modelin yeni parametrelerini, w_k^{t+1} istemci k ’nın yerel model güncellemesini ve $p_k = \frac{n_k}{n}$ her bir istemcinin veri seti büyüklüğüne göre belirlenen ağırlığını ifade eder. Bu formül, FedAvg’in matematiksel temelini gösterir ve her bir istemcinin katkısının nasıl hesaplandığını açıklar. Böylece adil, dengeli ve

genelleştirilebilir bir model ortaya çıkarılır. Şekil 4.14, FL sistemlerinde istemcilerden sunucuya model parametre aktarımı, TLS ile şifreleme, ve sunucudan global modelin istemcilere asenkron olarak dağıtılmasını göstermektedir.



Şekil 4.14: FL istemci-sunucu haberleşme mimarisi.

Çizelge 4.7 , FL sisteminde iletişimi sağlayan temel katmanları ve bu katmanların işlevlerini özetlemektedir. Uygulama katmanı, model parametrelerinin istemci ve sunucu arasında oluşturulması ve paylaşılmasını yönetir. Şifreleme katmanı (örneğin TLS), iletilen verilerin güvenliğini sağlayarak dış müdahalelere karşı koruma sunar. İletim katmanı ise HTTP veya soket (socket) gibi protokoller aracılığıyla verinin taraflar arasında taşınmasını sağlar. Son olarak, asenkron kontrol mekanizması sayesinde yavaş çalışan istemcilerin sistemin genel performansını olumsuz etkilemesi önlenir. Bu katmanlar birlikte çalışarak hem güvenli hem de verimli bir FL altyapısı oluşturur.

Çizelge 4.7: FL iletişim katmanları ve görevleri.

Katman	Görev
Uygulama Katmanı	Model parametrelerinin oluşturulması ve alınması
Şifreleme Katmanı (TLS)	Veri aktarımının güvenliğini sağlama
İletim Katmanı	Sunucu-istemci arasında veri taşıma (HTTP/Soket)
Asenkron Kontrol	Yavaş istemcilerin sistem performansını düşürmemesi

Asenkron haberleşme mekanizmaları, FL sistemlerinin heterojen ve geniş ağlarda ölçeklenmesini kolaylaştırırken, TLS ve benzeri şifreleme protokolleri ise veri gizliliği ile birlikte bütünlük ve yetkilendirme unsurlarını da güvence altına alır. Bu yapı, endüstriyel düzeyde güvenli ve yüksek performanslı bir öğrenme altyapısı sağlar.

4.2.2 Model güncelleme mekanizması

Sunucu, genel bir model oluşturmak için gelen güncellemeleri toplar ve optimize eder (Altınışık ve Bilgin, 2024). Bu mekanizma, FL'in veri gizliliği ve dağıtık öğrenme avantajlarını korurken, global modelin sürekli olarak iyileştirilmesini sağlar. Aynı


zamanda, modelin farklı veri dağılımlarına maruz kalarak genelleştirme kabiliyetini artırmasına katkı sunar. FL uygulamasında, her bir istemci yerel verisi üzerinde model eğitimi yapmakta ve güncellenen model parametrelerini merkezi bir sunucuya iletmektedir; sunucu ise bu güncellemeleri birleştirerek genel bir model oluşturmaktadır (Altınışik ve Bilgin, 2024). Bu da, verilerin merkezi bir yerde toplanmasına gerek kalmadan, dağıtık bir öğrenme sürecini mümkün kılar. Çalışmamızda kullanılan model güncelleme mekanizması, FedAvg algoritması temel alınarak geliştirilmiştir. Sunucu bir başlangıç modeli oluşturur ve bunu seçilen istemcilere gönderir. Bu, tüm istemcilerin aynı başlangıç noktasından eğitime başlamasını sağlar ve sistemde senkronizasyonu garanti eder. İstemciler kendi yerel verileri üzerinde belirli sayıda model eğitim adımı gerçekleştirir (Altınışik ve Bilgin, 2024). Bu, her istemcinin kendi verilerine özgü bir model eğitimi yapmasını sağlar. İstemciler eğitilmiş model güncellemelerini (örneğin, ağırlık değişiklikleri) sunucuya geri gönderir (Altınışik ve Bilgin, 2024). Bu, global modelin güncellenmesi için gerekli olan bilgiyi sağlar. Sunucu, alınan güncellemeleri ağırlıklı ortalama veya başka bir algoritma kullanarak birleştirir ve global modeli günceller. Bu ağırlıklandırma, her istemcinin katkısını adil bir şekilde değerlendirir. Matematiksel olarak, bu süreç şu şekilde ifade edilir:

$$w^{(t+1)} = \sum_{k=1}^K p_k \cdot w_k^{(t+1)} \quad (4.2)$$

Denklem 4.2 de, w^{t+1} global modelin $t + 1$ iterasyonundaki parametrelerini, w_k^{t+1} her istemcinin $t + 1$ iterasyonundaki yerel model parametrelerini ifade eder. Ayrıca, $p_k = \frac{n_k}{n}$ olarak tanımlanan oran her istemcinin veri seti büyüklüğüne göre belirlenen ağırlığını temsil eder. Bu ağırlıklandırma yöntemi, daha fazla veriye sahip istemcilerin global modele daha fazla katkı yapmasını sağlar. Böylece, modelin genelleştirilebilirliği iyileştirilmiş olur. Python ve TensorFlow, FL sistemlerinde yaygın olarak kullanılan araçlardır ve esnek yapılarıyla farklı model türlerinin eğitilmesine olanak tanır. Kod yapısında, istemciler, yerel model eğitimi sırasında SGD algoritmasını kullanmıştır. Ancak FL'nin dağıtık yapısı, iletişim maliyetlerinin en aza indirilmesini ve cihaz heterojenliği ile ilgili zorlukların ele alınmasını gerektirmektedir (Altınışik ve Bilgin, 2024). Bu da, modelin bazı istemcilerde daha az etkili olmasına neden olabilir. Çalışmamızda bu sorunu ele almak için birkaç strateji

uygulanmıştır. Bu stratejiler, veri heterojenliğinin olumsuz etkilerini azaltmayı amaçlar. İlk olarak, diferansiyel gizlilik yöntemleriyle istemcilerden gelen model güncellemelerine rastgele bir gürültü eklenmiştir. Bu, bireysel verilerin korunmasını sağlarken, modelin genelleştirilebilirliğini de artırır. Bu yöntem, bireysel istemcilerin veri özelliklerini gizlerken aynı zamanda model parametrelerinin genelleştirilebilirliğini artırmıştır. Çalışmamızda iletişim maliyetleri azaltmak için gradyan sıkıştırma (gradient compression) yöntemleri uygulanmıştır. Bu yöntem, yalnızca önemli parametrelerin gönderilmesini sağlayarak iletişim yükünü azaltmıştır. Ayırıştırma tekniği, tüm parametreler yerine önemli parametreleri göndermek için parametreleri ayırtırmayı amaçlar (Chen ve diğ, 2023). Bu da hem işlem yükünü hem de ağ üzerinden yapılan veri aktarım süresini düşürmüştür. Kesintili bağlantılar nedeniyle IoT için FL'nin yakınsaması her zaman garanti edilemez (Chen ve diğ, 2023). Daha yüksek hesaplama kapasitesine sahip cihazlar daha fazla yerel eğitim turu gerçekleştirebilir ve FL sürecine daha etkili bir şekilde katkıda bulunabilir (Chen ve diğ, 2023). Çalışmamızda, istemcilerin model güncellemelerini merkezi sunucuya farklı zaman dilimlerinde göndermesine olanak tanıyan asenkron bir yapı geliştirilmiştir. Bu yapı, yavaş çalışan istemcilerin sistemin genel verimliliğini düşürmesini engellemiş ve model güncellemelerinin gecikmesini önlemiştir. Performans değerlendirmeleri, FedAvg algoritmasının genel model doğruluğunu ve genelleştirme yeteneğini artırmada etkili olduğunu göstermiştir. İletişim maliyetleri optimize edilmiş ve veri heterojenliğinden kaynaklanan sorunlar büyük ölçüde giderilmiştir. Ayrıca, diferansiyel gizlilik ve gradyan sıkıştırma yöntemlerinin bir arada kullanılması, sistemin güvenlik ve performans dengesini başarıyla kurmasını sağlamıştır. Çalışmamızda kullanılan model güncelleme mekanizması, FL sistemlerinin temel gereksinimlerini karşılamak üzere tasarlanmıştır. Bu mekanizma, FL'in veri gizliliği ve performans avantajlarını korurken, global modelin sürekli olarak iyileştirilmesini sağlar. FedAvg algoritmasının etkin bir şekilde uygulanması, hem bireysel istemci verilerinin gizliliğini korumuş hem de global modelin doğruluğunu artırmıştır. Bu, FL'in endüstriyel uygulamalarda güvenilir bir çözüm olarak kullanılmasını sağlar. FL; gizlilik, büyük ölçekli makine öğrenimi ve dağıtık optimizasyon gibi alanlarda temel ilerlemeler gerektirir (Li, 2020a). Bu, FL sistemlerinin daha da geliştirilerek endüstriyel uygulamalarda yaygınlaşmasını sağlayabilir. Şekil 4.15 de ki diyagram, global modelin istemcilere gönderilmesi, yerel

eğitimlerin yapılması, güncellemelerin toplanması ve FedAvg algoritması ile ağırlıklı ortalama alınarak modelin güncellenmesi sürecini göstermektedir.



Şekil 4.15: FedAvg model güncelleme süreci.

Çizelge 4.8, FL sistemlerinde kullanılan farklı model güncelleme yöntemlerini ve bu yöntemlerin öne çıkan avantajlarını özetlemektedir. FedAvg, basitliği ve uygulanabilirliğiyle öne çıkan temel bir ortalama alma yöntemidir. FedProx (Heterojen Ağlarda Federe Optimizasyon), istemciler arası veri heterojenliğinden kaynaklanan dengesizlikleri azaltmaya yönelik geliştirilmiştir. FedOpt (Federe Optimizasyon), global model güncellemelerinde momentum veya Adam (Optimizasyon Algoritması) gibi optimizasyon tekniklerini kullanarak öğrenme sürecini hızlandırır. Gradyan sıkıştırma, iletişim maliyetlerini düşürerek özellikle büyük ölçekli FL sistemleri için verimliliği artırır. Asenkron güncelleme ise istemcilerden eşzamanlı veri beklemeksizin model güncellemelerine olanak tanıyarak sistemi yavaş istemcilerin etkisinden korur.

Çizelge 4.8: FL model güncelleme yöntemleri ve avantajları.

Yöntem	Açıklama / Avantaj
FedAvg	Temel ağırlıklı ortalama, basit ve etkili
FedProx	Veri heterojenliğine karşı dayanıklı güncelleme
FedOpt	Global model güncellemelerinde momentum/adam optimizasyonu
Gradyan Sıkıştırma	İletişim yükünü azaltır, ölçeklenebilirliği artırır
Asenkron Güncelleme	Yavaş istemcilerden bağımsız güncelleme sağlar

Şekil 4.16 da, her bir tag sütunu için ortalama değerin $\pm\%5$ 'lik sınırları referans alınarak veriler "iyi" ve "kötü" olarak sınıflandırılmaktadır. Böylece yerel model için hedef değişkenler oluşturularak sınıflandırma problemi tanımlanmış olur. Bu yaklaşım, her istemcinin kendi verisi üzerinde model eğitmesini ve sonrasında FedAvg yöntemiyle güncellenen küresel modele katkı sağlamasını mümkün kılar. Hedef değişkenlerin bu şekilde belirlenmesi, modelin üretim sürecindeki normal ve anormal koşulları ayırt edebilmesini sağlar. FedAvg algoritmasının bu temel yapısı, daha ileri FL algoritmalarının (ör. FedProx, FedOpt) da temelini oluşturmaktadır. Model

güncelleme sürecinde kullanılan stratejiler, sadece doğruluk değil, aynı zamanda güvenlik, iletişim verimliliği ve genelleştirme açısından da kritik rol oynamaktadır.


Algorithm 5 Ortalama Sapmasına Göre Etiketleme Yap

```
1: procedure SAPMAYAGOREETIKETLE(veri, sutun)
2:   İlgili sütunun ortalamasını hesapla:  $ortalama \leftarrow \text{mean}(\text{veri}[\text{sutun}])$ 
3:   Alt sınırı belirle:  $\text{alt\_sinir} \leftarrow ortalama \times 0.95$ 
4:   Üst sınırı belirle:  $\text{ust\_sinir} \leftarrow ortalama \times 1.05$ 
5:   for her bir değer içinde sütun sutun do
6:     if değer alt_sinir ile ust_sinir arasındaysa then
7:       “iyi” olarak etiketle
8:     else
9:       “kötü” olarak etiketle
10:    end if
11:  end for
12:  Etiket sütununu hedef değişken (target) olarak ekle
13:  Orijinal sütunu özellikler listesine dahil et
14: end procedure
```

Şekil 4.16: FedAvg yaklaşımında yerel modelin hedef değişkenlerinin belirlenmesi.

4.3 Veri Güvenliği Önlemleri

FL, endüstriyel IoT sistemlerinde artan güvenlik ve verimlilik ihtiyacını karşılar (Altınışık ve Bilgin, 2024). Veri gizliliği, düşük iletişim maliyetleri ve hızlı model güncellemeleri gibi avantajlarıyla FL, operasyonel performans izleme ve optimizasyon için değerli bir çözüm sunar (Altınışık ve Bilgin, 2024). Çalışmamızda hem istemci hem de sunucu tarafında veri bütünlüğünü ve gizliliğini koruyacak çok katmanlı güvenlik önlemleri entegre edilmiştir. Bu önlemler sistemin yalnızca güvenli değil, aynı zamanda ölçeklenebilir ve sürdürülebilir olmasını da hedeflemektedir. Şekil 4.17 de, sistemimizde istemciler ve merkezi sunucu arasındaki güvenli iletişim yapısı ve uygulanan güvenlik katmanları görselleştirilmiştir:



Şekil 4.17: Güvenlik katmanları.

FL sistemimizde kullanılan başlıca güvenlik mekanizmaları şunlardır:

- AES, istemciden sunucuya model güncellemeleri gönderilirken verilerin simetrik şifreleme ile korunmasını sağlar. Bu çalışmada AES-128 tabanlı Fernet kütüphanesi kullanılmıştır. Fernet, kendisi kullanılarak şifrelenen verilerin anahtar olmadan manipüle edilemeyeceğini veya okunamayacağını garanti eder (Singh ve Chauhan, 2024). Verilerin şifresini çözmek için sağlanması gereken simetrik bir anahtar kullanarak verileri güvenli bir şekilde şifreleyerek gizliliği sağlar (Singh ve Chauhan, 2024).
- TLS, istemci ve sunucu arasındaki tüm iletişimi şifreleyerek üçüncü taraf erişimlerini engeller. Uygulamada TLS destekli requests.post() ile model ağırlıkları sunucuya aktarılmıştır.
- Diferansiyel Gizlilik: Bu çalışmada add_noise_to_weights() fonksiyonu ile Laplace mekanizması uygulanmıştır.
- Güvenli Toplama (Secure Aggregation): İstemciler ve sunucu arasındaki iletişim sırasında, anahtar çiftleri aracılığıyla kimliklerinin sahipliğini korurken gizliliği korumak için grup paylaşımlı anahtar çiftleri kullanılır (Byun ve diğ., 2024). Bu kapsamda sunucu tarafında her 10 istemciden sonra ağırlıklar ortalanarak FedAvg algoritması uygulanmaktadır.

Algorithm 6 Model Ağırlıklarını Diferansiyel Gizlilik ile Şifreleme

- 1: Fernet kullanarak simetrik bir şifreleme anahtarı üret
 - 2: Oluşturulan anahtarla şifreleme nesnesini başlat
 - 3: Rastgele model ağırlıkları üret
 - 4: Diferansiyel gizlilik için ϵ değerini belirle
 - 5: Laplace dağılımı kullanarak, ölçek $1/\epsilon$ ve ağırlıkların şekline uygun şekilde gürültü üret
 - 6: Üretilen gürültüyü ağırlıklara ekle ve gizli (private) ağırlıkları elde et
 - 7: Gizli ağırlıkları şifreleyici ile şifrele ve bayt formatına dönüştür
 - 8: Gönderilecek veri yapısını oluştur:
 - 9: istemci_id: "client_1"
 - 10: sifreli_agirliklar: şifrelenmiş sonuç
-

Şekil 4.18: İstemci tarafında güvenli eğitim.

Şekil 4.18 de, istemci tarafında gerçekleştirilen güvenli model ağırlığı hazırlama süreci gösterilmektedir. Ağırlıklara öncelikle diferansiyel gizlilik amacıyla Laplace gürültüsü eklenmiş, ardından bu veriler simetrik bir şifreleme algoritması olan Fernet ile şifrelenmiştir. Bu yöntem, hem veri gizliliğini hem de iletim güvenliğini sağlamayı hedeflemektedir.

Algorithm 7 Şifrelenmiş Ağırlıkları Birleştir

- 1: **procedure** BIRLESTIR(sifreli_veriler, anahtar)
 - 2: Verilen anahtar ile Fernet şifreleyicisini başlat
 - 3: *toplam* $\leftarrow$ Hiçbir şey (None) olarak başlat
 - 4: **for** her bir *veri* içinde *sifreli_veriler* **do**
 - 5: *veri*["sifreli_agirliklar"] alanını şifre çözücüyle çöz
 - 6: Çözülen bayt veriyi float64 tipinde NumPy dizisine dönüştür
 - 7: **if** *toplam* boşsa **then**
 - 8: *toplam* $\leftarrow$ *agirliklar*
 - 9: **else**
 - 10: *toplam* $\leftarrow$ *toplam* + *agirliklar*
 - 11: **end if**
 - 12: **end for**
 - 13: Ortalama hesaplama: *ortalama* $\leftarrow$ *toplam* / veri sayısı
 - 14: **return** ortalama
 - 15: **end procedure**
-


Şekil 4.19: Sunucu tarafında güvenli toplama.

Şekil 4.19 da, istemcilerden şifrelenmiş olarak gelen ağırlıkların sunucu tarafında güvenli bir şekilde çözülmesi ve ortalamasının alınması sürecini göstermektedir. Fernet anahtarıyla şifre çözme işlemi gerçekleştirilmekte ve her istemcinin ağırlıkları çözülerek toplama işlemine dahil edilmektedir. Tüm ağırlıklar çözüldükten sonra, ortalama hesaplanarak merkezi model güncellemesi için hazır hale getirilir. Bu

yöntem, FL süreçlerinde hem veri gizliliğini korur hem de merkezi güncelleme için güvenli bir toplama mekanizması sunar. Veri güvenliği yalnızca veri aktarımı ile sınırlı kalmayıp, istemci ve sunucu arasında gerçekleşen bağlantının güvenilirliğini de kapsamaktadır. Bu doğrultuda:

- SSL anahtar değişimi, oturum anahtarını istemciden sunucuya şifreleyen oturum anahtarı değişimi için asimetrik bir teknik olan RSA algoritması kullanabilir (Ho ve Chai, 2010). RSA anahtar değişimi SSL el sıkışması sırasında gerçekleştirilir (Ho ve Chai, 2010).
- Uygulanan güvenlik önlemleri, yalnızca gizliliği sağlamakla kalmamış; aynı zamanda sistemin iletişim verimliliğini de artıracak şekilde yapılandırılmıştır:
- Yerel güncelleme yöntemleri toplam iletişim turu sayısını azaltabilirken, model sıkıştırma şemaları da FL’deki veri aktarım hacmini azaltmak için kullanılabilir (Neto ve diğ., 2023).
- Seyrek güncellemeler: Bu sayede ağ trafiği azaltılmakta, enerji ihtiyacı düşürülmektedir (Büyüktanır ve diğ., 2023).

Gerçekleştirilen simülasyonlar, uygulanan güvenlik mekanizmalarının model başarımı üzerinde minimal etkiyle yüksek veri gizliliği sağladığını ortaya koymuştur. Bu, özellikle hassas üretim verilerinin işlendiği senaryolarda FL mimarisinin güvenli kullanılabileceğini göstermektedir. Çalışmamızda diferansiyel gizlilik, güvenli toplama, AES ve TLS gibi modern mekanizmaların entegre biçimde kullanılması sayesinde, FL sisteminin hem güvenli hem de regülasyonlara uyumlu bir yapıya kavuşması sağlanmıştır. Gelecekte daha karmaşık güvenlik protokollerinin FL mimarilerine entegre edilmesiyle, bu sistemlerin çok daha geniş çaplı endüstriyel uygulamalarda yaygınlaşması mümkün olacaktır. Böylece, veri güvenliği alanındaki inovasyonlar, FL tabanlı sistemlerin yaygın ve güvenilir kullanımının temel yapı taşlarından biri olmaya devam edecektir. Şekil 4.20’de ki diyagramda FL sisteminin istemci tarafındaki LSTM tabanlı eğitim süreci, DP (Farklılaştırılmış Gizlilik), AES şifreleme, TLS+RSA ile şifreli iletişim ve sunucu tarafında FedAvg ile SA mimarisi gösterilmektedir.



Şekil 4.20: FL güvenlik mimarisi (katmanlı koruma yapısı).

Çizelge 4.9, FL sisteminin güvenlik mimarisi ve kullanılan koruma protokollerini özetlemektedir.

Çizelge 4.9: Kullanılan güvenlik protokolleri ve rolleri.

Protokol / Mekanizma	Görev / Açıklama
AES-128	İstemcide yerel model güncellemelerini simetrik şekilde şifreleme
DP	Bireysel veri çıkarımına karşı rastgele gürültü ekleme
TLS	Sunucu-istemci arasında güvenli veri iletimi
RSA	Anahtar paylaşımı ve kimlik doğrulama
SA	İstemci katkılarını anonim şekilde birleştirme
Parametre Sıkıştırma	İletişim trafiğini azaltma ve verimlilik

Şekil 4.21 de, diferansiyel gizlilik ve AES benzeri simetrik şifreleme tekniklerinin birlikte kullanılarak güvenli ağırlık gönderimini göstermektedir. İlk olarak, model ağırlıklarına $\epsilon=0.5$ parametresiyle Laplace gürültüsü eklenerek hassas veri koruması sağlanmıştır. Ardından, elde edilen özel ağırlıklar Fernet ile şifrelenmiş ve istemci bilgisiyle birlikte veri paketi yapısında iletme hazır hâle getirilmiştir.

Algorithm 8 Gürültülü Model Ağırlıklarını Şifrele ve Yük Oluştur

- 1: Fernet kullanarak şifreleme anahtarı üret
- 2: Bu anahtarla şifreleyiciyi başlat
- 3: Rastgele model ağırlıkları oluştur
- 4: Diferansiyel gizlilik için ϵ değerini belirle
- 5: Laplace dağılımı ile, ölçek $1/\epsilon$ ve ağırlıklarla aynı şekle sahip gürültü üret
- 6: Gürültüyü ağırlıklara ekle: $ozel_agirliklar \leftarrow agirliklar + gurutlu$
- 7: $ozel_agirliklar$ 'ı bayt formatına çevir ve şifreleyici ile şifrele
- 8: Yüğü oluştur:
- 9: $istemci_id \leftarrow "client_1"$
- 10: $sifreli_agirliklar \leftarrow$ şifrelenmiş bayt verisi

Şekil 4.21: Diferansiyel gizlilik + AES ile güvenli ağırlık gönderimi

Şekil 4.22 de şifrelenmiş istemci ağırlıklarını çözerek merkezi model güncellemesi için güvenli bir şekilde toplama işlemini gerçekleştirmektedir. Her bir veri paketi

içerisindeki ağırlıklar Fernet anahtarı ile çözülür ve np.frombuffer ile tekrar sayısal formata dönüştürülerek toplam ağırlıklar hesaplanır. Toplam ağırlıklar istemci sayısına bölünerek ortalama alınmakta ve bu sonuç, FedAvg algoritmasında kullanılmak üzere sunucu tarafında döndürülmektedir. Böylece hem veri gizliliği korunur hem de güvenli ve merkezi birleştirme sağlanır. FL sistemlerinde uygulanan güvenlik mekanizmaları yalnızca verinin gizliliğini değil, sistemin bütünlüğünü, erişim kontrolünü ve sürdürülebilirliğini de koruma amacı taşımaktadır. Güvene dayanmayan mimari (trustless architecture) yaklaşımı ve doğrulanabilir hesaplama (verifiable computation) sistemleri, gelecekte FL sistemlerinin daha da güvenli hale gelmesini sağlayacaktır.

Algorithm 9 Şifrelenmiş Ağırlıkları Çözerek Birleştirme

```

1: procedure BIRLESTIR(sifreli_veriler, anahtar)
2:   Verilen anahtar ile Fernet şifreleyiciyi başlat
3:   toplama ← Hiçbir şey (None) olarak başlat
4:   for her bir veri içinde sifreli_veriler do
5:     “sifreli_agirliklar” alanını şifre çözücüyle çöz
6:     Çözülen baytları float dizisine dönüştür
7:     if toplama boşsa then
8:       toplama ← agirliklar
9:     else
10:      toplama ← toplama + agirliklar
11:    end if
12:  end for
13:  if toplama boş değilse then
14:    return toplama / yük sayısı
15:  else
16:    return Hiçbir şey (None)
17:  end if
18: end procedure

```

Şekil 4.22: Güvenli Toplama Fonksiyonu (Sunucu Tarafı).

4.3.1 Şifreleme mekanizmaları

FL, Merkezi veri paylaşımı olmadan çalışsa da, aktarılan model parametreleri potansiyel saldırılarla hassas bilgilerin açığa çıkmasına neden olabileceğinden, yalnızca gizlilik değil veri bütünlüğü ve kimlik doğrulama da kritik öneme sahiptir. Aşağıda, istemci tarafında model parametrelerinin AES ile nasıl şifrelendiğine dair örnek bir Python kod parçası sunulmuştur:

Algorithm 10 Model Ağırlıklarını AES-GCM ile Şifreleme

- 1: Örnek model ağırlıkları üret
 - 2: $agirlıklar \leftarrow$ rastgele ondalıklı (float) dizi
 - 3: 256-bit simetrik AES anahtarı üret
 - 4: Rastgele bir nonce ile GCM kipinde AES şifreleyicisi oluştur
 - 5: Ağırlıkları şifrele ve doğrulama etiketi üret:
 - 6: $sifreli_veri, etiket \leftarrow sifreleyici.encrypt_and_digest(agirlıklar)$
 - 7: İletim için yükü hazırla:
 - 8: $nonce \leftarrow sifreleyici.nonce$
 - 9: $sifreli_veri \leftarrow$ şifrelenmiş ağırlıklar
 - 10: $etiket \leftarrow$ doğrulama etiketi
 - 11: Tüm bileşenleri içeren bir yük nesnesi oluştur
-

Şekil 4.23: Model parametrelerinin AES ile şifrlenerek gönderime hazırlanması.

Şekil 4.23 de, model ağırlıklarının AES algoritması ile şifrlenerek güvenli şekilde iletilmesini sağlamaktadır. Model ağırlıkları, AES-GCM (Galois/Sayaç Şifreleme Modu) algoritmasıyla şifrelenmiş ve TLS ile güvenli bir şekilde sunucuya iletilmiştir. Bu yapı, veri bütünlüğü ve gizliliğini koruyarak sunucunun yalnızca model parametreleriyle işlem yapmasına olanak tanımıştır. Örneğin istemci tarafında TLS bağlantısı kurularak verilerin güvenli bir şekilde sunucuya aktarılması aşağıdaki gibi yapılandırılmıştır:


Algorithm 11 Şifrelenmiş Yükü TLS Üzerinden İlet

- 1: Varsayılan bir SSL/TLS bağlamı (context) oluştur
 - 2: Sunucunun 443 numaralı portuna TCP bağlantısı kur
 - 3: Güvenli iletişim için soketi (socket) SSL bağlamıyla sar
 - 4: Şifrelenmiş yükü güvenli soket üzerinden gönder:
 - 5: Yük içindeki şifreli veriyi TLS ile ilet
-

Şekil 4.24: TLS protokolü ile şifreli veri aktarımı.

Şekil 4.24 de, istemciden sunucuya veri aktarımını TLS protokolü üzerinden güvenli hale getirmektedir. ssl kütüphanesi kullanılarak bir güvenli bağlantı konteksi oluşturulur ve soket ile sunucuya bağlantı sağlanır. Ardından, wrap_socket fonksiyonu ile bu bağlantı TLS katmanıyla sarılır ve şifrelenmiş veri (ciphertext) güvenli biçimde iletilir. Bu yöntem, aktarım sırasında üçüncü tarafların veriye erişmesini engelleyerek uçtan uca güvenlik sağlar. FL uygulamalarında iletişim katmanının güvenliği, sadece gizlilik açısından değil, aynı zamanda sistemin bütünlüğünü korumak açısından da kritik öneme sahiptir. Bu nedenle, çalışmamızda yalnızca güçlü şifreleme yöntemleri kullanılmakla kalmamış; aynı zamanda bu yöntemlerin sistem performansı üzerindeki

etkileri de analiz edilmiştir. Özellikle geniş çaplı FL sistemlerinde, büyük miktarda verinin sürekli şifrlenmesi ve çözülmesi ekstra işlem yükü oluşturabilir. Bu yükü azaltmak amacıyla; AES-CBC (Şifreleme Blok Zinciri) şifrelemesinde, her bir doğrudan şifreleme için giriş bloğu (ilki hariç) bir önceki doğrudan şifreleme işleminin sonucuna bağlıdır, bu nedenler doğrudan şifreleme işlemi paralel olarak gerçekleştirilemez (Medetov ve diğ, 2023). Bu nedenle, sayısal deneylerde kullanılan FPGA (Alanda Programlanabilir Kapı Dizileri)'da, AES-GCM ve AES-CCM (CBC Sayaç Modu) şifrelemesini dört akışa, Chacha20'yi ise yalnızca iki akışa paralelleştirmek mümkündür (Medetov ve diğ, 2023). Benzer şekilde; TLS, önceki bağlantılardan gelen kriptografik TLS durumunu yeniden kullanarak gecikmeyi azaltan ve pahalı kriptografik işlemlerden tasarruf sağlayan kısaltılmış yeniden başlatma el sıkışmaları yoluyla önceki bağlantıları devam ettirebilir (Sy ve diğ, 2020). Böylece, hem güvenlik hem de verimlilik bir arada sağlanmıştır. Günümüzde şifreleme protokollerinin tek başına yeterli koruma sağlamadığı durumlar da olabilmektedir. Bu nedenle, sistemimize diferansiyel gizlilik ve güvenli toplama gibi ilave güvenlik katmanları da entegre edilmiştir. Bu kombinasyon sayesinde, yalnızca iletim sürecindeki veriler değil; aynı zamanda istemcilerin bireysel katkılarının da anonim kalması sağlanmıştır. Bu durum, sistem genelinde gizlilik düzeyini daha da yükseltmiş ve bireysel veri farklılıklarının korunmasına olanak tanımıştır. FL sistemimizde uygulanan tüm şifreleme mekanizmalarının etkinliği, özel olarak gerçekleştirilen güvenlik testleriyle değerlendirilmiştir. Bu sonuçlar, sistemimizin endüstriyel uygulamalarda güvenle kullanılabileceğini ortaya koymuştur. İlerleyen dönemde, özellikle post-kuantum şifreleme algoritmaları gibi daha gelişmiş tekniklerin entegrasyonu ile FL sistemlerinin güvenlik kapasitesi daha da artırılabilir. Bu gelişmeler, FL mimarisinin daha geniş ölçekli ve kritik endüstriyel uygulamalarda güvenle kullanılmasına olanak tanıyacaktır. Şekil 4.25 de ki görsel, istemci tarafında model parametrelerinin önce AES ile şifrlenmesini, ardından TLS üzerinden güvenli biçimde sunucuya iletilmesini ve burada SA ile birleştirilmesini göstermektedir.



Şekil 4.25: Şifreleme katmanları ve veri akışı.

Çizelge 4.10 da, AES ve TLS protokollerinin temel özellikleri karşılaştırılmaktadır. AES, simetrik şifreleme yöntemiyle model ağırlıklarının veri düzeyinde korunmasını sağlarken; TLS, istemci ve sunucu arasındaki iletişim kanalını güvenli hale getirir.

Anahtar yönetimi açısından AES, istemciye özgü tek bir anahtar kullanırken; TLS, dijital sertifikalar ve oturum anahtarları ile daha karmaşık bir yapı sunar. Her iki yöntem de gizlilik ve bütünlük sağlar, ancak kullanım bağlamları ve uygulama katmanları farklılık göstermektedir.

Çizelge 4.10: AES ve TLS özelliklerinin karşılaştırılması.

Özellik	AES	TLS
Şifreleme Türü	Simetrik (GCM Modu)	Asimetrik + Simetrik
Kullanım Yeri	Veri şifreleme (model parametresi)	İletişim kanalı güvenliği
Anahtar Yönetimi	Tek anahtar (istemciye özel)	Sertifika ve oturum anahtarları
Performans	Yüksek hız	Optimizasyon (TLS 1.3)
Gizlilik + Bütünlük	Evet (GCM tag)	Evet (MAC, el sıkışma)

AES ve TLS gibi şifreleme mekanizmaları, FL sistemlerinin hem veri gizliliği hem de iletişim güvenliğini sağlaması açısından kritik bileşenlerdir. Özellikle TLS 1.3'ün düşük gecikme ve oturum anahtarı yönetimi avantajları ile AES'in GCM modunun sağladığı hızlı ve bütünlük korumalı şifreleme, endüstriyel sistemlerde sürdürülebilir güvenlik sağlar. Gelecekte post-kuantum algoritmaların (örneğin lattice-based) entegrasyonu bu korumayı daha ileri seviyeye taşıyacaktır.

4.3.2 Gizlilik koruma protokolleri

FL, gizliliğin korunmasının yapay zekanın geliştirilmesinde kilit bir faktör haline gelmesiyle birlikte son zamanlarda araştırmaların büyük ilgisini çekmiştir (Hu ve diğ, 2024). FL, birden fazla kullanıcının gizliliklerinin tehlikeye atılmamasını sağlarken model eğitime katılmasına izin veren özel bir tür dağıtılmış öğrenme çerçevesidir; ancak bu paradigma hala çeşitli saldırganlardan gelen güvenlik ve gizlilik tehditlerine karşı savunmasızdır (Hu ve diğ, 2024). Bu durum, FL'in dağıtık yapısını sürdürülebilir ve güvenli kılmak adına uygulamada da zorunlu hale gelmiştir. Çalışmamızda diferansiyel gizlilik ve güvenli toplama gibi modern yaklaşımlar uygulanarak bireysel verilerin ifşa edilmesi riski ortadan kaldırılmıştır. Bu protokollerin etkinliği, hem

sistemin bütünlüğünü hem de istemcilerin FL'e duyduğu güveni doğrudan etkilemektedir. Diferansiyel gizlilik, sağlam ve titiz garantileri nedeniyle gizliliği koruyan veri analizi için yaygın olarak resmi fizlilik olarak kabul edilir ve kamu hizmetleri, akademi ve endüstride giderek daha geniş bir şekilde benimsenir (Su, 2024). FL mimarisi içerisinde bu yöntem, model güncellemelerine belirli bir düzeyde rastgelelik (gürültü) eklenerek uygulanmıştır. Gelişmiş bir gizlilik koruma teknolojisi olan DP, veri sorguları ve model güncellemeleri sırasında rastgele gürültü ekleyerek FL 'nin gizlilik koruma kapasitesini daha da artırır (Shan ve diğ, 2024).



Şekil 4.26: Diferansiyel gizlilik süreci.


Şekil 4.26 de ki yapı sadece gizliliği korumakla kalmaz, aynı zamanda sistemin daha geniş kullanıcı gruplarınca benimsenmesini de kolaylaştırır. DP ile gizlilik koruma olasılıksaldır: gizlilik kaybı bütçe parametresi ϵ ile sınırlandırılırlar (Nanayakkara ve diğ, 2023). Bu tür metaforlar, insanların bir gizlilik-doğruluk ödünleşimi olduğunu anlamalarına yardımcı olabilir; öyle ki enjekte edilen gürültüyü arttırmak gizlilik garantisini güçlendirir ancak doğruluğa zarar verir (Nanayakkara ve diğ, 2023). Bu sebeple sistemimizde bu parametre dikkatle optimize edilmiştir. Veri akışında kullanılan Laplace ve Gaussian mekanizmaları, özellikle sayısal hassasiyet gerektiren üretim verilerinde bireysel veri noktalarının anonimleştirilmesini sağlamakta etkili olmuştur. Uç durumları yönetmenin yanı sıra, istemci tarafından paylaşılan istatistikleri, eğitilmiş modelin eşitsizliğini anlamada çok önemli bir rol oynar (Corbucci ve diğ, 2024). Model adaletinin genel bir görünümü, sunucunun tüm veri kümesine erişimi varmış gibi demografik eşitsizliğin hesaplanmasına olanak tanıyan, bireysel istemcilerden gelen çeşitli sayaçların toplanmasını içerir (Corbucci ve diğ, 2024). Python ile geliştirilen sistemimizde, aşağıdaki gibi bir örnekle bu yapı entegre edilmiştir:

Algorithm 12 Laplace Mekanizması ile Diferansiyel Gizlilik Ekleme

- 1: Gizlilik parametresini ayarla: $\epsilon \leftarrow 0.7$
 - 2: Verilen ϵ ile Laplace mekanizmasını başlat
 - 3: Gerçek değeri giriş olarak al: $x \leftarrow 2.718$
 - 4: Diferansiyel gizlilikli çıktı üret:
 - 5: $gurultulu_deger \leftarrow \text{LaplaceMechanism.randomise}(x)$
-

Şekil 4.27: Laplace mekanizması ile diferansiyel gizlilik uygulaması.

Şekil 4.27 da, model güncellemelerine rastgele gürültü eklenmiş ve istemciler arası ayrımcılığı önleyen bir anonimlik katmanı sağlanmıştır.



Şekil 4.28: SA akış diyagramı.


Şekil 4.28 de ki bu yapının avantajı, istemcilerin birbirlerinin verilerini bilmesine gerek olmadan güncellemelerin toplanmasını sağlamasıdır. Çalışmamızda güvenli toplama, RSA temelli şifreleme algoritmalarıyla gerçekleştirilmiştir. Aşağıda kullanılan yapıya ait örnek kod sunulmuştur:

Algorithm 13 Model Güncellemesini RSA ile Şifreleme

- 1: 2048-bit uzunluğunda RSA anahtar çifti oluştur
 - 2: OAEP şeması kullanarak RSA şifreleyicisini başlat
 - 3: Model güncellemesini bayt dizisi olarak tanımla
 - 4: Model güncellemesini RSA ile şifrele
 - 5: Şifrelenmiş sonucu güvenli iletim için sakla
-


Şekil 4.29: RSA ve OAEP ile asimetrik şifreleme kullanımı.

Şekil 4.29 da, model güncellemelerinin asimetrik şifreleme yöntemiyle korunmasını göstermektedir. 2048 bit uzunluğunda bir RSA anahtar çifti oluşturulmuş ve PKCS1_OAEP modülü kullanılarak model ağırlıkları (model_weights) şifrelenmiştir. Bu yöntem, özellikle istemciden sunucuya güvenli veri iletiminde kullanılır ve yalnızca alıcının özel anahtarı ile çözülebilir. OAEP (Optimum Asimetrik Şifreleme Dolgusu) dolgulama şeması, RSA algoritmasını daha güvenli hale getirerek şifreleme saldırılarına karşı ek koruma sağlar. İstatistiklerin sunucu ile paylaşılması, modelin tahminleri ve her bir istemcinin veri dağılımı hakkında potansiyel olarak bilgi sızdırabilir (Corbucci ve diğ., 2024). Bu nedenle, σ_3 gürültüsüne karşılık gelen bir gizlilik bütçesi (ϵ_3, δ_3) kullanarak paylaşılan istatistiklere DP uyguluyoruz (Corbucci ve diğ., 2024). DP-SGD'yi küçük değişikliklerle kullandığımız için model eğitiminin gizliliği hemen ardından gelir; mini yığın (minibatch), belirli bir örnekleme oranıyla Poisson örnekleme yoluyla seçilir ve örnek başına gradyanları kırparız ve her boyuta $N(0, B^2\sigma_1^2)$ olarak dağıtılan gürültü ekleriz (Corbucci ve diğ., 2024).




Şekil 4.30: Epsilon değerine göre gizlilik/doğruluk eğrisi.

Yukarıda açıklanan optimizasyonlar, FL sisteminin güvenliğini korurken işlem süresini minimize etmeyi başarmış ve sistemin genel başarımını yükseltmiştir. Bu çalışmalar sonucunda FL sistemimiz, yalnızca gizliliği sağlamakla kalmamış, aynı zamanda endüstriyel veri güvenliği standartlarına da uyum göstermiştir. Şekil 4.30 da görüldüğü gibi elde edilen sonuçlar, diferansiyel gizlilik ve güvenli toplama mekanizmalarının hem bireysel veriyi koruma hem de FL sisteminin ölçeklenebilirliğini destekleme konusunda etkili olduğunu göstermektedir. Bu sistem yapısı, özellikle gizli üretim verilerinin işlendiği senaryolarda güvenilirlik düzeyini artırmıştır. Katkımız, yüksek doğruluk, istemcilerin güvenliği ve yeterince temsil edilmeyen gruplar için adalet sağlayabilen FL modellerinin geliştirilmesine yönelik önemli bir adımı temsil etmektedir (Corbucci ve diğ., 2024). Model güncellemeleri üzerine rastgele gürültü eklenmesi ve bu güncellemelerin şifrelenerek sunucuya iletilme süreci gösterilmektedir. Şekil 4.31 de anlatılan mimarinin akış diyagramı görülmektedir.



Şekil 4.31: Diferansiyel gizlilik süreci.

SA yapısı ise Şekil 4.32 de tanımlanmıştır.



Şekil 4.32: SA yapısı.

Çizelge 4.11, FL sistemlerinde uygulanan gizlilik koruma yöntemlerinin güçlü yönlerini ve sınırlılıklarını karşılaştırmalı olarak sunmaktadır. SA, sunucunun istemciye ait bireysel güncellemeleri görmesini engeller ancak istemcilerin çevrimdışı kalma durumlarına karşı tolerans gerektirir. AES ve TLS kombinasyonu, aktarım esnasında veri güvenliğini sağlarken; bu yöntemlerin uygulanmasında anahtar yönetimi operasyonel karmaşıklık yaratabilir. Bu tablo, güvenlik-gizlilik dengesinin teknik gereksinimlerle birlikte değerlendirilmesi gerektiğini ortaya koymaktadır.

Çizelge 4.11: Gizlilik koruma yöntemlerinin avantaj ve sınırlılıkları.


Yöntem	Avantaj	Sınırlılık
Diferansiyel Gizlilik	Bireysel katkıların gizlenmesi	Model doğruluğunda azalma riski
SA	Sunucunun bireysel güncellemeleri görememesi	Bağlantı kesintisi (dropout) toleransı gerektirir
AES + TLS	Aktarım sırasında veri güvenliği	Anahtar yönetimi karmaşıklığı

Gizlilik koruma protokolleri, yalnızca FL sistemlerinin güvenliğini değil, aynı zamanda regülasyonlara uyumluluğunu da sağlar. Diferansiyel gizlilik, GDPR ve HIPAA gibi yasal düzenlemelerle doğrudan örtüşmektedir. Ayrıca bu yapılar, FL sistemlerini karşıt model yeniden yapılandırma (adversarial reconstruction) gibi saldırılara karşı da korumakta, veri sahiplerinin güvenliğini artırmaktadır.

4.4 Performans Metrikleri ve Değerlendirme Kriterleri

FL ile geliştirilen modelin performansı doğruluk, F1 score, kesinlik ve duyarlılık gibi ölçütler kullanılarak değerlendirilmiştir (Altınışık ve Bilgin, 2024). Çalışmamızda, doğruluk metriklerinin yanı sıra iletişim yükü, genelleştirme yeteneği ve hesaplama verimliliği gibi unsurlar da performans analizine dahil edilmiştir. Heterojen veri setlerinin oluşturduğu dengesizlik durumu, bu metriklerin birlikte kullanılmasını zorunlu hale getirmektedir. Doğruluk kaybını en aza indirmek için, gelecekteki araştırmaların daha gelişmiş optimizasyon yöntemlerini keşfetmesi ve FL modellerinin doğruluğunu artırmak için iyileştirmeler uygulaması önerilmektedir (Altınışık ve Bilgin, 2024). Model güncellemelerinin sıkıştırılması, ağ üzerinden iletilen veri miktarını azaltarak iletişim maliyetlerini düşürür ve sistem verimliliğini

artırır (Altınışik ve Bilgin, 2024). Ancak her istemci nin merkezi sunucuya model güncellemelerini göndermesi gerektiğinden, bu süreçte oluşan veri trafiği özellikle geniş çaplı sistemlerde ciddi bir yük haline gelebilir. Bu yükü azaltmak için çalışmamızda Şekil 4.33 de gösterildiği gibi gradyan sıkıştırma ve seyrek güncelleme yöntemleri kullanılmıştır.




Şekil 4.33: İletişim maliyetini azaltan yapı.

Bu yaklaşım, ağ üzerindeki veri aktarımını azaltmış, FL sisteminin gecikmesiz çalışmasına olanak tanımıştır. Modelin heterojen veri setleri üzerindeki başarımı, genelleştirme yeteneğinin belirlenmesi açısından kritik bir diğer değerlendirme alanıdır. İstemciler genellikle farklı sektörlerden, makinelerden veya süreçlerden veri toplar. İstemciler arasındaki veri heterojenliği, tek bir istemci ile öğrenmeye kıyasla aşırı uyumun gerçekleşme olasılığını daha yüksek hale getirecektir (Chen ve Chen, 2022). Güvenli toplamanın diferansiyel gizlilik ile birleştirilmesi, FL sistemlerinde uçtan uca gizlilik sağlar (Stevens ve diğ., 2022). Elde edilen bulgular, bu protokollerin yalnızca veri gizliliğini sağlamakla kalmayıp, aynı zamanda sistemin genel performansını da artırdığını göstermektedir. Bu, FL mimarisinin hem güvenli hem de istikrarlı olabileceğini kanıtlayan önemli bir göstergedir. Performans değerlendirmesi sırasında dikkate alınan bir diğer ölçüt ise sistemin ölçeklenebilirliğidir. Özellikle, istemci sayısı arttığında modelin güncellemeleri senkron veya asenkron şekilde yönetilmesi sistemin esnekliğini ortaya koymuştur. FL sistemlerinde senkron ve asenkron iletişim yapılarının model eğitimi üzerindeki etkileri karşılaştırmalı olarak analiz edilmiştir. Senkron yapı, tüm istemcilerin model güncellemelerini tamamladıktan sonra sunucunun ağırlıkları güncellemesi prensibine dayanırken, asenkron yapı, güncellemelerin eşzamanlılık zorunluluğu olmaksızın sunucuya iletilmesine olanak tanımaktadır. Çizelge 4.12 de ki sonuçlara göre, senkron yaklaşımda bir global tur süresi ortalama 14.2 saniye olup toplam eğitim süresi 48 saniyeye ulaşmıştır. Bu yapı ile elde edilen doğruluk oranı %95.3 seviyesindedir. Asenkron yapıda ise daha kısa global tur süresi (~6.8 saniye) ve toplamda daha düşük eğitim süresi (32 saniye) elde edilmiş, ancak doğruluk oranı %92.1'e düşmüştür. Bu bulgular, senkron yapının doğruluk açısından avantaj sağlarken; asenkron yapının zaman ve iletişim verimliliği bakımında öne çıktığını göstermektedir. Bu nedenle yapı tercihi, uygulamanın doğruluk ve zaman duyarlılığına göre belirlenmelidir.

Çizelge 4.12: Asenkron ve senkron mimarilerin performans analizi

Kategori	Açıklama
Doğruluk Metrikleri	Hassasiyet, hatırlama, F1 skor ile modelin pozitif sınıfları tanıma başarısı ölçüldü.
İletişim Maliyeti	Gradyan sıkıştırma ve seyrek güncellemeler ile veri aktarım boyutu azaltıldı.
Genelleştirme Yeteneği	Heterojen veri dağılımına karşı modelin kararlılığı test edildi.
Ölçeklenebilirlik	5–100 istemci arasında test edildi; performans ve doğruluk sürdürüldü.
Hesaplama Verimliliği	Paralel hesaplama ve asenkron eğitim ile eğitim süresi ve kaynak tüketimi optimize edildi.
Gizlilik Etkisi	Diferansiyel gizlilik ve güvenli toplama protokollerinin performansa etkisi analiz edildi.

Şekil 4.34 de FL ortamında istemci sayısındaki artışın model doğruluğu ve iletişim süresi üzerindeki etkilerini çift eksenli bir grafik ile göstermektedir. İstemci sayısı arttıkça model doğruluğunun kademeli olarak azaldığı, buna karşılık iletişim süresinin belirgin şekilde yükseldiği gözlemlenmektedir. Bu durum, daha fazla istemcinin sisteme dahil edilmesinin veri çeşitliliğini artırarak doğruluğu olumsuz etkileyebileceğini ve aynı zamanda iletişim yükünü artırarak sistemin gecikmesine yol açabileceğini ortaya koymaktadır.



Şekil 4.34: İstemci sayısına göre doğruluk ve gecikme.

Hesaplama verimliliği, sistem performansını etkileyen önemli bir faktördür. Model eğitimi sırasında istemcilerde kullanılan CPU (Merkezi İşlem Birimi) ve GPU kaynakları izlenmiş, eğitim süresi ve kaynak kullanımı analiz edilmiştir. Paralel hesaplama teknikleri ve optimize kod yapısı sayesinde eğitim süresi önemli ölçüde kısaltılmıştır. Ayrıca, uç cihazlarda daha hafif model seçenekleri değerlendirilmiş ve istemciler arasındaki senkronizasyon, asenkron mimariyle desteklenmiştir. Bu sayede düşük donanım kapasitesine sahip istemcilerin sisteme katılması kolaylaştırılmıştır. Modelin başarısı, yalnızca doğruluk oranıyla değil; iletişim, hesaplama ve genelleştirme gibi farklı kriterlerle birlikte değerlendirilmiştir. Özellikle güvenlik protokollerinin performansı olumsuz etkilememesi, çalışmanın önemli sonuçlarından biri olmuştur. Sonuçlar, FL mimarisinin merkezi veri toplamaya ihtiyaç duymadan yüksek performanslı, güvenli ve esnek bir öğrenme süreci sunabileceğini göstermiştir.

Çizelge 4.13: Performans metrikleri ve FL sistemine katkıları.

Kategori	Açıklama
Doğruluk Metrikleri	Hassasiyet, hatırlama, F1 skor ile modelin pozitif sınıfları tanıma başarısı ölçüldü.
İletişim Maliyeti	Gradyan sıkıştırma ve seyrek güncellemeler ile veri aktarım boyutu azaltıldı.
Genelleştirme Yeteneği	Heterojen veri dağılımına karşı modelin kararlılığı test edildi.
Ölçeklenebilirlik	5–100 istemci arasında test edildi; performans ve doğruluk sürdürüldü.
Hesaplama Verimliliği	Paralel hesaplama ve asenkron eğitim ile eğitim süresi ve kaynak tüketimi optimize edildi.
Gizlilik Etkisi	Diferansiyel gizlilik ve güvenli toplama protokollerinin performansa etkisi analiz edildi.


Çizelge 4.13, FL sisteminin çok boyutlu performans değerlendirmesine ilişkin temel metrikleri ve bu metriklerin sisteme katkılarını özetlemektedir. Doğruluk metrikleri, özellikle hassasiyet, hatırlama ve F1 skor aracılığıyla modelin sınıflandırma başarısını ortaya koyarken; iletişim maliyeti, gradyan sıkıştırma ve seyrek güncellemeler ile optimize edilmiştir. Genelleştirme yeteneği, heterojen veri senaryolarında modelin tutarlılığını ölçmek için değerlendirilmiş; ölçeklenebilirlik, farklı istemci sayılarında test edilerek doğruluğun sürdürülebilirliği gözlemlenmiştir. Ayrıca, hesaplama verimliliği paralel işleme ve asenkron eğitim stratejileriyle artırılmış; gizlilik etkisi ise diferansiyel gizlilik ve SA tekniklerinin doğruluk üzerindeki etkileri analiz edilerek incelenmiştir. Bu bütüncül yaklaşım, FL sistemlerinin hem güvenli hem de etkili bir şekilde çalışmasını sağlamaya yöneliktir.

Çizelge 4.14: Performans göstergeleri özeti.

Metrik	Uygulama Biçimi	Gözlemler / Sonuçlar
Hassasiyet - Hatırlama - F1 Skor	İstemci başına ayrı değerlendirme, sonra global ölçüm	Dengeli sınıflarda yüksek uyum
İletişim Maliyeti	Sıkıştırma ve delta temelli güncelleme	%60'a varan veri transfer azaltımı
Genelleştirme Yeteneği Sistem	Heterojen veri kümeleri ile eğitim	Aşırı öğrenme (Overfitting) gözlemlenmedi
Ölçeklenebilirliği Eğitim Zamanı / Kaynak Kullanımı	5, 10, 25, 50, 100 istemci ile test	Gecikmeler sınırlı, doğruluk stabil
	GPU + CPU karma kullanımı	%30 daha kısa eğitim süresi

Çizelge 4.14, FL sistemine ilişkin temel performans göstergelerinin uygulama biçimlerini ve elde edilen sonuçları özetlemektedir. Hassasiyet, hatırlama ve F1 skor, her bir istemci için ayrı ayrı hesaplanarak global ölçekte birleştirilmiş ve dengeli sınıf dağılımlarında yüksek başarı elde edilmiştir. İletişim maliyeti, sıkıştırma ve delta tabanlı güncellemeler sayesinde %60'a varan veri transferi azaltımı ile optimize edilmiştir. Genelleştirme yeteneği, heterojen veri kümeleriyle yapılan eğitimlerde aşırı öğrenme oluşmadan korunmuştur. Sistem ölçeklenebilirliği, farklı istemci sayılarıyla yapılan testlerde doğruluğun korunması ve gecikmenin sınırlı kalmasıyla başarıyla sağlanmıştır. Son olarak, eğitim zamanı ve kaynak kullanımı, GPU ve CPU'nun birlikte kullanılması sayesinde %30 daha kısa sürede tamamlanarak verimlilik artırılmıştır. Şekil 4.35, FL sisteminde istemci sayısındaki artışın model doğruluğu ve iletişim süresi üzerindeki etkisini göstermektedir. İstemci sayısı arttıkça doğruluğun başlangıçta yükseldiğini ancak belirli bir noktadan sonra yataylaştığını ve hafifçe düşüş eğilimi gösterdiğini ortaya koymaktadır. Bu durum, istemci sayısındaki artışın sistemin doğruluk kazancı ve iletişim maliyeti açısından dikkatli bir şekilde dengelenmesi gerektiğini vurgulamaktadır. Özellikle 50 istemciden sonra doğrulukta

anlamalı bir artış gözlemlenmemesine rağmen iletişim süresindeki artış devam etmektedir.



Şekil 4.35: İstemci sayısına göre doğruluk ve iletişim süresi.

Bununla birlikte FL sistemlerinin başarımı yalnızca doğruluk metriği ile değil; iletişim, hesaplama verimliliği, gizlilik etkisi ve genelleştirme kapasitesi ile bütünsel olarak değerlendirilmelidir. Bu çalışma, tüm bu kriterlerin birlikte optimize edilebileceğini ve FL'in hem güvenli hem de esnek bir çözüm olduğunu göstermektedir.

5. UYGULAMA VE DENEYSEL SONUÇLAR

Bu bölümde, önerilen FL yaklaşımının uygulanma aşamaları, deneysel süreçler, model eğitimi, hiperparametre optimizasyonu ve performans değerlendirmesi detaylandırılmıştır. Gerçekleştirilen analizler doğrultusunda modelin doğruluğu, güvenilirliği, hesaplama verimliliği ve iletişim maliyeti incelenmiş, geleneksel merkezi öğrenme yöntemleriyle karşılaştırmalı analizler sunulmuştur.

5.1 Deney Ortamı ve Veri Seti Özellikleri

Bu çalışmanın deneysel aşaması, kurumsal üretim tesislerinde kullanılan OPC sistemlerinden elde edilen sensör verilerinin işlenmesi ve yorumlanması yoluyla gerçekleştirilmiştir. Deneylerde kullanılan veri seti, üretim hattındaki makine ve süreçlerin çeşitli aşamalarında yer alan 37 farklı sensör (tag) çıktısını içermektedir. Veri setinde ayrıca STOCKID, EMPLOYEEID ve INSERTDATE gibi temel değişkenler de yer almaktadır. Veri toplama, 1'er günlük periyotlar halinde yapılmış ve saatlik olarak 500 ila 1500 veri noktası elde edilmiştir. Çalışmada kullanılan üretim verileri, farklı ekstrüder makinelerden toplanan sensör verilerini içermekte olup, her bir makinenin sahip olduğu özellik (feature) sayısı değişkenlik göstermektedir. FL ortamında model eğitiminin sağlıklı ve tutarlı bir şekilde gerçekleştirilebilmesi için, her bir istemcinin eş boyuta ve eş yapıda veri seti sunması gerekmektedir. Bu gereklilik doğrultusunda, tüm makinelerin eşit sayıda özelliğe (40 feature) sahip olmasını sağlamak amacıyla sanal özellik tamamlama (virtual feature completion) yaklaşımı uygulanmıştır. Bu yöntemin temel amacı, eksik olan özellikleri, makineye özgü yapay olarak tanımlanmış, ancak eğitimi bozmayan ve modele anlamsız bilgi yüklemeyen nötr değerlerle doldurarak, tüm veri örneklerinin boyutsal bütünlüğünü korumaktır. Bu yöntem, FL ortamında heterojen veri yapılarının homojen hale getirilmesi amacıyla uygulanmış olup, istemciler arası parametrik tutarlılığı sağlamada kritik rol oynamaktadır. Ayrıca, sanal feature alanlarının katkı sağlamadığı, ancak boyutsal uyumluluğu temin ettiği model çıktı analizlerinde de doğrulanmıştır. Bu veri setindeki hedef değişken, her bir sensörün ortalama değerinin $\pm 5\%$ 'lik sapma aralığında kalıp

kalmadığına göre belirlenmiş ve veriler “iyi” veya “kötü” olarak etiketlenmiştir. Bu sınıflandırma, üretim sürecinin kararlılığını analiz etmede etkili olmuştur. Özellikle, $\pm\%5$ sapma aralığı, süreç kontrolünün hassasiyetine uygun olarak seçilmiş ve ani değişimlerin erken tespiti için kritik olmuştur. Veriler, MSSQL (Microsoft Server Yapılandırılmış Sorgu Dili) üzerinden çekilmiş ve Python betikleriyle temizlenip ölçeklendirilmiştir. Veri ön işleme süreci, sensör verilerinin yüksek boyutlu yapısı nedeniyle dikkatle yürütülmüş; ölçekleme ve format dönüştürme işlemleri uygulanmıştır. Eğitimlerde NVIDIA RTX 3060 GPU kullanılarak TensorFlow kütüphanesiyle model eğitimi gerçekleştirilmiştir. Deney ortamı konfigürasyonu Çizelge 5.1’de verilmiştir.

Çizelge 5.1: Donanım ve yazılım konfigürasyon özeti.


Donanım / Yazılım	Özellik / Versiyon
CPU (Merkezi İşlem Birimi)	Intel Core i7-12700H
RAM (Rastgele Erişimli Bellek)	32 GB
GPU (Grafik İşlem Birimi)	NVIDIA RTX 3060 (6 GB VRAM)
İşletim Sistemi	Windows 11 Pro
Veritabanı	MSSQL
Python Sürümü	3.10
Kullanılan Kütüphaneler	TensorFlow, Scikit-learn, MSSQL

FL yöntemiyle model eğitimi yapılmış, her gün gelen verilerle model güncellenmiş, ağırlıklar merkezi sunucuya gönderilmiştir. Sunucu, gelen parametreleri FedAvg ile birleştirerek yeni global modeli üretmiştir. Bu yapı, veri gizliliğini korurken iletişim maliyetlerini azaltmış; INSERTDATE ile üretim sürecine dair zaman temelli analiz yapılmıştır. Veri setine ilişkin örnek yapı Çizelge 5.2’de sunulmuştur. En çok gözlenen sensörler için özet istatistikler verilmiştir. HatHizi ve SicakCapReel arasında r (korelasyon katsayısı) > 0.7 korelasyonu bulunmuştur. Eksik veri oranı $\%2$ ’nin altında kalmış, aykırı değerler z -skor > 3 kriteriyle belirlenmiştir. Gözlemler, gece vardiyasında sapmaların arttığını göstermiştir.

Çizelge 5.2: Örnek veri seti yapısı.

STOCKID	EMPLOYEEID	INSERTDATE	tag_1	tag_2	...	tag_37
100	12	2024-01-01 08:15:00	108.32	107.54	...	110.21
101	15	2024-01-01 08:15:00	102.67	103.12	...	105.90
102	12	2024-01-01 08:15:00	99.42	98.75	...	101.10
101	15	2024-01-01 08:16:00	99.56	102.54	...	104.54
102	12	2024-01-01 08:16:00	101.72	106.45	...	106.20
102	12	2024-01-01 08:17:00	100.08	104.01	...	100.42
101	15	2024-01-01- 08:17:00	106.15	99.95	...	99.12
...	...	...	...	...	...	...

Sensör verilerinin zaman serisi boyunca $\pm 5\%$ 'lik tolerans aralığında kalma durumu Şekil 5.1'de gösterilmiştir. Bu görselleştirme, anomali tespiti ve süreç kontrolü için kritik öneme sahiptir.



Şekil 5.1: Zaman serisinde $\pm 5\%$ sapma gösterimi.

Bu yapılandırma dâhilinde, TensorFlow'un NVIDIA GPU desteği etkinleştirilmiş, veri ön işleme (temizleme, filtreleme, ölçeklendirme vb.) adımları ile model kurma ve değerlendirme aşamaları birlikte ve eşzamanlı olarak planlanmıştır. Buna ek olarak, FL yöntemiyle model eğitimi yapılması, her gün gelen yeni verilerin modele katılması ve güncellenen model ağırlıklarının merkezi sunucuya iletilmesi prensibiyle yürütülmüş, bu sayede üretim sürecinin çoklu lokasyon verileri arasında küresel bir öğrenme mekanizması oluşturulmuştur. FL yaklaşımında, her lokasyon veya veri grubu tarafından eğitilen model parametreleri belirli aralıklarla merkezi sunucuya aktarılmış ve FedAvg algoritmasıyla birleştirilerek güncellenmiştir. Bu yapı, veri gizliliğini korurken iletişim maliyetlerini azaltma avantajı sunmuştur. $\pm 5\%$ 'lik sapma

sınırlarının aşılması durumunda modelin anormal sensör davranışlarını başarıyla tespit ettiği gözlemlenmiştir. Ayrıca, INSERTDATE alanı sayesinde üretim sürecine ait zaman temelli değişimler (gün, saat, vardiya) analiz edilebilmiştir. Böylece modelin, üretim sürecinin zamansal dinamiklerine duyarlı bir şekilde çalıştığı ortaya konmuştur. Çizelge 5.2, daha önce açıklanmış olan sensor veri yapısının bir özetini sunmaktadır. En çok gözlemlenen tag'lerden bazıları için özet değerler şöyledir:

HatHizi: Ortalama = 118.3 m/dk, Std. sapma = 6.2, Min = 100.1, Max = 132.7

MotorAkim: Ortalama = 21.7 A, Std. sapma = 4.1, Min = 15.2, Max = 33.5

SicakCapReel: Ortalama = 105.9 mm, Std. sapma = 3.7, Min = 98.6, Max = 111.4

Tag'lerin yaklaşık %88'i "iyi" sınıfında etiketlenmişken, %12'si "kötü" sınıfında yer almıştır. Vardiyalara göre dağılımda, gece vardiyasında sapmaların arttığı gözlemlenmiştir. Eksik veri oranı %2'nin altında tutulmuş, aykırı veriler ise z-skor > 3 kriteriyle belirlenmiştir (yaklaşık %1). Tag'ler arası korelasyon analizinde özellikle HatHizi ve SicakCapReel arasında $r > 0.7$ gibi güçlü bir ilişki bulunmuştur. Bu temel istatistiksel bilgiler, veri setinin modellemeye uygun, dengeli ve güvenilir bir yapıya sahip olduğunu göstermektedir. Veri setinin günlük periyotlar halinde toplanması ve her saat gelen verilerin eklenerek modelin yeniden eğitilmesi, üretim sürecinin olabildiğince güncel verilerle beslenmesini sağlamıştır. Dolayısıyla, sistemin dinamizmi ve üretim koşullarındaki dalgalanmalara yanıt verme kabiliyeti artmıştır; bu durum, özellikle endüstri 4.0 konsepti ve ileri süreç kontrol uygulamaları bağlamında dikkate değer bir katma değer yaratmaktadır. Şekil 5.1 de, sensör verisinin zaman içindeki değişimini ve $\pm 5\%$ 'lik normal kabul edilen aralık dışına çıkıp çıkmadığını göstermektedir. Bu tarz bir izleme, sapmaların erkenden fark edilmesi ve anomalilerin tanımlanması açısından oldukça kritiktir.

Çizelge 5.3: FCNN ve diğer modellerin karşılaştırılması

Özellik	FCNN	LSTM	CNN	XGBoost
Yapı	Katmanlar arasında tüm düğümler birbirine bağlıdır.	Bellek hücreleri ve kapılar içerir.	Konvolüsyon ve havuzlama katmanlarında n oluşur.	Karar ağaçları topluluğu temellidir.
Veri Türü	Sabit boyutlu girdiler.	Zaman serisi / sıralı veri	Görüntü, uzamsal veriler	Yapılandırılmış tablo verisi
Zaman Bağlamı	Zaman bağımsız, her giriş ayrı ayrı işlenir.	Zaman bağımlı, geçmiş bilgiler hafızada tutulur.	Uzamsal bağlam önemlidir, zaman genellikle dikkate alınmaz.	Zaman bağlamı içermez, örnekler bağımsız değerlendirilir.
Hafıza Mekanizması	Bellek yok	Uzun süreli bağımlılıkları öğrenmek için belleğe sahiptir.	Bellek içermez, lokal filtrelerle çalışır.	Bellek içermez, geçmişe yönelik bağımlılığı modele katmaz.
Veri İlişkisi	Özellikler arası ilişkileri öğrenir.	Zamana bağlı örnekler arası ilişkileri öğrenir.	Uzamsal yakınlığa dayalı ilişkileri öğrenir.	Özellikler arası önem düzeyini karar ağaçlarıyla belirler.
Kullanım Alanı	Görüntü sınıflandırma, yapılandırılmış iş veri	Doğal dil işleme, zaman serisi tahmini, üretim verisi analizi	Görüntü işleme, video analizi	Yapay zekâ tabanlı karar destek sistemleri, tahminleme
Eğitim Zorluğu	Genelde daha hızlı ve kolay	Daha karmaşık, zaman ve kaynak açısından daha maliyetli	Hesaplama açısından yoğun, GPU gerektirebilir.	Eğitimi hızlıdır, ancak hiperparametre ayarlaması hassastır.
Vanishing Gradient Sorunu	Uzun ağırlarda sık görülür.	Kapı (Gated) mekanizma ile bu sorun LSTM' de azaltılmıştır.	Derin yapılarda görülebilir, çözümü için teknikler gereklidir.	Bu problem gözlemlenmez, çünkü gradyan temelli değildir.
Giriş Boyutu	Genellikle sabittir.	Değişken uzunluktaki girdilere uygundur.	Sabit boyutlu ızgara formatlı girişler bekler.	Sabit ya da önceden işlenmiş vektör formatında girişler alır.

Bu çalışmada kullanılan veri seti her ne kadar zamansal özellik taşısa da, model seçiminde sadece veri yapısı değil; sistemin genel mimarisi, FL ortamının sınırlamaları ve uygulama koşulları birlikte değerlendirilmiştir. Çizelge 5.3 te gösterildiği üzere, zaman serisi analizlerinde sıklıkla tercih edilen LSTM ve GRU gibi tekrarlayan yapılar, ardışık verilerdeki uzun dönemli bağımlılıkları öğrenme açısından avantajlıdır. Ancak bu tür modeller, parameter sayılarının fazlalığı ve eğitim süreçlerinin karmaşıklığı nedeniyle FL ortamlarında önemli dezavantajlar oluşturmaktadır. Bu bağlamda FCNN mimarisi, her bir veri örneğini zaman diliminden bağımsız olarak ayrı bir gözlem olarak ele alarak, özellikle birden çok özelliğe dayalı anlık durumu sınıflandırmak için yeterli temsil gücüne sahiptir. Bu çalışmada da zamansal ilişkilerin doğrudan modellendiği bir dizilimden ziyade, her bir gözlem noktası, kendi içindeki sensör değerleriyle birlikte değerlendirilmiştir. FCNN yapısı, uç istemcilerdeki sınırlı işlem kapasitesine uygun olarak daha düşük hesaplama maliyeti ile çalışmakta ve iletişim yükünü minimal seviyede tutmaktadır. Bu özellik, FL sistemlerinin dağıtık yapısı açısından kritik önemdedir. Ayrıca, bu çalışmada zaman bilgisinin doğrudan ardışık korelasyonlarını öğrenmek yerine, örneklerin “anlık” anomali ya da normal davranış gösterip göstermediğini belirlemek ön plandadır. Bu nedenle LSTM/GRU gibi sıralı bağlamlara ihtiyaç duyulmamış, bunun yerine FCNN modeli ile istatistiksel örüntülerin sınıflandırılması hedeflenmiştir. Bu gerekçeler ışığında, sıralı veri içerse dahi LSTM/GRU gibi tekrarlayan yapılardan ziyade, daha sade, daha az kaynak tüketen ve FL sistemleriyle daha doğal entegre olabilen FCNN mimarisi tercih edilmiştir.


5.2 Model Eğitimi ve Optimizasyon

Algorithm 14 Bir Sinir Ağı Modeli Oluştur ve Derle

```
1: procedure MODELOLUSTUR(girdi_boyutu, cikti_boyutu)
2:   Ardışıl (sequential) bir sinir ağı modeli başlat
3:   128 birimli, ReLU aktivasyonlu ve girdi_boyutu giriş şekline sahip bir
   Dense katmanı ekle
4:   64 birimli ve ReLU aktivasyonlu bir Dense katmanı ekle
5:   32 birimli ve ReLU aktivasyonlu bir Dense katmanı ekle
6:   16 birimli ve ReLU aktivasyonlu bir Dense katmanı ekle
7:   cikti_boyutu birimli ve sigmoid aktivasyonlu bir çıkış katmanı ekle
8:   Modeli aşağıdaki ayarlarla derle:
9:     Kayıp fonksiyonu: binary cross-entropy
10:    Optimizasyon algoritması: Adam
11:    Başarı metriği: Doğruluk (Accuracy)
12:   return derlenmiş model
13: end procedure
```

Şekil 5.2: Yapay sinir ağı modelinin oluşturulması.

Çalışmada kullanılan yapay sinir ağı modeli ile ilgili detaylara yer verilmiştir. Model, dört gizli katman içermekte olup sırasıyla 128, 64, 32 ve 16 nörondan oluşmakta, her birinde ReLU (Doğrultulmuş Doğrusal Birim) aktivasyon fonksiyonu kullanılmaktadır. Çıkış katmanı ise sigmoid aktivasyon ile yapılandırılmıştır. Bu mimariye ilişkin genel yapı Şekil 5.2’de sunulmuş.



Şekil 5.3: Kullanılan FCNN model mimarisi.

Çalışmada kullanılan FCNN (Tam Bağlantılı Sinir Ağı) modelinin görsel temsili Şekil 5.3’de verilmiştir. Katman yapılarına ve aktivasyon fonksiyonlarına ilişkin özet bilgiler Çizelge 5.4’te yer almaktadır.

Çizelge 5.4: FCNN katman özellikleri.

Katman	Nöron Sayısı	Aktivasyon
Giriş	37	—
Katman 1	128	ReLU
Katman 2	64	ReLU
Katman 3	32	ReLU
Katman 4	16	ReLU
Çıkış	1	Sigmoid

Modelin derlenmesinde binary_crossentropy kayıp fonksiyonu ve adam optimizasyon algoritması tercih edilmiştir. Eğitim süreci boyunca doğrulama kaybında iyileşme gözlenmediği durumlarda eğitimin erken sonlandırılması için Erken durdurma stratejisi uygulanmıştır. Bu sürecin temel akışı, Şekil 5.4'te kod kesiti üzerinden gösterilmiştir.

Algorithm 15 Modeli Eğit, Değerlendir ve Sunucuya Gönder

```

1: Girdi ve çıktı boyutlarını kullanarak modeli oluştur
2: if model başarıyla oluşturulduysa then
3:   “Eğitim başladı” mesajını yazdır
4:   Erken durdurma koşullarını tanımla:
5:     İzlenecek metrik: doğrulama başarımı
6:     Sabır: 10 dönem (epoch)
7:     En iyi ağırlıkları geri yükle
8:   Modeli  $X_{egitim}, y_{egitim}$  üzerinde 100 dönem boyunca eğit:
9:     Yığın boyutu: 512
10:    Doğrulama oranı:
11:    Erken durdurmayı uygula
12:   Toplam eğitim süresini kaydet
13:    $X_{test}$  üzerinde tahmin yap
14:   Değerlendirme metriklerini hesapla: doğruluk, F1 skoru, hassasiyet, geri
      çağırma
15:   if doğruluk değeri geçerliyse then
16:     Metrikleri sonuç listesine ekle
17:   end if
18:   Şifrelenmiş model ağırlıklarını sunucuya gönder
19:   İletişim turunu 1 artır
20:   Mevcut modele ait iletişim maliyetini hesapla
21: end if

```

Şekil 5.4: Model eğitimi, değerlendirme ve ağırlık gönderimi süreci.

Veri gizliliğini artırmak amacıyla, istemcilerde eğitilen modelin ağırlıklarına Laplace gürültüsü eklenmiş ve bu şekilde anonimleştirilmiş ağırlıklar merkezi sunucuya gönderilmiştir.

Algorithm 16 Model Ağırlıklarına Laplace Gürültüsü Ekle

```

1: procedure AGIRLIKLAGURULTUEKLE(agirliklar, epsilon)
2:   Boş bir liste başlat: gurultulu_agirliklar
3:   for her bir ağırlık  $a$  içinde agirliklar do
4:     Ölçek  $1/\epsilon$  ve  $a$  ile aynı şekle sahip Laplace gürültüsü üret
5:     Gürültüyü  $a$ 'ya ekle ve sonucu gurultulu_agirliklar listesine ekle
6:   end for
7:   return gurultulu_agirliklar
8: end procedure

```

Şekil 5.5: Gürültü ekleme fonksiyonu.

Bu yaklaşım, tekil veri noktalarının modelden çıkarımını zorlaştırmakta ve diferansiyel gizliliği sağlamaktadır. Bu sürecin teknik açıklaması Şekil 5.5' te

sunulmuştur. Bu süreçte kullanılan epsilon parametresine bağlı olarak gizlilik-performans dengesi yönetilmiştir.

Algorithm 17 Flask ile Sunucu Tarafı Ağırlık Birleştirme ve Doğrulama

```
1: Flask uygulamasını başlat
2: Birleştirme sıklığını ayarla (örneğin: her 10 turda bir)
3: Küresel değişkenleri başlat: tur_sayaci, agirlık_listesi
4: function AGIRLIKAL
5:   İstemciden gelen JSON isteğini ayrıştır
6:   if istek geçersizse veya ağırlıklar eksikse then
7:     400 hatası ile birlikte hata mesajı döndür
8:   end if
9:   Ağırlıkları diziye çevir ve agirlık_listesi'ne ekle
10:  Geçerli gönderim için başarı mesajı döndür
11:  tur_sayaci değişkenini artır
12:  if tur_sayaci mod birlesme_sikligi = 0 then
13:    Tüm gelen ağırlıkların şekillerinin tutarlı olup olmadığını kontrol et
14:    if şekiller uyuşmuyorsa then
15:      500 hatası ile hata mesajı döndür
16:    else
17:      Katman bazında ağırlıkların ortalamasını hesapla
18:      Ortalaması alınmış ağırlıkları JSON formatına dönüştür
19:      Yanıt olarak ortalama ağırlıkları istemciye gönder
20:      agirlık_listesi ve tur_sayaci sıfırla
21:    end if
22:  end if
23:  Durum 200 ile birlikte opsiyonel bilgi döndür
24: end function
25: Flask uygulamasını 192.168.1.26 adresinde ve 5000 portunda çalıştır
```

Şekil 5.6: Sunucu tarafında FedAvg ağırlık toplama ve yayma işlemi.


Eğitim süreci tamamlandığında, ağırlıklar merkezi sunucuya gönderilmiş ve burada FedAvg yöntemiyle ortalama alınarak global model oluşturulmuştur. Sunucuda gerçekleştirilen bu süreç Şekil 5.6'da detaylandırılmıştır.

Algorithm 18 Gürültülü Ağırlıkları Sunucuya Gönder

```
1: procedure AGIRLIKLARISUNUCUYAGONDER(model, sunucu_adresi, epsilon)
2:   “Model ağırlıkları sunucuya gönderiliyor” mesajını yazdır
3:   Modelden ağırlıkları çıkar
4:   Belirtilen epsilon değeri ile Laplace gürültüsü ekle
5:   Veri yükünü hazırla:
6:     ağırlıklar: gürültülü ağırlıkların listesi
7:     katman_sayisi: katman sayısı
8:   JSON yükü ile sunucuya POST isteği gönder
9:   if sunucudan gelen yanıt kodu 200 ise then
10:    “Ağırlıklar başarıyla sunucuya gönderildi” mesajını yazdır
11:    return sunucu yanıtı
12:  else
13:    Hata mesajını ve yanıt durumunu yazdır
14:    Sunucu yanıtının detaylarını yazdır
15:    return None
16:  end if
17:  Herhangi bir istisnayı (exception) yakala ve hata mesajı yazdır
18:  return Hatalı durumda None
19: end procedure
```

Şekil 5.7: Gürültü eklenmiş ağırlıkların sunucuya gönderimi.

İstemcilerde yapılan eğitim sonrasında ağırlıkların gönderimi ise Şekil 5.7 ile görselleştirilmiştir.



Şekil 5.8: Model eğitimi ve FL süreci.

Tüm FL model eğitimi sürecini uçtan uca özetleyen genel yapı Şekil 5.8’de verilmiştir. Model eğitimi yalnızca doğruluk üzerine değil; gizlilik, iletişim verimliliği ve öğrenme dayanıklılığı açısından da optimize edilmiştir. Bu çok boyutlu strateji, endüstriyel FL senaryolarında güvenli ve etkili öğrenme elde etmek için kritiktir.

5.2.1 Hiperparametre ayarlamaları

Bu bölümde, modelin eğitimi sırasında kullanılan hiperparametre ayarlarına ilişkin kapsamlı bir açıklama sunulmaktadır. Kod örneklerinde görüldüğü üzere, hem derin öğrenme mimarilerindeki temel hiperparametreler (katman sayısı, nöron sayısı,

aktivasyon fonksiyonları, toplu işlem boyutu, tur sayısı gibi) hem de FL yaklaşımı çerçevesinde eklenen bazı özel parametreler (örneğin diferansiyel gizlilik için epsilon değeri, sunucu tarafındaki aggregasyon sıklığı gibi) birlikte kullanılarak modelin davranışı şekillendirilmektedir. Geniş bir veri setiyle çalışırken, özellikle üretim ortamlarında sensör verilerinin çok boyutluluğu göz önüne alındığında, doğru hiperparametre seçimi modelin başarımını doğrudan etkilemektedir. Aşağıda, bu hiperparametreleri adım adım irdeleyerek hem kod parçalarındaki kullanımlarından hem de sonuçlara etkilerinden bahsedilecektir. Öncelikle tam bağlı sinir ağı FCNN modelinde kullanılan katman yapısına değinmek gerekmektedir. ReLU fonksiyonu, girdisi negatif olduğunda 0 değerini döndürürken, pozitif değerler için doğrusal bir davranış sergilemekte ve bu sayede geriye yayılım sırasında gradyanların sıfıra çok hızlı düşmesini engellemektedir. Çıkış katmanında tek nöron bulunmasının nedeni, ikili bir sınıflandırma problemini çözmektir (örneğin “sapma aralığında mı, değil mi” gibi “iyi” veya “kötü” olarak iki sınıfın yer aldığı bir senaryo). Bu çıkış katmanında sigmoid fonksiyonunun kullanılması, modelin 0 ile 1 arasında bir olasılık değeri üretmesine imkân tanıyarak, eşğin (örneğin 0.5) üzerinde olan değerleri “kötü”, eşğin altında kalanları “iyi” olarak ayırt etmede kolaylık sağlamaktadır. Modelin derlenmesi (compile) aşamasında, “optimizer='adam'” ifadesiyle Adam optimizasyon algoritması varsayılan parametreleriyle birlikte devreye alınmaktadır. Adam, hem momentum hem de adaptif öğrenme oranı mantığını bir araya getirerek özellikle büyük veri setlerinde ve karmaşık modellerde öğrenme sürecini hızlandırabilmektedir. Kod içerisinde bu optimizasyon algoritmasının belirli bir öğrenme oranı (örneğin 0.001 gibi) ayrıca tanımlanmamış olsa da, varsayılan değerlerin çoğu senaryoda iyi sonuç vermesi nedeniyle pratik bir başlangıç noktası sunar. Kayıp fonksiyonu (loss function) olarak “binary_crossentropy” seçilmesinin temel sebebi, çıkışın tek bir nöron olduğu ikili sınıflandırma probleminde yaygın olarak kullanılan bir ölçüt olmasıdır. Bu sayede, modelin verdiği tahmin ile gerçek etiket arasındaki fark, lojistik kayıp fonksiyonu temelinde hesaplanmakta ve geriye yayılım algoritmasıyla ağırlık güncellemeleri gerçekleştirilmektedir. Eğitim aşamasında kullanılan bir diğer önemli hiperparametre “batch_size” değeridir. Kod parçacığında görüldüğü üzere, “model.fit(...)” metodunun çağrısında “batch_size=512” tanımlanmıştır. Mini yığın büyüklüğü, her iterasyonda geriye yayılım için kullanılacak veri alt kümesinin boyutunu ifade eder. Büyük batch_size değerleri, genellikle daha kararlı gradyan tahminleri sağlamasına karşın donanım belleği üzerinde yüksek kullanım yaratabilmekte ve güncellemelerin

seyrekleşmesine yol açabilmektedir. Küçük batch_size değerleri ise daha sık ağırlık güncellemesi yapılmasını sağlarken, gürültülü gradyan tahminleri oluşturabilmektedir. Dolayısıyla 512 gibi bir değer, eldeki veri setinin büyüklüğü ve donanım imkanları (GPU belleği, CPU kapasitesi vb.) göz önünde bulundurularak dengeli bir seçim olarak belirlenmiştir. Kod içerisinde “epochs=100” atanarak maksimum eğitimin 100 tur (epoch) sürmesi planlansa da, Erken durdurma mekanizması devreye girdiğinden dolayı model genellikle bu değere ulaşmadan durabilmektedir. Şekil 5.9 da görüldüğü gibi, erken durdurma parametresi olarak “monitor='val_accuracy'” tanımlanmış ve “patience=10” ile on ardışık dönem boyunca doğrulama (validation) başarımında gelişme sağlanmazsa eğitim süreci sonlandırılmaktadır:

Algorithm 19 Erken Durdurma ile Model Eğitimi

- 1: Erken Durdurma (EarlyStopping) geri çağırma fonksiyonunu tanımla:
 - 2: İzlenecek metrik: doğrulama doğruluğu (validation accuracy)
 - 3: Sabır (patience): 10 dönem (epoch)
 - 4: Gelişme olmazsa en iyi ağırlıkları geri yükle
 - 5: Modeli aşağıdaki parametrelerle eğit:
 - 6: Girdi: X_{egitim}, y_{egitim}
 - 7: Dönem sayısı: 100
 - 8: Yığın boyutu: 512
 - 9: Doğrulama oranı:
 - 10: Eğitim sırasında Erken Durdurma uygulansın
-

Şekil 5.9: Erken durdurma kullanımı.

Burada “validation_split=0.2” ifadesi, eğitim verisinin yüzde 20’sinin doğrulama seti olarak ayrılmasını sağlamaktadır. Böylece, kalan yüzde 80’lik kısım ile model güncellenirken, her tur sonunda doğrulama seti üzerindeki metriklere (örneğin val_accuracy) bakılarak performans artışının sürüp sürmediği takip edilir. “patience=10” değeriyle beraber, modelin gereksiz yere aşırı öğrenmeye (overfitting) uğraması önlenmekte, aynı zamanda hesaplama kaynakları da daha verimli kullanılmaktadır. “restore_best_weights=True” ise en yüksek doğrulama başarımının elde edildiği noktadaki ağırlıkları hafızada tutarak eğitim tamamlandığında bu ağırlıkları modele geri yüklemektedir. Bu özellik, val_accuracy değerinin bazı turlarda dalgalanması durumunda en iyi sonucun elde edildiği dönemi kaydetmek açısından önemlidir. FL çerçevesinde kullanılan hiperparametreler incelendiğinde, diferansiyel gizlilik amaçlı “epsilon” değeri kod içerisinde sıklıkla karşımıza çıkmaktadır. Şekil

5.10 da, yerel düğümlerde eğitimi tamamlanan ağırlıkların sunucuya gönderilmeden önce gürültülenmesi sırasında bu parametrenin nasıl kullanıldığını göstermektedir:


Algorithm 20 Model Ağırlıklarını Göndermek İçin Fonksiyon Çağır

- 1: AGIRLIKLARISUNUCUYAGONDER(model, sunucu_adresi, $\epsilon = 0.1$) fonksiyonunu çağır
 - 2: Sunucudan gelen yanıtı *yanit* adlı değişkende sakla
-

Şekil 5.10: Sunucuya gönderilmeden önce fonksiyon parametreleri.


Laplace tabanlı gürültü eklemesi yapan “add_noise_to_weights” fonksiyonuna bu “epsilon” parametresi iletilmekte, küçük epsilon değerleri daha fazla gürültü eklenmesini ve dolayısıyla daha yüksek gizliliği garanti etmektedir. Buna karşın eklenen gürültü miktarı arttıkça model performansının (özellikle doğruluk, F1 skoru gibi) bir miktar düşme ihtimali doğar. Bu nedenle epsilon değeri, veri gizliliği ve model başarımı arasındaki hassas dengenin gözetilmesi gereken kritik bir hiperparametredir. Sunucu tarafında ise, toplanan ağırlıkların ortalama alınacağı tur sıklığını (aggregation_frequency) belirleyen bir hiperparametre öne çıkmaktadır. “aggregation_frequency = 10” şeklinde bir atama yapılarak, istemcilerden (yerel düğümlerden) toplamda 10 kez güncelleme geldikten sonra FedAvg mekanizması tetiklenmektedir. Her istemci, modeli kendi lokal verisiyle eğittikten ve gürültü ekledikten sonra, ağırlıkları merkezi sunucuya gönderir. Sunucuya gelen her POST isteği bir tur (round) olarak sayılır. “round_counter” ifadesi, bu tur sayısını tutar ve “round_counter % aggregation_frequency == 0” durumunda tüm ağırlıklar birleştirilerek ortalama alınır. Bu yöntem, istemcilerden rastgele zamanlarda veya farklı veri miktarlarıyla güncellemeler geldiğinde dahi sistemin senkron şekilde ortak bir model oluşturmaya imkân tanır. Tur sıklığı arttıkça (örneğin 20 veya 30 yapılırsa), güncellemeler daha seyrek birleştirilir, bu da sunucuya daha az yük bindirip ağ trafiğini azaltabilir; ancak modelin ortak bilgisini güncelleme sıklığı düşmüş olur. Tur sıklığı azaldıkça (örneğin 5 veya 1) ise model daha hızlı güncellenir, ama sunucu ile istemciler arasında daha fazla veri trafiği oluşabileceği gibi, her güncellemenin gürültü miktarını da sık sık sistemde ortalama alarak potansiyel olarak bazı hassas veri kayıplarını engelleme veya geciktirme durumları ortaya çıkabilir. Böylelikle hem sunucu hem istemci tarafında hiperparametre yönetimi, sistemin performansı, ölçeklenebilirliği ve gizlilik düzeyinin yanı sıra ağ üzerindeki iletişim yükünü de etkileyen bir faktör olarak dikkat çekmektedir. Bu projede kullanılan

hiperparametrelerin önemli bir kısmı, geleneksel derin öğrenme senaryolarında sıklıkla rastlanan tur, toplu işlem boyutu, aktivasyon fonksiyonu seçimi, optimizasyon ve kayıp fonksiyonu gibi temel bileşenlerden oluşmaktadır. Buna ek olarak, FL ve diferansiyel gizlilik yaklaşımlarıyla ilişkili epsilon, agregasyon sıklığı gibi parametreler de devreye girerek daha karmaşık bir hiperparametre seti ortaya çıkarmaktadır. Kod incelendiğinde, proje kapsamında bu ayarların çoğunun varsayılan veya sabit değerlere sahip olduğu, ancak dileyen araştırmacının veya mühendisin bu değerleri kolaylıkla değiştirerek farklı senaryolarda deneyler yapabileceği anlaşılmaktadır. Örneğin, epsilon değerinin 0.05, 0.1 ya da 0.2 seçilmesi, gizlilik ile doğruluk arasındaki dengeyi farklı biçimlerde etkileyebilecek; veya toplu işlem boyutu değerinin 256 yerine 512 yapılması, hem bellek kullanımını hem de turbaşına güncelleme sıklığını değiştirecektir. Tüm bu hiperparametreler, pratik uygulamalarda çeşitli faktörler gözetilerek optimize edilebilir. Söz gelimi, üretim hatlarında sensor verilerinin belirli saatlerde daha yoğun akması, verilerin homojen veya heterojen şekilde dağılması, veri gizliliğinin kritik seviyede olması veya olmaması gibi değişkenler, hangi ayarların seçileceğini doğrudan etkiler. “bekleme süresi” değerinin çok yüksek tutulması, modelin aşırı öğrenmeye uğrama riskini artırırken; çok düşük tutulması, modelin henüz olgunlaşmadan erken durdurulmasına neden olabilir. Bu noktada, her bir hiperparametrenin hem deneysel doğrulama seti performansına (Doğruluk, F1 skoru vb.) hem de pratik sınırlamalara (zaman, bellek, ağ trafiği, gizlilik gereksinimi) göre titizlikle seçilmesi tavsiye edilir. Kısacası, koddaki hiperparametre ayarlarının başarılı bir şekilde koordine edilmesi, hem geleneksel sinir ağı eğitimi hem de federated öğrenme ve diferansiyel gizlilik mekanizmalarının sorunsuz ve etkili biçimde işlemlerini sağlamaktadır. Bu sayede, farklı lokasyonlardaki veri kaynakları, gizlilik kaygılarını minimize ederek ortak bir küresel model oluşturabilir; aynı zamanda her bir lokasyon, kendi veri dağılımının özelliklerini modele katmış olur. Dolayısıyla buradaki hiperparametreler, yalnızca temel bir derin öğrenme modelinin başarımını değil, aynı zamanda sistemin dağıtık ve güvenlik odaklı doğasını da şekillendirmektedir. Şekil 5.11 de, diferansiyel gizlilik için kullanılan epsilon değerinin arttıkça modelin doğruluğunda yaşanan düşüşü göstermektedir. Küçük epsilon değerleri daha fazla gizlilik, ancak potansiyel olarak daha az doğruluk anlamına gelir.



Şekil 5.11: Epsilon değerine göre model doğruluğu.

Şekil 5.12 de, agregasyon sıklığı (aggregation frequency) arttıkça doğrulukta sınırlı bir düşüş gözlenirken, iletişim süresi belirgin biçimde azalmaktadır. Bu da sunucu trafiğini azaltırken performansın makul düzeyde korunabileceğini gösterir.



Şekil 5.12: Agregasyon sıklığı etkileri.

Çizelge 5.5, FL sisteminde kullanılan temel hiperparametrelerin açıklamalarını ve bu parametrelerin model performansı üzerindeki etkilerini özetlemektedir. Tursayısı, modelin eğitim tekrarlarını belirlerken aşırı öğrenme riski ve eğitim süresini doğrudan etkiler. Toplu işlem boyutu, her iterasyonda işlenen örnek sayısını ifade eder ve bellek kullanımı ile eğitim hızında belirleyici rol oynar. Epsilon değeri, diferansiyel gizlilik seviyesi ile ilişkilidir ve model doğruluğu ile veri gizliliği arasında denge kurulmasını sağlar. Agregasyon sıklığı, sunucuda gerçekleştirilen ortalama alma sıklığını belirleyerek iletişim yükü ve modelin güncelleme doğruluğu arasında denge sağlar. Ağırlıkların güncellenme hızı (Learning rate), ağırlıkların güncellenme hızını kontrol ederken konverjans süresi (convergence time) ve modelin kararlılığı açısından kritik öneme sahiptir. Son olarak, bekleme süresi parametresi, erken durdurma mekanizmasında kullanılarak aşırı öğrenmeyi önlemeye yardımcı olur.

Çizelge 5.5: Hiperparametre özeti ve sistem üzerindeki etkileri.

Parametre	Açıklama	Etkisi
Tur	Eğitim tekrar sayısı	Aşırı öğrenme riski, eğitim süresi
Toplu işlem boyutu	Her iterasyonda işlenen örnek sayısı	Bellek kullanımı, eğitim hızı
Epsilon	Gizlilik seviyesi	Doğruluk ↔ Gizlilik dengesi
Aggregation Frequency	Sunucudaki ortalama alma sıklığı	İletişim yükü, doğruluk
Ağırlıkların güncellenme hızı	Ağırlık güncelleme hızı	Konverjans hızı, stabilite
Bekleme süresi	Erken durduma eşiği	Aşırı öğrenme kontrolü

Bu hiperparametrelerin doğru kombinasyonu, FL sisteminin başarımını belirlemede kritik rol oynamaktadır. Özellikle gerçek zamanlı, gizliliğe duyarlı üretim ortamlarında epsilon ve agregasyon sıklığı gibi parametrelerin dikkatle optimize edilmesi gerekmektedir.

5.3 Performans Değerlendirmesi

Bu çalışmada, eğitim sonrası modelin başarımını takip etmek amacıyla doğruluk, kesinlik, duyarlılık ve F1 skoru gibi yaygın sınıflandırma metrikleri kullanılmıştır. İkili sınıflandırma görevlerinde kullanılan temel metriklerin formülleri, TP (Doğru Pozitif), TN (Doğru Negatif), FP (Yanlış Pozitif) ve FN (Yanlış Negatif) kavramlarına dayanmaktadır. Denklem 5.1 de, modelin doğru sınıflandırdığı örneklerin (hem “iyi” hem “kötü”) tüm örnekler içindeki oranını temsil eder.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5.1)$$

Denklem 5.2 de, modelin “kötü” olarak etiketlediği örneklerden kaç tanesinin gerçekten “kötü” olduğunu ifade eder; yanlış pozitifleri (false positives) azaltmak önem taşıyorsa bu metrik kritik hâle gelir.

$$Precision = \frac{TP}{TP + FP} \quad (5.2)$$

Denklem 5.3 de, gerçekte “kötü” olan örneklerin ne kadarının model tarafından yakalandığını gösterir. Özellikle “kötü” durumların atlanması (false negative) riskliyse, duyarlılık’ ın yüksek olması arzulanır.

$$Recall = \frac{TP}{TP + FN} \quad (5.3)$$

Denklem 5.4 te, kesinlik ve duyarlılık arasında bir denge kurmak amacıyla kullanılan armonik ortalama tabanlı metrik olup, dengesiz sınıf dağılımları veya kritik “kötü” örneklerin az olduğu durumlarda performansın bütüncül bir özetini sunar.

$$F1Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (5.4)$$

Çizelge 5.6 da gösterildiği gibi confusion matrix modelin hangi örnekleri doğru veya yanlış sınıflandırdığını tablo halinde gösterir. İkili sınıflandırmada tipik olarak 2x2 boyutlu bir matristir:

Çizelge 5.6: Karmaşıklık Matrisi.

Gerçek \ Tahmin	Tahmin edilen kötü (1)	Tahmin edilen iyi (0)
Gerçek kötü (1)	TP	FN
Gerçek iyi (0)	FP	TN

TP: Gerçekte “kötü” olup, modelce “kötü” tahmin edilen örnek sayısı.

TN: Gerçekte “iyi” olup, modelce “iyi” tahmin edilen örnek sayısı.

FP: Gerçekte “iyi” olup, modelce “kötü” tahmin edilen örnek sayısı.

FN: Gerçekte “kötü” olup, modelce “iyi” tahmin edilen örnek sayısı.

Şekil 5.13 te tahmin sonuçları üzerinden bir karmaşıklık matrisi (confusion matrix) elde edebileceğinizi gösterir:

Algorithm 21 Karmaşıklık Matrisi (Confusion Matrix) Hesapla

- 1: y_{test} 'ten gerçek etiketleri çıkar (eksen 1 boyunca argmax uygula)
 - 2: Olasılık değerlerinden tahmin etiketlerini üret:
 - 3: Eşik değeri = 0.5
 - 4: Olasılıkları ikili (binary) tahminlere çevir
 - 5: Sınıf etiketlerini elde etmek için eksen 1 boyunca argmax uygula
 - 6: Gerçek ve tahmin edilen etiketleri kullanarak karmaşıklık matrisini hesapla
 - 7: Karmaşıklık matrisini yazdır veya döndür
-

Şekil 5.13: Tahminleme sonuçları sonrasında confusion matrix çıktısını veren kod.

Deneylerin sonucunda, farklı veri periyotları veya farklı deney koşulları (örn. farklı epsilon değerleri, farklı toplu işlem boyutu ayarları vb.) için metriklerin ortalama değerleri tutulmuş olabilir. Bu metrik değerleri yalnızca tek bir çalıştırmadan elde edilmemiş, her deney koşulu en az 5 defa tekrar edilerek yürütülmüştür. Aşağıdaki tabloda, bazı deney koşulları altında yapılan çoklu çalıştırmaların ortalama $\pm$ standart sapma biçiminde özetlenmiş sonuçları sunulmaktadır:

Çizelge 5.7: Farklı koşullarda yürütülen deney sonuçlarının performans metrikleri.

Deney Koşulu	Doğruluk ($\pm$ std)	Kesinlik ($\pm$ std)	Duyarlılık ($\pm$ std)	F1 Skor ($\pm$ std)
Epsilon=0.1 Batch=512	0,911 $\pm$ 0.006	0.890 $\pm$ 0.007	0.915 $\pm$ 0.004	0.902 $\pm$ 0.005
Epsilon=0.2 Batch=256	0.927 $\pm$ 0.004	0.912 $\pm$ 0.005	0.921 $\pm$ 0.005	0.918 $\pm$ 0.006
Epsilon=0.05 Batch=512	0.880 $\pm$ 0.009	0.860 $\pm$ 0.008	0.895 $\pm$ 0.007	0.877 $\pm$ 0.006


Çizelge 5.7 de;

Deney Koşulu: Farklı koşullarda yürütülen deneyleri ayırt etmeye yarar. Örneğin ilk deneyde epsilon=0.1ve Toplu İşlem Boyutu = 512 kullanılmış, ikinci deneyde epsilon=0.2'ye artırılmış ve Toplu İşlem Boyutu = 256 azaltılmış. Üçüncü deneyde toplu işlem boyutu değiştirilmiş ve epsilon değeri = 0.05 e düşürülmüştür.

Tur: Erken durdurma sonucu ulaşılan tursayıdır. Her deneyin sonunda, belirlenen bekleme süresi (örn. 10) süresi aşılmadan doğrulama başarımının duraklamasıyla eğitim tamamlanabilir.

Doğruluk, Kesinlik, Duyarlılık, F1 Skor: Her deneyin final aşamasında test kümesi üzerinden hesaplanan ortalama metrik değerlerini yansıtır.


TP, TN, FP, FN: Test kümesindeki karmaşıklık matrisi değerlerinden okunarak tabloya eklenmiş sayılardır.



Şekil 5.14: Doğruluk değerinin model parametrelerine göre değişimi.

Şekil 5.14 te gösterildiği gibi, doğruluk, kesinlik, duyarlılık ve F1 skoru, üretim verileri üzerindeki model başarımının hem genel hem de kritik durumlarda ne ölçüde etkili olduğunu göstermektedir. Özellikle hataların hangi boyutta gerçekleştiğini görmek isteyen endüstriyel uygulamalar için, confusion matrix tablosu yadsınamaz bir bilgi sağlar. Üretim hattındaki sapma aralığı dışı değerlerin (kötü) tespitinde, modelin yanlış alarm sayısını (FP) ve kaçırdığı gerçek hataları (FN) düşük tutma hedefi, kesinlik ve duyarlılık metriklerinin dengeli bir şekilde yüksek olmasını gerektirir. Bu dengenin sağlanıp sağlanmadığı da F1 skoru üzerinden takip edilebilir. FL ve diferansiyel gizlilik yöntemleriyle birlikte uygulanan bu performans izleme süreci, bir yandan veri paylaşımını asgari düzeye indirerek gizliliği korur, diğer yandan ise merkezî modelin farklı üretim lokasyonlarından (fabrika, atölye vb.) gelen bilgilere dayanan daha geniş bir öğrenme kapasitesi kazanmasını sağlar. Tabloya aktarılan metrikler, eğitimin ve güncellemelerin ilerleyişine dair zaman içindeki değişimleri de yakından inceleme fırsatı sunar. Dolayısıyla, gerçek zamanlı ya da periyodik veri akışında model performansının korunduğundan, sapmaların yakalanma oranının belirli bir eşiğin altına düşmediğinden ve yanlış alarmların (FP) üretime zarar verecek boyutta artmadığından emin olunabilir. Bu tablolar ve metrik analizleri, model başarımının sayısal ifadesi için temel olmakla birlikte, hangi parametre değişikliklerinin hangi metriklere nasıl etki yaptığını görmek açısından da yönlendirici ipuçları sunmaktadır. Akademik araştırmalarda veya kurumsal uygulamalarda, benzer

tablolarla hiperparametre seçimlerinin, model mimari değişikliklerinin veya veri ön işleme stratejilerinin etkilerini detaylı biçimde karşılaştırmak mümkündür. Şekil 5.15, farklı epsilon ve toplu işlem boyutu değerleri ile yürütülen deneylerde F1 skorunun ortalama ve standart sapmasını göstermektedir. FL ortamında bu dengenin korunması, hem yanlış alarm riskini hem de kaçırılan hata oranını kontrol altında tutmak için kritik öneme sahiptir.



Şekil 5.15: Deney koşullarına göre F1 skoru ($\pm$ standart sapma).

Çizelge 5.8 de, ikili sınıflandırma problemlerinde modelin tahmin performansını değerlendirmek için kullanılan temel kavramları tanımlamaktadır. TP, modelin gerçekten ‘kötü’ olan bir örneği doğru şekilde ‘kötü’ olarak tahmin etmesi durumudur. TN ise modelin gerçekten ‘iyi’ olan bir örneği doğru olarak ‘iyi’ şeklinde sınıflandırmasını ifade eder. Buna karşılık, FP durumu, modelin ‘iyi’ olan bir örneği hatalı biçimde ‘kötü’ olarak tahmin etmesiyle oluşur. FN ise, ‘kötü’ olan bir örneğin yanlış şekilde ‘iyi’ olarak tahmin edilmesidir. Bu dört temel kategori, özellikle hassasiyet, hatırlama ve F1 skoru gibi metriklerin hesaplanmasında kritik rol oynamaktadır.

Çizelge 5.8: İkili sınıflandır: TP, TN, FP, FN açıklamaları.

Kavram	Tanım
TP	Gerçekten iyi olan ve doğru şekilde kötü olarak tahmin edilen örnek sayısı.
TN	Gerçekten kötü olan ve doğru şekilde iyi olarak tahmin edilen örnek sayısı.
FP	Gerçekten iyi olan ancak yanlış şekilde kötü olarak tahmin edilen örnek sayısı.
FN	Gerçekten kötü olan ancak yanlış şekilde iyi olarak tahmin edilen örnek sayısı.

Şekil 5.16, modelin tahmin performansını değerlendirmek için yaygın kullanılan dört sınıflandırma metriğini hesaplamaktadır. `accuracy_score`, modelin genel doğruluğunu; `precision_score`, pozitif sınıf tahminlerinin doğruluğunu ifade eder. `recall_score`, modelin gerçek pozitifleri ne kadar iyi yakaladığını gösterir ve `f1_score`, kesinlik ile duyarlılık dengesini sağlayan harmonik ortalamadır. Bu metrikler, özellikle dengesiz veri setlerinde modelin etkinliğini çok yönlü analiz etmek için önemlidir. Fonksiyon, bu dört metriği sırasıyla döndürerek değerlendirme süreçlerinde esneklik sağlar.

Algorithm 22 Sınıflandırma Başarı Metriklerini Değerlendir

```

1: procedure METIKDEGERLENDIR(y_gercek, y_tahmin)
2:   Doğruluk (Accuracy) hesapla: doğru tahminlerin oranı
3:   Hassasiyet (Precision) hesapla: doğru pozitiflerin, tahmin edilen poziti-
     flere oranı
4:   Duyarlılık (Recall) hesapla: doğru pozitiflerin, gerçek pozitiflere oranı
5:   F1 skoru hesapla: hassasiyet ve duyarlılığın harmonik ortalaması
6:   return doğruluk, hassasiyet, duyarlılık, F1 skoru
7: end procedure

```

Şekil 5.16: Sınıflandırma metrikleri hesaplama fonksiyonu.

5.3.1 Model doğruluğu ve güvenilirlik

Bu bölümde, geliştirilen modelin doğruluk seviyesini ve üretim sürecindeki farklı koşullara karşı güvenilirliğini artırmaya yönelik yaklaşımlar ele alınmakta, aynı zamanda kod düzeyinde örnekler sunulmaktadır. Üretim verilerinin karmaşık ve sıklıkla değişken bir doğaya sahip olması, modelin yalnızca yüksek doğrulukta tahmin yapmasını değil, aynı zamanda hatalı tahminlerin türleri ve sıklığı hakkında da ayrıntılı bilgi sağlamasını gerektirir. Model doğruluğunu ölçmek için, kod içerisinde doğruluk, kesinlik, duyarlılık ve F1 skoru gibi ikili sınıflandırmada yaygın kullanılan metrikler hesaplanmaktadır. Bu metrikler, sınıflandırma kalitesini farklı açılardan değerlendirir: örneğin, üretim hattında oluşan “sapma dışı” (kötü) örnekleri atlamamak açısından duyarlılık büyük önem taşırken, yanlış alarm (false positive) oranını düşürmeyi hedefleyen senaryolarda kesinlik ön plana çıkabilir. Metriklerin “harmonik ortalaması” gibi işlev gören F1 skoru da, dengesiz veri setlerinde performansı dengeleyen kritik bir gösterge görevi üstlenir. Modelin güvenilirliğini güçlendirmek adına birkaç ek mekanizma devreye alınmıştır. İlki, erken durdurma yaklaşımıdır. Erken durdurma, uzun süren eğitim döngülerinde modelin aşırı öğrenmeye kaymasını engellemek amacıyla doğrulama metriklerini (örn. `val_accuracy`) takip eder ve belirli

bir süre gelişme kaydedilmediğinde eğitimi sonlandırır. Böylece hem zaman hem de kaynak tasarrufu sağlanır, ayrıca modelin genelleme yeteneği korunur. Bir diğer kritik unsur, karmaşıklık matrisi üzerinden yapılan hata analizi ve kaydını otomatikleştirmektir. Şekil 5.17 de, her eğitim turunun sonunda (veya belirli bir zaman periyodunda) modelin performans metriklerini ve karmaşıklık matrisini hesaplayarak, elde edilen sonuçları bir CSV (Virgülle Ayrılmış Değerler) dosyasına kaydeder. Bu sayede hem anlık izleme hem de geçmişe yönelik birikimli analiz mümkün hâle gelir:

Algorithm 23 Modeli Değerlendir ve Metrikleri CSV Dosyasına Kaydet

```


1: procedure DEGERLENDIRVEKAYDET(model,  $X_{test}$ ,  $y_{test}$ , tur_no,
   cikti_dosyasi)
2:   Modeli kullanarak olasılık tahminleri yap
3:   Olasılıkları 0.5 eşik değeriyle sınıf tahminlerine dönüştür
4:   Gerçek ve tahmin edilen etiketleri argmax ile çıkar
5:   Aşağıdaki metrikleri hesapla:
6:     Doğruluk (Accuracy)
7:     F1 skoru (ağırlıklı)
8:     Hassasiyet (ağırlıklı)
9:     Duyarlılık (ağırlıklı)
10:  Karmaşıklık matrisini hesapla
11:  Tur numarasını ve metrikleri yazdır
12:  if CSV dosyası mevcut değilse then
13:    Dosyayı oluştur ve başlık satırını yaz
14:  end if
15:  Karmaşıklık matrisinden TN, FP, FN, TP değerlerini çıkar
16:  Tur numarası ve metrikleri CSV dosyasına yaz
17:  Başarı mesajı yazdır
18: end procedure

```

Şekil 5.17: Performans metriklerini hesaplayarak kaydeden kod.


Bu fonksiyon, eğitim süreci sonunda elde edilen test sonuçlarını analiz eder, TP, TN, FP ve FN gibi hata türlerini CSV kaydı şeklinde saklayarak hem geçmiş turlarla hem de farklı model yapılandırmalarıyla kıyaslama imkânı sunar. Gerekirse, CSV dosyası Excel’de açılabilir ve grafikli analizlere dönüştürülebilir. Örneğin, farklı “epsilon” değerlerinde elde edilen sonuçlar kıyaslanarak diferansiyel gizliliğin model performansı üzerindeki etkisi nicel olarak saptanabilir. Elde edilen metriklerin sadece sayısal olarak değil, aynı zamanda görsel olarak analiz edilmesi, model davranışını yorumlamayı kolaylaştırmaktadır. Bu amaçla, kutu grafiği (boxplot) ve hata çubuğu (error bar) grafiklerinden faydalanılmıştır. Kutu grafikleri, çoklu çalıştırmalarda metriklerin dağılımını gösterirken; hata çubuğu grafiklerinde her metrik için ortalama

$\pm$ standart sapma bilgisi sunulmaktadır. Şekil 5.18 ve Şekil 5.19 doğruluk, F1 Skor, kesinlik ve duyarlılık için hazırlanmış örnek kutu grafiği görselleri gösterilmektedir. Bu görseller, özellikle hiperparametre ayarlarının (epsilon, toplu işlem boyutu, agregasyon sıklığı gibi) model üzerindeki etkilerini karşılaştırmalı olarak analiz etmede kullanılabilir.



Şekil 5.18: Doğruluk değeri model parametrelerine göre kutu grafiği gösterimi.


Şekil 5.18 ve Şekil 5.19 de eğitim sürecinde farklı parametrelerin etkilerini daha somut biçimde görselleştirme imkânı sunmaktadır. Özellikle dengesiz veri yapılarında, istatistiksel sapmaların izlenmesi için önemlidir.



Şekil 5.19: F1 Skor model parametrelerine göre değişimi.

Diferansiyel gizlilik bağlamında epsilon parametresi küçük seçildiğinde (daha fazla gürültü eklenerek gizlilik düzeyi artırıldığında), modelin doğruluğu ve duyarlılık değerinde potansiyel olarak kısmi bir düşüş yaşanabilir. Ancak bu düşüş, hassas verilerin geri çıkarılmasını zorlaştırdığı için güvenilirlik kapsamına giren veri gizliliği açısından olumlu bir sonuç olarak görülebilir. Kodda yer alan “add_noise_to_weights” fonksiyonu, Laplace dağılımından gelen rastgele değerleri model ağırlıklarına ekleyerek sunucuya gönderilen parametrelerin anonimleştirilmesini sağlar. Böylelikle,

yerel veri setlerinin ham hâldeki bilgileri sunucuya ulaşmamış olur. Tüm bu analizlerin ışığında, modelin doğruluğunun yanı sıra üretim verilerinin korunması ve FL yaklaşımı içerisinde iletişim maliyetlerinin yönetilmesi gibi faktörler de güvenilirlik çerçevesine katkıda bulunur. Örneğin, “calculate_communication_cost(model)” fonksiyonuyla modelin ağırlık boyutu ölçülüp, sık güncellemelerin veya büyük mimarilerin ne düzeyde veri trafiği gerektirdiği izlenebilir. Bu durum hem gerçek zamanlı uygulamalarda hem de ağ kaynaklarının kısıtlı olduğu senaryolarda sistem dayanıklılığı için önemlidir. Model doğruluğu ve güvenilirlik, eğitim sürecinde bir arada gözetilmesi gereken iki kritik hedeftir. Erken durdurma, diferansiyel gizlilik, karmaşıklık matrisi analizi ve performans metriklerinin düzenli takibi gibi uygulamalar, modelin üretim ortamında hem isabetli tahmin hem de veri gizliliğini koruyan bir yaklaşım sunmasını sağlamaktadır. Bu sayede, endüstriyel süreçlerin analizi ve izlenmesi daha verimli ve güvenli bir biçimde yürütülebilir. Şekil 5.20, doğruluk, kesinlik, duyarlılık ve F1 Skor metriklerinin çoklu deney sonuçlarına göre dağılımını göstermektedir. Ortalama değerler yüksek düzeyde tutarlı gözükmeyle birlikte, varyanslar ilgili metriklerin sistem davranışına duyarlılığını da yansıtmaktadır.



Şekil 5.20: Model Değerlendirme Metrikleri.

Çizelge 5.9 da, FL sisteminde modelin güvenilirliğini ve sürdürülebilirliğini artırmak amacıyla uygulanan başlıca yöntemleri özetlemektedir. Erken durdurma tekniği, doğrulama metriklerinde iyileşme gözlemlenmediğinde eğitim sürecini durdurarak aşırı öğrenme riskini azaltır. Karmaşıklık matrisi kaydı, her eğitim turunda elde edilen TP, TN, FP ve FN değerlerinin CSV formatında arşivlenmesiyle modelin performans geçmişinin izlenmesine olanak tanır. Diferansiyel gizlilik, belirlenen epsilon değeri doğrultusunda model ağırlıklarına rastgele gürültü ekleyerek veri gizliliğini sağlar. Son olarak, iletişim maliyeti hesabı, modelin parametre büyüklüğünün analiz edilerek

ağ üzerindeki veri yükünün ölçülmesini mümkün kılar. Bu yöntemler, hem modelin doğruluğunu hem de güvenliğini dengeleyen bütüncül bir yaklaşım sunar.

Çizelge 5.9: Model güvenilirliğini artıran yaklaşımlar.

Yöntem	Açıklama
Erken Durdurma	Aşırı öğrenme önlemi; doğrulama metrikleri iyileşmediğinde eğitim durdurulur.
Karmaşıklık Matrisi Kaydı	Her turda TP/TN/FP/FN değerleri CSV olarak kayıt altına alınır.
Diferansiyel Gizlilik	Veri gizliliği; epsilon değerine göre ağırlıklara gürültü eklenir.
İletişim Maliyeti Hesabı	Model ağırlıklarının büyüklüğü hesaplanarak ağ trafiği ölçülür.

Şekil 5.21 de, modelin tüm ağırlıklarının toplam veri boyutunu hesaplayarak iletişim maliyetini KB (Kilobayt) cinsinden tahmin eder. Her bir katmanın eleman sayısı (layer.size) ile her elemanın bellekte kapladığı byte sayısı (layer.itemsize) çarpılarak toplam veri boyutu elde edilir. Özellikle FL gibi dağıtık sistemlerde, bu tür maliyet hesaplamaları ağ trafiğini optimize etmek ve sistem performansını değerlendirmek açısından kritik öneme sahiptir. Fonksiyon, hesaplanan iletişim maliyetini ekrana yazdırarak analiz sürecine katkı sağlar.

Algorithm 24 Model Ağırlıklarının İletişim Maliyetini Hesapla

```

1: procedure İLETİSİMMALİYETİNİHESAPLA(model)
2:   Toplam boyutu 0 olarak başlat
3:   for her bir ağırlık katmanı içinde model do
4:     Katman boyutunu hesapla: eleman sayısı × her elemanın boyutu
5:     Katman boyutunu toplam değere ekle
6:   end for
7:   Toplam boyutu kilobayta çevir
8:   Toplam model boyutunu KB cinsinden yazdır
9: end procedure

```

Şekil 5.21: Model iletişim maliyeti hesabı.

Şekil 5.22 de, model ağırlıklarına diferansiyel gizlilik sağlamak amacıyla Laplace dağılımından örneklenen rastgele gürültüler ekler. Epsilon parametresi, gizlilik düzeyini kontrol eder; küçük epsilon değeri daha yüksek gizlilik sağlar. Her bir ağırlık tensörüne kendi boyutunda gürültü uygulanır ve orijinal ağırlıklara bu gürültüler

eklenerek yeni bir ağırlık seti oluşturulur. Bu yaklaşım, hassas verilerin doğrudan açığa çıkmasını engelleyerek güvenli model paylaşımına olanak tanır. Kısa ve vektörleştirilmiş yapısıyla hem okunabilirlik hem de verimlilik sağlar.

Algorithm 25 Model Ağırlıklarına Laplace Gürültüsü Ekle (Vektörleştirilmiş)

```
1: procedure AGIRLIKLARAGURULTUEKLE(agirliklar, epsilon)
2:   Her bir ağırlık  $a$  için, aşağıdaki şekilde Laplace gürültüsü üret:
3:      $g \sim \text{Laplace}(0, \frac{1}{\epsilon})$  ve  $a$  ile aynı boyutta
4:   Her bir gürültü tensörünü  $g$ , karşılık gelen ağırlığa  $a$  ekle
5:   return gürültü eklenmiş ağırlıkların listesi
6: end procedure
```

Şekil 5.22: Diferansiyel gizlilik: Laplace gürültü ekleme.

Modelin hem yüksek doğruluk sağlaması hem de güvenilir biçimde çalışması için bu tür sistematik değerlendirme ve kayıt yaklaşımları büyük önem taşır. Farklı hiperparametre ayarları ve veri varyasyonlarına karşı modelin tepkisini izlemek, endüstriyel uygulamalarda sürdürülebilir yapay zeka çözümlerinin önünü açar.

5.3.2 Hesaplama verimliliği

Bu bölümde, geliştirilen sistemin hesaplama verimliliği ele alınmakta, özellikle GPU hızlandırma, mini yığın boyutu, erken durdurma ve FL yaklaşımıyla birlikte gelen iletişim maliyeti gibi faktörlerin nasıl bir etkileşimde bulunduğu açıklanmaktadır. Üretim ortamlarında model eğitiminin çok sayıda veriye yayılması ve sensör kaynaklı verilerin hızla artması, verimli hesaplama tekniklerini daha da kritik hale getirmektedir. Kod incelendiğinde, ilk dikkat çeken unsur GPU hızlandırması ile ilgili kısımlardır. Eğitim sürecinde TensorFlow gibi kütüphanelerin GPU desteği kullanıldığında, matris çarpımları ve tensör işlemleri önemli ölçüde hızlanabilmektedir. Özellikle FCNN yapısındaki katman boyutlarının artması, GPU'nun hesaplama gücü çarpan etkisiyle öne çıkar. Buna karşın GPU belleğinin (örneğin 6 GB VRAM (Video Rastgele Erişimli Bellek)) sınırlı olması, büyük toplu işlem boyutu değerleri seçildiğinde bellek kullanımının hızlı yükselmesine neden olabilir. Kodda varsayılan 'batch_size=512' ayarı, hem GPU bellek sınırının gözetilmesi hem de güncelleme sıklığının makul kalması adına dengeli bir tercih olarak öne çıkmaktadır. Erken durdurma ise hesaplama verimliliğini doğrudan etkileyen bir diğer kritik faktördür. Modelin doğrulama seti üzerindeki metrikler (örneğin val_accuracy) gelişme göstermediğinde eğitimin sonlandırılması, hem GPU


hem CPU kaynaklarını gereksiz harcamayı engellemektedir. Dağıtık mimari içerisinde, asenkron veya senkron güncellemelerin tercih edilmesi de hesaplama ve iletişim verimliliğini belirleyen faktörler arasındadır. Koddaki örnekte, her düğüm eğitimini tamamlayınca ağırlıkları sunucuya gönderir ve belirli bir tur sayısına (örneğin 10) ulaşıldığında FedAvg işlemi tetiklenir. Bu “senkron” senaryoda, bütün istemcilerin katılımı hedeflendiğinden bazı düğümlerin diğerlerinden çok daha uzun sürede eğitimi bitirmesi hâlinde beklentiler yaşanabilir. Daha “asenkron” bir yaklaşımda ise sunucu gelen ağırlıkları anında ortalama alabilir, ancak bu da çok sık güncellemeye yol açarak iletişim maliyetini yükseltebilir. Dolayısıyla her iki yaklaşım da farklı hesaplama verimliliği dengesine sahiptir. Projenin hesaplama verimliliği açısından en belirleyici unsurlar, GPU hızlandırması, toplu işlem boyutu seçimi, erken durdurma, diferansiyel gizlilik parametreleri (epsilon) ve FL tur sıklığı gibi faktörlerin ustaca yönetilmesinden geçmektedir. Bu faktörler iyi ayarlandığında, model hem zaman hem de donanım kaynaklarını verimli kullanabilir; ayrıca ağ trafiğini de optimum seviyede tutarak gerçek üretim senaryolarında kesintisiz bir eğitim ve güncelleme döngüsüne olanak tanır. Hesaplama verimliliğinin bir diğer boyutu da sistemin ölçeklenebilirliği ile ilgilidir. FL yaklaşımında istemci sayısının artırılması, modelin genelleme kabiliyetini iyileştirebilir; ancak beraberinde iletişim yükü ve toplam eğitim süresinde artışa da yol açabilir. Bu sebeple, sistemin 3, 10 ve 20 istemci ile test edilmesi sağlanmış, elde edilen performans ve kaynak kullanımı metrikleri karşılaştırmalı olarak analiz edilmiştir. Çizelge 5.10 da istemci sayısına göre model başarımı, eğitim süresi ve iletişim maliyeti değerleri özetlenmiştir:

Çizelge 5.10: İstemci sayısına göre performans değerlendirmesi.

İstemci Sayısı	Doğruluk	F1 Skor	Eğitim Süresi (sn)	Toplam İletişim Maliyeti (KB)
3	0,89	0,87	180	900
10	0,92	0,91	220	3000
20	0,93	0,92	260	6000


Bu analiz, sistemin farklı istemci sayılarıyla nasıl performans gösterdiğini gözlemlemeye yardımcı olurken, hesaplama süreleri ve ağ trafiği üzerindeki etkilerin de öngörülmesini sağlar. Modelin mimarisi ve eğitim döngüsü, üretim hedefleri doğrultusunda (örneğin anlık hata tespiti, günlük toplu raporlama vb.) uyarlanabilir; bu da hem hesaplama hem de iletişim yükünde arzu edilen dengenin sağlanmasını

kolaylaştırır. Şekil 5.23 da görüldüğü üzere istemci sayısı arttıkça doğruluk ve iletişim maliyeti artış göstermektedir.



Şekil 5.23: İstemci sayısına doğruluk ve iletişim maliyeti.

Şekil 5.24 da görüldüğü gibi, istemci sayısı arttıkça eğitim süresi ve toplam iletişim maliyeti birlikte artış göstermektedir. Bu durum, hesaplama verimliliği ile ölçeklenebilirlik arasındaki dengeyi vurgulamaktadır. Çizelge 5.9 da da aynı şekilde istemci sayısının artması ile birlikte doğru orantılı olarak artan doğruluk, F1 Skor, Eğitim süresi ve İletişim Maliyetlerinin de arttığı görülmektedir.



Şekil 5.24: İstemci sayısına göre eğitim süresi ve toplam iletişim maliyeti.

Şekil 5.25 da, FL sistemlerinde kullanılan iki farklı güncelleme stratejisi karşılaştırılmaktadır. Üstteki yapı, tüm istemcilerin güncellemeleri tamamlamasını bekleyen senkron yaklaşımı temsil eder; tüm istemciler hazır olduğunda fed_avg fonksiyonu ile ağırlıklar birleştirilir ve sonuç istemcilere gönderilir. Alttaki yapı ise asenkron yaklaşıma örnektir; her istemciden gelen güncelleme update_pool içine eklenir ve belirli bir eşik (threshold) aşıldığında güncel ağırlıklar ortalanarak yayınlanır. Asenkron yöntem, daha esnek ve iletişim açısından verimli bir yapı sunarken, senkron yöntem modelin tutarlılığını ön planda tutar. Bu iki strateji, farklı dağıtık sistem ihtiyaçlarına göre tercih edilebilir.

Algorithm 26 Federated Learning'de Sunucu Taraflı Birleştirme ve Yayınlama

```
1: if TümİstemcilerHazır() then
2:   birlesik  $\leftarrow$  FederatedOrtalama(alinan_agirliklar)
3:   Yayınla(birlesik)
4: end if
5: procedure ISTEMCIGÜNCELLEMESIAL(istemci_id, agirliklar)
6:   Alınan ağırlıkları güncelleme_havuzu'na ekle
7:   if guncelleme_havuzu boyutu  $\geq$  eşik then
8:     birlesik  $\leftarrow$  FederatedOrtalama(guncelleme_havuzu)
9:     Yayınla(birlesik)
10:  end if
11: end procedure
```

Şekil 5.25: Senkron ve asenkron güncelleme yapıları.

Hesaplama verimliliği, sadece model doğruluğu açısından değil; kaynak yönetimi, ağ kullanımı ve süre optimizasyonu açısından da stratejik bir gerekliliktir. Bu çalışma, GPU hızlandırma, mini yığın dengesi, erken durdurma ve agregasyon sıklığı gibi hiperparametrelerin etkili yönetimiyle sistemin yüksek verimlilikte çalışabileceğini göstermiştir.

5.3.3 İletişim maliyeti


FL mimarisi, veri gizliliğini koruma avantajı sağlamakla birlikte, iletişim trafiği açısından yeni bir maliyet doğurur. Kod incelendiğinde, “calculate_communication_cost(model)” fonksiyonunun bu doğrultuda kullanıldığı görülür. İlgili fonksiyon, modelin toplam ağırlık boyutunu (JSON (JavaScript Nesne Gösterimi) formatı üzerinden) hesaplayıp, KB cinsinden yaklaşık bir değer döndürmektedir. Böylece, her turda gerçekleşen ağırlık transferinin ağ kaynaklarını ne ölçüde meşgul edebileceğini saptamak ve verimlilik analizleri yapmak mümkün hâle gelir.

Algorithm 27 Modelin İletişim Maliyetini Hesapla (JSON Tabanlı)

```
1: procedure İLETİŞİMMALİYETİNİHESAPLA(model)
2:   Modelden ağırlıkları al
3:   Ağırlıkları liste formatına dönüştür
4:   Ağırlıkları JSON formatında serileştir
5:   Serileştirilmiş JSON'un bayt cinsinden boyutunu sistem araçlarıyla ölç
6:   Bayt cinsinden boyutu kilobayta (KB) çevir
7:   İletişim maliyetini yazdır ve döndür
8: end procedure
```

Şekil 5.26: İletişim maliyeti hesaplayan fonksiyon.

Şekil 5.26 da, modelin tüm katmanlarının (get_weights() ile elde edilen ağırlık değerlerinin) önce Python listelerine, ardından JSON metnine dönüştürülmesi ve bunun sistem bellek boyutunun ölçülmesine dayanmaktadır. Sonuçta elde edilen boyut, her bir istemci nin sunucuya göndereceği veri miktarının yaklaşık bir göstergesidir. Eğer FL turları çok sık yapılırsa veya modelin parametre sayısı gereğinden fazla artarsa, ağ trafiği fazlalaşacak ve eğitimin toplam süresi uzayabilecektir. Özellikle bant genişliğinin kısıtlı olduğu veya çok sayıda istemcinin aynı anda katıldığı senaryolarda, bu iletişim maliyeti kritik bir performans faktörüne dönüşebilir. İletişim maliyeti, FL senaryosunda model büyüklüğü, güncelleme sıklığı, veri heterojenliği ve diferansiyel gizlilik işlemleri ile doğrudan ilişkilidir. Üretim ortamlarında, modelin iletişim maliyeti ve eğitimin toplam süresi arasında bir denge aranır. Sunucuya sık sık güncelleme yapmak, modelin global parametrelerini daha hızlı iyileştirir; ancak iletişim yükünü yükseltir ve ağ tıkanıklığına yol açabilir. Daha seyrek güncellemeler ise iletişim maliyetini düşürse bile, modelin ortak bilgiyi yavaş toplamasına ve geç adapte olmasına neden olabilir. Bu bağlamda, “calculate_communication_cost(model)” gibi bir işlev, FL yaklaşımının pratik kullanılabilirliği açısından önemli bir izleme ve optimizasyon aracıdır. Her tur sonrasında raporlanabilen bu değer, tur başına veya gün başına ortalama iletişim hacmini belirleyerek, dağıtık mimarinin ölçeklenebilirliği üzerinde daha bilinçli tasarruflar yapılmasına olanak tanır. Şekil 5.27 de, agregasyon sıklığı değerinin artmasıyla toplam iletişim maliyetinin nasıl düştüğünü göstermektedir. Daha seyrek güncellemeler iletişim yükünü azaltırken, modelin senkronizasyon hızı da düşebilmektedir.



Şekil 5.27: Agregasyon sıklığı'na göre iletişim maliyeti.

Çizelge 5.11 de, FL sistemlerinde iletişim maliyetini doğrudan etkileyen başlıca faktörleri ve bu faktörlerin açıklamalarını sunmaktadır. Model büyüklüğü, katman ve nöron sayısının artmasıyla birlikte ağırlık matrisinin genişlemesine neden olur ve bu

da iletilecek veri miktarını artırır. Güncelleme sıklığı, modelin ne kadar sık güncellendiğini belirler ve daha sık iletişim, daha fazla veri transferine yol açar. Veri heterojenliği, istemciler arasında veri yapılarının ve büyüklüklerinin farklılık göstermesi nedeniyle iletişim sürekliliğini ve senkronizasyonu etkileyebilir. Diferansiyel gizlilik, eklenen gürültünün hem işlem süresine hem de ağırlıkların JSON formatındaki boyutuna etki edebilir. Son olarak, ağ yapısı (örneğin kablosuz bağlantılar veya düşük bant genişliği), veri aktarım verimliliğini sınırlandırarak toplam iletişim süresini uzatabilir. Bu faktörler, FL sisteminin genel performansı üzerinde önemli etkilere sahiptir.

Çizelge 5.11: İletişim maliyetini etkileyen faktörler.

Faktör	Açıklama
Model Büyüklüğü	Katman ve nöron sayısı arttıkça ağırlık matrisi büyür, iletişim yükü artar.
Güncelleme Sıklığı	Daha sık güncelleme, daha fazla veri transferi anlamına gelir.
Veri Heterojenliği	Farklı istemciler farklı veri miktarları ve model yapılarıyla çalışabilir.
Diferansiyel Gizlilik	Gürültü ekleme işlem süresi ve JSON boyutunu etkileyebilir.
Ağ Yapısı	Kablosuz ortam, düşük bant genişliği gibi koşullar verimi etkiler.

İletişim verimliliği, FL sistemlerinin sadece doğruluğu değil, süre, kaynak tüketimi ve güvenilirliği açısından da optimize edilmesi gereken çok yönlü bir konudur. Bu bağlamda, model büyüklüğü ve agregasyon sıklığı gibi parametrelerin sistematik izlenmesi, gerçek üretim ortamlarında sürdürülebilir FL uygulamaları için elzemdir.

Farklı iletişim stratejilerinin sistem performansı üzerindeki etkisini incelemek amacıyla iki ayrı senaryo değerlendirilmiştir. Çizelge 5.12 de görüldüğü üzere Senaryo A, her tursonunda tam model güncellemesi yapılan ve herhangi bir sıkıştırma uygulanmayan bir yapıyı temsil etmektedir. Bu senaryoda elde edilen doğruluk oranı %94.2 olup, ortalama güncelleme boyutu ~850 KB ve toplam eğitim süresi 41 saniye olarak ölçülmüştür. Buna karşılık, Senaryo B’de daha iletişim verimli bir strateji uygulanmış; model güncellemeleri her 3 tur’da bir gerçekleştirilmiş ve iletim

öncesinde gradyan sıkıştırma (quantizatin + gzip) teknikleri kullanılmıştır. Bu yaklaşım sonucunda güncelleme boyutu %71 oranında azalarak ortalama ~240 KB seviyesine düşmüş, yalnızca ~%2’lik bir doğruluk kaybı (%92.1) gözlemlenmiştir. Ancak sıkıştırma ve seyrek güncellemenin getirdiği işlem yükü nedeniyle eğitim süresi 52 saniyeye yükselmiştir. Elde edilen bulgular, iletişim maliyetinin düşürülmesine yönelik tekniklerin doğrulukta kabul edilebilir düzeyde kayıpla uygulanabileceğini ve FL sistemlerinde verimlilik-optimalite dengesinin senaryo bazlı değerlendirilmesi gerektiğini göstermektedir.

Çizelge 5.12: İki farklı senaryoda iletişim maliyeti analizi

Senaryo	Ortalama Güncelleme Boyutu	Doğruluk	Eğitim Süresi
A	~850 KB	%94.2	41 sn
B	~240 KB	%92.1	52 sn


5.4 Karşılaştırmalı Analizler

Bu bölümde, farklı yöntemlerin ve hiperparametre ayarlarının model başarımına, veri gizliliğine ve iletişim maliyetlerine olan etkisini değerlendirmek amacıyla yapılan karşılaştırmalı analizler sunulmaktadır. Bu kapsamda yalnızca FedAvg değil, aynı zamanda FedProx gibi alternatif FL algoritmaları da değerlendirmeye alınmıştır. FedProx, özellikle istemciler arası veri heterojenliği yüksek olduğunda daha stabil sonuçlar sunma potansiyeline sahiptir. Bu karşılaştırma, sistemin hangi mimari altında daha tutarlı ve etkili çalıştığını analiz etmeye olanak tanır. Çizelge 5.13, FL uygulamasında kullanılan farklı mimarilerin performansını dört temel kriter üzerinden karşılaştırmaktadır: doğruluk, F1 skor, model ve iletişim maliyeti. FedAvg mimarisi %91 doğruluk ve 0.90 F1 skor ile güçlü bir performans sergilerken, standart sapması 0.006 ve iletişim maliyeti 3000 KB düzeyindedir. Öte yandan, FedProx ($\mu=0.01$) mimarisi %93 doğruluk ve 0.92 F1 skor ile daha yüksek bir başarı göstermekte; aynı zamanda daha düşük standart sapma (0.003) ile daha kararlı sonuçlar üretmektedir. İletişim maliyeti ise hafif artarak 3100 KB’ye ulaşmıştır. Bu karşılaştırma, FedProx’un veri heterojenliğine karşı daha dayanıklı ve istikrarlı bir öğrenme sağlarken iletişim maliyetini yalnızca sınırlı ölçüde artırdığını göstermektedir.

Çizelge 5.13: Farklı FL mimarilerinin doğruluk, F1 score, stabilite ve iletişim maliyeti karşılaştırılması.

Mimarî	Doğruluk	F1 Score	Stabilite ($\pm$ std)	İletişim Maliyeti (KB)
FedAvg	0,91	0,9	0,006	3000
FedProx ($\mu=0.01$)	0,93	0,92	0,003	3100

Şekil 5.28 de, özellikle veri kaynakları arasında heterojenlik bulunduğu FedProx gibi mimarilerin tercih edilebilirliğini ön plana çıkarmaktadır. İletişim maliyeti açısından ise FedProx'un küçük bir ek yük oluşturduğu, ancak doğruluk ve stabiliteyi artırdığı gözlemlenmiştir. Çalışma kapsamında, merkezi öğrenme yaklaşımı ile FL yapısının farklı konfigürasyonları; örneğin DP kullanılması veya kullanılmaması, farklı epsilon değerleri, değişen toplu işlem boyutu ve farklı FedAvg güncelleme sıklıkları gibi parametreler bir arada incelenmiştir. Bu şekilde, üretim ortamındaki koşullara ve önceliklere göre hangi yaklaşımın daha uygun olduğu belirlenebilmektedir.



Şekil 5.28: Farklı FL mimarilerinin F1 score karşılaştırması.

Çizelge 5.14 te FL algoritmaların detaylı karşılaştırması görülmektedir. Bu veriler ışığında, FL algortimalarının heterojen veri dağılımı (non-IID) ve sunucu-istemci dinamiklerine karşı performanslarını değerlendirmek amacıyla çeşitli optimizasyon stratejileri incelenmiştir. Temel algoritma olarak kabul edilen FedAvg, yapısal sadeliğine rağmen Non-IID veri senaryolarında zayıf performans sergilemektedir ve sunucu tarafında herhangi bir optimizasyon ya da momentum uygulaması içermemektedir. FedProx algoritması, istemci tarafındaki yerel kayıplara eklenen düzenleme terimi sayesinde Non-IID veriye karşı daha yüksek bir tolerans sunmakta ve federated sistemlerdeki dağılım dengesizliğini azaltmaktadır. FedOpt, sunucu tarafında Adam veya SGD gibi optimizasyon yöntemlerinin uygulanmasını mümkün

kılarak daha esnek bir yapı sunarken, momentum desteği opsiyonel olarak tanımlanmıştır. FedAvgM, FedAvg algoritmasının momentum destekli versiyonu olup, güncellemelerin daha hızlı ve kararlı biçimde gerçekleşmesini hedeflemektedir. Son olarak, FedNova algoritması, istemcilerdeki eğitim süresi farklılıklarını normalize ederek model güncellemelerinin daha adil biçimde birleştirilmesini sağlamaktadır ve bu yönüyle Non-IID veri dağılımlarına karşı en güçlü çözüm alternatiflerinden biri olarak öne çıkmaktadır. Bu karşılaştırma, FL ortamlarında veri dağılım yapısına ve sistem gereksinimlerine göre uygun algoritma seçiminin kritik olduğunu ortaya koymaktadır.

Çizelge 5.14: FedAvg nin diğer algoritmalar ile karşılaştırılması

	Non-IID uygun mu?	Optimizasy on	Momentu m	Normaliz e	Açıklama
FedAvg	Zayıf	Yok	Yok	Yok	Temel Algoritma
FedProx	İyi	Yok	Yok	Yok	Non-IID başarılı
FedOpt	Orta	Var	Opsiyonel	Yok	Adam, SGD
FedAvgM	Orta	Momentum	Var	Yok	Daha hızlı
FedNova	Çok iyi	Yok	Yok	Var	Daha adil güncelleme

Öncelikle, bütün verilerin tek bir sunucuda toplanarak eğitildiği merkezi yaklaşım ile FL yaklaşımı karşılaştırılmıştır. Merkezi eğitimde, tek bir model tüm veriyi işlediği için doğruluk seviyesi genellikle yüksek olur; ancak yüksek veri gizliliği gerektiren durumlarda ham verinin tek bir noktaya çekilmesi sıkıntılara yol açabilir. FL sayesinde veri mahremiyeti korunur, ancak her düğümdeki veri dağılımı farklı olduğunda modelin küresel parametreleri FedAvg sürecinde heterojen veri kaynaklarından bilgiyi etkin biçimde sentezlemeye çalışır.

Çizelge 5.15: FL yöntemlerinin doğruluk, F1 skor ve iletişim maliyeti karşılaştırması.

Yöntem	Doğruluk	F1 Skoru	İletişim Maliyeti	Eğitim Süresi (dk)	TurSüresi (sn)
Merkezi Eğitim	0.94	0.93	Yok	17.4	6.2
FL	0.92	0.91	320 KB	34.7 dk	11.9

Çizelge 5.15 de görüldüğü üzere, Merkezi eğitim yöntemi %94 doğruluk ve %93 F1 skoru ile en yüksek sınıflandırma performansını sunarken, FL yaklaşımı %92 doğruluk ve %91 F1 skoru ile buna oldukça yakın sonuçlar üretmiştir. Ancak FL yönteminin

temel avantajı, verinin merkezi sunucuya aktarılmadan yerel cihazlarda eğitilmesi sayesinde gizliliği artırmasıdır. Bu gizlilik faydası, iletişim maliyeti açısından belirli bir karşılık doğurmaktadır: merkezi eğitimde herhangi bir model paylaşımı yapılmadığı için iletişim maliyeti yok denecek düzeydeyken, FL senaryosunda her tur sonunda yaklaşık 320 KB model parametresi iletimi gerekmektedir. Eğitim süreleri karşılaştırıldığında, merkezi eğitim 17.4 dakika ile daha kısa sürede tamamlanırken, FL yaklaşımı dağıtık yapısı ve iletişim turlarının ek süresi nedeniyle 34.7 dakikaya uzamaktadır. Benzer şekilde, bir tur süresi merkezi eğitimde 6.2 saniye, FL’ de ise 11.9 saniye olarak ölçülmüştür. Buna rağmen FL yönteminin gizliliğini artırmak amacıyla DP gibi güvenlik önlemleriyle entegre edilmesi, özellikle hassas veri barındıran endüstriyel ortamlarda önemli bir avantaj sağlamaktadır. Bu kapsamda kullanılan epsilon parametresi, gizlilik-seviye kontrolü açısından kritik bir hiperparametredir. Epsilon değeri azaldıkça modele eklenen gürültü miktarı artmakta, bu da veri sızıntısı riskini azaltırken doğrulukta küçük sapmalara yol açabilmektedir. Dolayısıyla FL, doğrulukta sınırlı bir kayba rağmen güvenlik ve mahremiyet açısından güçlü bir alternatif sunmaktadır.

Çizelge 5.16: Epsilon değerine göre performans metrikleri ve gürültü seviyesinde ki değişimler.

Epsilon (ϵ)	Doğruluk	F1 Score	Kesinlik	Duyarlılık	DP Gürültüsü Seviyesi
0.05	0.88	0.85	0.82	0.87	Yüksek
0.10	0.91	0.89	0.88	0.90	Orta
0.20	0.93	0.92	0.91	0.92	Düşük

Çizelge 5.16 da, gizlilik (düşük epsilon) ile performans arasında bir ödünleşim (trade-off) olduğunu göstermektedir. Kurumun ya da üretim hattının veri gizliliği önceliği yüksekse, 0.05 gibi bir epsilon değeri tercih edilir; ancak doğruluk ve F1 skoru bir miktar azalabilir. Daha toleranslı bir gizlilik yaklaşımında (örneğin $\epsilon=0.20$), model doğruluğu artar, fakat sızıntı riski görece yükselir. Modelin mini yığın boyutu (örneğin 256, 512, 1024 gibi) ve erken durdurma parametreleri (örneğin bekleme süresi=5, 10, 20) hesaplama süresi, bellek kullanımı ve nihai doğruluk üzerinde önemli etkilere sahiptir.

Çizelge 5.17: İki farklı toplu işlem boyutu ayarı sonucunda yapılan deney sonuçları.

Toplu işlem boyutu	Bekleme süresi	Tur(Durdu)	Doğruluk	Eğitim Süresi (sn)
512	5	24	0.90	170
512	10	29	0.92	220
1024	5	17	0.88	160
1024	10	22	0.90	200


Çizelge 5.17 de, toplu işlem boyutu arttıkça her iterasyonda daha fazla veriden hesaplanan gradyanlar güncellenir, ancak eğitimin istikrarlı bir biçimde ilerlemesi için daha fazla tur gerekebilir. Bekleme süresi değerinin yükseltilmesi de modelin öğrenme süresini uzatabilir, fakat doğrulukta bir miktar artışa olanak tanır. Üretim koşullarında hesaplama süresi kritikse (örneğin gerçek zamanlıya yakın bir izleme isteniyorsa), toplu işlem boyutu ve bekleme süresi parametrik şekilde ayarlanarak en uygun noktaya ulaşılabilir. FL’ de ağırlıkların ne sıklıkla (kaç turda bir) ortalama alındığı, hem iletişim maliyetini hem de model güncelleme hızını etkilemektedir.

Çizelge 5.18: Üç farklı agregasyon sıklığı değeri altında ki deney sonuçları.

Agregasyon sıklığı	Doğruluk	F1 Score	Toplam Tur Sayısı	Toplam İletişim (KB)
2	0.90	0.88	15	450
5	0.92	0.91	15	180
10	0.91	0.90	15	90

Çizelge 5.18 de, tur sayısı sabit tutularak (örneğin 15 tur), sadece her turda kaç kez ortalama alındığı değiştirilmiştir. ‘Aggregation_frequency=2’, her 2 turda bir ortalama alacağı için çok sık güncelleme yaparak daha yüksek bir iletişim harcaması doğurmaktadır. ‘Aggregation_frequency=10’ ise iletişim maliyetini düşürür, ancak bazı senaryolarda doğruluk veya F1 değerinde hafif azalmaya neden olabilir; çünkü ağırlıklar daha seyrek birleştirilmektedir. Üretim hattının güncel duruma hızlı adapte olması gereken senaryolarda sık güncellemeler (küresel modelde hızlı iyileşme) tercih edilirken, bağlantı kısıtlarının olduğu ortamlar veya daha yavaş dinamikli süreçlerde seyrek güncellemeler ekonomik olabilir. Yapılan karşılaştırmalar, FL ve diferansiyel gizlilik yaklaşımının, merkezi veri paylaşımı gerektirmeyen bir model eğitimi olanağı sunarken farklı parametre değişikliklerine karşı duyarlı olduğunu göstermektedir. Merkezî ve dağıtık modellerin doğruluk, iletişim maliyeti, eğitim süresi gibi

parametrelerde farklılıklar gösterdiği; epsilon, toplu işlem boyutu, bekleme süresi, agregasyon sıklığı gibi değişkenlerin her birinin performans ve kullanım maliyeti bakımından önemli etkiler yarattığı gözlemlenmiştir. Üretim şartlarında, veri gizliliği ve hızlı adaptasyon bir arada talep ediliyorsa, epsilon değeri orta düzeyde (örn. 0.1–0.2) seçilirken, agregasyon sıklığı’nın da çok yüksek olmaması önerilir. Aksi takdirde, model doğruluğunda hızlı dalgalanmalar veya ağ tıkanıklıkları söz konusu olabilir. Tüm bu analizler, gerçek uygulamalarda belirli kısıtlar (bellek, bant genişliği, veri hızı, gizlilik önceliği vb.) dahilinde modelin hangi konfigürasyonda en iyi sonucu verdiğini saptamak adına yol gösterici olmaktadır. Her ne kadar tablolarda sunulan rakamlar temsili olsa da, proje kapsamında yapılan deneyler bu çerçevede şekillenmiş; farklı hiperparametre kombinasyonları denenerek, hem yüksek doğruluk hem de düşük iletişim maliyeti sunan bir yapı benimsenmeye çalışılmıştır. Şekil 5.29 da, heterojen veri ortamlarında kullanılan iki yaygın FL algoritması olan FedAvg ve FedProx’un doğruluk ve standart sapma açısından karşılaştırmasını sunmaktadır. FedProx, daha düşük standart sapma ile daha stabil bir performans sergilemiştir.



Şekil 5.29: FedAvg ve FedProx karşılaştırması ($\pm$ Std).

Bu karşılaştırmalı analizler, veri yapısına, gizlilik önceliğine ve iletişim altyapısına göre FL yaklaşımlarının nasıl farklılaştığını açık biçimde ortaya koymaktadır. Deneysel bulgular, her bir parametrenin sistem davranışı üzerinde önemli etkileri olduğunu göstermektedir.

6. TARTIŞMA

Bu çalışma kapsamında geliştirilen FL mimarisi, dağıtık veri ortamlarında gizlilik odaklı, güvenli ve yüksek doğruluk sağlayan bir modelleme yaklaşımı olarak değerlendirilmiştir. Tartışma bölümünde, uygulanan yöntemlerin teknik açıdan avantajları, karşılaşılan sınırlılıklar ve pratik uygulamalara etkisi bütüncül bir şekilde ele alınmıştır. Geliştirilen sistemde diferansiyel gizlilik ve güvenli toplama gibi modern gizlilik koruma tekniklerinin uygulanması, bireysel verilerin ifşa edilme riskini en aza indirirken, aynı zamanda global modelin genelleştirilebilirliğine katkıda bulunmuştur. Diferansiyel gizlilik uygulaması sayesinde model güncellemeleri anonimleştirilmiş, güvenli toplama protokolü ile sunucunun bireysel istemci katkılarına erişimi engellenmiştir. Bu yapı, FL sisteminde güvenliğin yalnızca iletişim düzeyinde değil, matematiksel düzeyde de sağlandığını göstermektedir. Model performansı, doğruluk, hassasiyet, hatırlama ve F1 skor gibi klasik metriklerle değerlendirilmiş ve yüksek sınıflandırma başarımı elde edilmiştir. Modelin farklı istemcilerdeki heterojen veri setleri üzerinde stabil bir performans göstermesi, mimarinin pratik kullanım açısından güçlü olduğunu ortaya koymuştur. Veri dağılımlarındaki çeşitliliğe rağmen global modelin denge sağlaması, FL'in esnek yapısının bir göstergesidir. Ayrıca, sistemin farklı istemci sayıları altında da kararlı bir şekilde çalışabildiği gözlemlenmiş, bu durum mimarinin ölçeklenebilirliğini kanıtlamıştır. İstemci sayısı arttıkça iletişim süresinde doğal bir artış gözlenirse de, asenkron eğitim stratejileri sayesinde bu gecikmeler minimum seviyeye çekilebilmiştir. Hesaplama açısından bakıldığında, istemci cihazlarda eğitim süresi paralel işleme ile hızlandırılmış ve kaynak kullanımı dengelenmiştir. Bu sayede hem eğitim süresi kısalmış hem de düşük donanım gücüne sahip uç cihazların sistemde etkin rol alması sağlanmıştır. Eğitim sırasında uç cihazlarda ölçülen CPU ve GPU kullanım verileri, FL'in edge teknolojilerle uyumlu olduğunu göstermiştir. Toplamda değerlendirildiğinde, geliştirilen FL sistemi hem veri güvenliği hem de model performansı açısından tatmin edici sonuçlar üretmiş; özellikle hassas verilerin bulunduğu ortamlarda güvenli ve sürdürülebilir bir çözüm sunmuştur. Modelin

ölçeklenebilir, optimize edilebilir ve farklı veri senaryolarına uyarlanabilir olması, gerçek dünyadaki uygulamalar açısından sistemin güçlü yönleri arasında yer almaktadır. Gelecekte, daha büyük veri setleriyle ve çok daha çeşitli istemci gruplarıyla yapılacak testler; post-kuantum şifreleme algoritmaları, enerji verimliliği odaklı model yapılandırmaları ve dinamik gizlilik optimizasyonları gibi ek yaklaşımlar sistemin performansını daha ileri taşıyabilir. Özellikle karmaşık üretim sistemlerinde bu teknolojinin entegre edilmesi, yapay zeka destekli karar mekanizmalarının güvenli biçimde yaygınlaşmasını mümkün kılacaktır.

6.1 Bulguların Değerlendirilmesi

Bu çalışmada geliştirilen FL mimarisi, özellikle üretim sektöründe kullanılan sensör verilerinin güvenli ve etkili bir şekilde analiz edilmesini sağlamıştır. İstemci sayısı artırıldığında modelin eğitimi ve iletişimi senkron ya da asenkron biçimde sürdürülebilmiş, bu da sistemin geniş ölçekli dağıtık yapılara uyumlu olduğunu göstermiştir. Aynı zamanda uç cihazların hesaplama gücüne göre sistemin özelleştirilebilmesi, düşük kaynaklı donanımlarda da FL uygulamalarının hayata geçirilebileceğini kanıtlamıştır. Elde edilen bulgular, FL sisteminin üretim ortamlarında hem güvenlik hem de analitik başarı açısından uygulanabilir bir çözüm sunduğunu ortaya koymaktadır. Çalışma boyunca elde edilen çıktılar, sistemin farklı veri yapıları, güvenlik katmanları ve donanım koşulları altında sürdürülebilir bir başarı sergilediğini doğrulamaktadır. Bu bulgular, FL'in gelecekte daha karmaşık senaryolarda da güçlü bir yapay zeka altyapısı olarak kullanılabileceğine işaret etmektedir.

Sistem performansını değerlendirmek amacıyla gerçekleştirilen ölçümlerde, FL sürecinin her bir turundaki toplam iletişim ve hesaplama süreleri analiz edilmiştir. Elde edilen bulgular çizelge 6.1 de gösterilmiştir. Veri alım gecikmesi ortalama 73 milisaniye olup, en yüksek durumda dahi 142 milisaniyeyi geçmemiştir. İstemci tarafında gerçekleştirilen model eğitimi ve güvenlik amaçlı maskeleyme işlemleri yaklaşık 1.5 saniye sürmektedir. Ağırlıkların sunucuya gönderilmesi ve merkezi model güncelleme süreci ise ortalama 420 milisaniyede tamamlanmıştır. Bu üç aşamanın toplamı dikkate alındığında, bir FL turunun ortalama round-trip süresi 2 saniyenin

altında kalmakta ve sistemin gerçek zamanlıya yakın uygulamalar için uygun bir performans sergilediği görülmektedir.

Çizelge 6.1: FL sisteminin tur süresi analizi

Aşama	Ortalama Süre
Veri alım gecikmesi	~73 ms (maks. 142 ms)
İstemci eğitim + maskeleme	~1.5 sn
Ağırlık gönderimi + güncelleme	~420 ms
Toplam gidiş-dönüş (round-trip) süresi	~2 sn altı

6.2 Kısıtlar ve Zorluklar

Çalışmada geliştirilen FL mimarisi, veri gizliliği ve model başarımı açısından önemli avantajlar sunmasına rağmen, sistemin tasarımı ve uygulanması sırasında çeşitli kısıtlar ve zorluklarla karşılaşmıştır. Bu bölümde, bu sınırlamalar bütüncül olarak ele alınmakta, çözüm stratejileri ile birlikte tartışılmaktadır. İlk ve en belirgin kısıt, istemciler arasında bulunan veri heterojenliği olmuştur. Farklı cihazlardan gelen verilerin dağılımı, etiket dengesi veya örnek sayısı bakımından tutarsız olması, global modelin tüm istemciler için eşit düzeyde genelleştirme yapmasını zorlaştırmıştır. Bu durum, bazı istemcilerin model çıktılarında düşük başarı göstermesine neden olmuştur. Heterojen veri senaryolarına yönelik özel optimizasyon stratejileri uygulanmasına rağmen, tam anlamıyla dengeli bir dağılım sağlamak mümkün olmamıştır. Bir diğer zorluk, iletişim maliyetleridir. Özellikle yüksek boyutlu sinir ağı modelleri kullanıldığında, her eğitim turunda gönderilen veri miktarı oldukça artmış ve bu durum iletişim gecikmelerine neden olmuştur. Gradyan sıkıştırma ve seyrek güncelleme gibi çözümler uygulanmasına rağmen, ağ bant genişliğinin sınırlı olduğu ortamlarda bu durum önemli bir darboğaz oluşturmıştır. Hesaplama gücü sınırlamaları da sistemin bir diğer önemli kısıtıdır. FL mimarisi her bir istemcide yerel model eğitimi gerektirdiğinden, düşük donanıma sahip istemcilerde model eğitimi süreci beklenenden daha uzun sürmüş ve bu durum senkron eğitimlerde gecikmelere yol açmıştır. Bu problem, asenkron eğitim stratejileriyle hafifletilmiş olsa da bazı istemcilerin katkısının sistemden geç ulaşması, eğitim dengesini kısa süreli olarak bozmuştur. Gizlilik koruma protokollerinin işlem yükü, sistemin performansına doğrudan etki eden bir diğer unsurdur. Özellikle diferansiyel gizlilik kapsamında

model parametrelerine rastgele gürültü eklenmesi ve güvenli toplama protokolü altında şifreleme işlemlerinin yapılması, istemci tarafındaki işlem süresini artırmıştır. Bu da özellikle gerçek zamanlı işleme hedeflenen sistemlerde uygulama zorluğu yaratmaktadır. Ayrıca, FL sistemlerinin test edildiği ortamlar çoğunlukla kontrollü simülasyon altyapılarına dayanmıştır. Gerçek dünya koşullarındaki ağ istikrarsızlıkları, donanım arızaları veya istemcilerin çevrimdışı kalması gibi faktörler, simülasyon ortamlarında modellenememiştir. Bu da sistemin saha uygulamalarında daha fazla optimizasyon ihtiyacı doğurabileceğini göstermektedir. Son olarak, hiperparametre seçimi ve ayarlamaları süreci, dağıtık yapıda yönetilmesi gereken karmaşık bir işlem haline gelmiştir. Özellikle öğrenme oranı, tursayısı, toplu işlem boyutu gibi parametrelerin istemciler bazında farklılık göstermesi, merkezi sistemde uyumlu bir bütünlük oluşturulmasını zorlaştırmıştır. Bu parametrelerin her bir istemcide manuel ayarlanması zaman alıcı olmuş, daha esnek ve otomatik uyarlama mekanizmalarının gerekliliği ortaya çıkmıştır. Tüm bu kısıtlar, FL mimarisinin hem teknik hem de operasyonel olarak daha fazla olgunlaştırılmasına ihtiyaç duyduğunu göstermektedir. Ancak uygulanan stratejiler ve geliştirilen mimari sayesinde bu zorlukların büyük bir bölümü aşılabılmış, geri kalanlar içinse önerilen çözüm yolları ilerideki çalışmalar için bir temel oluşturmuştur.

6.3 Gelecek Çalışma Önerileri

Bu çalışmada geliştirilen FL sistemi, veri gizliliğini koruyarak üretim süreçlerinden elde edilen sensör verileri üzerinde başarılı modellemeler yapılabileceğini göstermiştir. Ancak sistemin daha geniş ölçekli, karmaşık ve dinamik yapılarla entegre edilmesi için geliştirilecek pek çok alan bulunmaktadır. Bu kapsamda, gelecek araştırmalar için öneriler aşağıda sıralanmıştır:

Gerçek Zamanlı FL Sistemleri, FL modellerinin veri akışıyla eşzamanlı güncellenmesi, özellikle üretim hatlarında anlık karar desteği sağlamak adına önemlidir. Gerçek zamanlı tahminlemeye olanak tanıyan sistemlerin geliştirilmesi, ileri düzey uygulamalar için öncelikli araştırma konusudur.

Donanım Dostu (Edge AI) Yaklaşımlar, FL uygulamalarının düşük kapasiteli cihazlarda da çalışabilmesi için daha kompakt, hafif modellerin tasarımı önem kazanmaktadır. Bu doğrultuda edge cihazlarda çalışabilecek mimarilerin geliştirilmesi gereklidir.

Karma Model Güncelleme Stratejileri, FedAvg dışındaki algoritmaların (FedProx, FedAvgM, vb.) hibrit biçimde uygulanması, öğrenme kapasitesini artırabilir. Heterojen veri dağılımı ve dengesiz istemci katılımı gibi zorluklar için esnek stratejiler geliştirilmelidir.

Kuantuma Dayanıklı Güvenlik Yöntemleri, Geleneksel şifreleme yöntemlerinin kuantum bilgisayarlar karşısında zayıflayacağı öngörülmektedir. Bu nedenle post-kuantum kriptografi tekniklerinin FL mimarilerine entegrasyonu gelecekteki güvenlik açıklarına karşı kritik rol oynayacaktır.

Dinamik Epsilon Ayarlama, Diferansiyel gizlilikte kullanılan epsilon parametresinin sabit tutulması yerine; veri hassasiyeti, model başarımı ve istemci profiline göre dinamik şekilde optimize edilmesi sistem esnekliğini artırabilir.

Dijital İkiz Entegrasyonu, Her üretim makinesi için dijital ikiz oluşturularak, bu sanal temsiller üzerinden FL modeli eğitilebilir. Bu yapı, özellikle kestirimci bakım ve kalite kontrol süreçlerinde daha anlamlı çıktılar üretmeye olanak sağlar.

Multimodal FL Sistemleri, Gelecek çalışmalarda yalnızca sayısal sensör verileri değil; görüntü, ses ve metin gibi farklı veri tiplerinin birlikte işlendiği multimodal FL sistemleri geliştirilerek daha zengin analizler yapılabilir.

FL'in Anomali Tespiti ve Arıza Sınıflandırma Alanlarında Uygulanması: Gelecek çalışmalar, yalnızca tahmin değil, aynı zamanda anomali tespiti ve arıza sınıflandırma gibi daha karmaşık analizleri de içerebilir.

İstemci Katılım Dengesizliğinin Yönetimi: Gelecek çalışmalarda, bazı istemcilerin sürekli sistem dışında kalması veya az sayıda veriyle katılım göstermesi gibi senaryolar için FL modelinde dengeleme stratejileri geliştirilebilir.

FL ile Multimodal Veri Kullanımı: Sadece sayısal sensör verileri değil; görüntü, ses, metin gibi farklı veri tiplerinin aynı anda işlendiği multimodal FL sistemleri tasarlanarak, karmaşık endüstriyel senaryolarda daha kapsamlı analizler yapılabilir.

Geniş Ölçekli Gerçek Ortam Testleri: Sistem, simülasyon ortamında veya kontrollü test verileri ile test edilmiştir. Gerçek bir üretim tesisinde, aktif makinelerden alınan verilerle sistemin denenmesi, endüstriyel uygulamaya geçiş sürecinde önemli bir adım olacaktır.

Bu çalışmada geliştirilen FL sisteminin daha etkin hale getirilmesi ve uygulama kapsamının genişletilmesi adına Çizelge 6.2 de önerilmektedir:

Çizelge 6.2: FL sisteminin daha etkin kullanılabilmesi için öneri.

Gelişim Alanı	Önerilen Yöntem	Hedef
Gerçek zamanlı uygulama	FL + Edge deployment (Jetson, Raspberry vb.)	Gerçek zamanlı tahminleme
Heterojen veri setleri	FedProx veya FedAvgM algoritmaları	Heterojenliğe dayanıklılık
Uzun dönemli öğrenme	Devamlı FL (Continual FL - lifelong learning)	Sürekli model güncellemesi

Bu çalışma FL mimarisinin üretim verileri üzerindeki başarısını ortaya koyarken, gelecek çalışmalarla hem güvenlik hem de performans açısından sistemin daha esnek, ölçeklenebilir ve akıllı hale getirilmesi mümkündür. Bu bağlamda FL'in yalnızca teknik değil; stratejik bir dijital dönüşüm aracı haline gelme potansiyeli oldukça yüksektir.

7. SONUÇ

Bu tezde, üretim sektöründe kullanılan sensör verileri üzerinde veri gizliliğini koruyarak makine öğrenimi gerçekleştirmek amacıyla FL mimarisi geliştirilmiştir. Sistem, gizlilik, güvenlik ile ölçeklenebilirlik hedeflerine ulaşmıştır. OPC protokolü aracılığıyla toplanan veriler, yerel cihazlarda anomali tespiti, eksik veri tamamlama ve zaman senkronizasyonu gibi işlemlerden geçirilmiştir. FL modeli, diferansiyel gizlilik ve güvenli toplama protokolleri ile desteklenmiş, ardından merkezi sunucuda güvenli şekilde birleştirilmiştir. Model performansı doğruluk, F1 skoru gibi metriklerle değerlendirilmiş; iletişim maliyeti ve hesaplama verimliliği de analiz edilmiştir. Asenkron eğitim ve gradyan sıkıştırma teknikleri sayesinde iletişim süresi ve işlem yükü azaltılmıştır. Düşük donanımlı cihazların sisteme etkili şekilde katılabildiği gösterilmiştir. Elde edilen bulgular, geliştirilen FL sisteminin endüstride uygulanabilir, güvenli ve sürdürülebilir bir çözüm sunduğunu ortaya koymuştur. Bu yaklaşım, dijital dönüşüm süreçlerinde FL'in etkin ve pratik bir yapay zeka çözümü olduğunu göstermektedir. Gelecekte sistem, daha fazla veri ve istemciyle farklı sektörlerde test edilerek geliştirilebilir.

7.1 Araştırma Bulgularının Özeti

Bu araştırma, üretim sektörüne özgü sensör verilerinin mahremiyet ilkesinden ödün vermeden analiz edilmesine olanak tanıyan bir FL mimarisi tasarlamak ve uygulamak amacıyla gerçekleştirilmiştir. FL sistemi, merkezi veri toplamayı ortadan kaldırarak, her istemcinin kendi verisi üzerinde yerel olarak model eğitmesini ve yalnızca model parametrelerini paylaşmasını sağlamıştır. Çalışma kapsamında elde edilen temel bulgular şu şekilde özetlenebilir:

- Veri gizliliği korunarak model başarımı sağlanmıştır.
- FL modeli, yüksek sınıflandırma başarımı göstermiştir.
- Diferansiyel gizlilik ve güvenli toplama protokolleri başarıyla uygulanmıştır.
- İletişim maliyeti etkili biçimde düşürülmüştür.
- FL mimarisi, heterojen veri setlerine karşı genelleştirme yeteneği sergilemiştir.

- Sistem, farklı ölçeklerde kararlı çalışmıştır.
- Kaynak kullanımı verimli biçimde optimize edilmiştir.

Tüm bu bulgular, önerilen FL mimarisinin üretim sektöründe veri güvenliği, performans ve esneklik açısından uygulanabilir bir çözüm sunduğunu ortaya koymuştur. Araştırma çıktıları, yalnızca teknik başarılar değil; aynı zamanda güvenli yapay zeka uygulamalarının endüstriyel düzeyde nasıl hayata geçirilebileceğine dair önemli bir çerçeve sunmuştur.

7.2 Teorik ve Pratik Katkılar

Bu çalışmada elde edilen teorik katkılar, önceki bölümlerde sunulan analiz ve tartışmalarla ayrıntılı biçimde ele alınmıştır. Temel teorik katkılar aşağıda özetlenmiştir:

- FL mimarisi, üretim verileri bağlamında ele alınarak literature özgün bir perspektif kazandırılmıştır. Özellikle zaman kısıtlılığı ve veri güvenliğinin ön planda olduğu üretim sektörlerinde FL'in nasıl yapılandırılabilceği örneklerle ortaya konmuştur.
- FL sistemine diferansiyel gizlilik ve güvenli toplama gibi veri koruma yöntemlerinin entegre edilmesiyle, bu alandaki güvenlik tartışmalarına somut katkılar sunulmuştur.
- FL'in bilinen zayıf yönleri olan veri heterojenliği, yüksek iletişim maliyeti ve senkronizasyon sorunları üzerine odaklanılmış, bu sınırlamaların nasıl yönetilebileceğine ilişkin öneriler geliştirilmiştir.
- FL mimarisinin veri gizliliğini nasıl koruduğu ve bu gizliliğin model başarımlarını nasıl dengelenbileceği teorik bir çerçevede ele alınmıştır.

Uygulamada elde edilen katkılar ise şu şekildedir:

- FL mimarisinin gerçek zamanlı veri üreten bir üretim ortamında uygulanabilirliği gösterilmiştir. OPC protokolü aracılığıyla elde edilen sıcaklık, basınç ve hız gibi sensör verileri, merkezi veri toplamaya gerek kalmadan FL modeli ile başarıyla analiz edilmiştir.

- Veri gizliliği korunarak model eğitimi gerçekleştirilmiş ve bu sayede özellikle bilgi güvenliğinin öncelikli olduğu üretim sektörlerinde yapay zeka uygulamalarının güvenli biçimde nasıl gerçekleştirilebileceğine dair örnek bir uygulama sunulmuştur.
- İletişim yükü ve donanım gereksinimleri en aza indirilmiştir. Bu amaçla, parameter sıkıştırma, seyrek güncellemeler ve asenkron iletişim gibi yöntemlerden yararlanılmış; böylece sınırlı kaynaklara sahip cihazların da sürece dahil edilmesi mümkün hale getirilmiştir.
- 5 ile 10 arasında değişen istemci sayılarıyla testlerle, FL mimarisinin küçük ölçekli sistemlerden daha büyük ve karmaşık dağıtık yapılara kadar geniş bir yelpazede etkili biçimde çalışabildiği gözlemlenmiştir.
- FL için özel olarak tasarlanan veri ön işleme süreci de bu çalışmanın özgün katkılarından. Eksik verilerin tamamlanması, anomali tespiti, zaman senkronizasyonu ve normalizasyon adımları birlikte değerlendirilerek bütüncül bir veri hazırlık süreci önerilmiştir.

Bu katkılar, çeşitli senaryolarda gerçekleştirilen modelleme ve test çalışmaları sonucunda elde edilen deneyimlere dayanmaktadır.

7.3 Endüstriyel Uygulamalar için Öneriler

Bu çalışmada geliştirilen FL mimarisi, üretim sektöründe gizliliği koruyarak makine öğrenimi modellerinin uygulanabilirliğini göstermiştir. Sahada kullanılabilirliği artırmak adına aşağıdaki öneriler endüstriyel entegrasyon süreci için sunulmaktadır.

Endüstri 4.0 ve 5.0 kavramları, üretim süreçlerinin dijitalleşmesinden insan merkezi akıllı sistemlere geçişi temsil eden ardışık evrimsel aşamalardır. Çizelge 7.1 de görüldüğü üzere endüstri 4.0, IoT, yapay zeka ve siber-fiziksel sistemler aracılığıyla üretim süreçlerinin otomatikleşmesini ve verimliliğin artırılmasını hedeflemektedir; Endüstri 4.5 ise Türkiye'ye özgü bir geçiş aşaması olarak konumlanmakta ve özellik veri toplama, MES/ERP entegrasyonu gibi yapısal hazırlıkları içermektedir. Bu geçiş süreci, sanayi işletmelerinin dijital dönüşüm yetkinliklerinin artırarak Endüstri 4.0' a adapte olmalarını kolaylaştırmayı amaçlamaktadır. Öte yandan, Endüstri 5.0, üretimde insan ve makinenin iş birliğini esas alarak, etik üretim, kişiselleştirme ve sürdürülebilirlik gibi daha ileri düzey hedefleri ön plana çıkarmaktadır. Bu bağlamda,

FL gibi veri gizliliğini koruyan ve uçtan uca öğrenmeyi destekleyen yaklaşımlar; hem Endüstri 4.0'ın dijitalleşme odaklı yapısına hem de Endüstri 5.0'in insan merkezli esnek üretim vizyonuna uygun çözümler sunma potansiyeline sahiptir.

Çizelge 7.1: FL' nin endüstri üzerindeki rolü

	Endüstri 4.0	Endüstri 4.5	Endüstri 5.0
Tanım	Dijitalleşmiş ve otomatik üretim	Türkiye' ye özgü geçiş süreci	İnsan ve makinenin iş birliğine dayalı üretim
Odak Noktası	IoT, yapay zeka, siber-fiziksel sistemler	Veri toplama, MES/ERP entegrasyonu	İnsan merkezlilik, etik üretim, yapay zeka + insan işbirliği
Amaç	Verimlilik, otomasyon, otonom sistemler	Endüstri 5.0' a hazır hale gelmek	Sürdürülebilir, esneklik, kişiselleştirilmiş üretim

Kesitimci bakım ve kalite kontrol entegrasyonu, FL sistemleri, üretim hatlarında kestirimci bakım ve ürün kalitesi izleme uygulamalarına doğrudan entegre edilmelidir. Bu sayede operatör müdahalesi gerektirmeden arıza tespiti ve kalite sapmaları belirlenebilir.

Çok lokasyonlu uygulamalar, farklı şehirlerdeki üretim tesislerinde aynı ürünü üreten hatlar arasında FL modeli ile iş birliği sağlanarak genel bir kalite modeli oluşturulabilir. Bu yöntem, veri aktarımı gereksinimini ortadan kaldırırken gizliliği korur.

MES (Üretim Yürütme Sistemi)\ERP (Kurumsal Kaynak Planlaması) sistemleriyle entegrasyon, FL modelleri, üretim yönetim sistemleriyle çift yönlü veri alışverişine uygun biçimde entegre edilmelidir. Eğitim verisi MES'ten alınabilir, sonuçlar doğrudan üretim yönetimi ekranlarında gösterilebilir.

Rekabetçi sektörlerde ortak modelleme, otomotiv, ilaç, savunma gibi rekabetin yüksek olduğu sektörlerde, FL sayesinde firmalar veri paylaşmadan ortak model geliştirebilir. Bu, sektörel bilgi paylaşımı için önemli bir stratejidir.

Enerji ve sürdürülebilirlik uygulamalar, farklı tesislerin enerji tüketim verileri, FL aracılığıyla analiz edilerek sürdürülebilir üretim stratejileri geliştirilebilir. Bu, verilerin merkezi toplamadan genel enerji optimizasyonu sağlar.

Siber güvenlik ve haberleşme protokolleri, FL sistemlerinde kullanılan iletişim protokolleri, endüstriyel güvenlik standartlarına uygun yapılandırılmalıdır. Siber saldırılara karşı ek önlemler alınmalıdır.

Endüstriyel pilot uygulamalar, simülasyon ortamında başarı gösteren FL sistemleri, gerçek üretim tesislerinde test edilerek saha geçerliliği kontrol edilmelidir. Pilot uygulamalar, lojistik ve fiziksel sorunları ortaya çıkararak sistemin sahaya uygunluğunu değerlendirir.

FL' in dijital dönüşümündeki rolü, FL sistemleri yalnızca teknik bir çözüm değil, aynı zamanda veri güvenliğini inceleyen dijital dönüşüm araçları olarak değerlendirilmelidir.

KAYNAKLAR

- Abadi, M., Chu, A., Goodfellow, I., McMahan, H. B., Mironov, I., Talwar, K., Zhang, L.** (2016, October). Deep learning with differential privacy. *In Proceedings of the 2016 ACM SIGSAC conference on computer and communications security* (pp. 308-318).
- Abbas, S., Al Hejaili, A., Sampedro, G. A., Abisado, M., Almadhor, A. S., Shahzad, T., Ouahada, K.** (2023). A novel federated edge learning approach for detecting cyberattacks in IoT infrastructures. *IEEE Access*, 11, 112189-112198.
- Abdelli, K., Cho, J. Y., Azendorf, F., Griesser, H., Tropschug, C., Pachnicke, S.** (2022). Machine-learning-based anomaly detection in optical fiber monitoring. *Journal of optical communications and networking*, 14(5), 365-375.
- AbdulRahman, S., Tout, H., Ould-Slimane, H., Mourad, A., Talhi, C., Guizani, M.** (2020). A survey on federated learning: The journey from centralized to distributed on-site learning and beyond. *IEEE Internet of Things Journal*, 8(7), 5476-5497.
- Acar, A., Aksu, H., Uluagac, A. S., Conti, M.** (2018). A survey on homomorphic encryption schemes: Theory and implementation. *ACM Computing Surveys (Csur)*, 51(4), 1-35.
- Akşit, B. N., Akay, B. B., Slowik, A.** (2023). Medikal Verilerin Sınıflandırılmasında Federe Öğrenme. *Erciyes Üniversitesi Fen Bilimleri Enstitüsü Fen Bilimleri Dergisi*, 39(3), 548-570.
- Altınışik, S. B., Bilgin, T. T.** (2024). Analysis of OPC Data Using Federated Learning: An Evaluation of Performance and Privacy. *Orclever Proceedings of Research and Development*, 5(1), 410-426.
- Asad, M., Shaukat, S., Hu, D., Wang, Z., Javanmardi, E., Nakazato, J., Tsukada, M.** (2023). Limitations and future aspects of communication costs in federated learning: A survey. *Sensors*, 23(17), 7358.
- Athiyarath, S., Paul, M., Krishnaswamy, S.** (2020). A comparative study and analysis of time series forecasting techniques. *SN Computer Science*, 1(3), 175.
- Ay, Ş.** (2023). *Beyin MR görüntülerinde gizlilik tabanlı yaklaşım: Federe öğrenme* (Yüksek lisans tezi, Sakarya Uygulamalı Bilimler Üniversitesi, Lisansüstü Eğitim Enstitüsü).
- Ba-Alawi, A. H., Loy-Benitez, J., Kim, S., Yoo, C.** (2022). Missing data imputation and sensor self-validation towards a sustainable operation of wastewater treatment plants via deep variational residual autoencoders. *Chemosphere*, 288, 132647.

- Behnke, I., Austad, H.** (2023). Real-time performance of industrial IoT communication technologies: A review. *IEEE Internet of Things Journal*, 11(5), 7399-7410.
- Beltrán, E. T. M., Pérez, M. Q., Sánchez, P. M. S., Bernal, S. L., Bovet, G., Pérez, M. G., ... Celdrán, A. H.** (2023). Decentralized federated learning: Fundamentals, state of the art, frameworks, trends, and challenges. *IEEE Communications Surveys & Tutorials*, 25(4), 2983-3013.
- Bey, R., Goussault, R., Grolleau, F., Benchoufi, M., Porcher, R.** (2020). Fold-stratified cross-validation for unbiased and privacy-preserving federated learning. *Journal of the American Medical Informatics Association*, 27(8), 1244-1251.
- Bischi, B., Binder, M., Lang, M., Pielok, T., Richter, J., Coors, S., ... Lindauer, M.** (2023). Hyperparameter optimization: Foundations, algorithms, best practices, and open challenges. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 13(2), e1484.
- Boiano, A., Di Gennaro, M., Barbieri, L., Carminati, M., Nicoli, M., Redondi, A., ... Serio, L.** (2024, October). A secure and trustworthy network architecture for federated learning healthcare applications. In *2024 20th International Conference on Wireless and Mobile Computing, Networking and Communications (WiMob)* (pp. 124-129). IEEE.
- Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., ... Roselander, J.** (2019). Towards federated learning at scale: System design. *Proceedings of machine learning and systems*, 1, 374-388.
- Brockwell, P. J., Davis, R. A.** (2022). Time series analysis and its applications: With R examples (5th ed.). *Springer*.
- Büyüktanır, B., Yıldız, K., Ülkü, E. E., Büyüktanır, T.** (2023). du-CBA: Veriden habersiz ve artırılmış sınıflandırmaya dayalı birliktelik kuralları çıkarma mimarisi. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 38(3), 1919-1930.
- Byun, S., Sarker, A., Chang, S. Y., Kalita, J.** (2024). Secure Aggregation for Privacy-preserving Federated Learning in Vehicular Networks. *Journal on Autonomous Transportation Systems*, 1(3), 1-25.
- Campolo, C., Genovese, G., Singh, G., Molinaro, A.** (2023). Scalable and interoperable edge-based federated learning in IoT contexts. *Computer Networks*, 223, 109576.
- Cetin, B.** (2020). *Wireless network intrusion detection and analysis using federated learning* (Master's thesis, Youngstown State University).
- Ceyhan, H., Kasapbaşı, M. C.** (2022). Üretim sistemlerinde makine öğrenmesi ile kestirimci bakım uygulaması ve modellenmesi. *Avrupa Bilim ve Teknoloji Dergisi*, (33), 167-175.
- Chen, L., Chen, T.** (2022) Understanding Benign Overfitting in Personalized Federated Learning.

- Chen, Z., Cui, H., Wu, E., Yu, X.** (2023). Computation and communication efficient adaptive federated optimization of federated learning for Internet of Things. *Electronics*, 12(16), 3451.
- Corbucci, L., Heikkilä, M. A., Noguero, D. S., Monreale, A., Kourtellis, N.** (2024). PUFFLE: Balancing Privacy, Utility, and Fairness in Federated Learning. *arXiv preprint arXiv:2407.15224*.
- Çağlayan, C.** (2023). *Cluster-based scoring for malicious model detection in federated learning* (Master's thesis, Boğaziçi University, Institute for Graduate Studies in Science and Engineering, Graduate Program in Computer Engineering).
- Çakır, Z.** (2022). *Age of Information and Unbiased Federated Learning in Energy Harvesting Error-Prone Channels* (Master's thesis, Middle East Technical University (Turkey)).
- Dayan, I., Roth, H. R., Zhong, A., Harouni, A., Gentili, A., Abidin, A. Z., ... Li, Q.** (2021). Federated learning for predicting clinical outcomes in patients with COVID-19. *Nature medicine*, 27(10), 1735-1743.
- Dwork, C., Roth, A.** (2014). The algorithmic foundations of differential privacy. *Foundations and Trends® in Theoretical Computer Science*, 9(3–4), 211-407.
- Elía, I., Pagola, M.** (2024). Anomaly Detection in Smart-Manufacturing Era: A Review. Available at SSRN 4815859.
- Elmas, G., Dar, S. U. H., Korkmaz, Y., Ozbey, M., Cukur, T.** (2023). *Federated MRI reconstruction with deep generative models* (Doctoral dissertation, bilkent university).
- Eriş, M. C., Kantarci, B., Oktug, S.** (2021, December). Unveiling the wireless network limitations in federated learning. In *2021 IEEE International Symposium on Dynamic Spectrum Access Networks (DySPAN)* (pp. 262-267). IEEE.
- Farahani, M. A., McCormick, M. R., Gianinny, R., Hudacheck, F., Harik, R., Liu, Z., Wuest, T.** (2023). Time-series pattern recognition in smart manufacturing systems: A literature review and ontology. *Journal of Manufacturing Systems*, 69, 208-241.
- Fu, A., Zhang, X., Xiong, N., Gao, Y., Wang, H., Zhang, J.** (2020). VFL: A verifiable federated learning with privacy-preserving for big data in industrial IoT. *IEEE Transactions on Industrial Informatics*, 18(5), 3316-3326.
- George, W., Pergert, A.** (2023). *Data-driven process improvement in production* (Master's thesis, Scania CV, KTH Royal Institute of Technology). KTH DiVA Portal.
- Ghaleb, M., Obeed, M., Felemban, M., Chaaban, A., Yanikomeroğlu, H.** (2025). Federated Testing (FedTest): A New Scheme to Enhance Convergence and Mitigate Adversarial Attacks in Federating Learning. *arXiv preprint arXiv:2501.11167*.
- Gosselin, R., Vieu, L., Loukil, F., Benoit, A.** (2022). Privacy and security in federated learning: A survey. *Applied Sciences*, 12(19), 9901.

- Guan, H., Yap, P. T., Bozoki, A., Liu, M.** (2024). Federated learning for medical image analysis: A survey. *Pattern Recognition*, 110424.
- Hard, A., Rao, K., Mathews, R., Ramaswamy, S., Beaufays, F., Augenstein, S., ... Ramage, D.** (2018). Federated learning for mobile keyboard prediction. *arXiv preprint arXiv:1811.03604*.
- He, P., Lin, C., Montoya, I.** (2024). DPFedBank: Crafting a Privacy-Preserving Federated Learning Framework for Financial Institutions with Policy Pillars. *arXiv preprint arXiv:2410.13753*.
- Hegiste, V., Legler, T., Fridman, K., Ruskowski, M.** (2023, September). Federated object detection for quality inspection in shared production. In *2023 Eighth International Conference on Fog and Mobile Edge Computing (FMEC)* (pp. 151-158). IEEE.
- Hirsch, E., Hoher, S., Huber, S.** (2023, July). An OPC UA-based industrial Big Data architecture. In *2023 IEEE 21st International Conference on Industrial Informatics (INDIN)* (pp. 1-7). IEEE.
- Ho, S. B., Chai, I.** (2010) A Comparison Study on Key Exchange-Authentication protocol. *International Journal of Computer Applications*, 975, 8887.
- Hu, K., Gong, S., Zhang, Q., Seng, C., Xia, M., Jiang, S.** (2024). An overview of implementing security and privacy in federated learning. *Artificial Intelligence Review*, 57(8), 204.
- Hu, S., Jiang, L., He, B.** (2024, August). Practical hybrid gradient compression for federated learning systems. In *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence* (pp. 4147-4155).
- Islam, F., Raihan, A. S., Ahmed, I.** (2023). Applications of Federated Learning in Manufacturing: Identifying the Challenges and Exploring the Future Directions with Industry 4.0 and 5.0 Visions. *arXiv preprint arXiv:2302.13514*.
- Işık Polat, E.** (2021). *BYZANTINE ATTACK ROBUST FEDERATED LEARNING* (Master's thesis, Middle East Technical University).
- Jalali, N. A., Chen, H.** (2023). Federated learning security and privacy-preserving algorithm and experiments research under internet of things critical infrastructure. *Tsinghua Science and Technology*, 29(2), 400-414.
- Jardine, A. K., Lin, D., Banjevic, D.** (2006). A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical systems and signal processing*, 20(7), 1483-1510.
- Jiao, S., Meng, J., Zhao, Y., Cheng, K.** (2024). Efficient DP-FL: Efficient Differential Privacy Federated Learning Based on Early Stopping Mechanism. *Computer Systems Science & Engineering*, 48(1).
- Kairouz, P., McMahan, H. B., Avent, B., Bellet, A., Bennis, M., Bhagoji, A. N., ... Zhao, S.** (2021). Advances and open problems in federated learning. *Foundations and trends® in machine learning*, 14(1–2), 1-210.

- Khan, L. U., Saad, W., Han, Z., Hossain, E., Hong, C. S.** (2021). Federated learning for internet of things: Recent advances, taxonomy, and open challenges. *IEEE Communications Surveys & Tutorials*, 23(3), 1759-1799.
- Kim, C., Bae, G., Shin, W., Wang, S., Oh, H.** (2025). EKF-Based Radar-Inertial Odometry with Online Temporal Calibration. *arXiv preprint arXiv:2502.00661*.
- Kim, M. S., Han, S., Park, H. S.** (2010, September). An automatic robot software design tool: An open platform for robotics services. In *2010 IEEE 15th Conference on Emerging Technologies & Factory Automation (ETFA 2010)* (pp. 1-4). IEEE.
- Kocadurdu, K.** (2023). *Comparison of federated learning frameworks for medical image domain* (Yüksek lisans tezi, İzmir Bakırçay Üniversitesi, Lisansüstü Eğitim Enstitüsü, Bilgisayar Mühendisliği Anabilim Dalı).
- Konečný, J., McMahan, H. B., Yu, F. X., Richtárik, P., Suresh, A. T., Bacon, D.** (2016). Federated learning: Strategies for improving communication efficiency. *arXiv preprint arXiv:1610.05492*.
- Kritzinger, W., Karner, M., Traar, G., Henjes, J., Sihn, W.** (2018). Digital Twin in manufacturing: A categorical literature review and classification. *Ifac-PapersOnline*, 51(11), 1016-1022.
- Kumari, R., Kumar, S., Poonia, R. C., Singh, V., Raja, L., Bhatnagar, V., Agarwal, P.** (2021). Analysis and predictions of spread, recovery, and death caused by COVID-19 in India. *Big Data Mining and Analytics*, 4(2), 65-75.
- Ladegourdie, M., Kua, J.** (2022). Performance analysis of opc ua for industrial interoperability towards industry 4.0. *IoT*, 3(4), 507-525.
- Landi, F., Baraldi, L., Cornia, M., Cucchiara, R.** (2021). Working memory connections for LSTM. *Neural Networks*, 144, 334-341.
- Lee, J., Bagheri, B., Kao, H. A.** (2015). A cyber-physical systems architecture for industry 4.0-based manufacturing systems. *Manufacturing letters*, 3, 18-23.
- Lee, J., Lapira, E., Bagheri, B., Kao, H. A.** (2013). Recent advances and trends in predictive manufacturing systems in big data environment. *Manufacturing letters*, 1(1), 38-41.
- Li, D., Zhang, S., Sun, Y., Guo, Y., Che, Z., Chen, S., ... Pei, D.** (2023, October). An empirical analysis of anomaly detection methods for multivariate time series. In *2023 IEEE 34th International Symposium on Software Reliability Engineering (ISSRE)* (pp. 57-68). IEEE.
- Li, T., Sahu, A. K., Talwalkar, A., Smith, V.** (2020). Federated learning: Challenges, methods, and future directions. *IEEE signal processing magazine*, 37(3), 50-60.
- Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., Smith, V.** (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine learning and systems*, 2, 429-450.

- Li, Z., He, Y., Yu, H., Kang, J., Li, X., Xu, Z., Niyato, D.** (2022). Data heterogeneity-robust federated learning via group client selection in industrial IoT. *IEEE Internet of Things Journal*, 9(18), 17844-17857.
- Li, Z., Shao, J., Mao, Y., Wang, J. H., Zhang, J.** (2022, July). Federated learning with gan-based data synthesis for non-iid clients. *In International workshop on trustworthy federated learning* (pp. 17-32). Cham: Springer International Publishing.
- Lu, Y., Huang, X., Dai, Y., Maharjan, S., Zhang, Y.** (2020). Federated learning for data privacy preservation in vehicular cyber-physical systems. *IEEE Network*, 34(3), 50-56.
- Lu, Z.** (2020). A case study about different network architectures in Federated Machine Learning.
- Mahmoud, R., Yousuf, T., Aloul, F., Zualkernan, I.** (2015, December). Internet of things (IoT) security: Current status, challenges and prospective measures. *In 2015 10th international conference for internet technology and secured transactions (ICITST)* (pp. 336-341). IEEE.
- McMahan, B., Moore, E., Ramage, D., Hampson, S., y Arcas, B. A.** (2017, April). Communication-efficient learning of deep networks from decentralized data. *In Artificial intelligence and statistics* (pp. 1273-1282). PMLR.
- Medetov, B., Serikov, T., Tolegenova, A., Zhexebay, D., Yskak, A., Namazbayev, T., Albanbay, N.** (2023). DEVELOPMENT OF A MODEL FOR DETERMINING THE NECESSARY FPGA COMPUTING RESOURCE FOR PLACING A MULTILAYER NEURAL NETWORK ON IT. *Eastern-European Journal of Enterprise Technologies*, 124(4).
- Mehta, M., Shao, C.** (2023). A greedy agglomerative framework for clustered federated learning. *IEEE Transactions on Industrial Informatics*, 19(12), 11856-11867.
- Mpofu, P., Kembo, S. H., Chimbwanda, M., Jacques, S., Chitiyo, N., Zvarevashe, K.** (2023). A privacy-preserving federated learning architecture implementing data ownership and portability on edge end-points. *International Journal of Industrial Engineering and Operations Management*, 5(2), 118-134.
- Nanayakkara, P., Smart, M. A., Cummings, R., Kaptchuk, G., Redmiles, E. M.** (2023). What are the chances? explaining the epsilon parameter in differential privacy. *In 32nd USENIX Security Symposium (USENIX Security 23)* (pp. 1613-1630).
- Nasim, M. D., Soshi, F. T. J., Biswas, P., Ferdous, A. S., Rashid, A., Biswas, A., Gupta, K. D.** (2025). Principles and Components of Federated Learning Architectures. *arXiv preprint arXiv:2502.05273*.
- Neto, H. N. C., Hribar, J., Dusparic, I., Mattos, D. M. F., Fernandes, N. C.** (2023). A survey on securing federated learning: Analysis of applications, attacks, challenges, and trends. *IEEE Access*, 11, 41928-41953.

- Nevratakı, T., Iliadou, A., Ntolkeras, G., Sfakianakis, I., Lazaridis, L., Maraslidis, G., ... Fragulis, G. F.** (2023, November). A survey on federated learning applications in healthcare, finance, and data privacy/data security. In *AIP Conference Proceedings* (Vol. 2909, No. 1). AIP Publishing.
- Nguyen, D. C., Ding, M., Pathirana, P. N., Seneviratne, A., Zomaya, A. Y.** (2021). Federated learning for COVID-19 detection with generative adversarial networks in edge cloud computing. *IEEE Internet of Things Journal*, 9(12), 10257-10271.
- Nguyen, D. C., Ding, M., Pathirana, P. N., Seneviratne, A., Li, J., Poor, H. V.** (2021). Federated learning for internet of things: A comprehensive survey. *IEEE Communications Surveys & Tutorials*, 23(3), 1622-1658.
- Pacella, M., Papadia, G.** (2021). Evaluation of deep learning with long short-term memory networks for time series forecasting in supply chain management. *Procedia CIRP*, 99, 604-609.
- Reddi, S., Charles, Z., Zaheer, M., Garrett, Z., Rush, K., Konečný, J., ... McMahan, H. B.** (2020). Adaptive federated optimization. *arXiv preprint arXiv:2003.00295*.
- Sakurada, L., Leitão, P.** (2020, June). Multi-agent systems to implement industry 4.0 components. In *2020 IEEE conference on industrial cyberphysical systems (ICPS)* (Vol. 1, pp. 21-26). IEEE.
- Saleh, T. E.** (2022). *Comparison of the Effects of Data Privacy Preserving Methods on Machine Learning Algorithms in Iot* (Master's thesis, Marmara Universitesi (Turkey)).
- Schulze, C., Plank, M., Linzbach, J., Herrmann, C., Thiede, S.** (2019). Energy flexible management of industrial technical building services: a synergetic data-driven and simulation approach for cooling towers. *Procedia CIRP*, 81, 775-780.
- Shan, F., Mao, S., Lu, Y., Li, S.** (2024). Differential Privacy Federated Learning: A Comprehensive Review. *International Journal of Advanced Computer Science & Applications*, 15(7).
- Shanmugam, L., Tillu, R., Tomar, M.** (2023). Federated learning architecture: Design, implementation, and challenges in distributed AI systems. *Journal of Knowledge Learning and Science Technology* ISSN: 2959-6386 (online), 2(2), 371-384.
- Shi, W., Cao, J., Zhang, Q., Li, Y., Xu, L.** (2016). Edge computing: Vision and challenges. *IEEE internet of things journal*, 3(5), 637-646.
- Sinap, V.** (2025). Yapay Zekâ Destekli Karar Destek Sistemleri ve Yönetim Bilişim Sistemlerine Entegrasyonu. *Yönetim Bilişim Sistemleri Alanında Yenilikçi Çözümler ve Güncel Yaklaşımlar*, 25.
- Singh, D., Singh, B.** (2020). Investigating the impact of data normalization on classification performance. *Applied Soft Computing*, 97, 105524.
- Singh, M., Chauhan, S. P. S.** (2024). Enhancing Data Security with KeyGuardian: Application of Fernet for Digital Asset Protection.

- Stevens, T., Skalka, C., Vincent, C., Ring, J., Clark, S., Near, J.** (2022). Efficient differentially private secure aggregation for federated learning via hardness of learning with errors. *In 31st USENIX Security Symposium (USENIX Security 22)* (pp. 1379-1395).
- Su, W. J.** (2024). A Statistical Viewpoint on Differential Privacy: Hypothesis Testing, Representation, and Blackwell's Theorem. *Annual Review of Statistics and Its Application*, 12.
- Sy, E., Moennich, M., Mueller, T., Federrath, H., Fischer, M.** (2020, August). Enhanced Performance for the encrypted Web through TLS Resumption across Hostnames. *In Proceedings of the 15th International Conference on Availability, Reliability and Security* (pp. 1-10).
- Syed, M. A. B., Hasan, M. R., Chowdhury, N. I., Rahman, M. H., Ahmed, I.** (2025). A systematic review of time series algorithms and analytics in predictive maintenance. *Decision Analytics Journal*, 100573.
- Tao, F., Qi, Q., Liu, A., Kusiak, A.** (2018). Data-driven smart manufacturing. *Journal of manufacturing systems*, 48, 157-169.
- Teh, H. Y., Kempa-Liehr, A. W., Wang, K. I. K.** (2020). Sensor data quality: A systematic review. *Journal of Big Data*, 7(1), 11.
- Truex, S., Baracaldo, N., Anwar, A., Steinke, T., Ludwig, H., Zhang, R., Zhou, Y.** (2019, November). A hybrid approach to privacy-preserving federated learning. *In Proceedings of the 12th ACM workshop on artificial intelligence and security* (pp. 1-11).
- Truong, N., Sun, K., Wang, S., Guitton, F., Guo, Y.** (2021). Privacy preservation in federated learning: An insightful survey from the GDPR perspective. *Computers & Security*, 110, 102402.
- Vavra, J., Hromada, M.** (2019). EVALUATION OF DATA PREPROCESSING TECHNIQUES FOR ANOMALY DETECTION SYSTEMS IN INDUSTRIAL CONTROL SYSTEM. *Annals of DAAAM & Proceedings*, 30.
- Wei, K., Li, J., Ding, M., Ma, C., Su, H., Zhang, B., Poor, H. V.** (2021). User-level privacy-preserving federated learning: Analysis and performance optimization. *IEEE Transactions on Mobile Computing*, 21(9), 3388-3401.
- Wen, J., Zhang, Z., Lan, Y., Cui, Z., Cai, J., Zhang, W.** (2023). A survey on federated learning: challenges and applications. *International Journal of Machine Learning and Cybernetics*, 14(2), 513-535.
- Xiao, F., Fan, J.** (2024). Unsupervised Anomaly Detection in The Presence of Missing Values. *Advances in Neural Information Processing Systems*, 37, 138130-138162.
- Xu, H., Seng, K. P., Smith, J., Ang, L. M.** (2024). Multi-level split federated learning for large-scale AIoT system based on smart cities. *Future Internet*, 16(3), 82.

- Yan, P., Abdulkadir, A., Luley, P. P., Rosenthal, M., Schatte, G. A., Grewe, B. F., Stadelmann, T.** (2024). A comprehensive survey of deep transfer learning for anomaly detection in industrial time series: Methods, applications, and directions. *IEEE Access*, 12, 3768-3789.
- Yang, Q., Liu, Y., Chen, T., Tong, Y.** (2019). Federated machine learning: Concept and applications. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 10(2), 1-19.
- Yang, Q., Liu, Y., Cheng, Y., Kang, Y., Chen, T., Yu, H.** (2019). Federated learning: synthesis lectures on artificial intelligence and machine learning. vol, 13, 1-207.
- Zang, Y., Xue, Z., Ou, S., Chu, L., Du, J., Long, Y.** (2024, March). Efficient asynchronous federated learning with prospective momentum aggregation and fine-grained correction. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 38, No. 15, pp. 16642-16650).
- Zeng, S., Guo, P., Wang, S., Wang, J., Zhou, Y., Qu, L.** (2024, October). Tackling data heterogeneity in federated learning via loss decomposition. In *International Conference on Medical Image Computing and Computer-Assisted Intervention* (pp. 707-717). Cham: Springer Nature Switzerland.
- Zhang, W., Yang, D., Wang, H.** (2019). Data-driven methods for predictive maintenance of industrial equipment: A survey. *IEEE systems journal*, 13(3), 2213-2227.
- Zhao, S. Y., Gao, H., Li, W. J.** (2019). Quantized epoch-SGD for communication-efficient distributed learning. *arXiv preprint arXiv:1901.03040*.
- Zhao, Y., Li, M., Lai, L., Suda, N., Civin, D., Chandra, V.** (2018). Federated learning with non-iid data. *arXiv preprint arXiv:1806.00582*.
- Zhou, K., Liu, T., Zhou, L.** (2015, August). Industry 4.0: Towards future industrial opportunities and challenges. In *2015 12th International conference on fuzzy systems and knowledge discovery (FSKD)* (pp. 2147-2152). IEEE.
- Zhu, B., Niu, L.** (2025). A privacy-preserving federated learning scheme with homomorphic encryption and edge computing. *Alexandria Engineering Journal*, 118, 11-20.
- Zhu, L., Liu, Z., Han, S.** (2019). Deep leakage from gradients. *Advances in neural information processing systems*, 32.
- Zonta, T., Da Costa, C. A., da Rosa Righi, R., de Lima, M. J., Da Trindade, E. S., Li, G. P.** (2020). Predictive maintenance in the Industry 4.0: A systematic literature review. *Computers & Industrial Engineering*, 150, 106889.
- Url-1** <<https://machinelearningmastery.com/multivariate-time-series-forecasting-lstms-keras/>>, erişim tarihi 12.02.2025

ÖZGEÇMİŞ

TARANMIŞ
VESİKALIK
FOTOĞRAF

Ad-Soyad : Süleyman Burak
ALTINIŞIK

Doğum Tarihi ve Yeri :

E-posta :

ÖĞRENİM DURUMU:

- **Lisans** : 2019, Yalova Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği

MESLEKİ DENEYİM VE ÖDÜLLER:

- trex Dijital (Veri Analisti ve Raporlama Uzmanı), 2020 – Halen çalışıyor

TEZDEN TÜRETİLEN ESERLER, SUNUMLAR VE PATENTLER:

- **Altınışik, S. B., Bilgin, T. T.** (2024). Analysis of OPC Data Using Federated Learning: An Evaluation of Performance and Privacy. *Orclever Proceedings of Research and Development*, 5(1), 410-426.

DİĞER ESERLER, SUNUMLAR VE PATENTLER:

- **Bilgin, T. T., Altınışik, S. B., Adıgüzel, N. A.** (2023). A Comparative Study of Classification and Clustering Methods for Data Analysis in Digital Transformation and IoT Systems. *Orclever Proceedings of Research and Development*, 3(1), 1-18.
- **Altınışik, S. B., Bilgin, T. T.** (2025). Optimizing Big Data Management on Microsoft SQL Server: Enhancing Performance through Normalization and Advanced Analytical Techniques. *International Journal of Innovative Engineering Applications*, 9(1), 23-36.